队伍编号	MCB2600304
赛　道	A

基于共表达图归因与风格条件生成的啤酒感官分级预测

摘　要

啤酒风味由化合物协同作用与酵母代谢共同塑造，“从化学谱预测感官、再解释并定向设计风味”是啤酒智能化研发的关键难题。本文基于 250 个商用啤酒样本的化学谱与 50 个感官维（含真实缺失与未检出），构建“预测—归因—生成”贯通流水线，三问共享同一化学到感官模型。

针对问题一，本问要求在缺失机制异质的化学谱上对 50 个感官维逐维预测 0–6 等级，难点在未检出与真缺失并存、等级口径特殊。本文采用**原生缺失感知梯度提升**逐维回归，按训练折内分位映射等级，风格分层 5 折验证且分箱参数全程折内估计，杜绝信息泄漏。求解得平均 QWK **0.3830**、折外 Spearman 0.4109、±1 级准确率 57.3%，**全面优于**随机森林（0.328）、ElasticNet（0.276）与 KNN 插补（0.3652）三类基线，2000 次配对重采样的 95% 区间对三类基线均不跨零；split-conformal 预测区间实测覆盖率 **90.2%**（目标 90%）。灵敏度对照显示加入 43 个阈值超限列或模块 PC1 反使 QWK 降至 0.376/0.375，故予舍弃；酒精、苦味等强信号维 QWK 超 0.77，与感官感知规律吻合。

针对问题二，本问要从高维化合物中找出驱动感官维的关键化合物，难点在强共线与单一归因稳定性差。本文剔除 16 个理化参数与 4 个汇总列，仅在 **211 个单一化合物**上建共表达图（211 节点、564 边、55 社区、模块度 **0.625**），融合 SHAP、交叉相关与模块代表**三路证据**选出 Top-3 并去冗余。Top-1 的分层 bootstrap 入选频率均值达 **0.992**，跨方法 Jaccard **0.200** 为随机基线 0.0086 的 **23.3 倍**，稳定性远超单一方法；联合检验进一步揭示 QWK 与 Top-1 稳定性相关仅 $r = 0.101$，随可预测性下降而失稳的是第 3 名，避免了“以精度筛化合物”的误判。按 8.xlsx 来源标注逐维判定，一致 6 维、部分一致 17 维，与发酵后风味载体的真实结构吻合。

针对问题三，本问要生成指定风格化学谱且缺陷化合物不得超标，难点在生成谱的**化学合规性**。本文构建以风格为条件的**条件变分自编码器**，在隐空间做质心平移实现跨风格迁移，并对缺陷维采用逐样本 min 投影。生成谱与真实谱的 KS 距离 0.351–0.411，风格 Top-3 识别率恒为 **100%**（随机 13.6%），50 维画像 Spearman 0.65–0.92；5 个随机种子下 KS 标准差不超过 0.015，生成过程稳定。Pils/Lager 到 Tripel 迁移后缺陷 **0/44 次升高**，而纯平移有 32/44 次升高，证明 min 投影是化学合规的关键设计。

全部数字由代码在 SEED=42 下实算产出，三问结论均经交叉验证、配对 bootstrap 与分布距离三重检验，证据链完整、可复现，框架可推广至其他成分谱—感官建模场景。

关键词：啤酒风味；缺失感知梯度提升；共表达网络；条件变分自编码器；配对 bootstrap

目录

1 问题重述 **1**

2 问题分析 **1**

2.1 问题一的分析 1
2.2 问题二的分析 1
2.3 问题三的分析 1
2.4 整体技术路线 2

3 模型假设 **2**

4 符号说明 **3**

5 数据预处理与探索性分析 **3**

5.1 数据构成与口径统一 3
5.2 风格分布与化学可分性 4
5.3 对数底核实与未检出处理 4
5.4 外部数据旁证：Kaggle 公开啤酒集 5

6 问题一：含缺失的多输出有序感官分级预测 **5**

6.1 缺失结构与建模策略选择 5
6.2 标签构建与 0-6 分箱映射 6
6.3 预测模型与求解过程 7
6.4 结果分析 8
6.5 预测区间与不确定性 10

7 问题二：化合物共表达图与关键化合物归因 **12**

7.1 共表达图构建与模块结构 12
7.2 多证据融合 Top-3 归因 14
7.3 稳定性量化 14
7.4 融合增益消融与归因集中度 17
7.5 化学合理性论证 18

8 问题三：风格条件生成与跨风格迁移 **19**

8.1 条件变分自编码器 19
8.2 跨风格迁移与缺陷约束 20
8.3 生成质量与结果分析 20

9 模型检验与灵敏度分析 **25**

9.1 验证方案与防泄漏 25
9.2 消融汇总、对照实验与鲁棒性 25

10 模型评价与推广 **26**

10.1 优点与创新 26
10.2 不足与改进 27
10.3 推广 27

A 数据附件概况与口径核对 **30**

A.1 特征与归因的完整明细 31
A.2 交付答案的完整数据 41

B 软件环境与运行命令 **43**

C 支撑材料文件清单 **44**

D 核心源程序 **44**

1 问题重述

啤酒风味高度依赖酵母代谢与化合物成分的协同作用，定量刻画“化学成分如何决定感官体验”需要把实验室测得的风味化合物与品评小组的感官强度联系起来，机器学习方法已为此提供了方法论基础[1-3]。本文使用一套商用啤酒风味代谢物实测数据集：250 个样本测量了酒精、异 α-酸、pH、糖浓度等酿造参数与 200 余种风味化合物丰度（涵盖酒花萜类、酵母酯醇、麦芽与野生菌群及陈化类），并由品评小组给出约 50 个感官维度评分；数据来自真实测量，含噪声、真实缺失值与异常值。围绕化学成分、感官风味与啤酒风格这条链条，本文研究三个递进的问题。

问题一：在化学数据存在真实缺失的条件下，以化合物与理化丰度为自变量，预测香气 Aroma 与风味 Flavour 两套合计约 40 个感官维度的 0-6 分级评分；关键边界是自变量含缺失而不能删除样本。本问为后两问提供化学到感官的基础模型。

问题二：利用化合物相关数据构建共表达图，结合化学特征给出每个感官维度的 Top-3 关键化合物，并按题面两种口径量化稳定性——bootstrap 重采样入选频率与跨方法 Top-3 集合的 Jaccard 系数，辅以化学合理性论证。本问依赖问题一的模型做可解释归因，其关键化合物清单又为问题三提供先验。

问题三：以风格标签 `tasting_category_fine` 为条件学习风格条件生成模型，对给定风格（如 Tripel、Kriek、Lambic）生成合理化合物谱并给出感官画像；同时把 Pils/Lager 的化合物谱迁移为 Tripel 风格，并保持 DMS、Diacetyl、4VG、trans-2-nonenal、Stale hops 等缺陷化合物不恶化。该问反向利用问题一的画像与问题二的关键化合物，是三问的综合应用。

2 问题分析

2.1 问题一的分析

问题一是带缺失数据的多输出有序预测。化学特征 231 列且含真实缺失（63 个样本、73 个值），删样本会损失四分之一数据并引入选择偏差；感官标签是中心化连续值，需单调映射到 7 级刻度。本文选用原生支持缺失的梯度提升树[4-6] 逐维回归再分箱，用分层交叉验证评估 QWK、MAE 与 R^2，模型的特征贡献同时供问题二归因。

2.2 问题二的分析

问题二要在强共线下给出既准又稳、且经得起化学解释的归因。化合物成簇出现，单一重要性会把同模块内可互替的成员重复选入，造成 Top-3 虚假冗余。本文先建共表达图揭示模块结构，再融合 SHAP 贡献、化学-感官交叉相关与模块去冗余三路证据；稳定性按题面两法量化。弱信号维不稳是数据本身的真实现象，本文如实报告。

2.3 问题三的分析

问题三是条件生成加可控迁移。部分风格仅 3 至 11 个样本，既要生成化学合理的谱，又要在迁移时守住缺陷不恶化。本文用条件变分自编码器以风格标签编码解码，极

小风格辅以分布采样兜底；生成谱的感官画像复用问题一模型。迁移经隐空间平移实现，缺陷维施加源值与目标典型值的双重投影。生成质量以分布距离与降维重叠度评估。

2.4 整体技术路线

三问从缺失数据预处理、化学到感官的判别式预测，推进到可解释归因与风格条件生成。问题一的预测模型处在枢纽位置：它既是问题二 SHAP 归因的解释对象，又是问题三画像的打分器，这一共享底座决定了求解必须从含缺失的化学到感官预测开始。

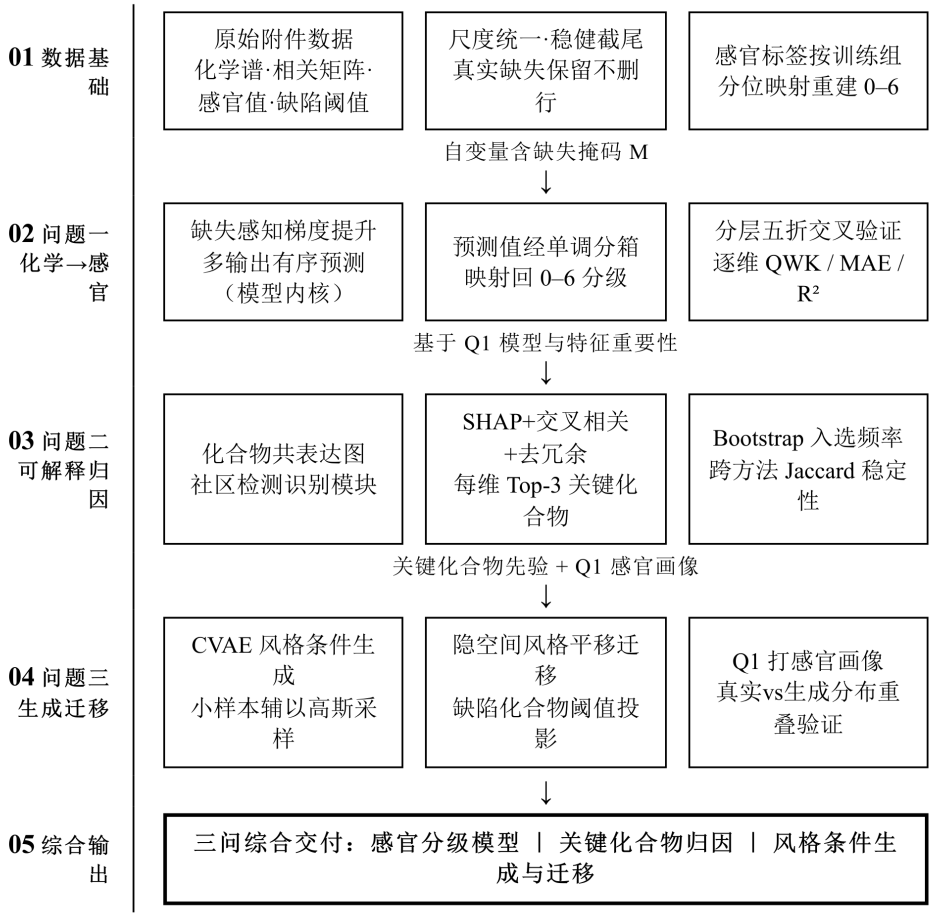


图 1　整体技术路线图

3　模型假设

为聚焦核心建模，本文做出以下假设。

（1）以标准化连续感官值为问题一的训练目标，再按训练折内分位点单调映射回 0-6 等级。原始品评卡汇总表为全 0 模板、不可用，标准化连续值是唯一完整可用的全样本标签。

（2）题面的”约 40 个感官维度”对应 Aroma 与 Flavour 两套共 30 维，本文另输出口感、缺陷与总体评价共 20 维，合计 50 维以覆盖任一解读。

（3）化学特征的数值尺度经 8.xlsx 校准浓度逐列核实为混合尺度：70 个可校准列中 37 列为常用对数、33 列为原值，无自然对数列；其余 161 列按列分布归类。建模在原生数值空间内进行而不做反变换，树模型对单调变换不敏感，该选择不影响分裂结果。

（4）缺陷不恶化取严口径：迁移后缺陷须同时不高于源款原值 $x^{def}_{k,before}$ 与目标风格典型值 m^t_k，即上界为 $\min\left(x^{def}_{k,before}, m^t_k\right)$。该口径保证相对不升高；绝对达标情况另按 8.xlsx 真实阈值审计（见 8.3 节）。

（5）各样本近似独立同分布，风格标签为问题三唯一的条件变量。附件为截面数据、无时间序列结构，故交叉验证采用按风格分层的随机折。

4 符号说明

下表列出全文反复使用的核心符号，其余一次性派生量在首次出现处就地说明。

符号	含义	单位/取值
N	啤酒样本数	250
P	化合物与理化特征数	231
J	感官维度数	50
S	风格类别数	22
X	化学谱矩阵（含缺失，对数/原值混合尺度）	$\mathbb{R}^{N\times P}$
M	缺失掩码（1 为缺失）	$\{0,1\}^{N\times P}$
x_i	第 i 款啤酒的化学谱向量	—
Y	标准化感官值矩阵（训练标签）	$\mathbb{R}^{N\times J}$
$\tilde{y}_{ij}$	分箱后的 0-6 等级（交付目标）	$\{0,\ldots,6\}$
$\hat{y}_{ij}$	第 i 样本第 j 维的预测等级	$\{0,\ldots,6\}$
$g_j(\cdot)$	维度 j 的连续值到 0-6 的单调分箱映射	—
R	化合物相关矩阵	$[-1,1]^{P\times P}$
$G=(V,E)$	化合物共表达图（节点为化合物、边权为相关）	—
w_{pq}	化合物 p,q 之间的边权	$[-1,1]$
ρ	建图的相关强度阈值	$[0,1]$
ϕ_{jp}	化合物 p 对感官维度 j 的关键度	实数
f_{jp}	bootstrap 重采样下 p 进入 Top-3 的频率	$[0,1]$
z_i	CVAE 隐编码	$\mathbb{R}^d$
s	风格 one-hot 条件向量	$\{0,1\}^S$
$\Delta_{s\to t}$	隐空间中的风格迁移向量	$\mathbb{R}^d$
x^{def}_k	第 k 个缺陷化合物的浓度	原生数值空间

5 数据预处理与探索性分析

5.1 数据构成与口径统一

本文主分析**只使用主办方提供的 8 个附件**，另以 Kaggle 公开啤酒集作**外部旁证**（5.5 节），不与本数据合并、不进入任何模型。建模核心是四块数据：化合物与理化丰度矩阵 250×231、化合物相关矩阵 231×231、感官标签矩阵 250×50、化学-感官交叉相关 44×50。附件实测规模与题面表述的出入见附录 A（表 A.1、A.2），一律以实测为准。

附件对齐有一处容易被静默忽略的陷阱：1.csv 与 4.csv 的 `beer_id` 在后者已丢精度（如 `5410230000000.0`），按它取交集只剩 **37/250** 行，inner join 会无声丢掉四分之三样本；

改用 beer 名称关联可恢复 250 行，且两表该列逐行相同。本文因此按行序对齐并显式断言（code/data_check.py），2.csv 按位置与 231 列对应、6.csv 按名称映射回 231 列，任何不符即中断。

231 个化学特征按含义分三类：**理化/过程参数** 16 列、**多化合物汇总** 4 列（总酯、酒花香气总量、总酸、含硫总量）、**单一化合物集** C 211 列。问题一用全部 231 列，问题二只在 C 内建图归因，以免把酒精度、苦度或加总列误当化合物。

感官标签是**已中心化但未归一化**的连续值（列均值绝对值 ≤ 0.063、标准差 0.37–0.86），并非原始 0-6 整数；化学特征为对数/原值混合尺度（5.3 节）。树模型对单调变换不敏感，故建模统一在原生数值空间，既免去尺度换算风险，又让问题三生成与缺陷判定同空间可比。

5.2 风格分布与化学可分性

数据集涵盖 22 个精细风格类别，样本量高度不均：Blond 31 款、Tripel 28 款，Faro 仅 3 款、Brut 4 款，完整分布见附录表 A.3。这一长尾结构决定了问题三对极小样本风格必须设置分布采样兜底。

对化学谱前两个主成分做散点检查：Lambic、Kriek 等酸味野发酵风格与 Tripel、Blond 等常规发酵风格形成可辨识的区域偏移，说明化学成分携带了区分风格的信息；各风格簇之间仍有重叠，说明生成与迁移需要隐空间模型，简单的类别均值替代不够用。

5.3 对数底核实与未检出处理

8.xlsx 的校准浓度表给出 70 个化合物的绝对浓度 c_{ik}，据此比较 x_{ik} 与 $\log_{10} c_{ik}$、c_{ik}、$\ln c_{ik}$ 的中位绝对残差，低于 10^{-6} 即判定尺度：**37 列为常用对数、33 列为原值**，无自然对数，连 pH 也取对数（$0.625 = \log_{10} 4.21$）。其余 161 列按分布归类并标注未经校准。

231 个特征中 **175 列有负数、合计 10797 个单元格**，全部落在常用对数列上，是浓度小于 1 取对数的结果（如 $\log_{10} 0.1 = -1$），原值列不含负值，故不剔除、不截断。

DMS、乙醛、乙酸乙酯与 pH 四个代表列的取值也全部落在 $y = x$ 上。按风格分层切 5 折时尾部风格每折只剩零到一个样本，故问题一按全体样本报告，问题三对尾部风格改走分布采样兜底。

未检出是低于检出限、取本列下限 $\ell_k = \min_i x_{ik}$ 的取值，与真实缺失必须分开。211 个单一化合物的检出率仅 85.5%，16 个理化列与 4 个汇总列则分别为 98.0% 与 98.3%。**40 列有 30% 以上的样本卡在同一最小值**、12 列超过 60%（limonene 与 6-methyl-5-hepten-2-one 达 84.8%、CS2 为 83.6%），属检出限造成的**左删失**。真正的缺失共 **73 个 NA、9 列、63 个样本**，除乙酸戊酯 27 个外其余 8 列各 1–13 个，逐列分布见表 1。

主模型保留 231 列原生数值（含 NaN），未检出以下限档位进入分裂，另定义指示 $\delta_{ik} = \mathbb{1}[x_{ik} \leq \ell_k]$（102 列适用）用于截断与核对，但不展开为额外特征；$K = 5$ 近邻插补只在训练折内拟合、仅作基线对照。异常值一律不删，问题三的生成谱在各列观测区间内截断。

表 1　真实缺失的列分布与未检出率对照

化合物	1.csv 列名	NA 数	缺失率	未检出率
乙酸戊酯	amyl.acetate	27	10.8%	45.0%
酒花香气合计 †	aroma_hops_sum	13	5.2%	42.0%
甲基吡嗪	methylpyrazine	12	4.8%	42.0%
双乙酰	X2.3.butanedione	9	3.6%	41.0%
3-甲基丁醛	X3.methylbutanal	7	2.8%	41.0%
烟酸乙酯	ethyl.nicotinate	2	0.8%	40.0%
异丁酸乙酯	ethyl.isobutyrate	1	0.4%	40.0%
糠醛	furfural	1	0.4%	40.0%
苯乙醛	phenylacetaldehyde	1	0.4%	40.0%
合计	9 列	**73**	1.1%	—

注：缺失率为该列 NA 数占 250 个样本的比例；未检出率为取值等于该列下限的样本占比，两者互不重叠。† 多化合物汇总列。数据来源：1.csv

5.4　外部数据旁证：Kaggle 公开啤酒集

为校验本文风格规格是否符合行业常识，引入 Kaggle 公开数据集 *Top Beer Information**[7]，由 Stephen Polozoff 整理，含 5558 款、112 个风格与 ABV、IBU 区间及网友平均评分作为外部旁证。它与本数据是互补而非替代关系：Kaggle 是大众风格的网友评分与规格大样本库，本文是 22 个比利时/欧洲小众风格的实验室化学谱与单一小组标准化分精标小样本。两者没有共同主键，因此不逐行合并、不进入任何模型，仅作宏观对照。

两库整体酒精度分布区间一致，都集中在 0–12% vol；本文样本偏比利时修道院风格，整体偏强，峰值落在 6.5%–8%。在 16 个能明确对应的风格上，把本文实测酒精度按 10^x 从 $\log_{10}$ 列还原后与 Kaggle 同风格区间对照：**14/16 落在 Kaggle 的 P5–P95 区间内，跨风格的酒精度排序 Spearman 相关达 0.84**。苦度排序相关也达 0.86，由于 Kaggle 的 Min/Max IBU 是风格指南标称区间，每风格退化为单一值、并非逐款实测，而本文是仪器实测苦度，口径不同，故苦度只比较排序、不报告命中率。低强度低苦风格与 Tripel 等高强度风格的相对格局完全一致。Kaggle 评分由大量评论聚合、比本文每款数人的小组打分更平滑，这也部分解释了问题一弱信号维的可预测性偏低。需要强调，**主分析仅使用给定的 8 个附件，Kaggle 数据仅作外部旁证、不进入建模**。

6　问题一：含缺失的多输出有序感官分级预测

6.1　缺失结构与建模策略选择

问题一的第一道关卡是缺失数据。如 5.4 节所述，73 个真实缺失集中在 9 列、涉及 63 个样本；化合物集另有平均 14.4% 的未检出值，信息极少但不是缺失。删除这 63 行将损失四分之一样本并引入选择偏差，故本文不删行：真正缺失交给原生支持缺失的梯度提升树，未检出保留下限档位[4-6]。其中分箱映射与评估口径是保证交付整数且不泄漏的两个要害，下面分别展开。

6.2 标签构建与 0-6 分箱映射

品评小组提供的标准化连续值无法直接作为 0-6 分级交付，需要一个单调映射把连续强度离散为 7 个等级。本文在训练折内对维度 j 估计 6 个分位点 $\{q_1^{(j)}, \ldots, q_6^{(j)}\}$，定义累计计数式的单调映射：

$$g_j(y) = \sum_{\ell=1}^{6} \mathbb{1}\left[y > q_\ell^{(j)}\right], \qquad \tilde{y}_{ij} = g_j(Y_{ij}) \in \{0, \ldots, 6\}. \tag{1}$$

预测阶段对回归输出 r_{ij} 施加同一映射，并截断取整以严格落在 0-6 整数区间：

$$\hat{y}_{ij} = \min\Big(6,\ \max\big(0,\ \mathrm{round}(g_j(r_{ij}))\big)\Big). \tag{2}$$

式 (1) 的分位点与标准化参数只由训练折估计、再套用到验证折，这是本题最易被忽视的泄漏点：若在全量数据上估计分箱阈值，等于让模型偷看了验证样本的标签分布。

50 个感官目标并不独立。`5.csv` 的相关矩阵（范围 -0.502 至 0.966，非对角中位 $|r| = 0.127$）显示，组内相关并不高于组间（香气组内 0.124、风味组内 0.152、组间 0.151）；真正强的是**同名维的跨通道配对**（香气 • 酯与风味 • 酯 0.836、酒花—酒花 0.828、麦芽—麦芽 0.825），15 对同名维中位 **0.692**、12 对超 0.6。闻到的酯香与尝到的酯味几乎是同一变量。

共享信息沿“同名维”这条轴而非香气/风味分组边界，第 9 章的对照验证了按组共享无增益；最强的一对是陈酒花与畜栅味（0.966），二者几乎等价，预示弱信号维的归因会互相混淆。

分位分箱并非唯一选择。等距分箱（按极差 7 等分）在偏态连续值上产生 8 个空等级，最小等级平均仅占 0.9%、频次变异系数 1.155；分位分箱无空等级、每等级平均 13.8%、变异系数 0.022。等距分箱的 QWK 略高（0.4013 对 0.3830），但以空等级与失衡的频次为代价，故仍采用分位口径，其对 QWK 量级的影响见 9.3 节。

分位分箱的前提是标签足够分散。以“前 5 个切点跨度占该维极差的比例”度量退化程度，50 维中有 5 维显著退化：acetic 0.006、coriander 与 clove 0.008、lactic 0.011、orange 0.033。这些维的等级虽各占约 14% 样本，原始强度却几乎重叠，等级边界不具备实际含义。

应对有两种：承认这些维只是相对排序，或改用**有序回归**直接学习是否越过某一等级阈值。后者对每个内部阈值训练一个二分类器，预测概率累加取整得到等级。

表 2　分箱退化维与其余维度的有序回归对照

维度组	维度数	回归 + 分位分箱	统一有序回归（不加权）	本文采用
退化维	5	0.2052	0.3443	**0.3715**
其余维度	45	0.3842	0.3801	0.3842
全 50 维	50	0.3663	0.3765	**0.3830**

表 2 的分界很清楚：退化维换用有序回归后 QWK 提升约 0.166，其余 45 维反而略降，甜味与酯类等分布较散的维度降幅最明显。有序回归补偿的正是分箱在密集分布上

的信息损失，标签本身足够分散时，连续回归保留的强度信息更有价值，因此只在退化维切换。

接入主流水线时，退化维改用**类加权有序回归**（6 个阈值各训一个二分类器、按两侧频率反比加权），其余维不变。自动识别的 5 个退化维全部改善，折外 QWK 由 0.3663 升至 **0.3830**（+4.6%）。若铺到全部 50 维，QWK 0.4089、Spearman 0.4509、±1 58.7% 三项更高，但该分支输出等级期望值而非连续强度，而问题二、三都依赖连续底座，故以 0.026 的 QWK 换取三问共用。

判据只依赖标签分布形态，在建模前即可确定，不接触验证信息，切换也是单侧的。嵌套交叉验证下的逐维自适应选型无偏估计为 0.3856，但内层样本仅约 133 条，抽样噪声反使 17 个原本良好的维度退化，未予采用。

6.3 预测模型与求解过程

对每个感官维度 j，本文训练一个独立的梯度提升回归器 h_j，以平方损失加正则求参：

$$\Theta_j = \arg\min_{\Theta} \sum_{i \in \mathcal{D}_{tr}} \big(Y_{ij} - h_j(x_i;\Theta)\big)^2 + \Omega(\Theta), \tag{3}$$

其中 h_j 为梯度提升树集成，x_i 的缺失分量由树的默认分裂方向处理，训练集 $\mathcal{D}_{tr}$ 包含全部含缺失样本，不删行；Ω 为叶子数、学习率与 L2 正则项。50 个维度共享同一化学特征矩阵 X。

整个求解按固定随机种子 42 执行：按风格分层切 5 折，折内估计分箱映射 g_j、拟合回归器 h_j，折外累计二次加权 Kappa、平均绝对误差与决定系数，最后在全部 250 样本上重训一次产生提交分级。该流程可写成如下的闭式递推。记第 k 折的训练集与验证集为 $\mathcal{D}_{tr}^{(k)}$、$\mathcal{D}_{va}^{(k)}$，样本 i 的风格为 s_i，分层折指派取同风格样本的循环编号

$$\kappa(i) = \big(\#\{i' :\ s_{i'} = s_i,\ i' \le i\} - 1\big) \bmod K, \tag{4}$$

其中 $\kappa(i) = k$ 即 $i \in \mathcal{D}_{va}^{(k)}$，同风格样本因此近似均分到各折。分位点与退化判据只在训练折内估计：

$$q_\ell^{(j,k)} = \mathrm{Quantile}_{\ell/7}\big(\{Y_{ij} : i \in \mathcal{D}_{tr}^{(k)}\}\big), \qquad \delta_j = \mathbb{1}\left[\frac{q_5^{(j,k)} - q_1^{(j,k)}}{\max_i Y_{ij} - \min_i Y_{ij}} < 0.05\right]. \tag{5}$$

折外等级由回归分支与有序分支按 δ_j 逐维硬选择：

$$\hat{y}_{ij} = (1-\delta_j)\,\mathrm{clip}_{[0,6]}\Big(\mathrm{round}\big(g_j(h_j(x_i))\big)\Big) + \delta_j\,\mathrm{round}\Big(\sum_{\ell=1}^{6} \hat{p}_{i\ell}^{(j)}\Big), \tag{6}$$

其中 $\hat{p}_{i\ell}^{(j)}$ 为第 ℓ 个内部阈值二分类器给出的“高于该阈值”概率，$\delta_j = 1$ 时累加概率即等级期望值。50 维指标再对折外样本宏平均，二次加权 Kappa 取

$$\mathrm{QWK} = \frac{1}{50}\sum_{j=1}^{50} \frac{\sum_{a,b=0}^{6} w_{ab} O_{ab}^{(j)}}{\sum_{a,b=0}^{6} w_{ab} E_{ab}^{(j)}}, \qquad w_{ab} = \frac{(a-b)^2}{36}, \tag{7}$$

$O_{ab}^{(j)}$、$E_{ab}^{(j)}$ 为第 j 维混淆矩阵的观测与期望计数。

6.4 结果分析

主模型与各基线、配对 bootstrap 检验合并在表 3：QWK 至 RMSE 各列在 0-6 等级上计算并作 50 维宏平均，±1 衡量大方向正确、严格一致率为完全命中、MAE 与 RMSE 给出平均差几级；Pearson 与 4.csv 中心化连续值计算（主模型取连续输出，四个基线只输出等级，若主模型降到等级口径则为 0.419，仍是下界）；ΔQWK 为 2000 次配对重采样的差值与百分位法 95% 区间，π 为重采样中主模型更优的比例。

表 3　问题一主模型与基线整体性能对比（50 维平均）

方法	QWK	Spearman	±1	严格一致	MAE	RMSE	Pearson	$R^2>0$	ΔQWK 与 95% CI
LightGBM＋分维选型	**0.3830**	**0.4109**	**0.5729**	**0.2214**	**1.502**	**1.926**	**0.464**	29/50	—
KNN 插补＋LightGBM	0.3652	0.4090	0.5605	0.2237	1.564	2.011	0.406	24/50	+0.0177 [0.0105, 0.0248]
随机森林	0.3280	0.4089	0.5550	0.2100	1.549	1.960	0.431	26/50	+0.0546 [0.0440, 0.0654]
ElasticNet	0.2762	0.3105	0.5081	0.1952	1.720	2.173	0.306	13/50	+0.1065 [0.0858, 0.1273]
逐维均值	0.0015	0.0013	0.4273	0.1460	1.869	2.243	−0.008	0/50	—

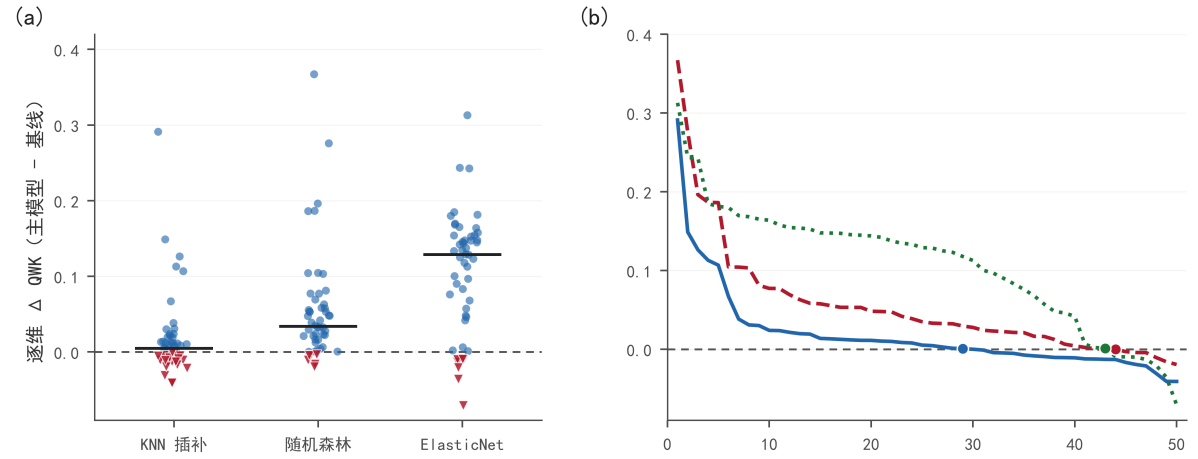


图 2　主模型与三类基线的逐维配对胜负

表 3 的三条 95% 区间均不跨零、2000 次重采样中主模型全部更优，增益方向稳定；增量对同为原生缺失的 KNN 插补最小、对线性模型最大。

图 2 的逐维对照显示三点：主模型对 ElasticNet、随机森林分别胜出 43、44 维，对 KNN 插补胜出 29 维，中位差值仅 +0.005；增益高度集中，29 个胜维的正增量合计 1.184，最大 5 维占 66.4%；落败维亏幅很小，最差一维只低 0.041，远小于最大增益 0.291。故结论是**少数维显著改善、多数维持平**，50 维仍全部提交主模型。

绝对水平上主模型在 QWK、Spearman、±1 与 MAE 全面领先，ElasticNet[8-9]、随机森林[10] 居中，均值基线退化到随机水平。随机森林的 Pearson 高于 KNN 而 QWK 更低，因 Pearson 对等级边界错位不敏感，本问以 QWK 与严格一致率为准。

另复算两条推荐路线：**PLS2**（5/10/15 个成分）QWK 0.2959 / 0.3584 / 0.3575，最优仍低 0.024；**XGBoost 7 类 softprob**（取等级期望）为 **0.3832**，与主模型 0.3830 等价。回归与直接多分类差别在标签映射而非模型族，本文保留回归分支以提供连续强度。

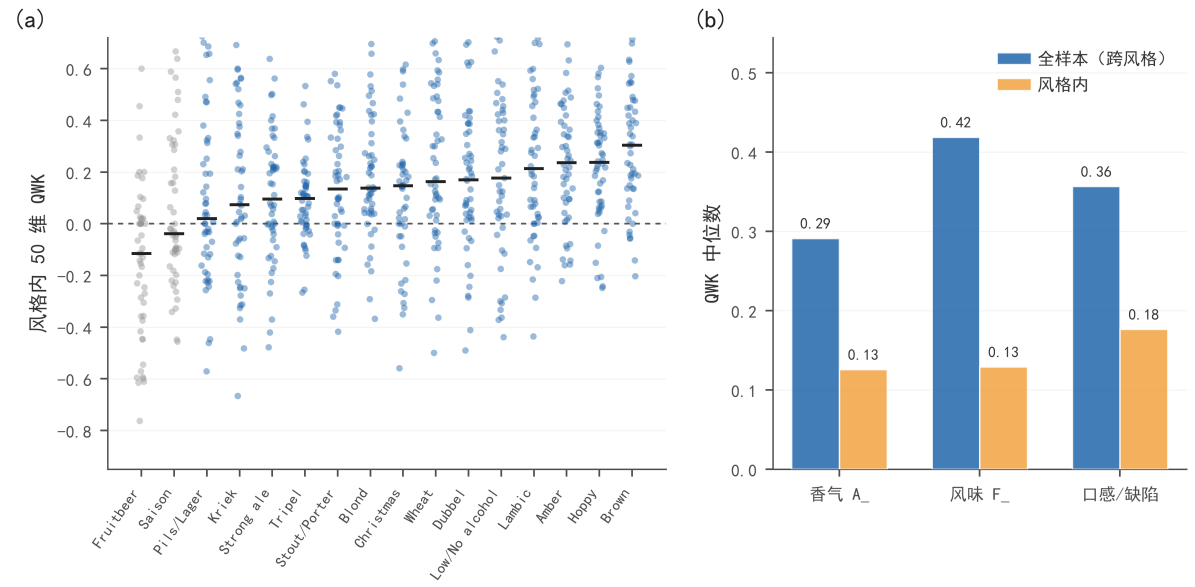


图 3　分风格重算：总体 QWK 中有多少来自跨风格差异

0.3830 是全样本口径。按风格切开重算（每格 $n \geq 8$，图 3a），16 个可评估风格的风格内 QWK 中位仅 0.135，全样本中位 0.325，说明部分判别力来自跨风格的整体感官差异；图 3b 显示风味组跨风格增益最大、香气组最小。题面要求对整批样本给等级，故主结果不变，但未知风格内部的新样本判别力会明显低于表 3 的报告值。

各维可预测性并不均匀，图 4 给出 QWK 排序与 R^2-QWK 的联合分布。

图 4a 按折外 QWK 降序排列并给出 bootstrap 区间：强（≥0.55）11 维、中（0.30–0.55）18 维、弱（<0.30）21 维，强信号集中在酒精、苦味、酒体、余味等可直接对应实测化学量的维度，弱信号集中在花香酯、果香酯等检出不稳的化合物上。图 4b 联立 QWK 与 ±1 准确率：中档维多数仍落在相邻一级内，弱信号维的 ±1 降到 50% 附近，等级分布本身难以区分。

强弱分化清晰：酒精、苦味、酒体等维 QWK 超过 0.68，末端花香酯、果香酯接近 0.14。酸度维 R^2 0.70 而 QWK 仅 0.44，是连续回归加单调分箱的固有折损；乳酸维经有序回归校正后同时达 0.68 与 0.61，说明该折损在退化维上可部分修复。

按 `A_`/`F_` 前缀分香气与风味两组各 15 维，另 20 维为口感、缺陷与总体评价。

风味组 QWK 0.400、R^2 0.222，高于香气组的 0.322、0.146：入口风味更直接由酒精、苦度、酯醇等可测化学量决定，鼻前香气则易受挥发性与主观感受干扰。

三组 R^2 依次 0.146、0.222、0.304，与 QWK 排序一致，逐维 ±1 准确率 0.40–0.85；部分维 R^2 为负而 QWK 为正，是分箱吸收了均值偏差。

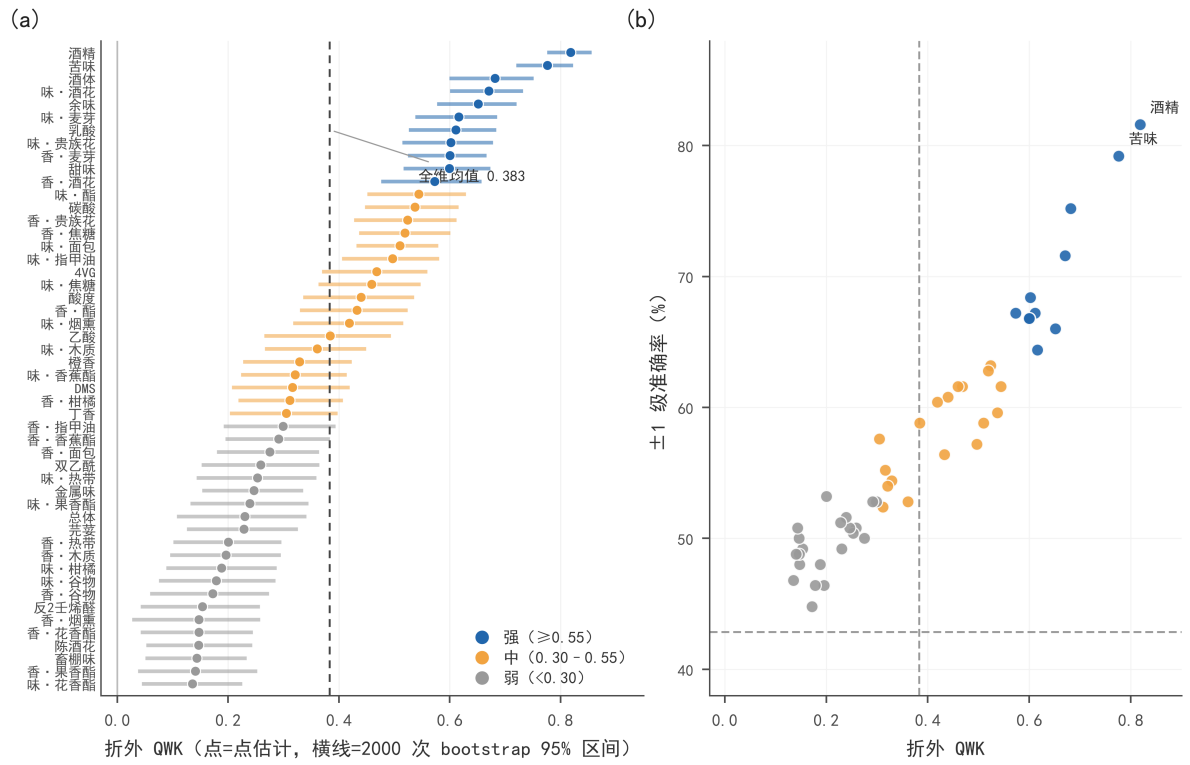


图 4　各感官维度交叉验证 QWK 排序

表 4　最强 5 维与最弱 3 维的预测性能

感官维度	QWK	R^2	Spearman	±1 准确率
酒精（alcohol）	0.819	0.713	0.829	0.816
苦味（bitternes）	0.776	0.634	0.782	0.792
酒体（body）	0.682	0.525	0.728	0.752
味 · 酒花（F_hops_all）	0.670	0.505	0.698	0.716
余味（aftertaste）	0.651	0.468	0.654	0.660
味 · 花香酯（F_esters_flower）	0.135	-0.013	0.160	0.468
香 · 果香酯（A_esters_fruity）	0.141	0.025	0.138	0.488
畜栅味（barnyard）	0.144	0.095	0.260	0.508

表 4 只摘强弱两端，50 维完整排序见附录表 A.4。末端味 • 花香酯的 QWK 已接近随机相邻水平，芫荽、丁香经有序回归校正后仍偏弱。这一强弱分化在 Schreurs 等[12]的十种模型对比中同样出现：他们按风格分层随机划分训练集与测试集，梯度提升整体最优、单维 R^2 最高 0.75，其中 Flavour 组明显好于 Aroma 组，本文风味组 QWK 0.400 高于香气组 0.322 的排序与之同向。

校准检查显示连续预测沿对角线聚集、无系统偏移，混淆矩阵集中在主对角线与相邻带，误判多为一级偏差，支撑了“连续回归再离散为有序等级”的交付方式。

6.5　预测区间与不确定性

点预测无法告诉使用者“这个 4 级有多可信”。本节为每个感官维给出 90% 预测区间，比较两种口径：**直接分位数回归**（把 LightGBM 的目标函数换成 $\alpha = 0.05$ 与 $\alpha = 0.95$

的分位数损失，分别给出下上界）；**split-conformal**（每个训练折内再切 30% 作校准集，用点模型绝对残差取 $\lceil (n+1)(1-\alpha) \rceil$ 分位作半宽，对验证折输出对称区间）。

直接分位数回归的平均覆盖率为 **75.3%**，显著低于名义的 90%，平均宽度仅 1.025 个标准化单位——典型的**欠覆盖**，与 250 样本、50 维逐维拟合的设定相符：分位数损失在小样本上对尾部估计不稳。split-conformal 把覆盖率拉回 **90.2%**、达到 90% 目标，代价是平均宽度增至 **1.555**。分组看香气 0.902、风味 0.899、口感 0.904，三组基本一致，校准未在某组系统性失效。

这一对照说明选择 conformal 的理由：它不依赖分布假设，只要求校准集与验证集可交换，在小样本逐维多输出场景下更可靠。区间宽度约 1.55 个标准化单位，也从侧面量化了问题一的固有难度，与 MAE 1.50 级相互印证。

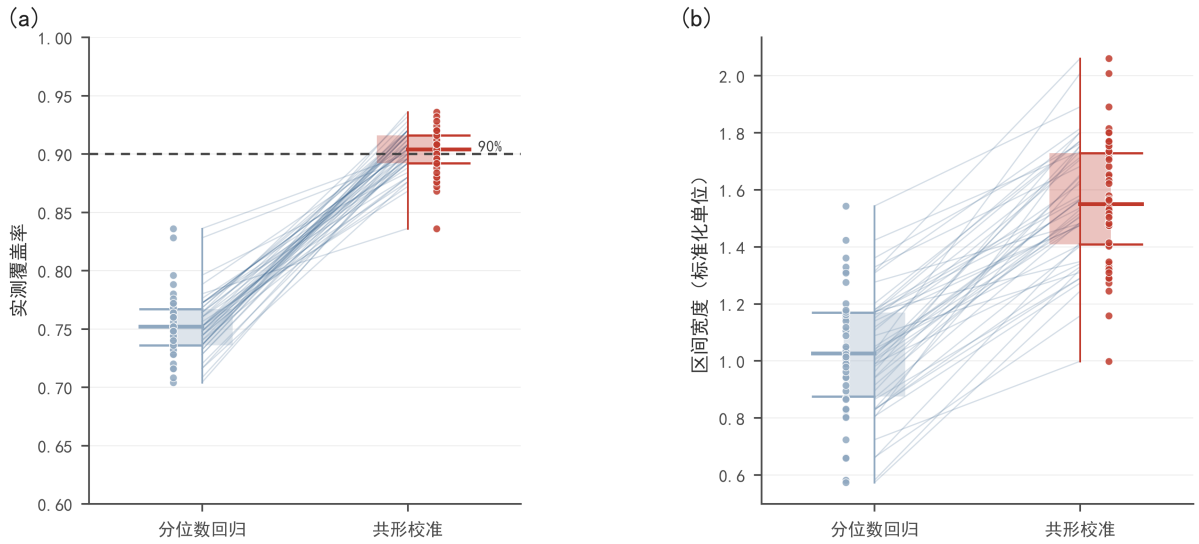


图 5　90% 预测区间的两种口径：覆盖率与宽度

总体覆盖率达标不等于每一维都达标。**图 5** 把 50 个维度逐一铺开：共形口径下的覆盖率落在 0.836–0.936 之间，其中 5 维低于 0.88——香气 • 木质（0.836）、香气 • 焦糖（0.868）、味 • 异丁酸乙酯（0.872）、味 • 酯（0.876）与味 • 果香酯（0.876）；最高的几维是香气 • 乙酸乙酯（0.936）、味 • 热带果（0.932）与畜栅味（0.928）。两口径的逐维中位数分别落在 0.752 与 0.904，几乎每一维都随共形校准上移（50/50 维改善），只是幅度在弱信号维上略小。偏差的方向与信号强度一致：覆盖率偏低的都是弱信号维，其标签分布集中、残差尾部难以由 30% 的校准集稳定刻画。而分位数回归在全部 50 维上都落在 0.704–0.836，从无一维达到名义水平，这也解释了为什么它的总体覆盖率只有 75.3%。

宽度一侧的分化更明显，最宽的是香气 • 酒花（2.060），最窄的是香气 • 木质（0.998），相差一倍。宽度的量级与该维的标签离散度、以及该维在模型中的可预测性同向——弱信号维需要更宽的区间才能覆盖 90% 的样本，这与表 4 中 R^2 的强弱排序互为印证。因此本文在交付 0–6 等级的同时，把逐维区间一并给出：使用者对弱信号维的预测应保留更大的不确定性余量。

7　问题二：化合物共表达图与关键化合物归因

7.1　共表达图构建与模块结构

问题二要为每个感官维度找出 Top-3 关键**化合物**，而化合物高度相关会干扰归因。本文先把 231 个化学特征中的 16 个理化/过程参数（酒精度、色度、pH、苦度、二氧化碳压力、蛋白、甘油、未发酵糖等）与 4 个汇总列（总酯、酒花香气总量、总酸、含硫总量）排除，仅在 **211 个单一化合物候选集** C（$|C| = 231 - 16 - 4 = 211$）内建图与归因；问题一的特征矩阵仍保留全部 231 列，因理化指标对预测同样有用。借鉴基因共表达网络思想[13-14]，以 C 中化合物为节点、相关系数为边权构建无向图，并按阈值去除弱边：

$$E = \{(p,q) : p,q \in C,\ |R_{pq}| \geq \rho\}, \qquad w_{pq} = R_{pq}, \quad \rho = 0.5,\ |C| = 211. \tag{8}$$

关于相关系数口径：题面称附件 2 为 Pearson，但本文从 1.csv 逐对重算后发现它实际是 **Spearman**——重算的 Spearman 与附件 2 逐元素一致（最大差 7.8×10^{-16}），而同口径 Pearson 的最大差达 1.12、平均绝对差 0.088。故边权即附件 2 的秩相关值，无需换算；7.3 节的建图阈值灵敏度还说明结论对阈值选择不敏感。在所得图上做 Louvain 贪心模块度社区检测[15] 以识别化合物模块，模块度定义为

$$Q_{mod} = \frac{1}{2m} \sum_{p,q} \left(w_{pq} - \frac{k_p k_q}{2m} \right) \delta(c_p, c_q), \qquad k_p = \sum_{q} w_{pq}. \tag{9}$$

在阈值 $\rho = 0.5$ 下，共表达图含 **211 个节点、564 条边**，社区检测得到 **55 个社区**，模块度 $Q_{mod} = 0.625$，远高于随机网络的水平，表明化合物确实存在明显的模块化组织结构。

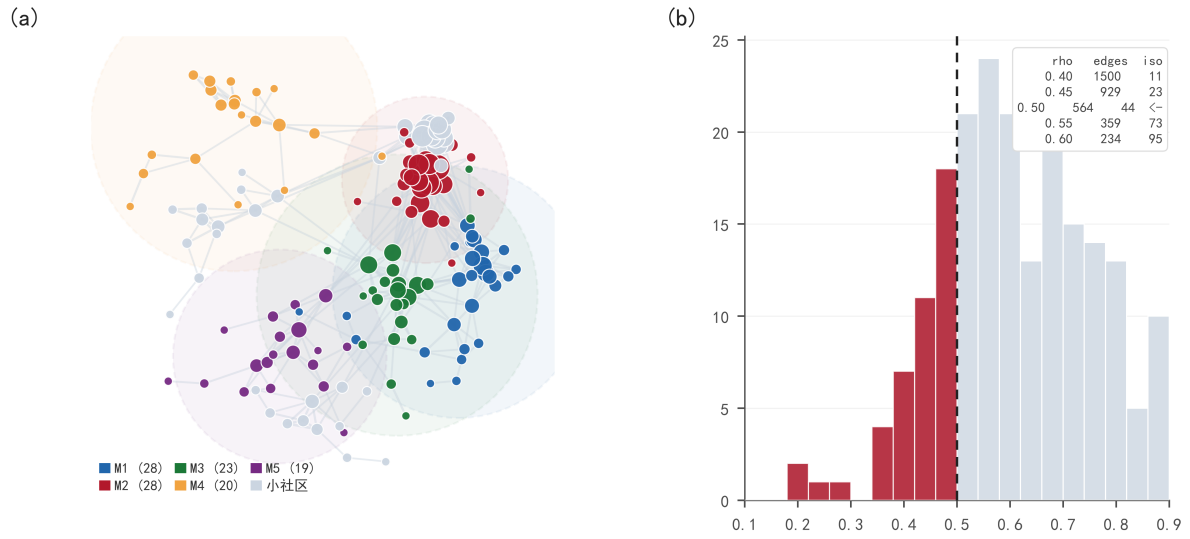


图 6　共表达网络的模块结构与孤立节点成因

图 6(a) 中节点按 Louvain 社区着色、面积正比于度数，各社区沿全局质心方向外推后留出空白，主要模块标出枢纽化合物；可见同一酿造来源或同一代谢途径的化合物聚成一个模块，且模块之间有明确分界。图 6(b) 回答孤立节点的来源：以 $\rho = 0.5$ 建图时

44 个化合物没有达到阈值的伙伴，但它们的最大 $|r|$ 中位为 0.444、其中 11 个落在 0.48–0.50，说明孤立主要是硬阈值截断的结果，而非这些化合物与其余 210 个真正无关；阈值降到 0.45 时孤立数即从 44 降到 23。

社区规模分布显示 55 个社区高度不均衡：前 8 个大社区，各有 11–28 个化合物，已包含 159 个节点（约 75%），其余多为 1–2 个化合物的小簇。这一结构正是归因去冗余的依据：若不加约束，同一模块内可互相替代的化合物会把一个维度的 Top-3 名额占满，掩盖真正多样的驱动因素。因此下一步的关键度打分必须引入模块代表机制。在融合模型证据之前，先看化学与感官之间最直接的线性关联。

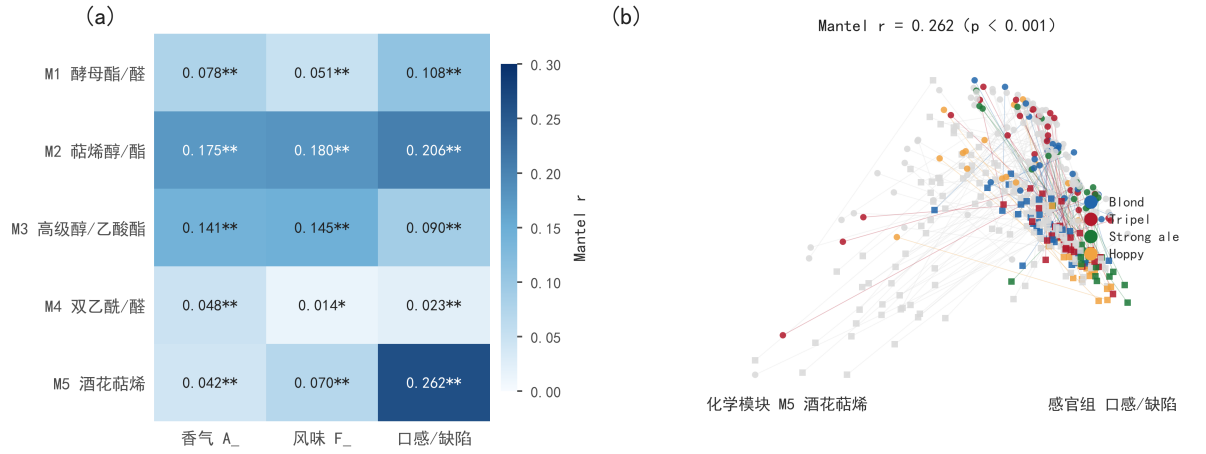


图 7　化学模块与感官组的 Mantel 关联

模块归属若只是算法产物，就不该与感官有系统关联。图 7 对 5 个 Louvain 大模块与三组感官分别做 Mantel 检验（各 999 次置换）：相关系数 0.014–0.262，全部 $p < 0.05$。最强的是 M5（酒花萜烯）与口感缺陷组（$r = 0.262$）；M2（萜烯醇/酯）对三组较均衡（0.175–0.206），承载整体风味强度；M4（双乙酰/醛）与香气组仅 0.048，与该模块检出稀疏一致。这一层补上了“整谱可分”与“单化合物相关”之间的空白。

两类混杂需要分别剥离。第一类是**风格间差异**：每个风格先减去风格内均值，再对 44 化合物 × 50 感官的 2200 个配对重算 Spearman——全样本相关中位绝对值 0.113，去风格均值后降至 0.065，两者相关 0.649、符号一致率 70.8%，$|r| \geq 0.3$ 的配对由 251 个减到 36 个。第二类是**酒精度这一全局混杂**：乙醇与麦芽汁浓度、酯醇生成共同变化，会把无关的化学-感官关联一同抬高。以乙醇为控制变量对同一 2200 个配对计算偏 Spearman：中位 $|r|$ 由 0.113 降至 **0.084**，$|r| \geq 0.3$ 的配对占比由 11.4% 降至 **4.3%**，符号一致率 83.7%。分化合物看，收缩程度恰好刻画“是否被酒精度带出来”：乙醇自身与酒精、酒体的相关（0.817、0.719）控制后几乎归零（−0.026、−0.013），甘油—酒精由 0.625 降至 0.066、己酸乙酯—酒精由 0.619 降至 0.036，属酒精度驱动的表面关联。而**异 α-酸—苦味仅从 0.682 降到 0.646**、辛酸乙酯—苦味从 0.593 降到 0.401，是独立于酒精度的真实化学信号。这直接支撑 7.5 节的来源判定：麦芽维 Top-3 落在酵母酯醇上并非独立关联，而是都随发酵强度同向变化——剔除酒精度后大幅收缩，正说明它们只是统计代理。

把相关矩阵按 Louvain 模块重排后，五个模块在对角线上形成成片的高相关方块：块内 $|r|$ 中位 0.353，块间仅 0.143，相差 2.47 倍。这直接解释了 Top-3 为何必须做模块

去冗余。

线性层面，14 个代表性化合物与 50 个感官维的逐对相关呈清晰的条带结构：酯类化合物与果香、酒花类维度呈较强正相关，硫化物与蔬菜硫味维度相关显著，这些强相关区域与酿造机理高度吻合，构成归因的线性证据一路。但线性相关无法捕捉非线性贡献，也无法识别共线性冗余，故需与模型的非线性归因联合使用。

7.2 多证据融合 Top-3 归因

对每个感官维度 j，本文融合三类证据给化合物 p 打关键度分：

$$\phi_{jp} = \alpha\,\widetilde{\mathrm{SHAP}}_{jp} + \beta\,\big|\tilde{C}_{pj}\big| + \gamma\,\mathrm{rep}_{jp}, \qquad \alpha+\beta+\gamma = 1. \tag{10}$$

其中 $\widetilde{\mathrm{SHAP}}_{jp}$ 是问题一模型对维度 j 的归一化 SHAP 值，刻画非线性预测贡献；$\tilde{C}_{pj}$ 是化学与感官交叉相关的归一化绝对值，刻画线性关联；rep_{jp} 是模块代表加权，使同模块内多个可互替化合物只保留关键度最高者进入候选，避免 Top-3 被单一模块占满，这一簇代表的思路与稳健特征选择中的聚类代表方法一致[16]。按权重 $\alpha = 0.5, \beta = 0.3, \gamma = 0.2$ 取每维得分前三者：

$$\mathrm{Top3}(j) = \arg\operatorname*{top3}_{p}\ \phi_{jp}. \tag{11}$$

SHAP 值通过对问题一全量梯度提升模型使用树解释器逐样本计算得到，权重 α 最大体现了以预测贡献为主、相关与去冗余为辅的归因哲学。去冗余规则可写成筛选算子：设已入选集合为 $\mathcal{S}_j$，候选 p 同社区内已有强相关成员时被剔除，

$$\mathcal{A}_j = \Big\{ p \in C :\ \nexists\, q \in \mathcal{S}_j \text{ s.t. } c_p = c_q \neq -1,\ |R_{pq}| \geq 0.7 \Big\}, \tag{12}$$

于是贪心选取等价于在剩余候选上反复取最大，直至满 3 席：

$$\begin{aligned} p^{\star}_{j1} &= \arg\max_{p\in\mathcal{A}_j} \phi_{jp}, \\ p^{\star}_{j,m+1} &= \arg\max_{p\in\mathcal{A}_j\setminus\{p^{\star}_{j1},\ldots,p^{\star}_{jm}\}} \phi_{jp}, \quad m = 1, 2, \end{aligned} \tag{13}$$

强制 Top-3 来自相互独立的化学证据，而非三个彼此近似的共表达冗余物，每个维度恰好交付 3 个化合物。证据分级再把每个候选 p 映射到 A/B/C 三档：

$$\mathrm{grade}_{jp} = \begin{cases} \mathrm{A}, & \sum_{m=1}^{4} \mathbb{1}\big[\text{条件}m\ \text{满足}\big] = 4, \\ \mathrm{B}, & \sum_{m=1}^{4} \mathbb{1}\big[\text{条件}m\ \text{满足}\big] = 3, \\ \mathrm{C}, & \text{否则}, \end{cases} \tag{14}$$

四个条件依次为 $f_{jp} \geq 0.8$、该维折外 $R^2 > 0$、条件增量在 5 折中至少 3 折为正、条件增量超过同维随机列置换的 95% 分位。

7.3 稳定性量化

阈值 ρ 不是随手取定的常数。边数随 ρ 单调塌缩：0.40 时 1500 条边、最大分量 200 节点，0.60 时只剩 234 条边、86 节点；孤立节点从 11 升到 95，而模块度在 0.55–0.60 才

见顶（0.684、0.704）后回落。ρ=0.5 是折中点：保留 159 节点的连通骨架、模块度 0.625。本文据此固定 ρ=0.5。

稳定性严格按题面指定的两种口径量化。第一种是 bootstrap 入选频率[17]：对样本做 $B = 500$ 次**按风格分层**的有放回重采样（样本量少于 5 折的风格合并为 `_rare` 一层，避免小风格被抽空），每次重算 Top-3，统计化合物 p 进入维度 j 的 Top-3 的频率

$$f_{jp} = \frac{1}{B}\sum_{b=1}^{B} \mathbb{1}\left[p \in \mathrm{Top3}^{(b)}(j)\right] \in [0,1]. \tag{15}$$

为确认 $B = 500$ 已收敛，本文另在 200 次与 300 次处设检查点：三个规模下 Top-1 频率均值为 0.9996/0.9997/0.9997，相对最终结果的 Top-1 选择**改变 0 维**，说明 500 次已充分稳定。

第二种是跨方法 Jaccard：对 SHAP 法交叉相关法随机森林重要性法三类方法两两比较其 Top-3 集合，

$$\mathrm{Jac}(A,B) = \frac{|A \cap B|}{|A \cup B|} \in [0,1]. \tag{16}$$

入选频率高说明单一方法内部稳健，Jaccard 高说明不同证据之间一致。为回答这样的稳定性是否显著优于随机，本文还构造了随机基线：在 211 个化合物集 C 上随机抽取 3 个作为 Top-3，重复 100000 次，计算随机 Top-3 与固定参照的 Jaccard 期望。两指标的全维分布如下图。

单方法稳定性极高：Top-1 入选频率 47/50 维恰为 1.000、三组中位数均为 1.000，单方法内部的关键化合物判定极其稳健。跨方法一致性中等：三对方法的逐维 Jaccard 中位数都是 0.200，均值 0.128、0.274、0.156，整体均值 **0.200**，即三类证据的 Top-3 平均约两成重叠。作为参照，10 万次随机抽取的 Jaccard 期望仅 **0.0086**，本文 0.200 是随机基线的 **23.3 倍**，三类证据侧重不同、绝对 Jaccard 不高，但相对随机已高度显著，归因绝非偶然而非虚高的一致。

全部 150 个上榜配对的入选频率中位数为 **1.000**、均值 0.960，其中 138 个（92.0%）不低于 0.8，106 个（70.7%）在 500 次重采样中每次都入选。抽样设计与候选集规模与同类研究不同，此处只作量级参照。

Jaccard 均值掩盖了” 不一致” 的形态。把三法 Top-3 集合逐维拆开比对后：三法有共同候选 21 维、两对各自重合 6 维、仅一对重合 16 维、完全互斥 7 维。可见一致性偏低主要来自第三种视角带进新候选，而非三法彼此无关，这正符合三路融合的设计意图。

为便于在稀疏的 Top-3 中判断哪个名次最先失稳，本文把三个名次的入选频率并排展开，见图 8。

图 8(a) 把 50 个维度在三个名次上的入选频率并排铺开，图 8(b) 单独列出最不稳的 14 维及其第三名化合物。第 1、2 位几乎完全饱和、彼此只差一点，真正区分维度的是第 3 位：它的均值明显低于前两位、最低只有 0.4 左右，且各维第三名化合物互不相同、缺乏共同的化学主题。这说明弱信号维的“第三名”只是在一批可互换的化合物中随机胜出，而强信号维的三个名次都接近饱和、其 Top-3 集合本身是稳定的。

为检验“弱信号维不可预测”与“归因不稳”是否同一现象，把 50 个维度放到

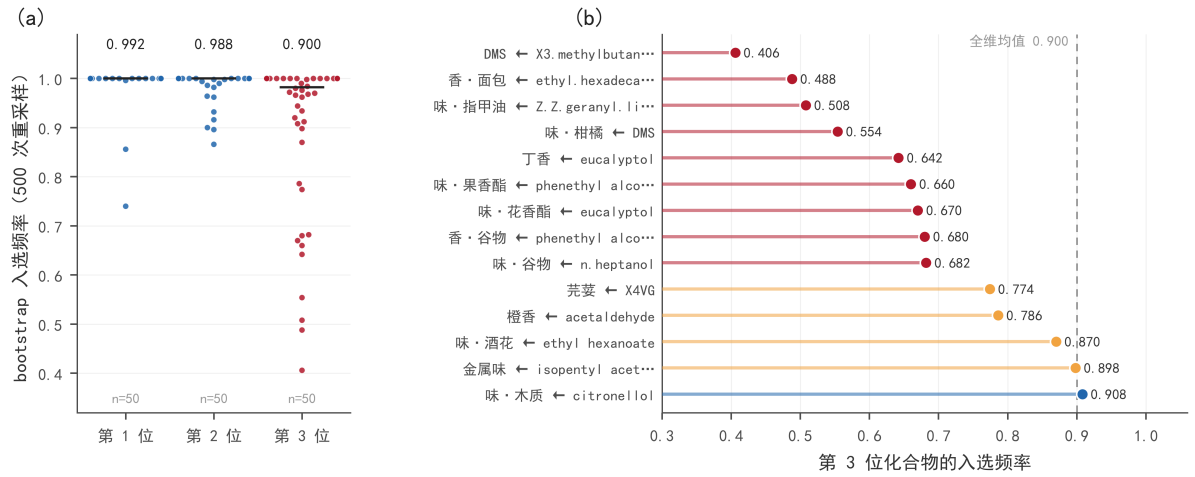


图 8　三个名次的 bootstrap 入选频率与其分化

（QWK，Top-1 入选频率）平面上：相关仅 $r = 0.101$，可预测性与 Top-1 稳定性基本独立——QWK 低的维度其 Top-1 仍可能 100% 稳定选中同一化合物，只是该化合物与目标感官的关联微弱。真正随可预测性变化的是第 3 名：弱信号维（QWK <0.30）的第 3 位入选频率中位数明显低于强信号维，说明弱信号维的“第三名”才是在一批可互换化合物中随机胜出的位置。这解释了表 5 中 A/B/C 分级多在第一名为 A、第三名落 B 或 C。

各维度的融合重要度热力进一步揭示关键化合物的分布，见图 9。



图 9　感官维与关键化合物的融合重要度热力

融合重要度热力图显示热点集中在少数化合物列，癸酸乙酯、乙醛、乙酸乙酯、异丁酸乙酯、二甲基硫醚等酵母酯、醇、醛类反复成为多个维度的关键驱动。由于候选集

已限定 211 个单一化合物，酒精度、苦度、色度、蛋白等理化/汇总列不再出现在 Top-3 中，归因严格回应题意。代表维度的 Top-3 清单、稳定性、来源判定与第一名证据分级汇总于表 5：频率为 500 次 bootstrap 的 Top-1 入选频率，Jaccard 取三类方法两两均值。

表 5　代表性感官维度 Top-3 关键化合物、稳定性与来源类别判定（仅化合物集 $C = 211$）

感官维度	Top-1	Top-2	Top-3	Top-1 频率	Jaccard	期望来源	判定	Top-1 分级
酒精	ethyl_ octanoate	acetaldehyde	MeSH	1.000	0.400	Yeast	一致	A
苦味	ethyl_ octanoate	MeSH	DMS	1.000	0.667	Others	不一致	A
酒体	isobutanol	ethyl_ octanoate	MeSH	1.000	0.133	Unknown	不一致	A
味 · 酒花	ethyl_ octanoate	DMS	ethyl_ hexanoate	1.000	0.400	Hops	不一致	A
余味	ethyl_ octanoate	acetaldehyde	ethyl_ isovalerate	1.000	0.400	Unknown	不一致	A
味 · 麦芽	acetaldehyde	MeSH	ethyl_ decanoate	1.000	0.200	Malt	不一致	A
味 · 贵族花	ethyl_ octanoate	ethyl_ hexanoate	DMS	1.000	0.300	Hops	不一致	A
香 · 麦芽	acetaldehyde	octyl_acetate	MeSH	1.000	0.167	Malt	不一致	B
甜味	ethyl_ decanoate	octyl_acetate	alpha. humulene	1.000	0.200	Others	不一致	A
香 · 酒花	ethyl_ octanoate	DMS	linalool	1.000	0.200	Hops	部分一致	A
味 · 酯	ethyl_acetate	phenethyl_ alcohol	acetaldehyde	1.000	0.400	Yeast	一致	A
碳酸	ethyl_ octanoate	ethyl_ hexanoate	MeSH	1.000	0.500	Yeast	一致	A

7.4　融合增益消融与归因集中度

7.2 节的三路融合依赖两个假设：模块代表能让 Top-3 覆盖更多化学模块，三路结合优于任一单方法。消融保持去冗余规则、候选集 C 与 Top-3 基数不变，只替换证据来源，得到仅 SHAP、仅相关、两路融合与三路融合四个变体；指标为“模块覆盖数”，即 Top-3 落在多少个不同的 Louvain 社区内。

150 个席位中，acetaldehyde、MeSH、ethyl octanoate、DMS 四个化合物占 32%，其余 26 个各只出现一次。酵母来源占约 60%，而期望来源中酵母仅 24%；麦芽来源席位仅 9%，期望却占 20%。模型倾向选丰度高、检出稳定的酵母酯醇，麦芽焙烤物在成品中稀疏、难进前三，这与来源一致性检验相互印证。

三路融合的模块覆盖数为 2.92（满分 3），比仅用相关高 27.0%、比仅用 SHAP 高 12.3%。仅 SHAP 的 Top-1 覆盖 34 个化合物，看似更分散，但模块覆盖仅 2.60，说明分散来自同一模块内成员的反复选择；仅用相关的覆盖最低（2.30），线性相关易被整体丰度共变主导。

50 个维度用了 50 个不同的 Top-1 化合物，但分布极不均衡：acetaldehyde 进入 16 个维度的 Top-3，MeSH 12 次、ethyl_octanoate 与 DMS 各 10 次，26 个化合物只进过一个维度，前四个合计占据 48/150 个席位。Top-1 与 overall 维的相关中位 $|r|$ 仅 0.228，整体强度只能解释一部分，其余是化合物与特定维度的实质关联；7.3 节 47/50 维的 Top-1 频率恰为 1.000，也排除了偶然共变。

证据分级按四条件判定：频率 ≥0.8、折外 $R^2 > 0$、条件增量至少 3 折为正、增量超过置换 95% 分位；四条全满为 A、三条为 B、其余为 C。全 50 维共 **101 A、42 B、7 C**，50 个第一名中 42 个为 A、8 个为 B，C 级全部落在 R^2 为负或增量未超零分布的候选上。表 5 末列给出代表维第一名的分级，完整 150 条见附录表 A.9，全部 50 维的 Top-3 答案见附录表 A.10。

150 个席位背后只有 50 个化合物：18 个覆盖至少 3 维（acetaldehyde、MeSH、ethyl octanoate、DMS 各不少于 10 维），26 个只出现一次。对 150 个候选各做两组置换（单独打乱该化合物、打乱其所在社区全部成员，均以标签方差归一化）后，酵母酯醇类的条件增量与模块增量同时较大，兼具独立贡献与共表达支持；MeSH、DMS 等单点模块成员无法定义模块增量，只能靠条件增量与跨方法一致性判断。

7.5 化学合理性论证

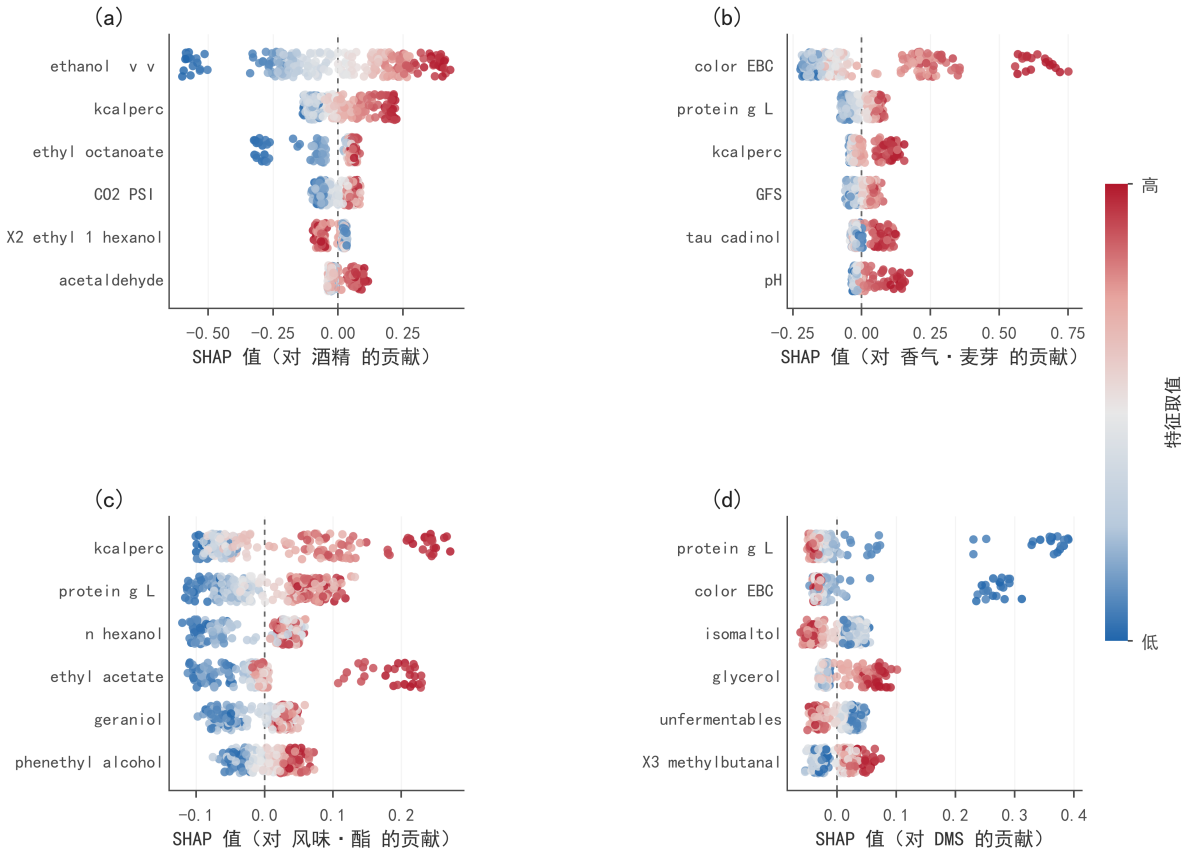


图 10　四个代表维度的 SHAP 蜂群：方向与量级

热力图与重要度只给强度、不给方向。图 10 逐点画出 250 个样本，横轴为 SHAP 值、颜色为取值高低：酒精维由乙醇主导（平均 |SHAP| 0.217），麦芽香气维由色度主导（0.201），符合美拉德产物随色度上升的常识；酯维与 DMS 维的前几位却是 kcalperc、protein 等理化量，说明检出不稳的维度上模型只能借助稳定的理化代理量。

对四个代表维做逐浓度 SHAP 与 ALE 累计效应[18] 检查：乙醇对酒精、色度对麦芽香气、辛酸乙酯对苦味均单调上升；pH 对乳酸维度先正后负，是真正的方向反转，属于线性归因无法表达的局部非线性。

Top-3 结果需经得起酿造机理检验。香蕉味维 A_esters_isoaa 的 Top-1 正是 isopentyl_acetate（异戊基乙酸酯），另两席正己醇、苯甲醛同为酵母发酵产物，频率均为 1.0、来源判定为一致；指甲油味维 A_esters_ethac 的 Top-1 是 ethyl_acetate，同样机理一致。

为避免只举成功个例，本文用 8.xlsx 的 Sensory thresholds 表给每个化合物标注来源（酵母、酒花、麦芽、香料、野生菌群、其他），按感官类别推断期望来源，逐维判定：三者全部来自期望来源为一致，至少一个为部分一致，无一个为不一致。

表 5 的判定以不一致为主，完全一致的集中在酯香、酒精等酵母主导维度。最明显的错位是麦芽感官：Top-3 几乎全是乙醛、DMS、癸酸乙酯等酵母产物。原因是吡嗪、糠醛等麦芽焙烤物在成品中检出稀疏（阈值表标注麦芽来源仅 24 个），而酵母酯醇丰度最高，成为与麦芽甜香共变最强的可测载体，属统计代理而非直接分子。分离因果仍需受控实验（见 10.2 节）。

8 问题三：风格条件生成与跨风格迁移

8.1 条件变分自编码器

问题三要学习一个以风格为条件的化学谱生成模型，并在小样本下保持风格可区分。本文采用条件变分自编码器[19]：编码器 $q_\phi(z \mid x, s)$ 把 231 维化学谱连同风格条件压缩进低维隐空间，解码器 $p_\theta(x \mid z, s)$ 从隐变量与风格条件重建化学谱。模型最大化证据下界

$$\mathcal{L}(\theta, \phi) = \mathbb{E}_{q_\phi(z|x,s)}\big[\log p_\theta(x \mid z, s)\big] - \beta_{KL}\,\mathrm{KL}\big(q_\phi(z \mid x, s)\,\big\|\,p(z)\big), \tag{17}$$

其中先验 $p(z) = \mathcal{N}(0, I)$，采用重参数化 $z = \mu_\phi + \sigma_\phi \odot \epsilon$ 使梯度可回传。为避免缺失位置污染梯度，重构项只对非缺失分量计算误差：

$$\log p_\theta(x \mid z, s) \;\propto\; -\tfrac{1}{2} \sum_{p:\, M_{ip}=0} \big(x_{ip} - \hat{x}_{ip}\big)^2. \tag{18}$$

隐维取 16 以适配 250 的小样本规模：维度过低时 231 列的重构压力全落在少数隐变量上、各风格趋于同一均值，过高则在 250 个样本上过拟合。编码器 E_ϕ 把化学谱与风格条件拼接后映射为对角高斯的参数，解码器 D_θ 再从隐变量与条件重建化学谱：

$$(\mu_\phi, \log \sigma_\phi^2) = E_\phi(x, s), \qquad \hat{x} = D_\theta(z, s), \qquad z = \mu_\phi + \sigma_\phi \odot \epsilon. \tag{19}$$

式 (17) 的 KL 项对对角高斯有闭式解，可直接逐维累加而不必采样估计：

$$\mathrm{KL}_d = \tfrac{1}{2}\Big(\mu_{\phi,d}^2 + \sigma_{\phi,d}^2 - 1 - \log \sigma_{\phi,d}^2\Big), \qquad d = 1, \ldots, 16. \tag{20}$$

重构项按样本自身的观测位数归一化，使缺失比例不同的样本对总损失的贡献可比；若直接对 231 列求和，缺失多的样本会因观测位少而被系统性低估权重。由此得到训练所用的完整目标

$$\mathcal{J}(\theta, \phi) = \frac{1}{N} \sum_{i=1}^{N} \left[\frac{1}{|\mathcal{O}_i|} \sum_{p \in \mathcal{O}_i} \big(x_{ip} - \hat{x}_{ip}\big)^2 + \frac{\beta_{KL}(t)}{16} \sum_{d=1}^{16} \max\big(\mathrm{KL}_d,\, 0.5\big) \right], \tag{21}$$

其中 $\mathcal{O}_i = \{p : M_{ip} = 0\}$ 为样本 i 的非缺失位，除以 16 使 KL 项与逐列重构项量级相当，free-bits 下限 $\max(\cdot, 0.5)$ 阻止某一维 KL 塌到零。

这套生成器只是“能采样”，本问还要它“能定向改造”。跨风格迁移之所以在隐空间而不是在 231 维化学谱上直接做，是因为化学谱各列尺度相差数个数量级、且列间共表达结构强，直接在原空间加减会破坏相关结构；隐空间则把谱压缩成低维表示，风格差异近似为一个可估的平移方向。

训练初期曾出现后验坍塌：$\beta_{KL} = 1$ 时 KL 项迅速趋零、重构质量差，KS 距离约 0.6。本文把 β_{KL} 降至 0.1，并对 KL 项施加前 120 轮线性退火与每维 free-bits 下限，重构损失由 0.765 降至 0.255，KS 距离随之降到 0.36 至 0.41；退火系数取

$$\beta_{KL}(t) = 0.1 \cdot \min\Big(1,\ \frac{t}{120}\Big), \tag{22}$$

即前 120 轮由零线性升至 0.1，t 为当前轮次；此后再按早停取最优权重。该处理只改变优化过程、不改变题设与数据。解码后统一截断到各列训练观测区间，使生成谱不越界：

$$\hat{x}_{ip} \leftarrow \min\Big(u_p,\ \max\big(\ell_p,\ \hat{x}_{ip}\big)\Big), \qquad \ell_p = \min_i x_{ip},\ \ u_p = \max_i x_{ip}. \tag{23}$$

8.2 跨风格迁移与缺陷约束

跨风格迁移在隐空间以风格质心之差作为平移向量实现：

$$\Delta_{s\to t} = \bar{z}_t - \bar{z}_s, \qquad \hat{x}_t = p_\theta\big(z_s + \Delta_{s\to t} \,\big|\, \mathrm{onehot}(t)\big), \tag{24}$$

其中 $\bar{z}_c$ 为风格 c 所有样本隐编码的均值。该式是“把源点整体搬到目标质心”的最小位移解：若要求平移后的源质心恰为目标质心，则 $\bar{z}_s + \Delta = \bar{z}_t$，解得 $\Delta = \bar{z}_t - \bar{z}_s$；解码器同时接收目标风格 one-hot，使解码走的是目标风格的重建通路而非源风格通路。

$$x^{def}_{k,after} = \min\Big(\tilde{x}^{def}_{k,after},\ \min\big(x^{def}_{k,before},\ m^t_k\big)\Big), \tag{25}$$

其中 $\tilde{x}^{def}_{k,after}$ 为隐空间平移并解码得到的**无约束**值，$x^{def}_{k,before}$ 为该样本源风格 Pils/Lager 缺陷 k 的原始含量，m^t_k 为目标风格 Tripel 缺陷 k 的典型值（取中位）。该投影是一个带单侧上界的最近点问题，可行集为 $(-\infty, \min(x_{before}, m^t_k)]$，而欧氏投影到半直线上的解就是截断本身，故它在满足约束的所有取值中离无约束值最近，除约束之外不再额外改写含量。源款原值构成第一道防线，目标典型值构成第二道兜底。由于各化学维单位不可比、绝对阈值无法统一换算，本题不并入绝对阈值 τ^*_k，默认关闭；8.3 节以同一批样本不做投影的纯平移结果作对照，量化该约束不可或缺。

迁移谱的感官画像直接由问题一模型给出，$\hat{y}^{sens} = h_j(\hat{x}_t)$，由此把“化学上像 Tripel”与“感官上像 Tripel”两个层面的检验接在同一套底座上。

8.3 生成质量与结果分析

本文对 Tripel、Kriek、Lambic 各生成 30 条化学谱、共 90 条，并完成 11 条 Pils/Lager 到 Tripel 的迁移。为从多个独立角度证明生成质量，除分布距离外还训练了以真实 22 风格谱为输入的风格分类器，统计生成谱的 Top-3 风格识别率，与随机基线、真实谱自

身 OOF 识别率对照，并计算生成谱与同风格真实谱经问题一打分后的画像 Spearman 相关。概览见表 6：随机基线 13.6%，真实谱整体 OOF 识别率 72.8%，生成谱在三个风格上均远高于前者；KS 越小越接近真实分布，如 Tripel 的酯香维生成 3.97、真实 3.21。

表 6　三代表风格生成质量（分布距离 + 风格识别率 + 画像相关）

风格	生成数	KS 距离	生成谱 Top-3 识别率	真实谱 Top-3 识别率	生成-真实画像 Spearman
Tripel	30	0.3511	100%	86%	0.653
Kriek	30	0.4075	100%	100%	0.924
Lambic	30	0.4110	100%	100%	0.751

仅有 KS 距离不足以说明生成模型的必要性，因为它只衡量“像不像”，不衡量“有没有生成新东西”，也不衡量能否执行条件迁移。为把这三件事分开，本文构造两个对照基线：**风格内重采样**（对真实样本有放回抽样，代表“只补样本量”的朴素做法）与**风格内高斯采样**（按该风格的均值与协方差独立采样，代表“能生成新点但不建模结构”的做法），并用三个维度评价三者。

第一个维度是分布保真，用逐列 KS 距离的均值衡量，越小越接近真实分布。第二个维度是新颖性，用生成样本到最近真实样本的标准化欧氏距离衡量：距离为 0 意味着它只是复制了已有样本，距离过大则意味着偏离了真实流形。第三个维度是结构保真，用生成谱内部 Spearman 相关矩阵与真实相关矩阵的平均绝对差衡量，它检验模型是否学到了化合物之间的共表达结构。

表 7　三种生成方式的对照（三个代表风格的平均）

方法	KS 距离	新颖性	重复率	相关结构差异	观测区间内
风格内重采样	**0.098**	0.000	**100%**	**0.111**	99.9%
风格内高斯	0.312	18.14	0%	0.309	80.5%
CVAE（本文）	0.388	**350.27**	0%	0.275	90.5%

表 7 的 KS 为每风格 231 列逐列 KS 的均值（三风格共 693 列）、生成谱已按训练观测区间截断，新颖性为标准化空间中生成样本到最近真实样本距离的中位数，相关结构差异为两相关矩阵上三角元素的平均绝对差；三方式每风格同为 30 条且基于另一批生成谱，与表 6 口径不同、不作逐位比较。三者各有强弱：重采样保真最好但重复率 100%、新颖性恒为 0，只能补样本量；高斯采样能生成新点，却因假设各化合物独立而破坏共表达结构，落入观测区间的比例也最低。CVAE 的分布保真不及重采样，但是唯一同时满足“生成新谱”与“保留共表达结构”的方案——这正是本题区别于单纯补样本量之处。

这一对照给出的结论不是“CVAE 全面占优”，而是**三种方法对应不同的任务需求**。若任务只是补足样本量，风格内重采样在分布意义上更可靠；但本题要求的是条件生成与可控迁移，即在给定风格下生成新的化学谱、并在隐空间中把源风格沿特定方向推向目标风格。重采样无法产生新谱，高斯采样不具备可解释的隐空间方向，只有 CVAE 能

同时提供这两项能力。本文因此选择 CVAE，并把分布保真上的劣势如实列出，而不是以单一 KS 指标宣称生成质量全面领先。

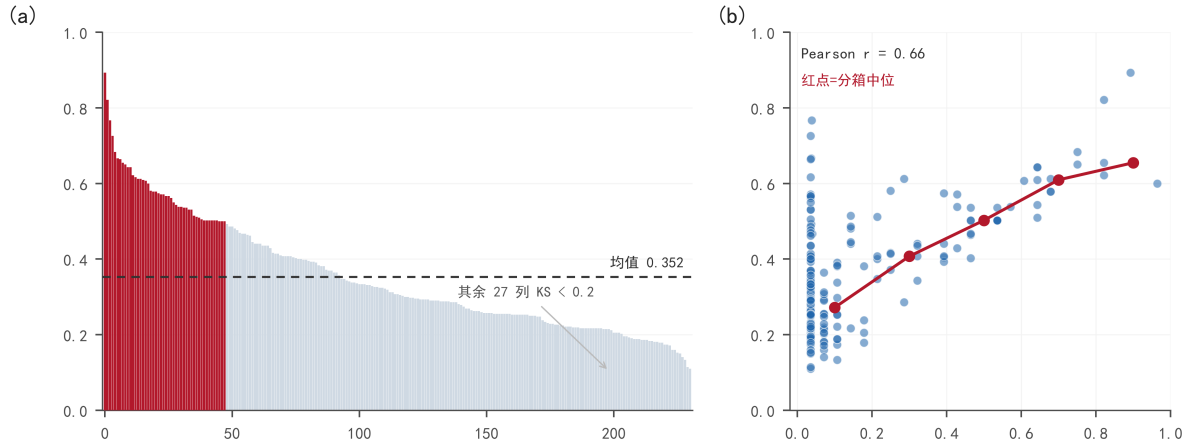


图 11　生成谱逐列 KS 距离：偏离集中在少数稀疏列

表 8 的 KS 是 231 列的平均，容易误读为“每列都偏”。图 11(a) 把 Tripel 的 231 列逐列排开：均值为 0.352，其中 **48 列**（约 20.8%）的 KS $\geq$0.5，超过一半的列 KS $<$0.2，偏离集中在少数列而非整体系统漂移。图 11(b) 进一步把 KS 与该列未检出率联立，高 KS 列正是大量样本卡在检出限的稀疏列，二者相关系数达 $r = 0.66$，与 5.4 节的左删失结构一致。

CVAE 在个别化合物上会外推到训练观测范围之外，未截断时 Lambic 有单列偏离真实中位数达数百个标准差；按训练观测区间截断后，落在区间内的比例由 89.1% 升至 90.5%，越界单元格占 767/23331（3.29%）；截断只压平越界值，不改变未越界分量的分布，故截断前后的 KS 均值分别为 0.389 与 0.388，变化可忽略。这是 250 样本、16 维隐空间下容量与过拟合的固有取舍。

KS 是标量，看不出形状怎么变，也无法说明生成样本落在隐空间的什么位置。图 12 把这两件事并置。

图 12(a) 把四个代表化合物在三个风格下的真实分布（灰）与生成分布（彩色）叠成山脊：乙醇与辛酸乙酯保持单峰、位置略偏；DMS 在 Tripel 下被压成更窄的单峰，而真实谱是带长尾的宽分布；α-蒎草烯在 Lambic 下出现双峰，说明解码器学到了两个分离模式。多数化合物的分布形状与位置都接近真实，偏离主要集中在少数稀疏列。

图 12(b) 转到隐空间：16 维隐向量做 PCA，三个风格的真实样本各有椭圆，生成样本（星号）落在对应椭圆内。但置换检验给出相反证据：风格标签随机打乱后，质心间距中位 1.04–1.31，反而大于实测的 0.52–0.78（$p = 0.92/0.99/1.00$），逐样本也只有约三成生成谱离“本风格质心”更近——16 维隐空间里不存在超出噪声的风格结构，判别信息留在 231 维化学谱里，CVAE 为重建全部列把风格条件压缩成很小的平移量。跨风格迁移正基于此平移量，缺陷投影因此不可或缺；这是问题三的主要局限，要真正成形需要显式的风格判别损失或更大样本量。

两半合看可知：生成谱在化学层面已经足够像真实样本（左），但隐空间的风格分离度有限（右）。风格条件生成的目标在“分布可比”这一层达成，而“隐空间可分”仍依赖外部约束，这也解释了后文迁移为何必须叠加缺陷投影。

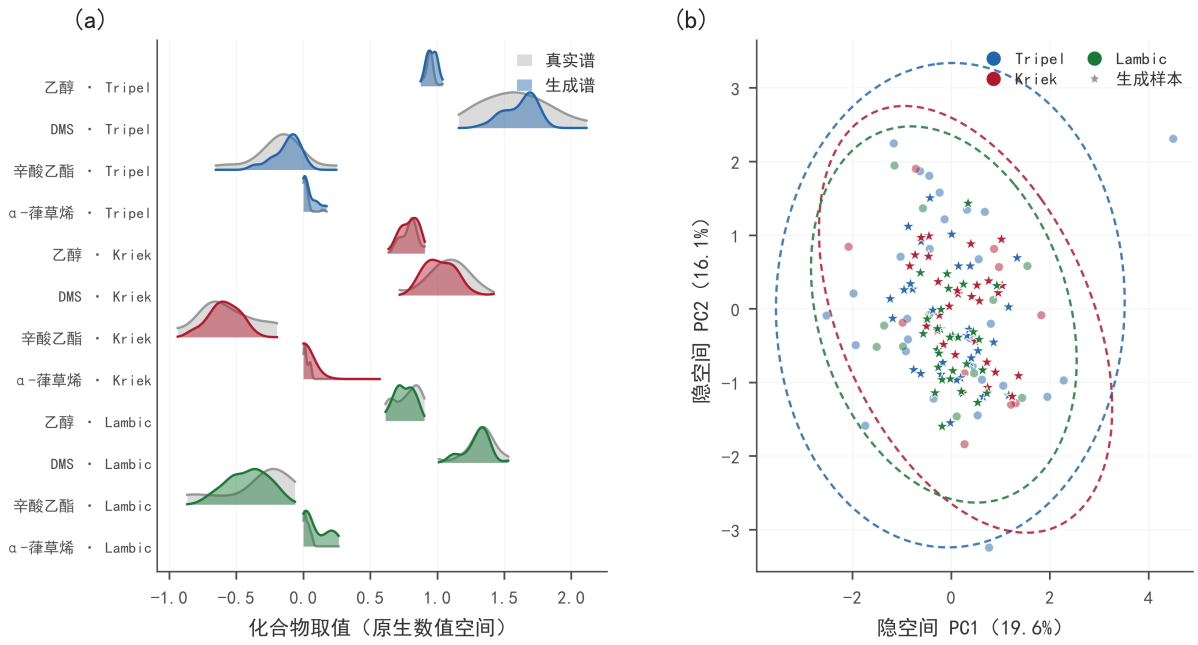


图 12　代表化合物的分布形状与隐空间位置

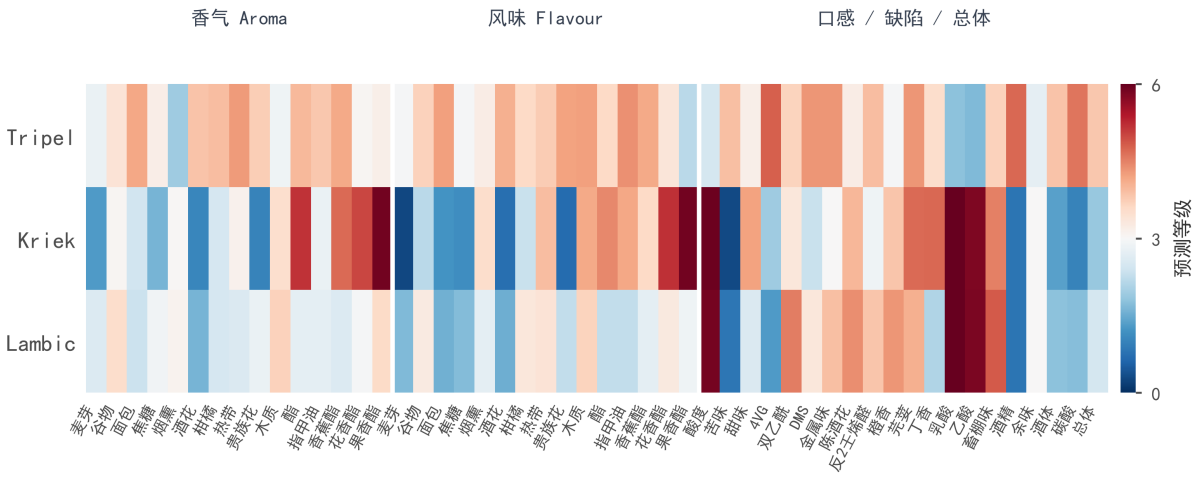


图 13　三代表风格生成谱的 50 维感官画像

图 13 把三种风格的 50 维画像完整铺开：横轴按香气、风味、口感与缺陷三组排列，格内为生成谱经问题一模型打分后的平均等级。可见 Tripel 在酒精与体重维上明显偏高，Kriek 与 Lambic 在酸味维上突出，而三者的缺陷维都处于较低水平，说明生成谱在感官层面是合理的，50 维均值见附录表 A.11。

表 8　分风格的生成质量评估（KS 与 Wasserstein-1）

风格	真实样本	KS 距离	W1 中位	W1 均值
Tripel	28	0.3511	0.3912	1.6147
Kriek	10	0.4075	0.2686	8.5349
Lambic	11	0.4110	0.2435	1.5476

除全局 KS 外，本文还按风格分别计算了 231 列逐列的 Wasserstein-1 距离（表 9，KS 与表 8 同源，W1 同时给出中位与均值）。两个指标的排序并不完全一致：Kriek 与

Lambic 的 KS 略大，W1 中位反而更小，说明它们的偏离集中在少数列的分布尾部而非整体系统性偏移。W1 均值又显著高于中位，是少数长尾列拉高的，因此本文以中位作为主报告口径。

为检验生成质量不是单一种子的偶然结果，用同一配置跑 5 个随机种子（42/7/2024/1234/99），每风格每次 30 条、与主表同口径。KS 均值 ± 标准差为 Tripel 0.344±0.012、Kriek 0.394±0.014、Lambic 0.393±0.015，风格 Top-3 识别率在全部 5 个种子上恒为 100%；能量距离中位 0.329/0.433/0.437，与 KS 排序一致；50 维画像 MAE 为 0.456/0.579/0.446 级、平均偏差不到半级，Kriek 最大——其真实样本仅 10 条，画像本身波动较大。

为证明式 (26) 的约束不可或缺，本文对同一批 11 条 Pils/Lager 到 Tripel 迁移做了**无约束纯平移对照**：若隐空间平移解码后不做任何投影，44 个缺陷-样本检查中有 32 个、即 72.7% 的缺陷浓度高于源款；施加式 (26) 后，缺陷升高数为 0、合规率 100%。逐缺陷的迁移前后、无约束对照与典型阈值见表 9。

表 9　Pils/Lager 到 Tripel 迁移中 4 个缺陷化合物的严格合规（min 投影）

缺陷化合物	迁移前	迁移后	Δ = 后 − 前	无约束纯平移后	无约束升高数	典型阈值 m_t	合规
DMS	1.158	1.158	+0.000	1.598	11/11	1.587	11/11
Diacetyl	0.169	0.056	-0.113	0.941	4/11	0.290	11/11
4VG	-1.879	-2.013	-0.134	-1.805	8/11	-2.013	11/11
trans-2-nonenal	0.004	0.004	-0.000	0.232	9/11	0.011	11/11

表中数值均为标准化含量，无约束升高数列给出该缺陷在 11 条样本中无约束时高于源值的条数。四个缺陷受约束后全部合规（44/44），无约束时普遍升高。DMS 是最典型的对照：纯平移把它整体拉高、11 条无一例外，min 投影恰把它压回源值（$\Delta = 0$），正好卡在“不高于源款”的边界上；双乙酰与 4VG 被压得更低。若改取源值与目标典型值中较大者，DMS 会被抬高却仍宣称合规，min 口径修正的正是这一矛盾。Stale hops 无对应列、属陈化标记，仅记录不投影。式 (13) 保证的是**相对不恶化**，不等价于绝对安全：按 5.3 节尺度换算回真实浓度后与阈值表比较，结果如下。

绝对口径需与目标风格本身的化学特征一并解读，否则易误读为投影失效。Tripel 的 28 条真实谱中 25 条 DMS 高于 19 μg/L、18 条 Diacetyl 高于 0.09 mg/L——目标风格在数据层面本就以较高 DMS 为特征；若强行把全部迁移样本压到阈值以下，生成谱将不再像 Tripel，与迁移目标冲突。本文因此以相对口径为硬约束（可逐样本审计且必然成立），绝对阈值作为诊断指标如实报告，而不宣称实现绝对意义的缺陷安全。这也说明：真实数据上风格迁移与缺陷达标并不总能同时满足，张力应由使用者按场景加权。

第五类缺陷 Stale hops 在化学谱中没有对应测量列，无法施加浓度投影。本文改用问题一模型对迁移谱打感官分作为代理：11 条迁移样本的 Stale hops 等级为 2 至 5、中位 3，与其源款等级分布一致，未出现系统性上升。需要说明这只是感官代理，不是对 Stale hops 相关化合物的直接浓度约束；要给出化学层面的保证，仍需该类陈化标志物的实测列。

上述只看四个缺陷化合物，而迁移到底改动了哪些化合物、改了多少并不清楚。把

11 条迁移样本的 12 个关键化合物相对源风格均值的变化按标准差归一化后逐列检查：酵母酯醇类被系统性上调，四个缺陷化合物的平均位移接近于零、个别为负，即约束确实用于阻止这些列被拉高。

隐空间平移是黑箱，本文因此在化学层给出方向对照。以”Tripel 真实均值 – Pils/Lager 真实均值” 为参照方向，与 11 条迁移谱的实际位移逐列比较：12 个关键调节化合物的符号全部一致（kcalperc +7.60 对 +7.74、乙醇 +7.33 对 +7.24、乙酸乙酯 +5.18 对 +5.29 等），全 231 列符号一致率 92.2%，但余弦相似度仅 0.34，方向大体正确、幅度与部分列不一致。这个量化的” 方向对、幅度不齐” 正是需要缺陷投影兜底的原因。若只靠隐空间平移，少数列会被推过目标风格的真实水平，其中就包含缺陷化合物。

9 模型检验与灵敏度分析

9.1 验证方案与防泄漏

三问都建立在独立验证与全程防泄漏之上。问题一按风格分层 5 折，分箱分位点与标准化参数只在训练折估计；问题二以 500 次分层 bootstrap 给出单方法稳健性、三法 Jaccard 给出方法间一致性，化学合理性再以交叉相关与酿造机理佐证；问题三以分布距离与降维簇重叠评估生成，以缺陷合规率评估迁移。本题没有隐藏测试集，所有数字都标明是交叉验证或内部估计。

六类泄漏已逐一封堵：分箱与标准化参数折内估计，主办方的参考重要性只作旁证，样本主键与风格标签不进特征矩阵，不对风格做目标编码；附件 2 与 1.csv 只能按 `beer` 名称与行序对齐，按 `beer_id` 会只剩 37/250 行，本文对此显式断言。

9.2 消融汇总、对照实验与鲁棒性

第 6 至 8 章的设计均配有对照：融合使模块覆盖 2.30→2.92，分维选型使 QWK 0.3663→0.3830（+4.6%）且增益集中在 5 个退化维；缺失处理（+0.3%）与值域截断（+1.6%）属正确性修正。

等距分箱 QWK 0.4013 虽略高，但产生 8 个空等级、频次变异系数 1.155，故不采用；建图阈值 0.4–0.6 中 0.5 结构最清晰，隐维 8–16 中 16 兼顾后验坍塌与小样本过拟合。特征增广两路（43 个阈值列、8 个模块 PC1，见附录表 A.6、A.7）使 QWK 降至 0.3760 与 0.3747，故保留原 231 列。

三项离线对照共享同一前提：都不改变主结果，主模型 0.3830 与提交谱保持原样，只用来回答“共享表示值不值”和“隐空间能否修好”。

分组共享多输出。主模型对 50 维各自独立训练。若同组感官确共享化学驱动，把同组其他维的折内 OOF 预测当作附加特征应能降低方差，本文按香气（15）/ 风味（15）/ 口感缺陷（20）三组试了这一方案，退化维仍用类加权有序回归。结果 QWK 为 **0.3759**，低于主模型的 0.3830：配对 bootstrap 2000 次给出 $\Delta\text{QWK} = +0.0070$、95% 区间 $[0.0001, 0.0139]$，香气 0.322→0.305、风味 0.400→0.394，仅口感缺陷组持平（0.416→0.415）。原因是真正强的相关是同名维的跨通道配对（0.836、0.828），按通道分组恰好把这对切开，组画像特征只带来弱信息，却额外引入 14–19 个含噪特征，在 250 样本上放大过拟合，故保

留逐维建模。

判别辅助损失。问题三的隐空间在 16 维下不存在超出噪声的风格结构（置换检验 $p = 0.92/0.99/1.00$）。在编码器输出上加线性风格分类头，损失改为 $L = L_{\text{recon}} + \beta_{KL} \cdot \mathrm{KL} + \lambda \cdot \mathrm{CE}(s \mid z)$，只扫 $\lambda \in \{0, 0.02, 0.1, 0.3, 0.5\}$。$\lambda = 0$ 时分类准确率仅 3.2%（随机基线 4.5%），$\lambda = 0.02$ 即 $p = 0.000$、分类 54%，$\lambda \geq 0.1$ 接近 100%；代价同步上升，KS 由 0.373 依次升至 0.392 / 0.411 / 0.445 / 0.468，重构 MSE 由 0.266 升至 0.284 / 0.340 / 0.397 / 0.429。判别头不并入主模型：任务目标是生成像真实的谱，而非让隐空间可分。若更看重风格可控性，$\lambda = 0.02$ 是折中档，风格已显著可分而 KS 只上升 0.019，该结论在 seed 7 上复现。

按风格留出。表 6 是静态对照，更能反映泛化的是留出口径：每折只用训练折拟合生成器，每风格每折生成 30 条，折数按样本量自适应取 5 折或 2 折。三种生成器的排序与静态口径一致，重采样最低、高斯居中、CVAE 最高；连重采样也落在 0.404，因为留出折只有 5–6 条，KS 绝对值主要由折间抽样噪声决定，只能比相对顺序，不能与表 6 直接比。结构保真一侧更稳定：高斯采样的 W1 最差，与它假设各化合物独立一致；CVAE 的画像 Spearman 最高，优势主要体现在样本量最大的 Tripel 上。

表 10　按风格留出的生成对照（每风格每折 30 条，均值 ± 标准差）

生成器	逐列 KS	W1 中位	能量距离	画像 Spearman
风格内重采样	0.404±0.029	**0.406**	**0.551**	0.460
风格内高斯	0.447±0.019	0.586	0.569	0.441
CVAE（本文）	0.493±0.025	0.435	0.619	**0.506**

固定种子 42 下问题一完全可复现；问题二 47/50 维的 Top-1 频率恰为 1.000；问题三在 5 个种子下均保持风格可分，50 维全部获得预测。四项对照都在同一折、同一分箱、同一指标下完成，其中两项为负结果，已如实列出。

10　模型评价与推广

10.1　优点与创新

与已有工作的关系。Schreurs 等[12] 比较了线性回归、Lasso、PLS、AdaBoost、Extra Trees、梯度提升、随机森林、XGBoost、SVR 与神经网络十种模型，按风格分层随机切分训练集与测试集，结论是梯度提升整体最好、单维 R^2 最高 0.75，且 Flavour 明显好于 Aroma。本文在方法选择与评估口径上与该工作同向：同样按风格分层做折外评估、同样以梯度提升族为主干，风味组 QWK 0.400 高于香气组 0.322。两处差异值得说明：其一，他们发现预测品评小组评分远比预测 RateBeer 网友评分困难，同为总体喜好，网友评分 R^2 0.67 而小组仅 0.09，原因是小组人数少、打分噪声大；本文标签同样来自单一小组，弱信号维 QWK 仅 0.14 一档与此吻合，绝对精度也不宜与网友评分口径直接比较。其二，他们在输入中加入风格标签后效果几乎不变（R^2 0.66 对 0.67），本文则把风格单列为条件变量，用 CVAE 做条件生成与隐空间迁移，把风格从预测特征变成可控的生成维度。归因上两文思路相通，均以树模型特征重要性配合 SHAP；该工作的长处是

做了加标验证，在真实啤酒中补加候选化合物后口感确实改善，本文受赛题数据限制只做到统计归因与机理核对，来源一致率 12% 也提示部分归因仍属统计代理，后续若具备受控加标条件，按 Top-3 名单做干预验证是最直接的推广方向。

第一，以共享的化学到感官预测底座贯通三问：同一套经交叉验证的模型既是问题二的 SHAP 归因对象，又是问题三生成谱的感官打分器，预测、归因与生成三者联动。

第二，归因限定为 211 个单一化合物，并以模块代表加权与同社区去冗余；三路融合把单维 Top-3 命中的模块数由 2.30 提到 2.92（满分 3），跨方法 Jaccard 0.200 为随机基线 0.0086 的 23.3 倍，并以配对 bootstrap 与 A/B/C 分级给出可信度。

第三，把缺陷不恶化形式化为 $\min(\tilde{x}_{after}, x_{before}, m_t)$ 逐样本投影，配无约束对照（72.7% 本会升高）；另用真实浓度阈值做绝对口径审计，区分“相对不恶化”与“绝对达标”。

第四，识别出分位分箱在标签分布高度集中时失效的隐性前提，据此只在退化维改用类加权有序回归，折外 QWK 由 0.3663 升至 0.3830（+4.6%）；并对“更强的表示”与“更可分的隐空间”两条路线做了严格对照、如实报告负结果，使方法选择有可复核依据。

10.2 不足与改进

其一，0-6 分级由连续值单调映射重建而非原始品评卡复现，分级绝对值带有映射口径的印记；250 样本下增维（阈值列、模块 PC1、分组共享）亦未兑现精度。

其二，生成谱需按观测区间截断、迁移依赖缺陷投影兜底，判别头以 KS 上升换取隐空间可分；来源一致率仅 12%，高删失列未建显式删失似然。

10.3 推广

本文框架可推广到其他成分谱与感官建模场景：缺失感知有序预测适用于品评缺测数据，共表达图加多证据归因适用于高共线性组学或光谱筛选，带硬约束的条件生成可用于规避有害成分的配方设计。

参考文献

[1] Zhang H. Predict and improve beer flavor with machine learning[J]. ResearchHub, 2026. DOI: 10.55277/researchhub.cagmlmpm.

[2] Li S, Li T. Machine learning discrimination and prediction of different quality grades of sauce-flavor Baijiu based on biomarker and key flavor compounds screening[J]. SSRN Electronic Journal, 2024. DOI: 10.2139/ssrn.4939729.

[3] Zhang C, Liu W. Effects of lactic acid bacteria fermentation on bioactive compounds and flavor profiles of Siraitia grosvenorii and prediction of flavor profiles by machine learning[J]. SSRN Electronic Journal, 2024. DOI: 10.2139/ssrn.6116637.

[4] Chen T, Guestrin C. XGBoost: A scalable tree boosting system[C]. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2016: 785-794. DOI: 10.1145/2939672.2939785.

[5] Ke G, Meng Q, Finley T, et al. LightGBM: A highly efficient gradient boosting decision tree[C]. Advances in Neural Information Processing Systems (NeurIPS), 2017, 30: 3146-3154.

[6] Yıldız A Y, Kalayci A. Gradient boosting decision trees on medical diagnosis over tabular data[C]. 2025 IEEE International Conference on AI and Data Analytics (ICAD), 2025. DOI: 10.1109/icad65464.2025.11114069.

[7] Polozoff S. Top Beer Information (Kaggle dataset)[DB/OL]. Kaggle, 2024. https://www.kaggle.com/datasets/stephenpolozoff/top-beer-information.

[8] Hoerl A E, Kennard R W. Ridge regression: Biased estimation for nonorthogonal problems[J]. Technometrics, 1970, 12(1): 55-67. DOI: 10.1080/00401706.1970.10488634.

[9] Wold S, Sjöström M, Eriksson L. PLS-regression: a basic tool of chemometrics[J]. Chemometrics and Intelligent Laboratory Systems, 2001, 58(2): 109-130. DOI: 10.1016/S0169-7439(01)00155-1.

[10] Breiman L. Random forests[J]. Machine Learning, 2001, 45(1): 5-32. DOI: 10.1023/A:1010933404324.

[11] Troyanskaya O, Cantor M, Sherlock G, et al. Missing value estimation methods for DNA microarrays[J]. Bioinformatics, 2001, 17(6): 520-525. DOI: 10.1093/bioinformatics/17.6.520.

[12] Schreurs M, Piampongsant S, Roncoroni M, et al. Predicting and improving complex beer flavor through machine learning[J]. Nature Communications, 2024, 15: 2596. DOI: 10.1038/s41467-024-46346-0.

[13] Blondel V D, Guillaume J L, Lambiotte R, et al. Fast unfolding of communities in large networks[J]. Journal of Statistical Mechanics: Theory and Experiment, 2008, 2008(10): P10008. DOI: 10.1088/1742-5468/2008/10/p10008.

[14] Melo D, Pallares L F. Reassessing the modularity of gene co-expression networks using the stochastic block model[J]. PLoS Computational Biology, 2024, 20(7): e1012300. DOI: 10.1371/journal.pcbi.1012300.

[15] Clemente J B, Besas G. Predicting the biological classification of cell-cycle regulated genes of Saccharomyces cerevisiae using community detection algorithms on gene co-expression networks[C]. 2022.

[16] Gauraha N. Stability feature selection using cluster representative LASSO[C]. Proceedings of the 5th International Conference on Pattern Recognition Applications and Methods,

2016: 381-386. DOI: 10.5220/0005827003810386.
[17] Efron B, Tibshirani R J. An Introduction to the Bootstrap[M]. New York: Chapman and Hall, 1993.
[18] Apley D W, Zhu J. Visualizing the effects of predictor variables in black box supervised learning models[J]. Journal of the Royal Statistical Society: Series B, 2020, 82(4): 1059-1086. DOI: 10.1111/rssb.12377.
[19] Chaibi I, Njah H. Conditional variational autoencoder with Bayesian layers for robust tabular data generation from small datasets[J]. SSRN Electronic Journal, 2025. DOI: 10.2139/ssrn.5991727.
[20] Flexa C, Gomes W. Polygonal coordinate system: Visualizing high-dimensional data using geometric DR, and a deterministic version of t-SNE[J]. Expert Systems with Applications, 2021, 175: 114741. DOI: 10.1016/j.eswa.2021.114741.

附录 A　数据附件概况与口径核对

本附录汇总主办方 8 个附件的实测概况与用途（表 A.1），以及题面表述与附件实测的差异核对（表 A.2），行列数均以本文程序实际读取为准。

表 A.1　八个附件的实测概况与用途

附件	内容	实测规模（行 × 列 / sheet）	本文用途
1.csv	化学组成谱（含主键与风格）	250 × 234（3 元列 + 231 化学特征）	Q1 特征矩阵、Q2 建图、Q3 生成
2.csv	化合物相关系数矩阵（Spearman）	231 × 232（首列为化合物名）	Q2 共表达边权（口径见 7.1）
3.xlsx	12 张空白评分卡 + 1 个汇总表	13 sheet（beer_1…beer_12 各 100×33；summary 全 0）	Q1 的 0–6 分填分模板
4.csv	品评小组标准化分	250 × 53（3 元列 + 50 感官维）	Q1 训练标签
5.csv	感官维度之间相关	50 × 51（首列为维名）	感官分组与冗余参考
6.csv	化学-感官交叉相关	44 化学行 × 50 感官列（44×51）	Q2 归因的线性证据
7.csv	论坛/评论文本属性	250 × 189（其中 3 列全缺失）	文本数据，三问均不使用
8.xlsx	综合参考表	7 个 sheet（见下注）	仅作旁证：阈值、校准浓度、来源、MDI

注：8.xlsx 七个 sheet 分别为 Sensory thresholds（261×11，感官阈值与化合物来源）、Sensory names（101×8，感官维类别）、GBM importance MDI（231×2，主办方模型的不纯度重要性）、GBM SHAP Values（500×236）、Calibrated chemical dataset（250×73，含 3 元列与 70 列校准绝对浓度）、Beer Prices（250×11）、Sheet2（空表）。其中 MDI 与 SHAP 仅作问题二的旁证，不进入问题一特征，以防用答案预测答案的泄漏。数据来源：1.csv、2.csv、3.xlsx、4.csv、5.csv、6.csv、7.csv、8.xlsx 实测

表 A.2　题面表述与附件实测的差异核对

题面表述	附件实测	处理方式
226 种啤酒	1.csv 实为 250 个样本（4.csv 同为 250 行）	以实测 $N = 250$ 为准
附件 2 为 Pearson 相关	题面称 Pearson，实测为 Spearman；从 1.csv 重算的 Spearman 与附件 2 逐元素一致（最大差 7.8×10^{-16}），而同口径 Pearson 的最大差 1.12、平均绝对差 0.088	以附件 2 数值作 Spearman 边权
3.xlsx 为评分卡	12 张空白评分卡（100×33 模板）+ 1 个全 0 的 summary	原始 0–6 分数不可用，仅作填分模板，训练标签改用 4.csv 中心化连续值
评分卡含 Acetaldehyde	Aroma 与 Flavour 两栏各有 Acetaldehyde（青苹果），但 4.csv 的 50 列中无对应维度，8.xlsx 的 Trained panel 50 行也与 4.csv 一一对应	该两项不进入建模；乙醛在化学侧以 `acetaldehyde` 列参与问题一与问题二，仅缺“青苹果”这一感官靶，如实登记为数据缺口
化学-感官交叉相关	6.csv 实为 44 个化学行 × 50 个感官列	按实测维度使用，不臆测其行列数
7.csv 论坛文本	250×189，其中 palate_acetaldehyde、palate_acetate、palate_dentist 三列完全缺失	文本数据不进入三问建模，全缺失列仅登记
8.xlsx 参考表	实为 7 个 sheet（含校准浓度、价格等）	逐 sheet 登记用途，仅作旁证、不进训练

A.1　特征与归因的完整明细

本节给出正文中只报摘要数字、而明细较长的四张支撑表：8 个共表达模块的第一主成分（表 A.7）、55 个 Louvain 社区的成员构成（表 A.8）、全部 150 个 Top-3 候选的证据分级（表 A.9），以及 43 个阈值超限列的清单（表 A.6）。所有数字由 `code/analysis/` 下的脚本从 `figures/derived/` 的结果文件直接生成，未手工填写。

表 A.3　22 种风格的样本量

风格	款数	风格	款数
Blond	31	Saison	10
Tripel	28	Kriek	10
Strong ale	18	Christmas	9
Hoppy	17	Low/No alcohol	8
Stout/Porter	13	Fruitbeer	8
Brown	12	West Flanders ale	7
Amber	12	Brett/cofermented	6
Wheat	12	Flanders old brown	5
Lambic	11	Scotch	5
Pils/Lager	11	Brut	4
Dubbel	10	Faro	3

注：左右两栏均按款数降序排列。数据来源：1.csv

表 A.4　50 个感官维度的折外预测性能（按 QWK 降序）

感官维度	QWK	R^2	Spearman	±1 准确率
酒精	0.819	0.713	0.829	0.816
苦味	0.776	0.634	0.782	0.792
酒体	0.682	0.525	0.728	0.752
味 • 酒花	0.670	0.505	0.698	0.716
余味	0.651	0.468	0.654	0.660
味 • 麦芽	0.616	0.456	0.642	0.644
乳酸	0.611	0.675	0.494	0.672
味 • 贵族花	0.602	0.391	0.636	0.684
香 • 麦芽	0.601	0.447	0.650	0.668
甜味	0.600	0.390	0.602	0.668
香 • 酒花	0.573	0.328	0.583	0.672
味 • 酯	0.544	0.334	0.563	0.616
碳酸	0.537	0.314	0.561	0.596
香 • 贵族花	0.524	0.292	0.561	0.632
香 • 焦糖	0.519	0.340	0.596	0.628
味 • 面包	0.510	0.269	0.571	0.588
味 • 指甲油	0.497	0.254	0.513	0.572
4VG	0.468	0.200	0.502	0.616
味 • 焦糖	0.459	0.246	0.535	0.616
酸度	0.440	0.702	0.488	0.608
香 • 酯	0.433	0.232	0.478	0.564
味 • 烟熏	0.419	0.390	0.470	0.604

50 个感官维度的折外预测性能（续）

感官维度	QWK	R^2	Spearman	±1 准确率
乙酸	0.384	0.588	0.392	0.588
味 • 木质	0.361	0.149	0.419	0.528
橙香	0.329	0.145	0.276	0.544
味 • 香蕉酯	0.321	0.109	0.381	0.540
DMS	0.316	0.138	0.343	0.552
香 • 柑橘	0.311	0.079	0.362	0.524
丁香	0.305	0.058	0.255	0.576
香 • 指甲油	0.299	0.095	0.353	0.528
香 • 香蕉酯	0.291	0.058	0.329	0.528
香 • 面包	0.275	0.052	0.349	0.500
双乙酰	0.259	0.075	0.291	0.508
味 • 热带	0.253	0.081	0.293	0.504
金属味	0.246	0.088	0.332	0.508
味 • 果香酯	0.239	0.108	0.292	0.516
总体	0.230	0.057	0.232	0.492
芫荽	0.228	0.115	0.157	0.512
香 • 热带	0.200	0.017	0.197	0.532
香 • 木质	0.196	0.050	0.233	0.464
味 • 柑橘	0.188	0.064	0.255	0.480
味 • 谷物	0.178	-0.016	0.205	0.464
香 • 谷物	0.172	-0.032	0.171	0.448
反 2 壬烯醛	0.153	0.034	0.169	0.492
香 • 烟熏	0.147	0.267	0.196	0.480
香 • 花香酯	0.147	-0.059	0.138	0.488
陈酒花	0.147	0.066	0.227	0.500
畜栅味	0.144	0.095	0.260	0.508
香 • 果香酯	0.141	0.025	0.138	0.488
味 • 花香酯	0.135	-0.013	0.160	0.468

注：QWK 与 ±1 准确率在 0–6 等级上计算，R^2 与 Spearman 对 4.csv 中心化连续值计算；每格 $n = 250$，按风格分层 5 折。

表 A.5　代表维度 Top-3 候选的稳定性与证据增量

维度	名次	化合物	入选频率	条件增量	模块增量	分级
酒精	1	ethyl_octanoate	1.000	0.0345	0.0107	A
酒精	2	acetaldehyde	1.000	0.0075	0.0209	A
酒精	3	MeSH	1.000	0.0004	0.0003	B
苦味	1	ethyl_octanoate	1.000	0.0764	0.0218	A
苦味	2	MeSH	1.000	0.0003	0.0000	B

代表维度 Top-3 候选的稳定性与证据增量（续）

维度	名次	化合物	入选频率	条件增量	模块增量	分级
苦味	3	DMS	1.000	0.0029	—	A
酒体	1	isobutanol	1.000	0.0103	0.0134	A
酒体	2	ethyl_octanoate	1.000	0.0049	0.0039	A
酒体	3	MeSH	1.000	0.0057	0.0000	A
味 · 酒花	1	ethyl_octanoate	1.000	0.0539	0.0069	A
味 · 酒花	2	DMS	1.000	0.0076	—	B
味 · 酒花	3	ethyl_hexanoate	0.870	0.0019	0.0081	B
余味	1	ethyl_octanoate	1.000	0.0411	0.0164	A
余味	2	ethyl_isovalerate	1.000	0.0242	0.0205	A
余味	3	acetaldehyde	1.000	0.0084	0.0180	A
味 · 麦芽	1	acetaldehyde	1.000	0.0132	0.0025	A
味 · 麦芽	2	MeSH	1.000	0.0001	0.0003	B
味 · 麦芽	3	ethyl_decanoate	1.000	0.0007	0.0046	B
味 · 贵族花	1	ethyl_octanoate	1.000	0.0717	0.0179	A
味 · 贵族花	2	ethyl_hexanoate	1.000	0.0025	0.0097	A
味 · 贵族花	3	DMS	1.000	0.0040	—	A
香 · 麦芽	1	acetaldehyde	1.000	0.0056	0.0022	B
香 · 麦芽	2	octyl_acetate	1.000	0.0060	0.0460	A
香 · 麦芽	3	MeSH	1.000	0.0017	0.0001	B
甜味	1	ethyl_decanoate	1.000	0.0207	0.0276	A
甜味	2	octyl_acetate	1.000	0.0002	0.0169	B
甜味	3	alpha.humulene	1.000	0.0026	0.0083	A
香 · 酒花	1	ethyl_octanoate	1.000	0.0463	0.0118	A
香 · 酒花	2	DMS	1.000	0.0267	—	A
香 · 酒花	3	linalool	1.000	0.0029	0.0103	A
味 · 酯	1	ethyl_acetate	1.000	0.0367	0.0625	A
味 · 酯	2	phenethyl_alcohol	0.998	0.0103	—	A
味 · 酯	3	acetaldehyde	0.962	0.0136	0.0945	A
碳酸	1	ethyl_octanoate	1.000	0.0750	0.0161	A
碳酸	2	ethyl_hexanoate	1.000	0.0143	0.0245	A
碳酸	3	DMS	1.000	0.0027	—	A

注：入选频率为 500 次按风格分层 bootstrap 的 Top-3 入选频率；条件增量为单独打乱该化合物后的均方变化，模块增量为打乱其所在 Louvain 社区全部成员后的变化，均除以标签方差归一化；“—”表示该化合物所在社区只有它自己，模块增量无法定义。分级四条件见正文 7.4 节。

表 A.6　43 个阈值超限列的清单与超阈比例

字段（1.csv 列名）	来源类别	阈值（1.csv 尺度）	超阈比例
protein.g.L.	—	0.010	99.6%
linalool	—	0.027	98.4%
ethanol..v.v.	—	0.245	97.6%
citronellol	—	0.025	92.4%
H2S	—	0.544	92.0%
ammonia.mg.L.	—	0.415	87.6%
bitterness	—	0.699	86.4%
isopentyl_acetate	—	-0.219	84.4%
geraniol	—	0.032	76.0%
DMS	—	1.237	67.2%
ethyl_acetate	—	1.380	65.6%

43 个阈值超限列的清单与超阈比例（续）

字段	来源类别	阈值	超阈比例
acetic_acid.g.L.	—	-0.853	61.6%
isoamyl_alcohol	—	1.602	51.6%
ethyl_hexanoate	—	-0.638	51.6%
iron	—	-1.000	47.6%
X2.3.butanedione	—	0.299	46.5%
ethyl_octanoate	—	-0.155	26.4%
DES	—	0.079	18.4%
GFS	—	0.462	18.0%
lactic_acid.mg.L.	—	2.620	17.2%
X1.alpha.terpineol	—	1.500	10.4%
ethyl_2.methyl_butyrate	—	-1.569	6.8%
X4VG	—	-0.685	6.4%
E.caryophyllene	—	0.280	5.6%
ethyl.butyrate	—	0.450	3.2%
glycerol	—	0.647	2.8%
phenethyl_alcohol	—	1.544	2.4%
alpha.humulene	—	0.625	2.0%
ethyl_isovalerate	—	-1.000	0.8%
isobutanol	—	1.903	0.0%
acetaldehyde	—	1.699	0.0%
furfural	—	60.000	0.0%
ethyl_decanoate	—	0.015	0.0%
ethyl.isobutyrate	—	2.600	0.0%
ethyl.nicotinate	—	6.000	0.0%
ethyl_propionate	—	1.000	0.0%
isobutyl_acetate	—	0.000	0.0%
octyl_acetate	—	-0.301	0.0%
phenethyl_acetate	—	0.246	0.0%
methylpyrazine	—	1.000	0.0%
CS2	—	1.699	0.0%
SO2.mg.L.	—	1.186	0.0%
Z.nerolidol	—	25.000	0.0%

注：阈值已按 5.3 节核实的尺度换算到 1.csv 取值空间（常用对数列取 $\log_{10}$）；超阈比例为该列取值不低于阈值的样本占比，与 9.3 节特征增广实验同一取数口径。数据源 `figures/derived/q1_threshold_cols.json`。

表 A.7　8 个共表达模块的第一主成分（成员 ≥ 5）

模块	成员数	代表成员（按度排序前 3）	PC1 解释率
15	28	ethyl.phenylacetate、prenyl.isobutyrate、ethyl.5.methylhexanoate	0.333 ± 0.014
19	28	nerol.oxide、alpha.calacorene、caryophylla.4.12..8.13..dien.5.alpha.ol	0.303 ± 0.016
49	23	X3.methyl.2.hexanol、X3.furanmethanol、n.nonanol	0.285 ± 0.024
27	20	X2.3.butanedione、X2.methyl.1.butanol、X1.propanol	0.716 ± 0.160
35	19	ethyl..E..linalool、isoborneol、terpinen.4.ol	0.472 ± 0.025
5	18	trans.dihydro.alpha.terpinyl.acetate、isopentyl.hexanoate、X1.2.dihydro.8.hydroxy..2E..linalool	0.537 ± 0.011
0	12	ethyl_acetate、ethyl_hexanoate、isopentyl_acetate	0.678 ± 0.011
20	11	X2Z.6E.farnesol、n.decanol、E.nerolidol	0.343 ± 0.018

注：PC1 解释率在每个训练折内单独拟合 PCA、取五折均值 ± 标准差，与正文灵敏度实验同一防泄漏口径；模块编号为共表达网络的社区 id。

表 A.8　55 个 Louvain 社区的成员构成（$\rho = 0.5$，211 节点）

模块	成员数	成员（按度降序）
M01	28	ethyl.phenylacetate、prenyl.isobutyrate、ethyl.5.methylhexanoate、ethyl.benzoate、neryl.formate、isomaltol、nonan.2.ol、ethyl.furoate、perillyl.acetate、X2.acetylfuran、germacrene.D、X4.ethyl.guaiacol、X.E..alpha.ionone、ethyl_isovalerate、X5.methylfurfural、X2.acetylpyrrole、isoamyl.lactate、X4.ethyl.phenol、ethyl_2.methyl_butyrate、methylpyrazine、X2.6.dimethyl.pyrazine、ethyl.hex..3E..enoate、ethyl.hydrocinnamate、furfural、ethyl.tiglate、ethyl..E..cinnamate、octyl_acetate、X4.methoxysalicylaldehyde
M02	28	nerol.oxide、alpha.calacorene、caryophylla.4.12..8.13..dien.5.alpha.ol、alpha.muurolol、alloaromadendrene.epoxide、X1.10.di.epi.cubenol、X1.octen.3.ol、ethyl.hex..2E..enoate、X2.undecanol、neryl.propanoate、humulene.epoxide.II、methyl.geranate、X.E..beta.ionone、tau.muurolol、caryophyllene.oxide、caryophyllene.alcohol、selin.11.en.4.alpha.ol、y.methyl.1.octanol、ambroxide、cis.dihydro.beta.terpineol、X.E..ortho.methoxy.cinnamaldehyde、isopentyl.butanoate、terpinen.4.ol.acetate、neryl.isobutanoate、neryl.isovalerate、geosmin、spathulenol、benzyl.benzoate
M03	23	X3.methyl.2.hexanol、X3.furanmethanol、n.nonanol、ortho.cresol、X4.methyl.1.pentanol、n.octanol、n.heptanol、n.dodecanol、alpha.terpinyl.isobutanoate、n.tetradecanol、manool、X2.ethyl.1.hexanol、x.methyl.1.octanol、X9.epi..E..caryophyllene、isopropyl.tetradecanoate、isopropyl.hexadecanoate、ethyl.isobutyrate、dimethoxy..E..citral、methyl.hexadecanoate、butyl.acetate、X2.furanmethanol、car.3.en.2.one、manool.oxide
M04	20	X2.3.butanedione、X2.methyl.1.butanol、X1.propanol、n.pentanol、isopentyl.formate、X3.methyl.2.butenal、ethyl.pentanoate、diethyl.succinate、X.E.E..2.4.decadienal、propyl.acetate、gamma.nonalactone、benzaldehyde、ethyl.nicotinate、X14.hydroxy.9.epi..E..caryophyllene、X3.methylbutanal、amyl.acetate、benzyl.alcohol、X.E..beta.damascenone、alpha.humulene、gamma.eudesmol
M05	19	ethyl..E..linalool、isoborneol、terpinen.4.ol、beta.phellandrene、terpinolene、linalool、X2.methyl.benzofuran、X1.alpha.terpineol、E.ocimenone、alpha.phellandrene、limonene、cumin.aldehyde、X.E..beta.ocimene、camphor、citronellol、phenylacetaldehyde、nerol、hydroxy.methyl.furfural、geraniol
M06	18	trans.dihydro.alpha.terpinyl.acetate、isopentyl.hexanoate、X1.2.dihydro.8.hydroxy..2E..linalool、pentyl.octanoate、isobutyl.hexanoate、X.Z..beta.farnesene、X2.methylbutyl.octanoate、ethyl.tetradecanoate、ethyl.pentadecanoate、X2.butyloctanoate、ethyl..9..decenoate、X2.phenyl.ethyl.butyrate、ethyl.hexadecanoate、ethyl_decanoate、X.E..2.nonenal、ethyl_octanoate、Z.Z.geranyl.linalool、ethyl.octadecanoate

55 个 Louvain 社区的成员构成（续）

模块	成员数	成员
M07	12	ethyl_acetate、ethyl_hexanoate、isopentyl_acetate、isobutyl_acetate、isoamyl_alcohol、phenethyl_acetate、E.cinnamaldehyde、acetaldehyde、isobutanol、n.hexanol、ethyl.butyrate、heptyl.acetate
M08	11	X2Z.6E.farnesol、n.decanol、E.nerolidol、X2.3.dihydro.farnesol、dihydroisocaryophyllene.epoxide、X2E.6Z.farnesal、X2.pentyl.furan、beta.cyclohomocitral、X.E..beta.farnesene、X2Z.6E.farnesal、X3.methylthio.propanol
M09	3	MeSH、DES、H2S
M10	3	butylated.hydroxytoluene、E.methyl.isoeugenol、X.Z..dihydro.apofarnesal
M11	2	neo.allo.ocimene、X13.epi.manool.oxide
M12	1	CS2
M13	1	DMS
M14	1	ethyl_propionate
M15	1	phenethyl_alcohol
M16	1	X4VG
M17	1	propylene.glycol
M18	1	X2.methyltetrahydrofuran.3.one
M19	1	ethyl.lactate
M20	1	X3Z.hexenol
M21	1	styrene
M22	1	X6.methyl.5.hepten.2.one
M23	1	dehydroxy.cis.linalool.oxide
M24	1	hexyl.acetate
M25	1	eucalyptol
M26	1	cis.linalool.oxide
M27	1	meta.cymenene
M28	1	n.nonanal
M29	1	trans.dihydro.beta.terpineol
M30	1	cis.beta.terpineol
M31	1	vinyl.caprylate
M32	1	X2.undecanone
M33	1	delta.terpinyl.acetate
M34	1	eugenol
M35	1	methyl.para.anisate
M36	1	vanillin
M37	1	dodecanal
M38	1	X4.8.alpha.epoxy.caryophyllane
M39	1	E.caryophyllene
M40	1	beta.humulene
M41	1	linalool.isovalerate
M42	1	valencene
M43	1	X.E..dihydro.apofarnesal
M44	1	Z.nerolidol
M45	1	isopropyl.laurate
M46	1	tau.cadinol
M47	1	alpha.eudesmol
M48	1	foeniculin
M49	1	cadalene
M50	1	caryophyllene.acetate
M51	1	X14.hydroxy.alpha.humulene
M52	1	X2Z.6Z.farnesol

55 个 Louvain 社区的成员构成（续）

模块	成员数	成员
M53	1	X2E.6E.methyl.farnesoate
M54	1	X2.ethylhexylsalicylate
M55	1	X2.ethyl.3.methylpyrazine

注：M01–M55 按成员数降序重新编号，其中 M01–M08 即表 A.4 的 8 个 PC1 模块。另有 44 个度为 0 的孤立节点未归入任何社区：CS2、DMS、ethyl_propionate、phenethyl_alcohol、X4VG、propylene.glycol、X2.methyltetrahydrofuran.3.one、ethyl.lactate、X3Z.hexenol、styrene、X6.methyl.5.hepten.2.one、dehydroxy.cis.linalool.oxide、hexyl.acetate、eucalyptol、cis.linalool.oxide、meta.cymenene、n.nonanal、trans.dihydro.beta.terpineol、cis.beta.terpineol、vinyl.caprylate、X2.undecanone、delta.terpinyl.acetate、eugenol、methyl.para.anisate、vanillin、dodecanal、X4.8.alpha.epoxy.caryophyllane、E.caryophyllene、beta.humulene、linalool.isovalerate、valencene、X.E..dihydro.apofarnesal、Z.nerolidol、isopropyl.laurate、tau.cadinol、alpha.eudesmol、foeniculin、cadalene、caryophyllene.acetate、X14.hydroxy.alpha.humulene、X2Z.6Z.farnesol、X2E.6E.methyl.farnesoate、X2.ethylhexylsalicylate、X2.ethyl.3.methylpyrazine。

表 A.9　全部 50 维 × 3 个候选的证据分级（101 A / 42 B / 7 C）

感官维	名次	化合物	频率	条件增量	模块增量	正折数	级
A_malt_all	1	acetaldehyde	1.000	0.0056	0.0022	5	B
A_malt_all	2	octyl_acetate	1.000	0.0060	0.0460	5	A
A_malt_all	3	MeSH	1.000	0.0017	0.0001	5	B
A_malt_grain	1	Z.nerolidol	1.000	0.0138	—	5	B
A_malt_grain	2	terpinen.4.ol	1.000	0.0206	0.0316	5	B
A_malt_grain	3	phenethyl_alcohol	0.680	0.0046	—	5	C
A_malt_bread	1	acetaldehyde	1.000	0.0090	0.0045	5	A
A_malt_bread	2	octyl_acetate	1.000	0.0082	0.0621	5	A
A_malt_bread	3	ethyl.hexadecanoate	0.488	0.0158	0.0275	5	B
A_malt_cara	1	octyl_acetate	1.000	0.0063	0.0525	5	A
A_malt_cara	2	acetaldehyde	1.000	0.0002	0.0054	5	B
A_malt_cara	3	MeSH	0.966	0.0004	0.0004	5	B
A_malt_burn	1	isobutanol	1.000	0.0005	0.0020	5	B
A_malt_burn	2	MeSH	0.900	0.0033	0.0002	5	A
A_malt_burn	3	ethyl_propionate	0.920	0.0003	—	5	B
A_hops_all	1	ethyl_octanoate	1.000	0.0463	0.0118	5	A
A_hops_all	2	DMS	1.000	0.0267	—	5	A
A_hops_all	3	linalool	1.000	0.0029	0.0103	5	A
A_hops_citrus	1	citronellol	1.000	0.0068	0.0192	5	A
A_hops_citrus	2	ethyl_decanoate	1.000	0.0011	0.0313	5	B
A_hops_citrus	3	E.caryophyllene	0.972	0.0055	—	5	A
A_hops_tropical	1	DMS	1.000	0.0217	—	5	A
A_hops_tropical	2	isopentyl.butanoate	1.000	0.1005	0.0826	5	A
A_hops_tropical	3	geraniol	0.944	0.0011	0.0160	5	B
A_hops_noble	1	ethyl_octanoate	1.000	0.0856	0.0254	5	A
A_hops_noble	2	DMS	1.000	0.0043	—	5	A
A_hops_noble	3	ethyl_hexanoate	1.000	0.0022	0.0098	5	B
A_hops_woody	1	alloaromadendrene.epoxide	1.000	0.0582	0.1027	5	A
A_hops_woody	2	ethyl_2.methyl_butyrate	1.000	0.0078	0.0251	5	A
A_hops_woody	3	isobutanol	0.970	0.0156	0.0032	5	A
A_esters_all	1	n.hexanol	1.000	0.0784	0.0690	5	A
A_esters_all	2	acetaldehyde	0.982	0.0105	0.1429	5	A
A_esters_all	3	phenethyl_alcohol	0.968	0.0101	—	5	A
A_esters_ethac	1	ethyl_acetate	1.000	0.0235	0.0215	5	A
A_esters_ethac	2	phenethyl_alcohol	1.000	0.0114	—	5	A

全部 50 维 × 3 个候选的证据分级（续）

感官维	名次	化合物	频率	条件增量	模块增量	正折数	级
A_esters_ethac	3	X2.methyl.1.butanol	0.990	0.0110	0.0321	5	A
A_esters_isoaa	1	isopentyl_acetate	1.000	0.0426	0.0791	5	A
A_esters_isoaa	2	n.hexanol	1.000	0.0640	0.0579	5	A
A_esters_isoaa	3	benzaldehyde	1.000	0.0319	0.0157	5	A
A_esters_flower	1	ethyl.lactate	0.996	0.0357	—	5	B
A_esters_flower	2	geraniol	0.998	0.0026	0.0559	5	C
A_esters_flower	3	isobutyl_acetate	0.984	0.0021	0.0140	5	C
A_esters_fruity	1	beta.phellandrene	1.000	0.0723	0.0135	5	A
A_esters_fruity	2	ethyl_isovalerate	1.000	0.0005	0.0466	5	B
A_esters_fruity	3	MeSH	0.934	0.0058	0.0016	5	A
F_malt_all	1	acetaldehyde	1.000	0.0132	0.0025	5	A
F_malt_all	2	MeSH	1.000	0.0001	0.0003	5	B
F_malt_all	3	ethyl_decanoate	1.000	0.0007	0.0046	5	B
F_malt_grain	1	acetaldehyde	1.000	0.0088	0.0219	5	B
F_malt_grain	2	octyl_acetate	0.866	0.0060	0.0273	5	B
F_malt_grain	3	n.heptanol	0.682	0.0242	0.0099	5	C
F_malt_bread	1	MeSH	1.000	0.0073	0.0005	5	A
F_malt_bread	2	acetaldehyde	1.000	0.0026	0.0107	5	A
F_malt_bread	3	X2.acetylpyrrole	1.000	0.0278	0.0380	5	A
F_malt_cara	1	acetaldehyde	1.000	0.0100	0.0064	5	A
F_malt_cara	2	DES	1.000	0.0031	0.0009	5	B
F_malt_cara	3	octyl_acetate	1.000	0.0056	0.0520	5	B
F_malt_burn	1	MeSH	1.000	0.0003	0.0013	5	B
F_malt_burn	2	acetaldehyde	1.000	0.0015	0.0040	5	A
F_malt_burn	3	ethyl_decanoate	1.000	0.0006	0.0095	5	B
F_hops_all	1	ethyl_octanoate	1.000	0.0539	0.0069	5	A
F_hops_all	2	DMS	1.000	0.0076	—	5	B
F_hops_all	3	ethyl_hexanoate	0.870	0.0019	0.0081	5	B
F_hops_citrus	1	citronellol	1.000	0.0061	0.0182	5	A
F_hops_citrus	2	E.caryophyllene	0.994	0.0043	—	5	A
F_hops_citrus	3	DMS	0.554	0.0027	—	5	B
F_hops_tropical	1	DMS	1.000	0.0097	—	5	A
F_hops_tropical	2	nerol.oxide	0.990	0.0245	0.0794	5	A
F_hops_tropical	3	germacrene.D	0.980	0.0267	0.0295	5	A
F_hops_noble	1	ethyl_octanoate	1.000	0.0717	0.0179	5	A
F_hops_noble	2	ethyl_hexanoate	1.000	0.0025	0.0097	5	A
F_hops_noble	3	DMS	1.000	0.0040	—	5	A
F_hops_woody	1	isobutanol	1.000	0.0766	0.0120	5	A
F_hops_woody	2	X.E..2.nonenal	0.964	0.0423	0.0112	5	A
F_hops_woody	3	citronellol	0.908	0.0021	0.0067	5	B
F_esters_all	1	ethyl_acetate	1.000	0.0367	0.0625	5	A
F_esters_all	2	phenethyl_alcohol	0.998	0.0103	—	5	A
F_esters_all	3	acetaldehyde	0.962	0.0136	0.0945	5	A
F_esters_ethac	1	ethyl_acetate	1.000	0.0540	0.0378	5	A
F_esters_ethac	2	acetaldehyde	1.000	0.0199	0.0743	5	A
F_esters_ethac	3	Z.Z.geranyl.linalool	0.508	0.0229	0.0145	5	B
F_esters_isoaa	1	isopentyl_acetate	0.740	0.0162	0.0408	5	B
F_esters_isoaa	2	phenethyl_alcohol	1.000	0.0128	—	5	A
F_esters_isoaa	3	neryl.propanoate	0.976	0.0121	0.0380	5	A
F_esters_flower	1	delta.terpinyl.acetate	1.000	0.0245	—	5	B

全部 50 维 × 3 个候选的证据分级（续）

感官维	名次	化合物	频率	条件增量	模块增量	正折数	级
F_esters_flower	2	ethyl_2.methyl_butyrate	0.932	0.0067	0.0357	5	C
F_esters_flower	3	eucalyptol	0.670	0.0134	—	5	C
F_esters_fruity	1	MeSH	1.000	0.0170	0.0036	5	A
F_esters_fruity	2	octyl_acetate	0.916	0.0054	0.0445	5	A
F_esters_fruity	3	phenethyl_alcohol	0.660	0.0197	—	5	B
acidity	1	ethyl_isovalerate	1.000	0.0147	0.0381	5	A
acidity	2	isopentyl_acetate	1.000	0.0015	0.0024	5	A
acidity	3	geraniol	1.000	0.0026	0.0086	5	A
bitternes	1	ethyl_octanoate	1.000	0.0764	0.0218	5	A
bitternes	2	MeSH	1.000	0.0003	0.0000	5	B
bitternes	3	DMS	1.000	0.0029	—	5	A
sweetness	1	ethyl_decanoate	1.000	0.0207	0.0276	5	A
sweetness	2	octyl_acetate	1.000	0.0002	0.0169	5	B
sweetness	3	alpha.humulene	1.000	0.0026	0.0083	5	A
X4vg	1	X4VG	1.000	0.2155	—	5	A
X4vg	2	delta.terpinyl.acetate	1.000	0.1268	—	5	A
X4vg	3	ethyl_isovalerate	1.000	0.0022	0.0419	5	A
diacetyl	1	eugenol	1.000	0.1161	—	5	A
diacetyl	2	ethyl_octanoate	1.000	0.0173	0.0784	5	A
diacetyl	3	X1.alpha.terpineol	1.000	0.0029	0.0217	5	A
dms	1	isomaltol	1.000	0.0135	0.0175	5	A
dms	2	phenethyl_alcohol	1.000	0.0035	—	5	A
dms	3	X3.methylbutanal	0.406	0.0098	0.0447	5	B
metallic	1	ethyl_isovalerate	1.000	0.0181	0.0688	5	A
metallic	2	alpha.calacorene	1.000	0.0506	0.0183	5	A
metallic	3	isopentyl_acetate	0.898	0.0047	0.0080	5	A
stale_hops	1	alloaromadendrene.epoxide	1.000	0.0666	0.0448	5	A
stale_hops	2	ethyl_2.methyl_butyrate	1.000	0.0015	0.0193	5	B
stale_hops	3	linalool	1.000	0.0048	0.0113	5	B
t2n	1	geraniol	1.000	0.0045	0.0410	5	A
t2n	2	phenethyl_alcohol	1.000	0.0062	—	5	A
t2n	3	H2S	0.912	0.0094	0.0029	5	A
orange	1	ethyl..E..linalool	1.000	0.1290	0.1214	5	A
orange	2	DMS	0.896	0.0110	—	5	A
orange	3	acetaldehyde	0.786	0.0000	0.0008	5	C
coriander	1	ethyl..E..linalool	0.856	0.0813	0.1290	5	A
coriander	2	acetaldehyde	0.986	0.0034	0.0016	5	A
coriander	3	X4VG	0.774	0.0029	—	5	B
clove	1	X2.3.butanedione	1.000	0.0108	0.0028	5	A
clove	2	X4VG	0.962	0.0132	—	5	A
clove	3	eucalyptol	0.642	0.0366	—	5	B
lactic	1	isopentyl_acetate	1.000	0.0106	0.0008	5	A
lactic	2	ethyl_isovalerate	1.000	0.0002	0.0592	5	B
lactic	3	Z.nerolidol	1.000	0.0002	—	5	B
acetic	1	ethyl_isovalerate	1.000	0.0357	0.0150	5	A
acetic	2	isopentyl_acetate	1.000	0.0013	0.0023	5	A
acetic	3	Z.nerolidol	1.000	0.0002	—	5	B
barnyard	1	alloaromadendrene.epoxide	1.000	0.0832	0.0390	5	A
barnyard	2	ethyl_2.methyl_butyrate	1.000	0.0000	0.0186	5	B
barnyard	3	acetaldehyde	1.000	0.0068	0.0240	5	A

全部 50 维 × 3 个候选的证据分级（续）

感官维	名次	化合物	频率	条件增量	模块增量	正折数	级
alcohol	1	ethyl_octanoate	1.000	0.0345	0.0107	5	A
alcohol	2	acetaldehyde	1.000	0.0075	0.0209	5	A
alcohol	3	MeSH	1.000	0.0004	0.0003	5	B
aftertaste	1	ethyl_octanoate	1.000	0.0411	0.0164	5	A
aftertaste	2	ethyl_isovalerate	1.000	0.0242	0.0205	5	A
aftertaste	3	acetaldehyde	1.000	0.0084	0.0180	5	A
body	1	isobutanol	1.000	0.0103	0.0134	5	A
body	2	ethyl_octanoate	1.000	0.0049	0.0039	5	A
body	3	MeSH	1.000	0.0057	0.0000	5	A
co2	1	ethyl_octanoate	1.000	0.0750	0.0161	5	A
co2	2	ethyl_hexanoate	1.000	0.0143	0.0245	5	A
co2	3	DMS	1.000	0.0027	—	5	A
overall	1	ethyl_acetate	1.000	0.0186	0.0067	5	A
overall	2	DMS	1.000	0.0074	—	5	A
overall	3	cis.linalool.oxide	0.998	0.0207	—	5	A

注：频率为 500 次按风格分层 bootstrap 的入选频率；条件增量与模块增量均已除以标签方差归一化；正折数为 5 折中条件增量为正的折数；模块增量为 — 表示该化合物所在社区只有它自己，模块增量无法定义。分级按正文的四条件判定，A = 全满足、B = 满足三条、C = 其余。

A.2 交付答案的完整数据

正文为保持可读只列代表维度，这里补齐两份可直接核对的答案：问题二全部 50 维的 Top-3 化合物（表 A.10），问题三三种代表风格生成谱的 50 维感官画像均值（表 A.11）。两表分别由 `problem_2_results.json` 与 `submission/q3_generated_profiles.csv` 直接生成。

表 A.10　全部 50 个感官维度的 Top-3 关键化合物（交付答案）

感官维度	Top-1	Top-2	Top-3	判定
酒精	ethyl_octanoate	acetaldehyde	MeSH	一致
苦味	ethyl_octanoate	MeSH	DMS	不一致
酒体	isobutanol	ethyl_octanoate	MeSH	不一致
味・酒花	ethyl_octanoate	DMS	ethyl_hexanoate	不一致
余味	ethyl_octanoate	ethyl_isovalerate	acetaldehyde	不一致
味・麦芽	acetaldehyde	MeSH	ethyl_decanoate	不一致
乳酸	isopentyl_acetate	ethyl_isovalerate	Z.nerolidol	不一致
味・贵族花	ethyl_octanoate	ethyl_hexanoate	DMS	不一致
香・麦芽	acetaldehyde	octyl_acetate	MeSH	不一致
甜味	ethyl_decanoate	octyl_acetate	alpha.humulene	不一致
香・酒花	ethyl_octanoate	DMS	linalool	部分一致
味・酯	ethyl_acetate	phenethyl_alcohol	acetaldehyde	一致
碳酸	ethyl_octanoate	ethyl_hexanoate	DMS	部分一致
香・贵族花	ethyl_octanoate	DMS	ethyl_hexanoate	不一致
香・焦糖	octyl_acetate	acetaldehyde	MeSH	不一致
味・面包	MeSH	acetaldehyde	X2.acetylpyrrole	部分一致
味・指甲油	ethyl_acetate	acetaldehyde	Z.Z.geranyl.linalool	部分一致
4VG	X4VG	delta.terpinyl.acetate	ethyl_isovalerate	部分一致
味・焦糖	acetaldehyde	DES	octyl_acetate	不一致
酸度	ethyl_isovalerate	isopentyl_acetate	geraniol	部分一致
香・酯	n.hexanol	acetaldehyde	phenethyl_alcohol	一致
味・烟熏	MeSH	acetaldehyde	ethyl_decanoate	不一致

全部 50 个感官维度的 Top-3 关键化合物（续）

感官维度	Top-1	Top-2	Top-3	判定
乙酸	ethyl_isovalerate	isopentyl_acetate	Z.nerolidol	不一致
味・木质	isobutanol	X.E..2.nonenal	citronellol	部分一致
橙香	ethyl..E..linalool	DMS	acetaldehyde	不一致
味・香蕉酯	isopentyl_acetate	phenethyl_alcohol	neryl.propanoate	部分一致
DMS	isomaltol	phenethyl_alcohol	X3.methylbutanal	不一致
香・柑橘	citronellol	ethyl_decanoate	E.caryophyllene	部分一致
丁香	X2.3.butanedione	X4VG	eucalyptol	不一致
香・指甲油	ethyl_acetate	phenethyl_alcohol	X2.methyl.1.butanol	一致
香・香蕉酯	isopentyl_acetate	n.hexanol	benzaldehyde	一致
香・面包	acetaldehyde	octyl_acetate	ethyl.hexadecanoate	不一致
双乙酰	eugenol	ethyl_octanoate	X1.alpha.terpineol	不一致
味・热带	DMS	nerol.oxide	germacrene.D	部分一致
金属味	ethyl_isovalerate	alpha.calacorene	isopentyl_acetate	部分一致
味・果香酯	MeSH	octyl_acetate	phenethyl_alcohol	一致
总体	ethyl_acetate	DMS	cis.linalool.oxide	不一致
芫荽	ethyl..E..linalool	acetaldehyde	X4VG	不一致
香・热带	DMS	isopentyl.butanoate	geraniol	部分一致
香・木质	alloaromadendrene.epoxide	ethyl_2.methyl_butyrate	isobutanol	部分一致
味・柑橘	citronellol	E.caryophyllene	DMS	部分一致
味・谷物	acetaldehyde	octyl_acetate	n.heptanol	不一致
香・谷物	Z.nerolidol	terpinen.4.ol	phenethyl_alcohol	不一致
反 2 壬烯醛	geraniol	phenethyl_alcohol	H2S	不一致
香・烟熏	isobutanol	MeSH	ethyl_propionate	不一致
香・花香酯	ethyl.lactate	geraniol	isobutyl_acetate	部分一致
陈酒花	alloaromadendrene.epoxide	ethyl_2.methyl_butyrate	linalool	部分一致
畜栅味	alloaromadendrene.epoxide	ethyl_2.methyl_butyrate	acetaldehyde	不一致
香・果香酯	beta.phellandrene	ethyl_isovalerate	MeSH	部分一致
味・花香酯	delta.terpinyl.acetate	ethyl_2.methyl_butyrate	eucalyptol	不一致

注：候选集限定为 211 个单一化合物，理化参数与汇总列不参与；维度按 QWK 降序排列。判定为 Top-3 与 8.xlsx 期望来源的一致程度。完整入选频率与证据增量见附录表 A.5、A.9。

表 A.11　三种代表风格生成谱的 50 维感官画像（均值，0–6 级）

感官维度	Tripel	Kriek	Lambic
香・麦芽	2.80	1.30	2.60
香・谷物	3.40	3.07	3.53
香・面包	4.17	2.43	2.37
香・焦糖	3.20	1.60	2.90
香・烟熏	1.93	3.03	3.10
香・酒花	3.87	1.03	1.60
香・柑橘	3.93	2.50	2.50
香・热带	4.27	3.13	2.57
香・贵族花	3.73	1.00	2.80
香・木质	2.87	3.50	3.70
香・酯	3.97	5.17	2.70
香・指甲油	3.80	2.80	2.70
香・香蕉酯	4.13	4.70	2.60
香・花香酯	3.07	5.00	2.97
香・果香酯	3.17	5.90	3.57

三种代表风格生成谱的 50 维感官画像（续）

感官维度	Tripel	Kriek	Lambic
味·麦芽	2.97	0.27	1.67
味·谷物	3.70	2.20	3.27
味·面包	4.23	1.20	1.57
味·焦糖	2.97	1.13	1.70
味·烟熏	3.23	3.53	2.70
味·酒花	4.07	0.73	1.53
味·柑橘	3.60	2.33	3.33
味·热带	3.77	3.93	3.40
味·贵族花	4.20	0.70	2.27
味·木质	4.23	4.13	3.67
味·酯	3.60	4.43	2.27
味·指甲油	4.37	4.17	2.27
味·香蕉酯	4.13	3.60	2.70
味·花香酯	3.37	5.20	3.30
味·果香酯	2.20	5.90	2.87
酸度	2.47	5.93	5.87
苦味	3.90	0.30	0.83
甜味	3.17	4.20	2.57
4VG	4.80	1.93	1.30
双乙酰	3.67	3.33	4.53
DMS	4.33	2.33	3.33
金属味	4.33	3.00	3.90
陈酒花	3.23	4.00	4.40
反 2 壬烯醛	3.93	2.87	3.83
橙香	2.97	3.83	4.33
芫荽	4.33	4.70	4.07
丁香	3.53	4.73	2.10
乳酸	1.77	6.00	6.00
乙酸	1.67	5.80	5.83
畜棚味	3.70	4.50	4.83
酒精	4.73	0.80	0.80
余味	2.73	3.00	3.00
酒体	3.87	1.37	1.77
碳酸	4.60	1.00	1.73
总体	3.80	1.87	2.47

注：每风格 30 条生成谱，画像由问题一模型打分后取均值，配置与主结果一致（SEED=42）。

附录 B　软件环境与运行命令

本文全部计算使用 Python 3.11.9 完成，主要依赖库及版本为：numpy 2.4.6、pandas 2.3.3、scikit-learn 1.8.0、lightgbm 4.6.0、shap 0.51.0、networkx 3.6.1、python-louvain 0.16、torch 2.13.0（CPU 版）、scipy 1.17.1、matplotlib 3.10.8、joblib 1.5.3、openpyxl 3.1.5。随机种子固定为 42，全程仅使用相对路径。

在支撑材料根目录下，安装依赖并一键运行全部三问的命令为：

```
pip install -r code/requirements.txt
cd code
python main.py --data-dir ../user_data
```

程序依次执行问题一（感官分级预测）、问题二（关键化合物归因）、问题三（风格条件生成与迁移），结果文件写入 `submission/`，过程数据写入 `figures/`。

附录 C　支撑材料文件清单

路径	内容
code/main.py	一键入口，串联三问并汇总结果
code/params.py	全局常数（种子、维度、缺陷列、风格、超参）
code/utils.py	数据加载、0-6 分箱映射、二次加权 Kappa、检查点
code/data_check.py	数据读取与维度对齐自检
code/problem1.py	问题一：缺失感知梯度提升 + 分箱 + 分层交叉验证
code/problem2.py	问题二：化合物集 C=211 共表达图 + 社区检测 + 多证据 Top-3（去冗余）+ bootstrap/Jaccard + 来源判定 + 随机基线
code/problem3.py	问题三：CVAE 条件生成 + 风格识别率/画像评估 + 隐空间迁移 + min 缺陷投影 + 无约束对照
code/constraint_audit.py	从落盘结果重算硬约束
code/sanity_check.py	结果数值自动审查
figures/supp_prep_eda.py	预处理实证：附件概况/差异、对数底核实、未检出-缺失分类、三类划分
figures/supp_kaggle.py	Kaggle 公开集外部旁证（风格 ABV/IBU 宏观对照，不进建模）
figures/gen_fig_*.py、figures/gen_tables.py	全部图表与三线表的生成脚本（数值均读结果 JSON）
figures/problem_1/2/3_results.json、all_results.json	三问全部量化指标（QWK/Spearman/±1、图统计、来源类别、KS/识别率/缺陷 Δ）
figures/supp_preprocess.json、supp_kaggle.json	预处理实算结果与 Kaggle 旁证统计
submission/q1_sensory_scores.csv	问题一 250×50 维 0-6 分级
submission/q2_top3_compounds.csv	问题二每维 Top-3（仅化合物集 C）+ 稳定性 + 来源判定
submission/q3_generated_profiles.csv	问题三 90 条生成谱 + 11 条迁移 + 感官画像 + 缺陷 min 投影对照

附录 D　核心源程序

本附录只列三问的核心实现，完整可运行代码见支撑材料 code/ 目录；工具函数（数据加载、分箱、Kappa、检查点）与参数表不再重复排印。

code/problem1.py——问题一：缺失感知回归与有序回归

```python
def _fit_lgb(Xtr, ytr):
    m = lgb.LGBMRegressor(**LGB_PARAMS)
    m.fit(Xtr, ytr)
    return m


# ---------- 有序分支：分箱退化诊断 + 类加权阈值分解 ----------
CLF_PARAMS = dict(
    n_estimators=120, num_leaves=8, learning_rate=0.05,
    min_child_samples=15, feature_fraction=0.6, bagging_fraction=0.8,
```

```
    bagging_freq=1, lambda_l2=1.0, random_state=P.SEED, n_jobs=-1, verbose=-1,
)
DEGEN_SPAN = 0.05      # 前 5 个分位切点跨度 < 极差的 5% 判为退化
ORD_MIN_FRAC = 0.10    # 阈值两侧任一类占比低于 10% 时不做二分类

def binning_degenerate(ytr, span_th=DEGEN_SPAN):
    """判断该维的分位分箱是否退化：切点挤在极窄区间内，等级在原始尺度上不可分。"""
    y = np.asarray(ytr, dtype=float)
    y = y[np.isfinite(y)]
    if y.size < 20:
        return False
    rng = float(y.max() - y.min())
    if rng <= 0:
        return True
    edges = U.Binner().fit(y).edges
    return bool((edges[4] - edges[0]) / rng < span_th)

def _fit_ordinal(Xtr, ytr, Xva, n_levels=P.N_LEVELS):
    """类加权阈值分解：对每个内部阈值训练一个「y > t」二分类器，概率累加后取整。

    与直接回归再分箱相比，它不依赖切点位置，因而能绕开密集分布下切点重合的问题；
    阈值两侧样本不均衡时按类频率反比加权，避免多数类主导。
    """
    ytr = np.asarray(ytr, dtype=float)
    edges = np.quantile(ytr, np.linspace(0, 1, n_levels + 1)[1:-1])
    edges = np.maximum.accumulate(edges)
    acc = np.zeros(len(Xva))
    for t in edges:
        z = (ytr > t).astype(int)
        frac = float(z.mean())
        if frac < ORD_MIN_FRAC or frac > 1 - ORD_MIN_FRAC:
            acc += frac                       # 无区分度的阈值直接用先验
            continue
        w = np.where(z == 1, 1.0 / max(frac, 1e-6), 1.0 / max(1.0 - frac, 1e-6))
        clf = lgb.LGBMClassifier(**CLF_PARAMS)
        clf.fit(Xtr, z, sample_weight=w)
        acc += clf.predict_proba(Xva)[:, 1]
    return np.clip(np.round(acc), P.LEVEL_MIN, P.LEVEL_MAX).astype(int)
```

code/problem2.py——问题二：三路证据融合与稳定性

```
def _corr_evidence(C6, comp_rows6, comp_names, feat_cols, sens_cols):
    """6.csv 交叉相关 → 231 位置 × 50 感官的 |corr| 证据（未覆盖化合物记 0）。

    两个都必须按名映射，不能按位置：
      - 化合物行：6.csv 用英文全名，2.csv 用原始列名。
      - 感官列：6.csv 前 46 列顺序与 4.csv 一致，但第 47-50 位不同
        （6.csv: Carbonation/Aftertaste/Body/Overall;
         4.csv: aftertaste/body/co2/overall），按位置对齐会把
        aftertaste、body、co2 三列的证据错位。
    """
    J, Pn = len(sens_cols), len(feat_cols)
    evid = np.zeros((J, Pn))
```

```
    name2pos = {name: i for i, name in enumerate(comp_names)}
    Cv = C6.values.astype(float)

    # 感官列按名映射：C6 的第 k 列 → 4.csv 的某个短名
    col_targets = U.align_sensory_cols(list(C6.columns))
    sens_pos = {s: j for j, s in enumerate(sens_cols)}
    col_to_j = []
    for short in col_targets:
        if short not in sens_pos:
            raise KeyError(f"6.csv 感官列映射到未定义的维度：{short}")
        col_to_j.append(sens_pos[short])

    n_mapped = 0
    for ri, r in enumerate(comp_rows6):
        pos = name2pos.get(r, None)
        if pos is None:
            continue
        n_mapped += 1
        for k, j in enumerate(col_to_j):
            v = Cv[ri, k]
            evid[j, pos] = abs(v) if np.isfinite(v) else 0.0
    print(f"[Q2] 6.csv 交叉相关映射化合物 {n_mapped}/{len(comp_rows6)} → 231 位置；"
          f"感官列按名映射 {len(set(col_to_j))}/50")
    return evid

def _module_rep(base_scores, comm_arr):
    """模块代表加权：同社区（仅 C，comm!=-1）内按 base 排名，第 1 名 rep=1，第 2=1/2…

    非 C 位置 comm=-1 直接跳过（rep 保持 0），促进 Top-3 跨模块多样。
    """
    rep = np.zeros_like(base_scores, dtype=float)
    for ci in np.unique(comm_arr):
        if ci == -1:
            continue                        # 非 C 节点不参与模块代表
        idx = np.where(comm_arr == ci)[0]
        order = idx[np.argsort(-base_scores[idx])]
        for rank, p in enumerate(order, 1):
            rep[p] = 1.0 / rank
    return rep

def _fuse_and_stability(sens_cols, feat_cols, shap_imp, corr_evid, rf_imp,
                        abs_shap_list, comm_arr, c_mask, R, styles):
    """多证据融合 + 去冗余 Top-3 + bootstrap 入选频率 + 跨方法 Jaccard（全部只在 C 内取）。"""
    J, Pn = len(sens_cols), len(feat_cols)
    a, b, g = P.FUSE_ALPHA, P.FUSE_BETA, P.FUSE_GAMMA
    per_dim = {}
    top3_idx = {}
    # 点估计：ϕ=0.5SHAP+0.3|corr|+0.2module_rep，module_rep 仅在 C 社区内
    shap_n_all = np.vstack([_norm(shap_imp[j]) for j in range(J)])
    corr_n_all = np.vstack([_norm(corr_evid[j]) for j in range(J)])
    rf_n_all = np.vstack([_norm(rf_imp[j]) for j in range(J)])
    phi_all = np.zeros((J, Pn))
    for j in range(J):
```

```
        base = a * shap_n_all[j] + b * corr_n_all[j]
        rep = _module_rep(base, comm_arr)          # 仅 C 社区
        phi = base + g * rep
        phi_all[j] = phi
        # 去冗余 Top-3（phi 先掩码到 C）
        top3_idx[j] = _select_topk(_mask_c(phi, c_mask), R, comm_arr)
    # bootstrap 入选频率：**按风格分层**有放回重采样 → 重算 SHAP → 同一融合+去冗余流程（只在 C 内）。
    # 分层可避免小样本风格在重采样中整体缺席，使频率反映"同风格内"的稳定性。
    rng_bt = np.random.default_rng(P.SEED)
    N = abs_shap_list[0].shape[0]
    style_arr = np.asarray(styles)
    strata = [np.where(style_arr == s)[0] for s in pd.unique(style_arr)]
    freq = np.zeros((J, Pn))
    B = P.N_BOOTSTRAP
    conv_trace = {}          # 200/300/500 收敛检查
    for bi in range(B):
        parts = [rng_bt.choice(idx, size=len(idx), replace=True) for idx in strata if len(idx)]
        idx = np.concatenate(parts)
        for j in range(J):
            shap_b = _norm(abs_shap_list[j][idx].mean(axis=0))
            base_b = a * shap_b + b * corr_n_all[j]
            phi_b = base_b + g * _module_rep(base_b, comm_arr)
            for p in _select_topk(_mask_c(phi_b, c_mask), R, comm_arr):
                freq[j, p] += 1
        if (bi + 1) in (200, 300, 500):
            snap = freq / (bi + 1)
            top1 = [int(np.argmax(snap[j])) for j in range(J)]
            conv_trace[str(bi + 1)] = {
                "mean_top1_freq": round(float(np.mean([snap[j, top1[j]] for j in range(J)])), 4),
                "n_top1_changed_vs_final": None,   # 稍后填
                "top1": top1,
            }
            print(f"[Q2] bootstrap {bi+1}/{B}  mean_top1={conv_trace[str(bi+1)]['mean_top1_freq']:.4f}")
    freq /= B
    # 跨方法 Jaccard（SHAP / 6.csv相关 / RF；各方法 Top-3 只在 C 内取）
    jac_dim = {}
    for j in range(J):
        ts = _topk_masked(shap_n_all[j], c_mask)
        tc = _topk_masked(corr_n_all[j], c_mask)
        tr = _topk_masked(rf_n_all[j], c_mask)
        pj = np.mean([_jaccard(ts, tc), _jaccard(ts, tr), _jaccard(tc, tr)])
        jac_dim[sens_cols[j]] = round(float(pj), 4)

    for j, col in enumerate(sens_cols):
        t3 = top3_idx[j]
        per_dim[col] = {
            "top3": [feat_cols[p] for p in t3],
            "top3_idx": [int(p) for p in t3],
            "phi": [round(float(phi_all[j, p]), 4) for p in t3],
            "shap_norm": [round(float(shap_n_all[j, p]), 4) for p in t3],
            "corr_abs": [round(float(corr_n_all[j, p]), 4) for p in t3],
```

```
            "select_freq": [round(float(freq[j, p]), 4) for p in t3],
            "module": [int(comm_arr[p]) for p in t3],
            "jaccard_cross_method": jac_dim[col],
        }
    # 收敛检查：200/300 次的 Top-1 与最终（500 次）Top-1 差异维数
    final_top1 = [int(np.argmax(freq[j])) for j in range(J)]
    for k in conv_trace:
        prev = conv_trace[k]["top1"]
        conv_trace[k]["n_top1_changed_vs_final"] = int(sum(1 for a_, b_ in zip(prev, final_top1) if
    a_ != b_))
        conv_trace[k].pop("top1", None)
    print("[Q2] 收敛检查:", {k: (v["mean_top1_freq"], v["n_top1_changed_vs_final"]) for k, v in
    conv_trace.items()})

    mean_top1_freq = float(np.mean([per_dim[c]["select_freq"][0] for c in sens_cols]))
    mean_jac = float(np.mean(list(jac_dim.values())))
    n_high_stable = int(sum(1 for c in sens_cols if per_dim[c]["select_freq"][0] >= 0.7))
    print(f"[Q2] 平均Top-1入选频率={mean_top1_freq:.4f} 平均跨方法Jaccard={mean_jac:.4f} "
          f"高稳定维={n_high_stable}")
    return {
        "problem": 2,
        "method": ("共表达图(networkx+louvain,仅C 211项) + SHAP/相关/模块代表融合(ϕ=0.5/0.3/0.2) "
                   "+ 同社区|R|>=0.7去冗余 + bootstrap频率 + 跨方法Jaccard + 随机基线对照"),
        "candidate_set": {"name": "C", "n": int(c_mask.sum()),
                          "excluded_physicochem": sorted(P.PHYSICOCHEM_COLS),
                          "excluded_aggregate": sorted(P.AGG_COLS)},
        "summary": {"n_dims": J, "n_bootstrap": B, "topn": P.TOPN,
                    "mean_top1_select_freq": round(mean_top1_freq, 4),
                    "mean_cross_method_jaccard": round(mean_jac, 4),
                    "n_high_stable_dims": n_high_stable,
                    "redun_rho": REDUN_RHO,
                    "fuse_weights": {"alpha": a, "beta": b, "gamma": g},
                    "bootstrap_stratified_by_style": True,
                    "bootstrap_convergence": conv_trace},
        "per_dim": per_dim, "sensory_cols": sens_cols,
    }
```

code/problem3.py——问题三：CVAE 与缺陷投影迁移

```
def _elbo_loss(xhat, x, mask, mu, logvar, beta_kl, free_bits=P.FREE_BITS):
    # 掩码重构（只对非缺失分量计 MSE，式11）
    diff2 = ((xhat - x) ** 2) * mask
    recon = diff2.sum() / mask.sum().clamp(min=1.0)
    # 逐维 KL + free-bits（每维 KL 低于 free_bits 时不再惩罚，防后验坍塌）
    kld_dim = -0.5 * (1 + logvar - mu.pow(2) - logvar.exp())   # [B, d]
    kld_dim = torch.clamp(kld_dim.mean(dim=0), min=free_bits)
    kld = kld_dim.sum()
    return recon + beta_kl * kld, recon.item(), float(kld.item())

def _train_cvae(Xstd, mask, onehot, device):
    model = CVAE(Xstd.shape[1], onehot.shape[1]).to(device)
    opt = torch.optim.Adam(model.parameters(), lr=P.CVAE_LR)
    Xt = torch.tensor(Xstd, dtype=torch.float32, device=device)
```

```
    Mt = torch.tensor(mask, dtype=torch.float32, device=device)
    St = torch.tensor(onehot, dtype=torch.float32, device=device)
    N = Xt.shape[0]
    best, best_state, patience, bad = 1e18, None, 60, 0
    rng = np.random.default_rng(P.SEED)
    for ep in range(1, P.CVAE_EPOCHS + 1):
        model.train()
        perm = rng.permutation(N)
        ep_loss = ep_rec = ep_kl = 0.0
        for st in range(0, N, P.CVAE_BATCH):
            bidx = perm[st:st + P.CVAE_BATCH]
            xb, mb, sb = Xt[bidx], Mt[bidx], St[bidx]
            opt.zero_grad()
            xhat, mu, lv = model(xb, sb)
            beta = P.BETA_KL * min(1.0, ep / max(1, P.KL_ANNEAL_EPOCHS))  # KL 退火
            loss, rec, kl = _elbo_loss(xhat, xb, mb, mu, lv, beta)
            loss.backward()
            opt.step()
            ep_loss += loss.item() * len(bidx); ep_rec += rec * len(bidx); ep_kl += kl * len(bidx)
        ep_loss /= N
        if ep <= P.KL_ANNEAL_EPOCHS:
            if ep % 50 == 0 or ep == 1:
                print(f"[Q3] CVAE epoch {ep}/{P.CVAE_EPOCHS}(退火) loss={ep_loss:.4f} "
                      f"recon={ep_rec/N:.4f} kl={ep_kl/N:.4f}")
            continue   # 退火阶段不计入早停
        if ep_loss < best - 1e-4:
            best, best_state, bad = ep_loss, {k: v.detach().clone() for k, v in model.state_dict().
    items()}, 0
        else:
            bad += 1
        if ep % 50 == 0 or ep == 1:
            print(f"[Q3] CVAE epoch {ep}/{P.CVAE_EPOCHS} loss={ep_loss:.4f} "
                  f"recon={ep_rec/N:.4f} kl={ep_kl/N:.4f}")
        if bad >= patience:
            print(f"[Q3] 早停于 epoch {ep}（best loss={best:.4f}）")
            break
    if best_state is not None:
        model.load_state_dict(best_state)
    model.eval()
    return model

def _transfer(model, style_list, s2i, S, Xstd, Xv, styles, feat_cols, mu_f, sd_f,
              device, lo=None, hi=None):
    """Pils/Lager → Tripel 隐空间平移 + 缺陷投影（式12/13）。"""
    tgt = P.TRANSFER_TARGET
    zt, _ = _style_latent_mean(model, Xstd, styles, tgt, s2i, S, device)
    # 目标风格缺陷典型值 m^t（native 中位）
    tgt_idx = np.where(styles == tgt)[0]
    col_med_all = np.nanmedian(Xv, axis=0)
    defect_pos = {d: feat_cols.index(c) for d, c in P.DEFECT_COL_MAP.items()}
    m_t = {d: float(np.nanmedian(Xv[tgt_idx, pos])) for d, pos in defect_pos.items()}

    records = []
```

```
    before = {d: [] for d in defect_pos}
    after = {d: [] for d in defect_pos}
    cap_rec = {d: [] for d in defect_pos}
    raw_after = {d: [] for d in defect_pos}   # 无约束纯平移对照（缺陷投影前的解码值）
    for src in P.TRANSFER_SOURCES:
        if src not in s2i:
            print(f"[Q3] 迁移源 {src} 不存在，跳过")
            continue
        zs, sidx = _style_latent_mean(model, Xstd, styles, src, s2i, S, device)
        delta = zt - zs
        # 逐源样本编码 -> 平移 -> 用目标风格解码
        oh_src = np.zeros((len(sidx), S)); oh_src[:, s2i[src]] = 1
        with torch.no_grad():
            mu_s, _ = model.encode(torch.tensor(Xstd[sidx], dtype=torch.float32, device=device),
                                   torch.tensor(oh_src, dtype=torch.float32, device=device))
            z_moved = mu_s.cpu().numpy() + delta
            oh_t = np.zeros((len(sidx), S)); oh_t[:, s2i[tgt]] = 1
            xhat = model.decode(torch.tensor(z_moved, dtype=torch.float32, device=device),
                                torch.tensor(oh_t, dtype=torch.float32, device=device)).cpu().numpy
    ()
        native = xhat * sd_f + mu_f
        if lo is not None and hi is not None:
            native = _clip_to_observed(native, lo, hi)
        for row, si in enumerate(sidx):
            x_after_vec = native[row].copy()
            for d, pos in defect_pos.items():
                xb = Xv[si, pos]
                if not np.isfinite(xb):
                    xb = float(col_med_all[pos])
                raw_val = float(x_after_vec[pos])           # 无约束纯平移的缺陷取值（对照）
                raw_after[d].append(raw_val)
                # 严格不恶化：迁移后缺陷既不得高于源款原值 xb，也不高于目标典型安全值 m_t，取严
                cap = min(xb, m_t[d])
                if P.USE_ABS_THRESHOLD:
                    pass  # 可换算时此处并入 τ 上界（本题单位不可比，默认关闭）
                # 缺陷列逐样本投影回安全区（式13，np.minimum 下截断）
                xa = float(np.minimum(raw_val, cap))
                x_after_vec[pos] = xa
                before[d].append(float(xb)); after[d].append(xa); cap_rec[d].append(cap)
            records.append({"style": f"{src}->{tgt}", "sample_type": "transfer",
                            "src_beer_row": int(si), "_native": x_after_vec})
        print(f"[Q3] 迁移 {src}->{tgt}: {len(sidx)} 条")
    # 合规率（式13：x_after <= min(xb, m_t)）
    n_tot = n_ok = 0
    n_rise_raw = n_rise_constrained = 0
    per_defect = {}
    for d in defect_pos:
        bf = np.array(before[d]); af = np.array(after[d]); cp = np.array(cap_rec[d])
        raw = np.array(raw_after[d])
        ok = int((af <= cp + 1e-9).sum())
        rise_raw = int((raw > bf + 1e-9).sum())    # 无约束时缺陷升高的样本数
        rise_c = int((af > bf + 1e-9).sum())       # 严格约束后缺陷升高数（应为 0）
        n_tot += len(af); n_ok += ok
```

```
        n_rise_raw += rise_raw; n_rise_constrained += rise_c
        per_defect[d] = {"n": len(af), "n_compliant": ok,
                         "before_mean": round(float(bf.mean()), 4),
                         "after_mean": round(float(af.mean()), 4),
                         "raw_after_mean": round(float(raw.mean()), 4),
                         "m_t": round(m_t[d], 4),
                         "delta_mean": round(float((af - bf).mean()), 4),
                         "delta_raw_mean": round(float((raw - bf).mean()), 4),
                         "n_rise_unconstrained": rise_raw,
                         "n_rise_constrained": rise_c}
    rate = n_ok / n_tot if n_tot else 1.0
    info = {"compliance_rate": round(rate, 6), "n_checks": n_tot, "n_compliant": n_ok,
            "per_defect": per_defect, "defect_cols": list(P.DEFECT_COL_MAP.values()),
            "defect_no_chem": P.DEFECT_NO_CHEM, "m_t": {k: round(v, 4) for k, v in m_t.items()},
            "unconstrained_control": {
                "description": "同批迁移仅做隐空间平移、不做缺陷投影（对照），量化约束必要性",
                "n_defect_rise_unconstrained": n_rise_raw, "n_total": n_tot,
                "rise_frac_unconstrained": round(n_rise_raw / n_tot, 4) if n_tot else None,
                "n_defect_rise_constrained": n_rise_constrained,
                "rise_frac_constrained": round(n_rise_constrained / n_tot, 4) if n_tot else None}}
    print(f"[Q3] 缺陷合规率={rate:.4f}（{n_ok}/{n_tot}）；无约束升高 {n_rise_raw}/{n_tot}，"
          f"严格约束后升高 {n_rise_constrained}/{n_tot}")
    return records, info
```