队伍编号	MCB2600304
赛　道	A

基于共表达图归因与风格条件生成的啤酒感官分级预测

摘　要

啤酒风味由化合物组成与酵母代谢共同决定。本文在含真实缺失与噪声的 250 个商用啤酒样本上，构建“化学到感官判别预测 → 可解释归因 → 风格条件生成”的贯通流水线，三问共享同一化学到感官模型。

针对问题一，采用**原生缺失感知的梯度提升**对 50 个感官维逐维回归，再按训练折内分位点映射为 0-6 等级，按风格分层 5 折验证且分箱参数全程折内估计。平均 QWK 达 **0.3830**，折外 Spearman 0.4109，±1 级准确率 57.3%，严格一致率 22.1%、MAE 1.50 级、RMSE 1.93，优于随机森林 0.328、ElasticNet 0.276 与 KNN 插补 0.3652；2000 次配对重采样的 95% 区间对三类基线均不跨零；另以 split-conformal 给出 90% 预测区间，实测覆盖率 90.2%（目标 90%），平均宽度 1.55 个标准化单位。特征增广对照显示，加入 43 个阈值超限列、8 个模块 PC1 后 QWK 反而降至 0.3760、0.3747，故未采用。风味组 QWK 0.400 高于香气组 0.322，酒精、苦味等强信号维超 0.77，花香酯类弱信号维接近噪声。

针对问题二，剔除 16 个理化参数与 4 个汇总列，仅在 **211 个单一化合物**上建共表达图，得 211 节点、564 边、55 社区，模块度 **0.625**；融合 SHAP、交叉相关与模块代表三路证据选出 Top-3 并去共线冗余。Top-1 的 bootstrap 入选频率均值 **0.992**（按风格分层重采样），跨方法 Jaccard **0.200** 为随机基线 0.0086 的 **23.3 倍**。50 维联合检验显示 QWK 与 Top-1 稳定性的相关仅 $r = 0.101$，二者是相互独立的两个维度；随可预测性下降而失稳的是第 3 名。按 8.xlsx 标注的来源逐维判定，一致 6 维、部分一致 17 维，麦芽维多落于酵母酯醇，如实反映发酵后风味载体的真实结构。

针对问题三，用**条件变分自编码器**以风格为条件生成化学谱，在隐空间做质心平移实现跨风格迁移。三个代表风格的 KS 为 0.351–0.411，偏离集中于稀疏检出列，KS 与未检出率相关 $r = 0.66$；5 个随机种子下 KS 的标准差不超过 0.015，能量距离 0.329–0.437，风格 Top-3 识别率恒为 100%（随机 13.6%），50 维画像 Spearman 0.65–0.92、画像 MAE 均值为 0.49 级。Pils/Lager 到 Tripel 的缺陷采用逐样本 min 投影，迁移后 **0/44 次升高**，而同批不做投影的纯平移有 32/44 次升高。

三问结论均经交叉验证、bootstrap 与分布距离检验，框架可推广到其他成分谱与感官建模场景。

关键词：啤酒风味；缺失感知梯度提升；共表达网络；条件变分自编码器；配对 bootstrap

目录

1 问题重述 1

2 问题分析 2

2.1 问题一的分析 2

2.2 问题二的分析 2

2.3 问题三的分析 3

3 模型假设 3

4 符号说明 3

5 数据预处理与探索性分析 3

5.1 数据构成与口径统一 3

5.2 风格分布与化学可分性 4

5.3 对数底核实与尺度统一 5

5.4 未检出、真实缺失与异常值 7

5.5 外部数据旁证：Kaggle 公开啤酒集 9

6 问题一：含缺失的多输出有序感官分级预测 9

6.1 缺失结构与建模策略选择 9

6.2 标签构建与 0-6 分箱映射 10

6.3 预测模型与求解过程 13

6.4 结果分析 14

6.5 预测区间与不确定性 18

7 问题二：化合物共表达图与关键化合物归因 20

7.1 共表达图构建与模块结构 20

7.2 多证据融合 Top-3 归因 22

7.3 稳定性量化 23

7.4 融合增益消融与归因集中度 26

7.5 化学合理性论证 29

8 问题三：风格条件生成与跨风格迁移 31

8.1 条件变分自编码器 31

8.2 跨风格迁移与缺陷约束 32

8.3 生成质量与结果分析 33

9 模型检验与灵敏度分析 38

9.1 验证方案与防泄漏 38

9.2 方法增益的消融汇总 39

9.3 模型层的两项对照实验 39

9.4 关键参数的灵敏度 41

9.5 鲁棒性 42

10 模型评价与推广 42

10.1 优点与创新 42

10.2 不足与改进 43

10.3 推广 43

A 数据附件概况与口径核对 45

A.1 特征与归因的完整明细 45

B 软件环境与运行命令 54

C 支撑材料文件清单 54

D 核心源程序 55

1 问题重述

啤酒以麦芽水为原料、加酒花并经酵母发酵而成，其风味高度依赖酵母代谢与化合物成分的协同作用。要定量刻画化学成分如何决定一款啤酒喝起来是什么味道，需要把实验室测得的数百种风味化合物与品评小组给出的感官强度联系起来。近年来，机器学习方法已被用于从化学成分预测啤酒及其他发酵饮品的风味特征[1-3]，为本文提供了方法论基础。本文使用一套商用啤酒风味代谢物实测数据集：对 250 个啤酒样本测量了酒精、异 α-酸、pH、糖浓度等酿造参数，以及 200 余种风味化合物的丰度，涵盖酒花萜类、酵母代谢酯醇、麦芽与野生菌群化合物及陈化类，并由品评小组给出约 50 个感官维度的评分。数据来自真实测量，含噪声、真实缺失值与异常值。围绕化学成分、感官风味与啤酒风格这条链条，本文研究三个递进的问题。

问题一：在化学数据存在真实缺失的条件下，以化合物与理化丰度为自变量，预测品评卡定义的香气 Aroma 与风味 Flavour 两套、合计约 40 个感官维度在 0-6 分制上的分级评分。任务对象是每一款啤酒样本，待求量是各感官维度的离散等级，关键边界是自变量含缺失而不能简单删除样本，评价目标是在缺失干扰下给出稳定可信的分级。本问为后两问提供化学如何映射到感官的基础模型。

问题二：利用化合物相关数据构建化合物共表达图，结合化学特征，给出每一个感官维度的 Top-3 关键因素化合物，并对所得结果做稳定性与化学合理性论证。稳定性按题面指定的两种口径量化——bootstrap 重采样下化合物进入 Top-3 的入选频率，以及不同建模方法间 Top-3 集合的 Jaccard 系数。本问依赖问题一的预测模型做可解释归因，其产出的关键化合物清单又为问题三识别风格判别成分提供先验。

问题三：以风格标签 `tasting_category_fine` 为条件学习一个风格条件生成模型，在给定风格时，例如 Tripel、Kriek、Lambic，生成合理的化合物谱并给出对应感官画像；同时完成跨风格迁移，即把 Pils/Lager 的化合物谱迁移为 Tripel 风格，并保持 DMS、Diacetyl、4VG、trans-2-nonenal、Stale hops 等缺陷化合物不恶化。该问反向利用问题一的感官画像与问题二的关键化合物，是三问的综合应用。

三个问题沿数据预处理、化学到感官的判别式预测、可解释归因、风格到化学的条件生成与迁移逐级推进，构成一条从理解到生成的完整流水线，其整体求解思路与依赖关系概括如下。

图 1 给出的技术路线中，问题一的预测模型处在枢纽位置：它既是问题二 SHAP 归因的解释对象，又是问题三生成谱感官画像的打分器。正是这一共享底座让三问环环相扣，也决定了求解必须从含缺失的化学到感官预测开始。

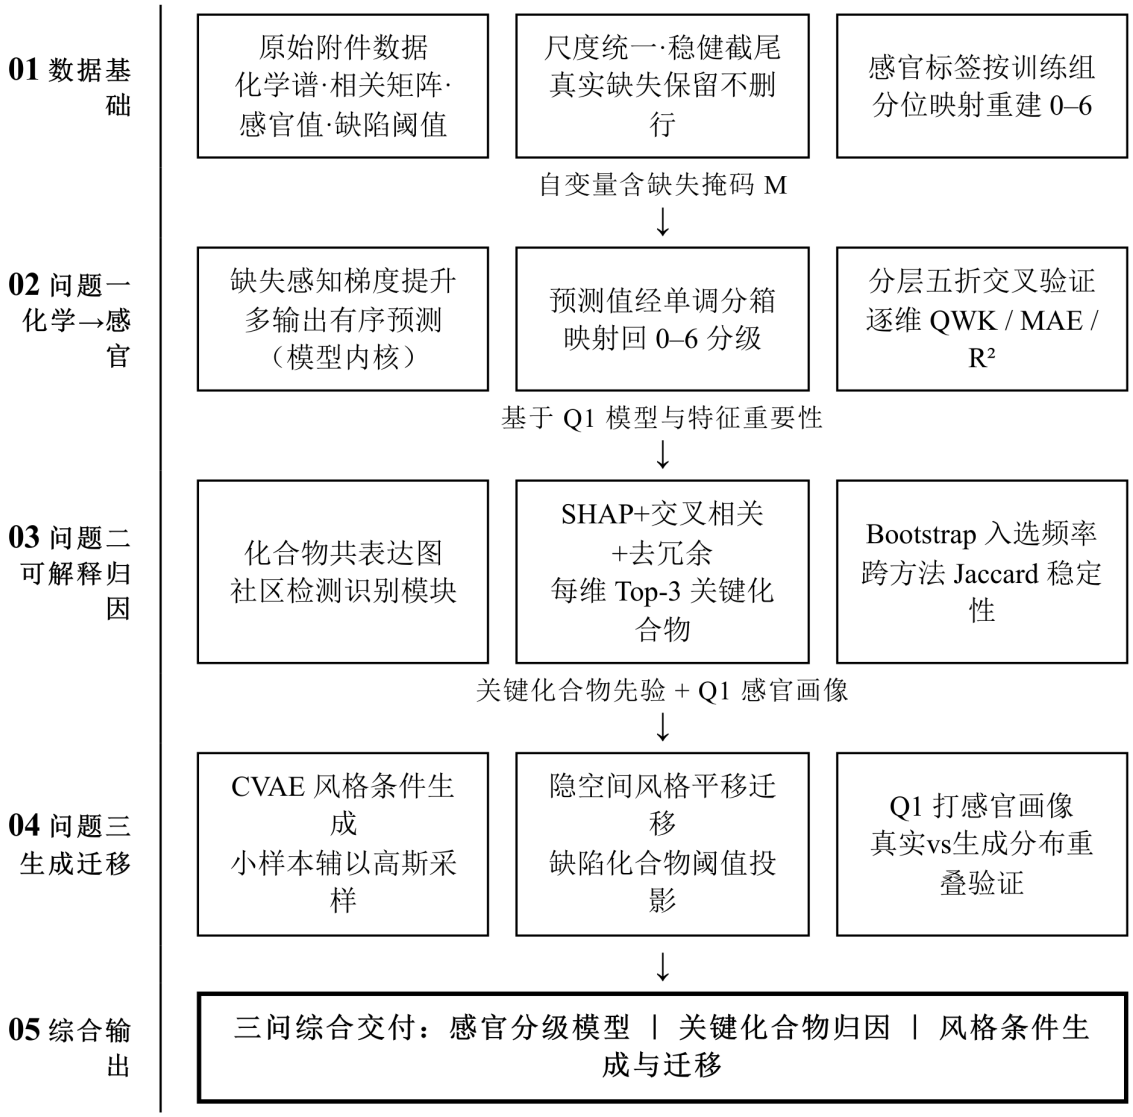


图 1　整体技术路线图

2　问题分析

2.1　问题一的分析

问题一本质是一个带缺失数据的多输出有序预测任务，核心难点集中在三处。其一，化学特征高维，共 231 列，且含真实缺失，其中 63 个样本、合计 73 个缺失值集中在少数几列，直接删除含缺失的样本会损失四分之一的数据并引入选择偏差，因此必须在缺失条件下建模。其二，品评小组提供的感官标签是中心化后的连续值（非单位方差）而非原始 0-6 整数，要交付题面要求的 0-6 分级，需要建立连续值到 7 级离散刻度的单调映射。其三，约 40 个感官维度彼此相关性强，宜共享同一套化学特征表示以提升稳健性。据此，本文选择原生支持缺失的梯度提升树[4-6] 作为主模型，对每个维度做回归后再分箱映射回 0-6 整数，并用分层交叉验证逐维评估二次加权 Kappa、平均绝对误差与

决定系数。相较先插补再建模的常规路线，原生缺失处理避免了插补偏差，其输出的特征重要性又可直接服务于问题二的归因。

2.2 问题二的分析

问题二是一个在共线性干扰下仍要既准、又稳、还有化学道理的可解释归因任务。许多化合物在相关矩阵里高度相关、成簇出现，单一重要性指标容易把同一化学模块里可以互相替代的化合物反复选入，造成 Top-3 虚假冗余。因此本文先用化合物共表达图揭示模块结构，再在模块意识下融合三类证据做归因：问题一模型给出的 SHAP 预测贡献、化学与感官的交叉相关，以及共表达模块的去冗余加权。稳定性严格按题面两法量化，bootstrap 入选频率刻画单方法内部的稳健性，跨方法 Jaccard 刻画不同证据之间的一致性。化学合理性则逐条对照已知酿造机理加以论证。需要强调，强信号维度的 Top-3 应当稳定、弱信号维度不稳定，这是数据本身的真实现象，本文如实报告而不强行制造稳定。

2.3 问题三的分析

问题三是条件生成加可控迁移任务，难点在于小样本条件下，部分风格仅有 3 至 11 个样本，既要保证生成谱的化学合理性与风格可区分性，又要在迁移时守住缺陷不恶化这一硬约束。本文用条件变分自编码器把化合物谱编码进低维隐空间、以风格标签为条件解码，兼顾生成多样性与风格可控；对极小样本风格辅以按风格的分布采样作为对照与兜底。生成谱的感官画像直接复用问题一的化学到感官模型，形成生成化学谱再预测感官的闭环。迁移通过在隐空间做源风格到目标风格的方向平移实现，并对缺陷化合物施加阈值与源值的双重投影，一旦超限即拉回安全区，确保迁移后缺陷不劣化。生成质量用真实谱与生成谱的分布距离及降维重叠度评估。

3 模型假设

为聚焦核心建模，本文做出以下假设。

（1）以标准化连续感官值为问题一的训练目标，再按训练折内分位点单调映射回 0-6 等级。原始品评卡汇总表为全 0 模板、不可用，标准化连续值是唯一完整可用的全样本标签。

（2）题面的”约 40 个感官维度”对应 Aroma 与 Flavour 两套共 30 维，本文另输出口感、缺陷与总体评价共 20 维，合计 50 维以覆盖任一解读。

（3）化学特征的数值尺度经 8.xlsx 校准浓度逐列核实为混合尺度：70 个可校准列中 37 列为常用对数、33 列为原值，无自然对数列；其余 161 列按列分布归类。建模在原生数值空间内进行而不做反变换，树模型对单调变换不敏感，该选择不影响分裂结果。

（4）缺陷不恶化取严口径：迁移后缺陷须同时不高于源款原值 $x_{k,before}^{def}$ 与目标风格

典型值 m_k^t，即上界为 $\min\left(x_{k,before}^{def}, m_k^t\right)$。该口径保证相对不升高；绝对达标情况另按 8.xlsx 真实阈值审计（见 8.3 节）。

（5）各样本近似独立同分布，风格标签为问题三唯一的条件变量。附件为截面数据、无时间序列结构，故交叉验证采用按风格分层的随机折。

4 符号说明

下表列出全文反复使用的核心符号，其余一次性派生量在首次出现处就地说明。

符号	含义	单位/取值
N	啤酒样本数	250
P	化合物与理化特征数	231
J	感官维度数	50
S	风格类别数	22
X	化学谱矩阵（含缺失，对数/原值混合尺度）	$\mathbb{R}^{N\times P}$
M	缺失掩码（1 为缺失）	$\{0,1\}^{N\times P}$
x_i	第 i 款啤酒的化学谱向量	—
Y	标准化感官值矩阵（训练标签）	$\mathbb{R}^{N\times J}$
$\tilde{y}_{ij}$	分箱后的 0-6 等级（交付目标）	$\{0,\ldots,6\}$
$\hat{y}_{ij}$	第 i 样本第 j 维的预测等级	$\{0,\ldots,6\}$
$g_j(\cdot)$	维度 j 的连续值到 0-6 的单调分箱映射	—
R	化合物相关矩阵	$[-1,1]^{P\times P}$
$G=(V,E)$	化合物共表达图（节点为化合物、边权为相关）	—
w_{pq}	化合物 p,q 之间的边权	$[-1,1]$
ρ	建图的相关强度阈值	$[0,1]$
ϕ_{jp}	化合物 p 对感官维度 j 的关键度	实数
f_{jp}	bootstrap 重采样下 p 进入 Top-3 的频率	$[0,1]$
z_i	CVAE 隐编码	$\mathbb{R}^d$
s	风格 one-hot 条件向量	$\{0,1\}^S$
$\Delta_{s\to t}$	隐空间中的风格迁移向量	$\mathbb{R}^d$
x_k^{def}	第 k 个缺陷化合物的浓度	原生数值空间

5 数据预处理与探索性分析

5.1 数据构成与口径统一

本文主分析**只使用主办方提供的 8 个附件**，另以 Kaggle 公开啤酒集作**外部旁证**（5.5 节），不与本数据合并、不进入任何模型。建模核心是四块数据：化合物与理化丰度矩阵 250×231、化合物相关矩阵 231×231、感官标签矩阵 250×50、化学-感官交叉相关 44×50。附件实测规模与题面表述的出入见附录 A（表 A.1、A.2），一律以实测为准。

附件对齐有一处容易被静默忽略的陷阱：1.csv 与 4.csv 的 `beer_id` 在后者已丢精度（如 `5410230000000.0`），按它取交集只剩 **37/250** 行，inner join 会无声丢掉四分之三样本；改用 `beer` 名称关联可恢复 250 行，且两表该列逐行相同。本文因此按行序对齐并显式断言（`code/data_check.py`），2.csv 按位置与 231 列对应、6.csv 按名称映射回 231 列，任何不符即中断。

231 个化学特征按含义分三类：**理化/过程参数** 16 列、**多化合物汇总** 4 列（总酯、酒花香气总量、总酸、含硫总量）、**单一化合物集** C 211 列。问题一用全部 231 列，问题二只在 C 内建图归因，以免把酒精度、苦度或加总列误当化合物。

感官标签是**已中心化但未归一化**的连续值（列均值绝对值 ≤ 0.063、标准差 0.37–0.86），并非原始 0-6 整数；化学特征为对数/原值混合尺度（5.3 节）。树模型对单调变换不敏感，故建模统一在原生数值空间，既免去尺度换算风险，又让问题三生成与缺陷判定同空间可比。

5.2 风格分布与化学可分性

数据集涵盖 22 个精细风格类别，样本量分布高度不均（图 2(a)），Blond 有 31 个、Tripel 有 28 个样本，而 Faro 仅 3 个、Brut 仅 4 个。这一长尾结构直接决定了问题三对极小样本风格必须设置分布采样兜底。在进入建模前，本文先用主成分分析观察化学谱是否天然按风格分离，以判断化学成分能否区分风格这一前提是否成立。

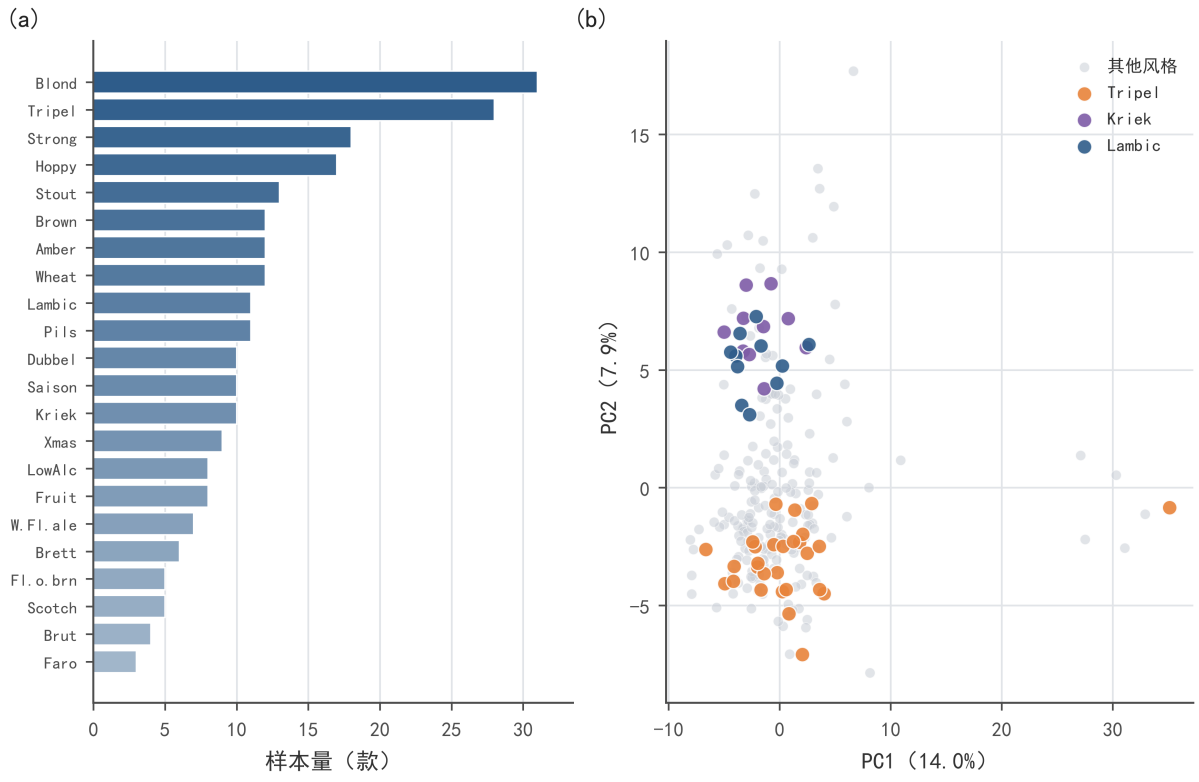


图 2　风格样本量与化学谱主成分分离

图 2(a) 给出 22 种风格的样本量分布，图 2(b) 给出化学谱前两个主成分的散点。可见长尾特征明显，而 Lambic、Kriek 等酸味野发酵风格与 Tripel、Blond 等常规发酵风格在主成分平面上形成可辨识的区域偏移。这说明化学成分确实携带了区分风格的信息，为问题三以风格为条件生成化学谱提供了数据层面的可行性依据；同时各风格簇之间存在重叠，也预示生成与迁移任务并非平凡，需要隐空间模型而非简单的类别均值替代。

5.3 对数底核实与尺度统一

化合物丰度取对数还是原值，直接影响浓度叙述。8.xlsx 的 Calibrated chemical dataset 给出 70 个化合物的校准绝对浓度 c_{ik}，本文据此对每列计算 x_{ik} 与 $\log_{10} c_{ik}$、c_{ik}、$\ln c_{ik}$ 三者的中位绝对残差，残差低于 10^{-6} 者即判定其尺度。结果为 **37 列严格为常用对数、33 列严格为原值**，两类残差均为 0、与对应尺度相关系数为 1.0，无自然对数；连 pH 也取常用对数（$0.625 = \log_{10} 4.21$）。常用对数列含全部 16 个理化指标与 21 个酵母酯、醇、硫化合物，原值列以酒花萜烯、醛、酚类为主。其余 161 列无校准浓度，按列分布归类并标注未经校准。

需要特别说明化学谱中的负值。231 个特征中有 **175 列出现负数，合计 10797 个负值单元格**，它们不是异常值或测量错误，而是浓度小于 1 的化合物取常用对数后的正常结果，例如 $\log_{10} 0.1 = -1$。按列核查，负值全部出现在已判定为常用对数的列上，原值列不含负值。因此本文不做任何剔除、截断或取绝对值，保留其原始对数取值；剔除这些行等于删掉近半数观测信息，还会使分布严重右偏。

核实过程与残差见图 3。

表 1　22 种风格的样本量

风格	款数	风格	款数
Blond	31	Saison	10
Tripel	28	Kriek	10
Strong ale	18	Christmas	9
Hoppy	17	Low/No alcohol	8
Stout/Porter	13	Fruitbeer	8
Brown	12	West Flanders ale	7
Amber	12	Brett/cofermented	6
Wheat	12	Flanders old brown	5
Lambic	11	Scotch	5
Pils/Lager	11	Brut	4
Dubbel	10	Faro	3

注：左栏与中栏均按款数降序排列，两栏对齐便于对读。数据来源：1.csv

表 1 显示 22 种风格的样本量高度不均：Blond 31 款、Tripel 28 款、Strong ale 18 款居前，而 Faro 仅 3 款、Brut 4 款、Scotch 与 Flanders old brown 各 5 款。这一长尾结构有

两层后果：其一，按风格分层做交叉验证时，尾部风格的每一折只剩零到一个样本，因此问题一的评估按全体样本分层而非按风格单独报告；其二，Faro、Brut 等 6 种风格不足以支撑独立的条件生成模型，问题三对它们改走按风格的分布采样兜底，而不强行训练一个样本量不足的生成分支。

表 2　三类特征的检出、未检出与缺失构成

特征类别	列数	单元格数	检出	未检出 / 真实缺失
理化/过程参数	16	4000	98.0%	2.0% / 0%
多化合物汇总	4	1000	98.3%	0.4% / 1.3%
单一化合物集 C	211	52750	85.5%	14.4% / 0.1%

注：未检出指取值不超过该列下限，在统计上属左删失而非缺测；真实缺失指单元格为空，全表共 73 个。数据来源：1.csv

表 2 把 231 个特征按理化/过程参数、多化合物汇总与单一化合物集三类拆开，统计每一类单元格的三种状态。理化与汇总两类几乎没有缺失，检出率均在 98% 以上；真正的问题出在单一化合物集 C：其检出率只有 85.5%，未检出占 14.4%，而真正的缺失仅 0.1%。由此可见，本文面对的并非“大量缺测”，而是“大量化合物落在检出限附近”。这两类情况的处理方式完全不同，因此本文将其严格分流：未检出保留为下限档位并另设指示列，缺失则交给原生缺失感知模型，详见 5.4 节。

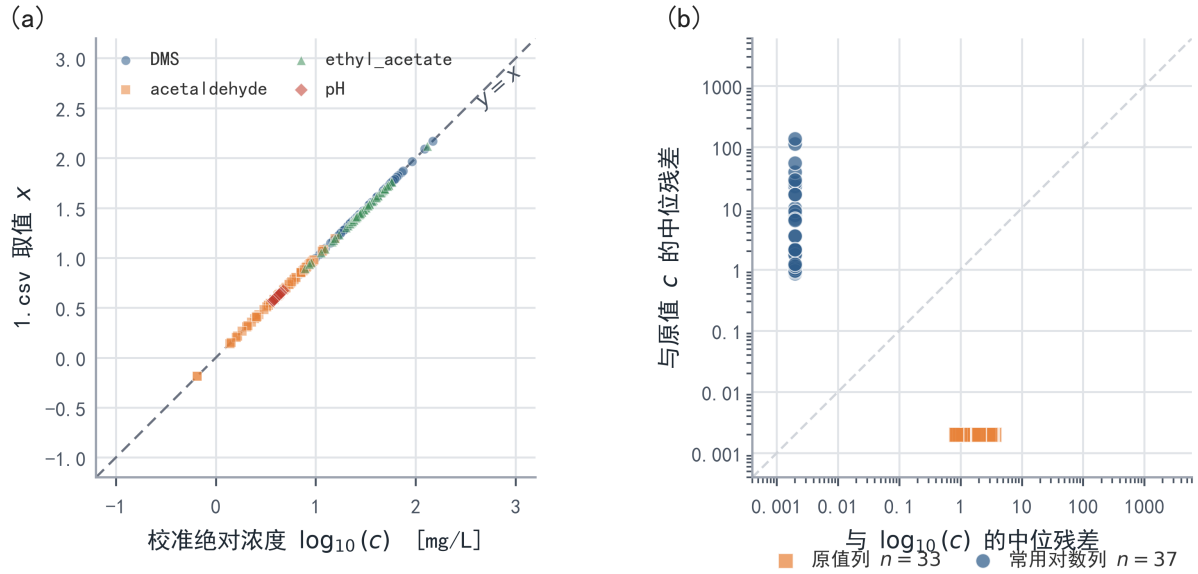


图 3　校准浓度与 1.csv 取值的对应关系及 70 个可校准列的中位残差

图 3(a) 以校准浓度为横轴、1.csv 取值为纵轴，DMS、乙醛、乙酸乙酯与 pH 四列散点全部落在 $y = x$ 上，说明 1.csv 取值即 $\log_{10}$ 校准浓度。图 3(b) 把核对推广到 70 个可校准列（双对数轴、各加 10^{-3} 避开零值）：37 列落在纵轴、对 $\log_{10}$ 残差为 0，33 列落在横轴、对原值残差为 0，无任何列靠近对角线，即不存在第三种尺度。

5.4 未检出、真实缺失与异常值

化学谱中的大量低值是**未检出**（低于仪器检出限，取本列下限 $\ell_k = \min_i x_{ik}$），与真正的缺失必须分开。真正的缺失共 **73 个 NA、9 列、63 个样本**，集中在乙酸戊酯（27 个，10.8%）、酒花香气合计（13 个）、甲基吡嗪（12 个）、双乙酰（9 个）与 3-甲基丁醛（7 个），其余 4 列各 1–2 个。

未检出的分布同样高度不均：211 个单一化合物的检出率仅 85.5%（未检出 14.4%），而 16 个理化列与 4 个汇总列分别为 98.0% 与 98.3%，可见丰度稀疏是化合物的常态。逐列看，**40 列有 30% 以上的样本卡在同一最小值**、12 列超过 60%（limonene 与 6-methyl-5-hepten-2-one 达 84.8%、CS2 为 83.6%、4VG 为 67.2%），这是检出限造成的**左删失**，而非自然测量得到的连续值。

本文因此不把下限值当作普通观测：主模型保留 231 列原生数值（含 NaN），未检出以下限档位进入分裂，另定义指示 $\delta_{ik} = \mathbb{1}[x_{ik} \le \ell_k]$（共 102 列适用）用于值域截断与核对，但不展开成额外特征（树模型能直接利用该档位）。仅 73 个真实 NA 需要插补，本文用 $K = 5$ 近邻插补，距离在标准化特征上计算，且只在训练折内拟合；KNN 插补仅用于基线对照，主模型不插补。

对异常值本文不删样本：树模型按秩分裂、二次加权 Kappa 只看等级次序，对极值与单调变换天然稳健；问题三的生成谱则在各列观测区间 $[\ell_k, u_k]$ 内截断，从源头杜绝越界。

表 3　真实缺失的列分布与未检出率对照

化合物	1.csv 列名	NA 数	缺失率	未检出率
乙酸戊酯	amyl.acetate	27	10.8%	45.0%
酒花香气合计 †	aroma_hops_sum	13	5.2%	42.0%
甲基吡嗪	methylpyrazine	12	4.8%	42.0%
双乙酰	X2.3.butanedione	9	3.6%	41.0%
3-甲基丁醛	X3.methylbutanal	7	2.8%	41.0%
烟酸乙酯	ethyl.nicotinate	2	0.8%	40.0%
异丁酸乙酯	ethyl.isobutyrate	1	0.4%	40.0%
糠醛	furfural	1	0.4%	40.0%
苯乙醛	phenylacetaldehyde	1	0.4%	40.0%
合计	9 列	**73**	1.1%	—

注：缺失率为该列 NA 数占 250 个样本的比例；未检出率为取值等于该列下限的样本占比，两者互不重叠。† 多化合物汇总列。数据来源：1.csv

图 4(a) 给出 63 个含缺失样本的缺失位置矩阵，图 4(b) 给出各列缺失率条形，可直接看出缺失集中在少数列，与表 3 的逐列统计互相印证。

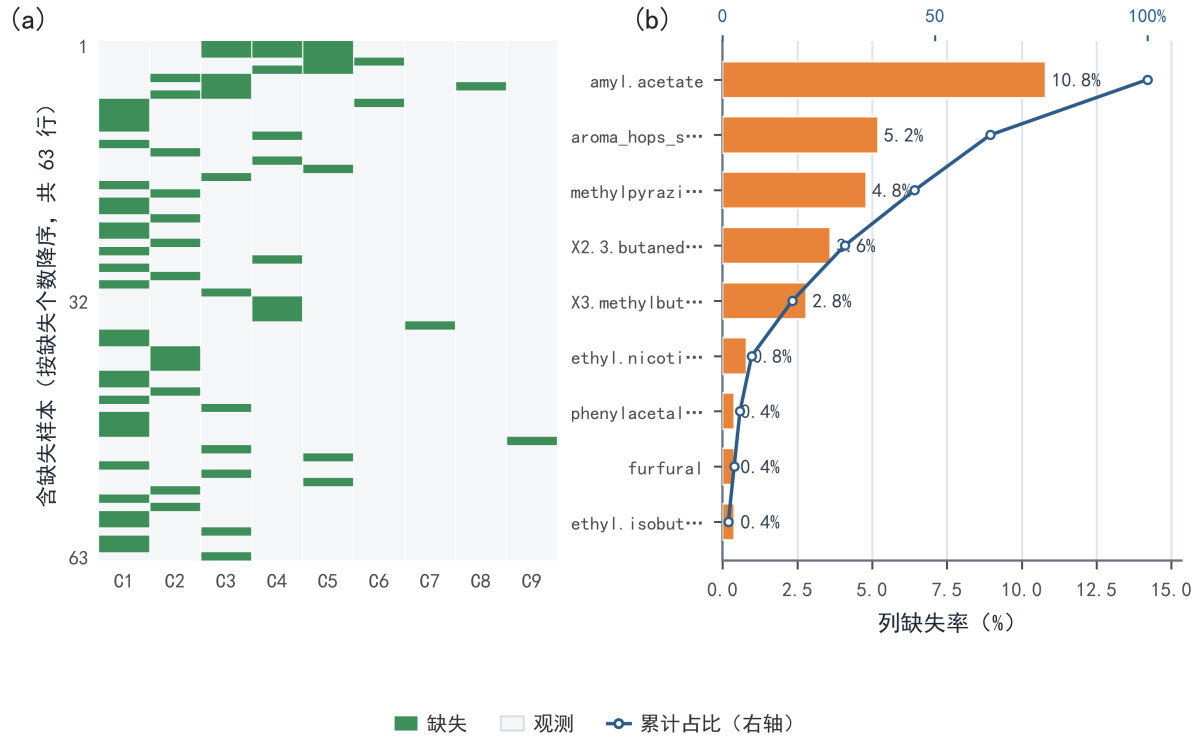


图 4　含缺失样本的缺失位置矩阵与列缺失率

5.5　外部数据旁证：Kaggle 公开啤酒集

为校验本文风格规格是否符合行业常识，引入 Kaggle 公开数据集 *Top Beer Information**[7]，由 Stephen Polozoff 整理，含 5558 款、112 个风格与 ABV、IBU 区间及网友平均评分作为外部旁证。它与本数据是互补而非替代关系：Kaggle 是大众风格的网友评分与规格大样本库，本文是 22 个比利时/欧洲小众风格的实验室化学谱与单一小组标准化分精标小样本。两者没有共同主键，因此不逐行合并、不进入任何模型，仅作宏观对照。

图 5(a) 显示两库整体酒精度分布区间一致，都集中在 0–12% vol；本文样本偏比利时修道院风格，整体偏强，峰值落在 6.5%–8%。在 16 个能明确对应的风格上，把本文实测酒精度按 10^{x} 从 $\log_{10}$ 列还原，与 Kaggle 同风格区间对照（图 5(b)）：**14/16 落在 Kaggle 的 P5–P95 区间内，跨风格的酒精度排序 Spearman 相关达 0.84**；苦度排序相关也达 0.86——由于 Kaggle 的 Min/Max IBU 是风格指南标称区间，每风格退化为单一值、并非逐款实测，而本文是仪器实测苦度，口径不同，故苦度只比较排序、不报告命中率。低强度低苦风格与 Tripel 等高强度风格的相对格局完全一致。Kaggle 评分由大量评论聚合、比本文每款数人的小组打分更平滑，这也部分解释了问题一弱信号维的可预测性偏低。需要强调，**主分析仅使用给定的 8 个附件，Kaggle 数据仅作外部旁证、不进入建模**。

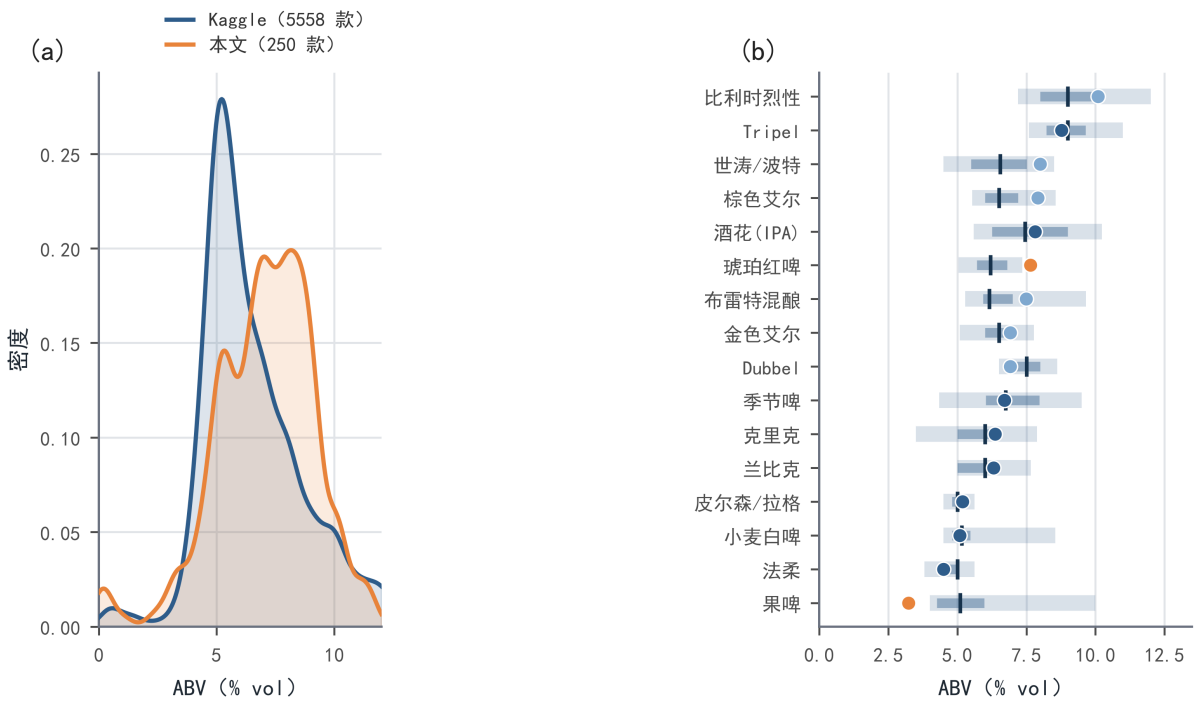


图 5　Kaggle 公开啤酒集与本文的风格规格宏观对照

6　问题一：含缺失的多输出有序感官分级预测

6.1　缺失结构与建模策略选择

问题一的第一道关卡是缺失数据。如 5.4 节所述，73 个真实缺失集中在 9 列、涉及 63 个样本，呈少数列集中、多数样本完好的模式；化合物集另有平均 14.4% 的未检出值，携带的信息极少但不是缺失。删除这 63 行将损失四分之一样本并引入选择偏差，故本文不删行：真正缺失交给原生支持缺失的梯度提升树，未检出保留下限档位[4-6]，让树为含缺失的分裂学习默认方向。图 1 的流水线自左向右为缺失感知梯度提升、逐维回归与 0-6 分箱、分层交叉验证；其中分箱映射与评估口径是保证交付整数且不泄漏的两个要害，下面分别展开。

6.2　标签构建与 0-6 分箱映射

品评小组提供的标准化连续值无法直接作为 0-6 分级交付，需要一个单调映射把连续强度离散为 7 个等级。本文在训练折内对维度 j 估计 6 个分位点 $\{q_1^{(j)},\dots,q_6^{(j)}\}$，定义累计计数式的单调映射：

$$g_j(y)=\sum_{\ell=1}^{6}\mathbb{1}\left[y>q_\ell^{(j)}\right],\qquad \tilde{y}_{ij}=g_j(Y_{ij})\in\{0,\dots,6\}. \tag{1}$$

预测阶段对回归输出 r_{ij} 施加同一映射，并截断取整以严格落在 0-6 整数区间：

$$\hat{y}_{ij} = \min\Big(6,\ \max\big(0,\ \mathrm{round}(g_j(r_{ij}))\big)\Big). \tag{2}$$

式 (1) 的分位点与标准化参数只由训练折估计、再套用到验证折，这是本题最易被忽视的泄漏点：若在全量数据上估计分箱阈值，等于让模型偷看了验证样本的标签分布。

50 个感官目标并非彼此独立。`5.csv` 的 50×50 相关矩阵（对角为 1，范围 -0.502 至 0.966，中位 $|r| = 0.127$）如图 6。直觉预期“组内紧密、组间松散”，实测相反：香气组内中位 0.124、风味组内 0.152，而两组之间 0.151。真正强的是**同名维的跨通道配对**——香气 • 酯与风味 • 酯 0.836、酒花—酒花 0.828、麦芽—麦芽 0.825；15 对同名维中位 **0.692**，12 对超 0.6，而全体非对角中位仅 0.127。即“闻到的酯香”与“尝到的酯味”几乎是同一变量，共享同一化学来源。

这一结构对本文有三点直接含义。第一，50 维不是 50 个独立任务，组间共享信息主要沿“同名维”这条轴，而非沿香气/风味的分组边界，因此按通道分组共享表示未必能带来增益（第 9 章的分组多任务对照验证了这一点）。第二，全局最强的一对是陈酒花与畜栅味（0.966），二者几乎等价，提示这两维在化学上难以分离，也预示弱信号维的归因会互相混淆。第三，36 对 $|r| \geq 0.6$ 的目标若逐维独立建模，等于把同一信号重复学习多次，这是本文仍选择逐维建模的代价——换来的是每维可独立诊断与解释。

分位分箱并非唯一选择。本文对分位分箱与等距分箱做了灵敏度对照：等距分箱把连续值按极差等分为 7 段，在偏态的标准化连续值上，50 个维度合计产生 8 个空等级、最小等级平均仅占 0.9% 的样本、各等级样本数的变异系数高达 1.155；分位分箱则没有空等级、每等级平均占 13.8%，接近 1/7，变异系数仅 0.022。等距分箱把多数样本压到中段，平均 QWK 反而略高（0.4013 对 0.3830），但这一偶然优势以空等级与严重失衡的等级频次为代价，对偏态分布不稳健；分位分箱的等级频次跨维可比、无空等级，且只依赖秩、对单调变换稳健，故本文采用后者。两口径下 QWK 绝对量级的依赖关系在 9.3 节另作说明。

分位分箱有一个容易被忽略的前提：各维度的连续标签必须足够分散，否则 6 个分位点会挤在极窄的区间内，切出的 7 个等级在原始尺度上无法区分。本文对 50 个维度逐一做了这项诊断，以“前 5 个切点跨度占该维极差的比例”作为退化程度的度量。结果显示有 5 个维度显著退化：acetic 为 0.006、coriander 与 clove 为 0.008、lactic 为 0.011、orange 为 0.033，它们的等级虽然仍各占约 14% 的样本，但这些等级对应的原始强度几乎重叠，等级之间的边界不具备实际含义。

对这一现象有两种应对思路。第一种是保留分位分箱，承认这些维度的等级划分在市场意义上只是“相对排序”。第二种是改用**有序回归**，直接学习“是否越过某一等级阈值”，不依赖分位点落在哪里。为判断第二种是否真的更好，本文在同一批样本、同一 5 折划分、同一 LightGBM 家族下做了对照：回归分支沿用现有流程，有序分支对每个内部阈值训练一个“标签高/低于该阈值”的二分类器，将各阈值的预测概率累加后取整得到 6 级等级。

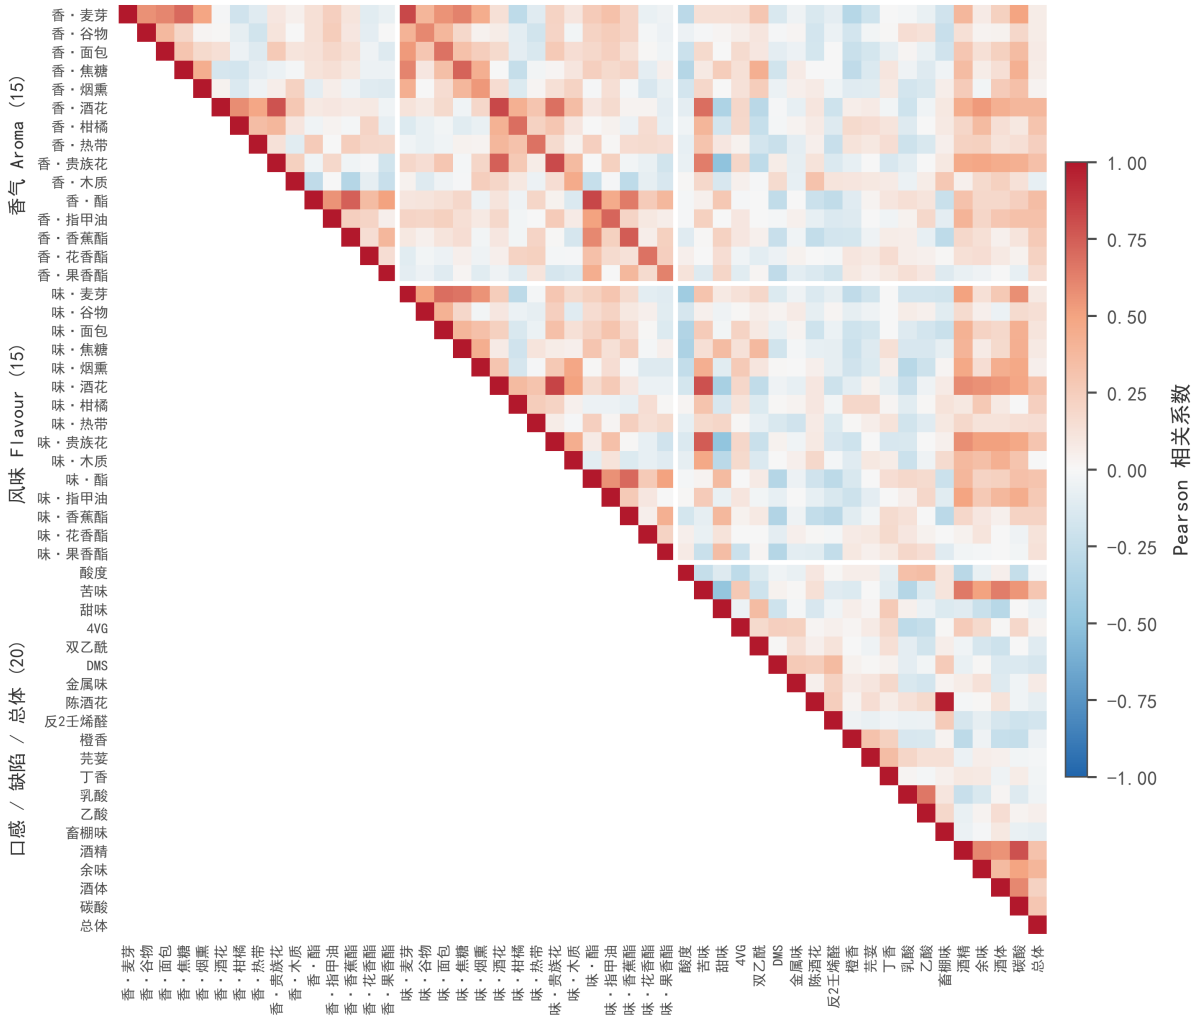


图 6　50 个感官目标的相关矩阵（按香气 / 风味 / 口感扩展分组，仅显示上三角）

表 4　分箱退化维与其余维度的有序回归对照

维度组	维度数	回归 + 分位分箱	统一有序回归（不加权）	本文采用
退化维（切点跨度 <5% 极差）	5	0.2052	0.3443	**0.3715**
其余维度	45	0.3842	0.3801	0.3842
全 50 维	50	0.3663	0.3765	**0.3830**

注：QWK 为同一 5 折分层划分下的折外均值。退化维指前 5 个分位切点跨度占该维极差不足 5% 的维度，共 5 个：acetic、coriander、clove、lactic、orange。“统一有序回归（不加权）”是把 50 维全部换为有序回归、阈值二分类器不加权重的对照；“本文采用”是只对退化维改用类加权有序回归、其余维保留回归的混合方案，两种有序口径都只用训练折、不接触验证折。若把类加权口径同样铺到全部 50 维，QWK 为 0.4089，未采用的理由见正文。数据来源：problem_1_results.json、figures/derived/q1_ordinal_counterfactual.json

表 4 的对照结果分界非常清晰：退化维上有序回归平均由 0.2052 升至 0.3715、提升 **0.166**；其中 lactic 由 0.315 升至 0.611、clove 由 0.127 升至 0.305、coriander 由 0.093 升至 0.228；而在其余 45 维上，统一换用有序回归不但没有提升，反而平均下降 0.0041，甜味、酯类等标签分布较散的维度降幅更明显（甜味由 0.600 降至 0.494）。这一分化说明，有序回归的优势并非普遍存在，它恰好补偿的是分箱在密集分布上的信息损失；当标签本身足够分散时，连续回归保留的强度信息反而更有价值。因此本文只在退化维上切换，而不是全部换用。

据此把判据接入主流水线：退化维改用**类加权有序回归**（6 个阈值各训一个二分类器、按两侧频率反比加权），其余维保持不变。自动识别的退化维为 orange、coriander、clove、lactic、acetic 共 5 个，折外 QWK 由 0.3663 升至 **0.3830**（+4.6%），5 维全部改善。需如实说明：若铺到全部 50 维，QWK 0.4089、Spearman 0.4509、±1 58.7% 三项更高；但该分支输出等级期望值而非连续强度，而问题二、三都依赖连续底座，故以 0.026 的 QWK 换取三问共用。

判据只依赖标签分布形态、在建模前即可确定，不接触验证信息；切换也是单侧的，只有退化维改用有序回归。作为对照，嵌套交叉验证下的逐维自适应选型无偏估计为 0.3856，但内层样本仅约 133 条、受抽样噪声驱动，反使 17 个原本良好的维度退化，未予采用。

6.3 预测模型与求解过程

对每个感官维度 j，本文训练一个独立的梯度提升回归器 h_j，以平方损失加正则求参：

$$\Theta_j = \arg\min_{\Theta} \sum_{i \in \mathcal{D}_{tr}} \big(Y_{ij} - h_j(x_i;\Theta)\big)^2 + \Omega(\Theta), \tag{3}$$

其中 h_j 为梯度提升树集成，x_i 的缺失分量由树的默认分裂方向处理，训练集 $\mathcal{D}_{tr}$ 包含全部含缺失样本，不删行；Ω 为叶子数、学习率与 L2 正则项。50 个维度共享同一化学特征矩阵 X。

整个求解按固定随机种子 42 执行：按风格分层切 5 折，折内估计分箱映射 g_j、拟合回归器 h_j，折外累计二次加权 Kappa、平均绝对误差与决定系数，最后在全部 250 样本上重训一次产生提交分级。该流程可写成如下的闭式递推。记第 k 折的训练集与验证集为 $\mathcal{D}_{tr}^{(k)}$、$\mathcal{D}_{va}^{(k)}$，样本 i 的风格为 s_i，分层折指派取同风格样本的循环编号

$$\kappa(i) = \big(\#\{i' :\ s_{i'} = s_i,\ i' \le i\} - 1\big) \bmod K, \tag{4}$$

其中 $\kappa(i) = k$ 即 $i \in \mathcal{D}_{va}^{(k)}$，同风格样本因此近似均分到各折。分位点与退化判据只在训练折内估计：

$$q_\ell^{(j,k)} = \text{Quantile}_{\ell/7}\big(\{Y_{ij} : i \in \mathcal{D}_{tr}^{(k)}\}\big), \qquad \delta_j = \mathbb{1}\left[\frac{q_5^{(j,k)} - q_1^{(j,k)}}{\max_i Y_{ij} - \min_i Y_{ij}} < 0.05\right]. \tag{5}$$

折外等级由回归分支与有序分支按 δ_j 逐维硬选择：

$$\hat{y}_{ij} = (1-\delta_j)\,\mathrm{clip}_{[0,6]}\Big(\mathrm{round}\big(g_j(h_j(x_i))\big)\Big) + \delta_j\,\mathrm{round}\Big(\sum_{\ell=1}^{6}\hat{p}_{i\ell}^{(j)}\Big), \tag{6}$$

其中 $\hat{p}_{i\ell}^{(j)}$ 为第 ℓ 个内部阈值二分类器给出的“高于该阈值”概率，$\delta_j = 1$ 时累加概率即等级期望值。50 维指标再对折外样本宏平均，二次加权 Kappa 取

$$\mathrm{QWK} = \frac{1}{50}\sum_{j=1}^{50}\frac{\sum_{a,b=0}^{6} w_{ab}O_{ab}^{(j)}}{\sum_{a,b=0}^{6} w_{ab}E_{ab}^{(j)}}, \qquad w_{ab} = \frac{(a-b)^2}{36}, \tag{7}$$

$O_{ab}^{(j)}$、$E_{ab}^{(j)}$ 为第 j 维混淆矩阵的观测与期望计数。

6.4 结果分析

主模型与各基线的整体对比如表 5。除题面要求的二次加权 Kappa 外，本文另报告折外 Spearman、±1 级准确率、严格一致率，以及等级口径的 MAE、RMSE 与连续 Pearson。±1 衡量“大方向正确”的实用命中率，严格一致率衡量完全命中，MAE 与 RMSE 则以 0-6 等级为单位直接给出“平均差几级”——主模型 MAE 为 1.50 级，是评委最容易直观理解的一列。表中 QWK 至 RMSE 各列均在 0-6 等级上计算并作 50 维宏平均；Pearson 一律与 4.csv 保留中心化尺度的连续值计算，主模型取连续输出、四个基线只输出等级故取等级值，若主模型也降到等级口径则为 0.419，仍是该列下界；末列统计逐维 $R^2 > 0$ 的维度数，若按连续口径计主模型为 46/50。

表 5　问题一主模型与基线整体性能对比（50 维平均）

方法	QWK	Spear-man	±1 准确率	严格一致率	MAE	RMSE	Pearson	$R^2>0$
LightGBM ＋分维选型	**0.3830**	**0.4109**	**0.5729**	**0.2214**	**1.502**	**1.926**	**0.464**	29/50
KNN 插补＋LightGBM	0.3652	0.4090	0.5605	0.2237	1.564	2.011	0.406	24/50
随机森林	0.3280	0.4089	0.5550	0.2100	1.549	1.960	0.431	26/50
ElasticNet	0.2762	0.3105	0.5081	0.1952	1.720	2.173	0.306	13/50
逐维均值	0.0015	0.0013	0.4273	0.1460	1.869	2.243	−0.008	0/50

为了判断 0.383 相对基线的提升是否为随机波动，本文对同一批 250 个折外预测做 2000 次配对重采样，每次重算主模型与基线的 50 维平均 QWK 并取差；区间取百分位法 2.5%–97.5%，π 为重采样中主模型更优的比例。结果如表 6：三条对比的 95% 置信区间均不跨零，重采样中主模型 2000 次全部更优（$\pi = 1.000$）；对 KNN 插补的增量最小（+0.0177），对 ElasticNet 的增量最大（+0.1065）。

表 6　主模型相对基线的配对 bootstrap 显著性检验

对比	Δ QWK	95% 置信区间	优于比例 π	结论
KNN 插补	+0.0177	[0.0105, 0.0248]	1.000	显著
随机森林	+0.0546	[0.0440, 0.0654]	1.000	显著
ElasticNet	+0.1065	[0.0858, 0.1273]	1.000	显著

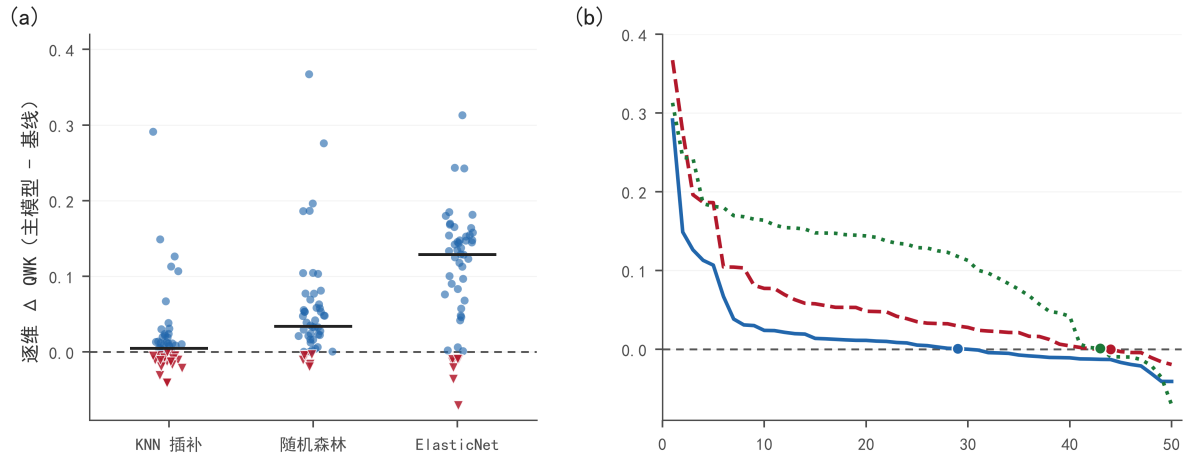


图 7　主模型与三类基线的逐维配对胜负

但均值掩盖了维间差异。图 7 把 50 个维度逐一对照，可见三点：图 7(a) 给出逐维差值分布，图 7(b) 把差值降序累加。其一，胜负并不一致：主模型对 ElasticNet 与随机森林分别胜出 43 与 44 维，对同为原生缺失处理的 KNN 插补只胜出 29 维，即仍有 21 维落后，中位差值仅 +0.005。其二，增益高度集中：与 KNN 相比，29 个胜维的正增量合计 1.184，其中最大的 5 维就占 66.4%，其余维几乎打平（图 7(b) 的曲线在头几维后迅速贴近零线）。其三，落败维的亏幅很小，最差一维也只低 0.041，远小于胜维的最大增益 0.291。因此准确的结论是：缺失感知与非线性建模带来的是**少数维显著改善、多数维持平**，而不是在每个维度上都优于插补基线；50 维主模型指标均不劣于朴素基线，故全部 50 维提交主模型预测。

主模型五项指标均最优：QWK 0.3830、Spearman 0.4109、±1 57.3%、严格一致率 22.1%、MAE 1.502 级；逐维均值基线仅 0.0015，ElasticNet[8-9] 0.2762，随机森林[10] 0.3280。原生缺失 0.3663 略优于 KNN 插补[11] 的 0.3652，方向稳定，说明缺失位置本身携带信息；50 维均不劣于朴素基线，故全部提交。另需说明一处不一致：Pearson 中随机森林（0.431）高于 KNN（0.406）而 QWK 更低——Pearson 只量线性强度、对等级边界错位不敏感，本问交付等级，故以 QWK 与严格一致率为准。

除上述三基线外，本文另测了两条在同类赛题中被推荐的路线，均在同一 5 折划分、同一分箱、同一指标下复算。**PLS2**（多输出偏最小二乘，化学计量学的标准方法，取 5/10/15 个成分）的 QWK 分别为 0.2959 / 0.3584 / 0.3575，最优仍低于主模型 0.024；

XGBoost 7 类 softprob 多分类（取等级期望）为 **0.3832**，与主模型的 0.3830 几乎相同（差 0.0002，在折间波动之内）。这一对照说明：本数据上回归加分箱与直接多分类等价，差别不在模型族而在标签映射方式；本文仍用回归分支，是因为它额外提供连续强度，而问题二的 SHAP 归因与问题三的画像打分都需要连续输出，多分类只能给出等级概率。

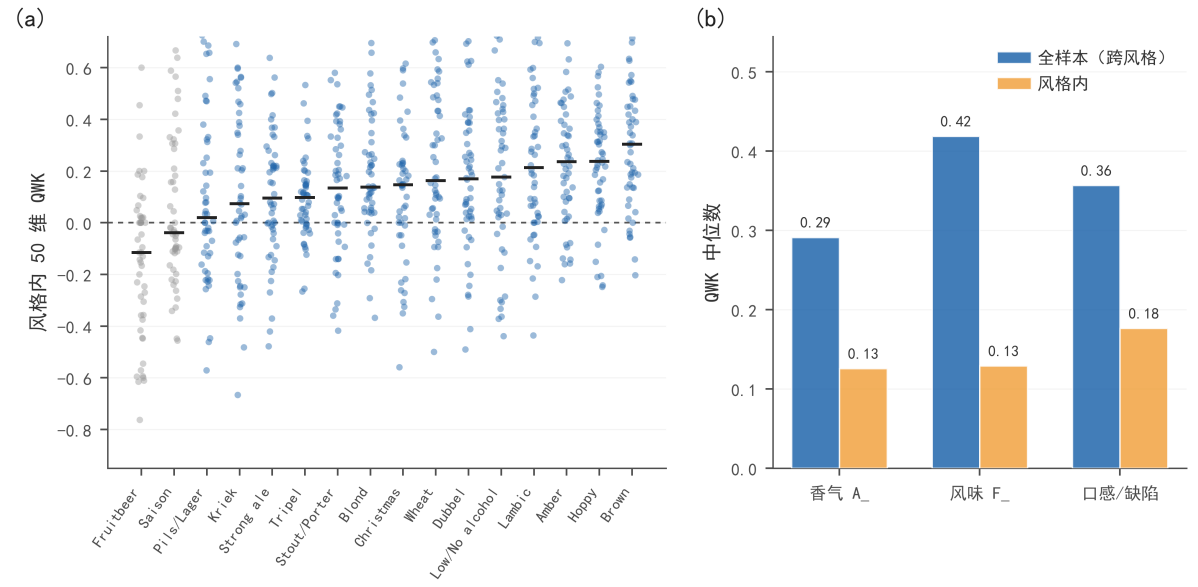


图 8　分风格重算：总体 QWK 中有多少来自跨风格差异

上述 0.3830 是全样本口径。为看清其中的来源（图 8），本文把样本按风格切开，在每个风格内部重算 50 维 QWK（每格 $n \geq 8$），见图 8(a)。16 个可评估风格的风格内 QWK 中位仅 0.135，而全样本中位为 0.325：说明相当一部分分级判别力来自“不同风格整体感官水平不同”这一跨风格成分，风格内部的分辨则明显更难。图 8(b) 按感官组对比：风味组的跨风格增益最大，香气组最小，与 5.2 节化学谱按风格分离的结论一致。这不是对主结果的否定——题面要求的正是对整批样本给出等级预测——但它划清了模型能力的边界：对未知风格内部的新样本，模型的判别力会明显低于表 5 的报告值。

把感官维度按 `A_` 与 `F_` 两个前缀分为香气与风味两组，各 15 维，另 20 维为口感、缺陷与总体评价，分组对比如图 10。

风味组平均 QWK 0.400、R^2 0.222，明显高于香气组的 0.322、0.146。这与化学常识一致：入口的风味更直接由酒精、苦度、酯醇等可仪器测量的化学量决定，而鼻前香气更易受品评时挥发性、温度与主观感受干扰，信噪比更低。

各感官维度的可预测性并不均匀，下面先看单维的排序，再看它们在 R^2-QWK 平面上的联合分布。

图 9(a) 把 50 个维度按折外 QWK 降序排列并给出逐维 bootstrap 区间，全维均值为 0.383，并按可预测性分三档着色：强（QWK ≥0.55）仅 11 维，中（0.30–0.55）18 维，弱（<0.30）21 维。强信号维集中在酒精、苦味、酒体、余味等能直接对应到酒精浓度、

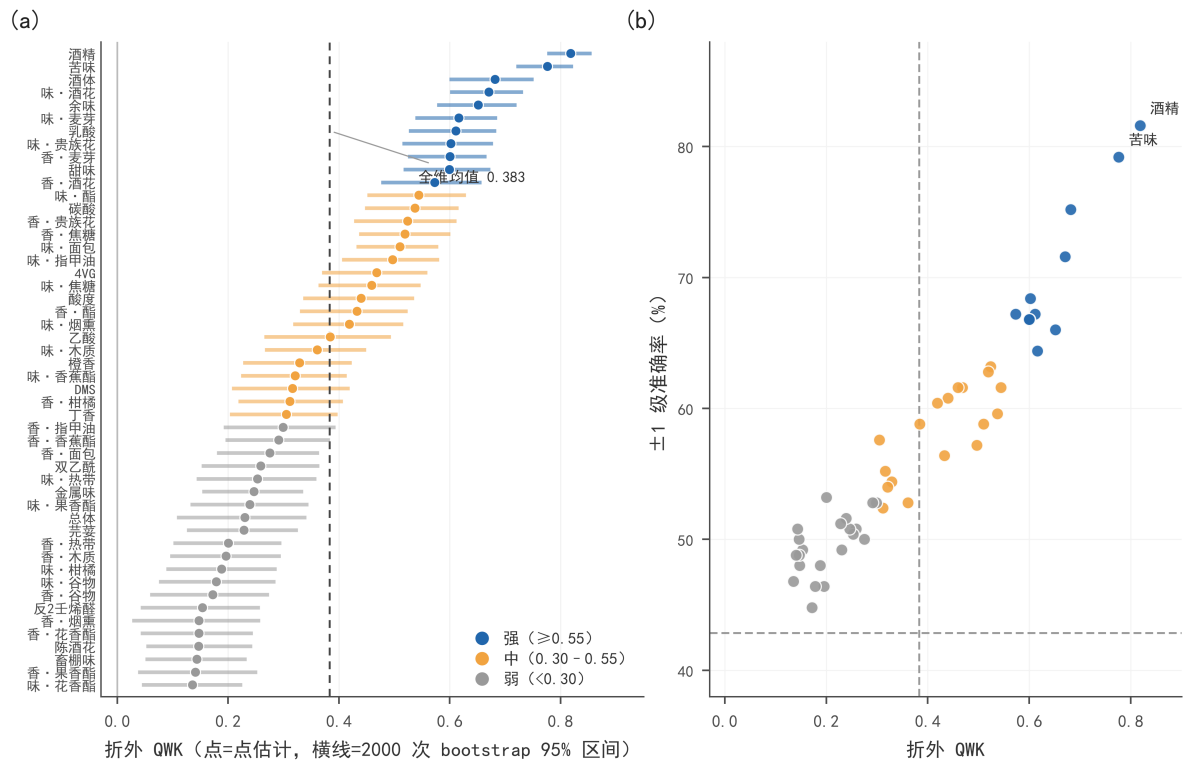


图 9　各感官维度交叉验证 QWK 排序

异 α-酸苦度等实测化学量的维度；而弱信号维集中在花香酯、果香酯等浓度低、检出不稳的化合物上，QWK 接近随机水平。图 9(b) 把 QWK 与 ±1 级准确率联立：即使 QWK 不高的中档维，预测也多数落在真实等级的相邻一级内；而弱信号维不仅 QWK 低，±1 也降到 50% 附近，说明它们的等级分布本身就不易区分。

图 10(a)(b)(c) 分别给出香气、风味、口感缺陷三组的逐维 R^2，点的大小表示该维的 ±1 级准确率（0.40–0.85），红虚线为组内平均 R^2：香气组平均 0.146、风味组 0.222、口感与缺陷组 0.304，三组逐级上升，与 QWK 的分组排序一致。值得注意的是部分维的 R^2 为负而 QWK 仍为正，这是分箱把连续预测的均值偏差吸收掉的结果，也说明两个指标需同时看。

图 9 显示清晰的强弱分化：酒精、苦味、酒体等维 Kappa 超过 0.68，与酒精浓度、异 α-酸苦度等明确化学信号直接挂钩；末端的花香酯、果香酯等维 Kappa 接近 0.14，对应信号近乎噪声。分维 R^2 与 QWK 同步分化；酸度维 R^2 达 0.70 而分级 QWK 仅 0.44，说明连续趋势可预测、映射到 7 级后判别力打折，这是连续回归加单调分箱的固有折损；乳酸维经有序回归校正后两者同时达 0.68 与 0.61，说明该折损在退化维上可部分修复。这一分化既反映各感官属性在化学层面可解释程度的客观差异，也为问题二强信号维归因稳定、弱信号维不稳的结论埋下伏笔。

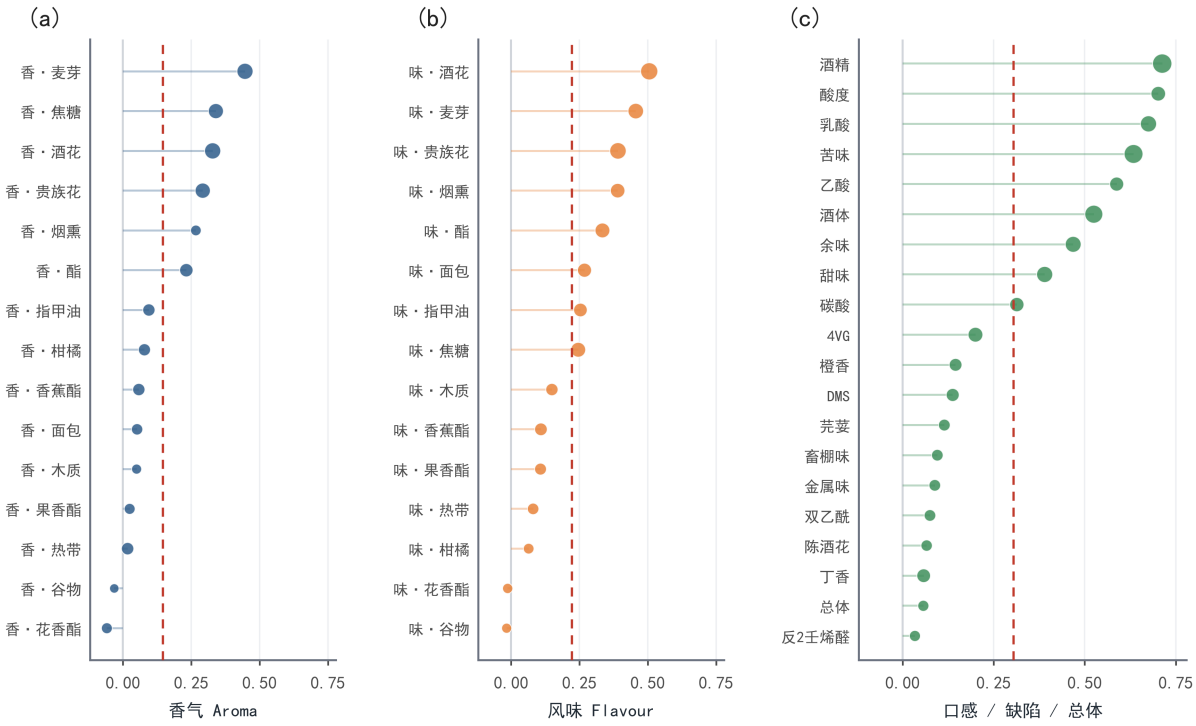


图 10　分组的 R^2 与 ±1 级准确率

表 7　最强 12 维与最弱 4 维的预测性能（QWK / R^2 / Spearman / ±1 准确率）

感官维度	QWK	R^2	Spearman	±1 准确率
酒精（alcohol）	0.819	0.713	0.829	0.816
苦味（bitternes）	0.776	0.634	0.782	0.792
酒体（body）	0.682	0.525	0.728	0.752
味 · 酒花（F_hops_all）	0.670	0.505	0.698	0.716
余味（aftertaste）	0.651	0.468	0.654	0.660
味 · 麦芽（F_malt_all）	0.616	0.456	0.642	0.644
味 · 贵族花（F_hops_noble）	0.602	0.391	0.636	0.684
香 · 麦芽（A_malt_all）	0.601	0.447	0.650	0.668
甜味（sweetness）	0.600	0.390	0.602	0.668
香 · 酒花（A_hops_all）	0.573	0.328	0.583	0.672
味 · 酯（F_esters_all）	0.544	0.334	0.563	0.616
乳酸（lactic）	0.611	0.675	0.494	0.672
… 中间 30 维见支撑材料 …				
香 · 果香酯（A_esters_fruity）	0.141	0.025	0.138	0.488
味 · 花香酯（F_esters_flower）	0.135	-0.013	0.160	0.468
陈酒花（stale_hops）	0.147	0.066	0.227	0.500
畜棚味（barnyard）	0.144	0.095	0.260	0.508

表 7 中酒精维 QWK 0.819、Spearman 0.829、±1 级准确率 0.816，苦味维 QWK 0.776、

Spearman 0.782、±1 准确率 0.792，均属高置信预测；而末端的味 • 花香酯维 QWK 仅 0.135、±1 准确率 0.468，接近随机相邻的水平，与其接近噪声的化学信号一致；芫荽、丁香两维经有序回归校正后分别为 0.228 与 0.305，仍属偏弱一侧。这一梯度提升树最优、按风格分层 5 折、单维可预测性强弱分化的整体格局，与 Schreurs 等[12] 在啤酒化学-感官机器学习研究中报告的化学信号对酒精、苦度等维度预测力强、对细微香料与香气维度预测力弱的发现一致；本文的特征解释以 SHAP 为主、8.xlsx 的树不纯度重要性 MDI 仅作旁证。为进一步核验预测质量，本文对代表维度做了校准检查。

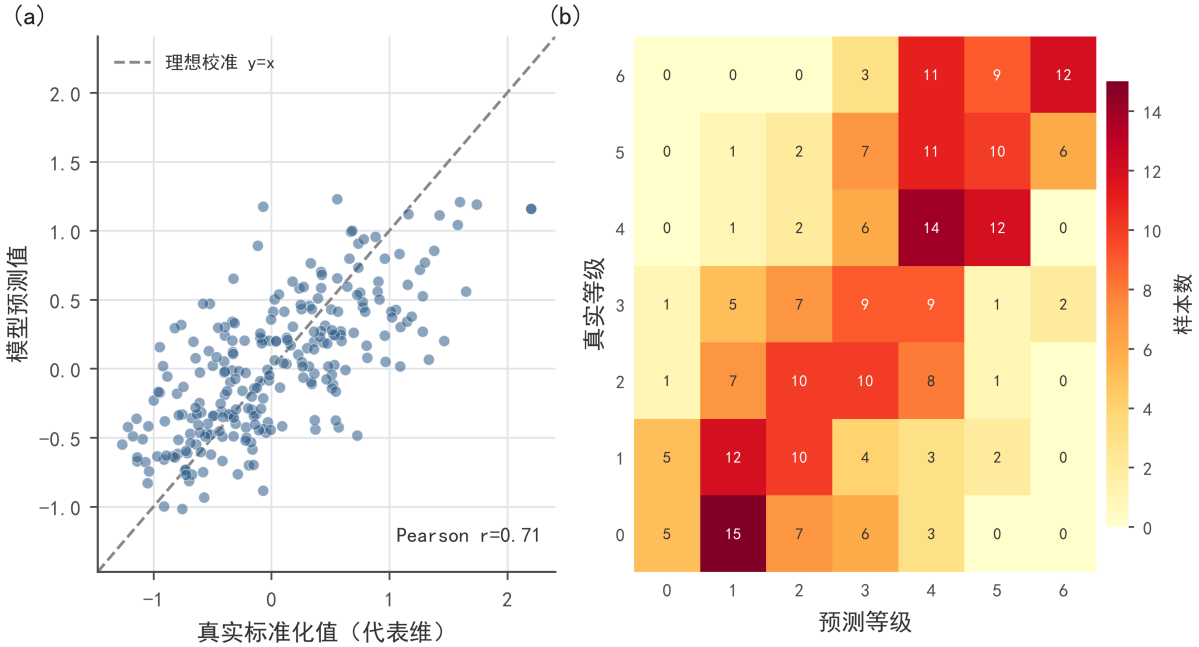


图 11　代表维度预测校准与等级混淆

校准检查的结果见图 11：图 11(a) 的连续预测对实际散点沿对角线聚集、无系统性偏移；图 11(b) 的 0-6 等级的混淆热力集中在主对角线及其相邻带上，说明即便出现误判也多为相邻等级之间的一级偏差，而非跨多级的严重错分。这一校准表现支撑了把连续回归离散为有序等级这一交付方式的合理性，也为后续以该模型作 SHAP 归因与感官画像打分提供了可信前提。

6.5　预测区间与不确定性

点预测无法告诉使用者“这个 4 级有多可信”。本节为每个感官维给出 90% 预测区间，并比较两种口径。第一种是**直接分位数回归**：把 LightGBM 的目标函数换成 $\alpha = 0.05$ 与 $\alpha = 0.95$ 的分位数损失，两个模型分别给出下界与上界。第二种是 **split-conformal**：在每个训练折内再切出 30% 作校准集，用点模型的绝对残差取 $\lceil (n+1)(1-\alpha) \rceil$ 分位作为半宽，对验证折输出对称区间。

结果见**图 12**。直接分位数回归的平均覆盖率为 **75.3%**，显著低于名义的 90%，平均宽度仅 1.025 个标准化单位——区间偏窄，属于典型的**欠覆盖**；这与 250 样本、50 个维

度逐维拟合的设定相符：分位数损失在小样本上对尾部估计不稳，两个分位模型各自独立拟合，误差难以相互抵消。split-conformal 则把覆盖率拉回 **90.2%**、达到名义的 90% 目标，代价是平均宽度增至 **1.555**，即用更宽的区间换取覆盖率的名义保证。分组看，香气 0.902、风味 0.899、口感 0.904，三组基本一致，说明校准并未在某一组上系统性失效。

这一对照也说明了选择 conformal 的理由：它不依赖分布假设，只要求校准集与验证集可交换，在本题这种小样本、逐维多输出的场景下比直接分位数回归更可靠。区间宽度的量级（约 1.55 个标准化单位）也从侧面量化了问题一的固有难度——即便覆盖率达标，单个样本的感官等级仍存在相当的不确定性，这与 MAE 1.50 级的结果相互印证。

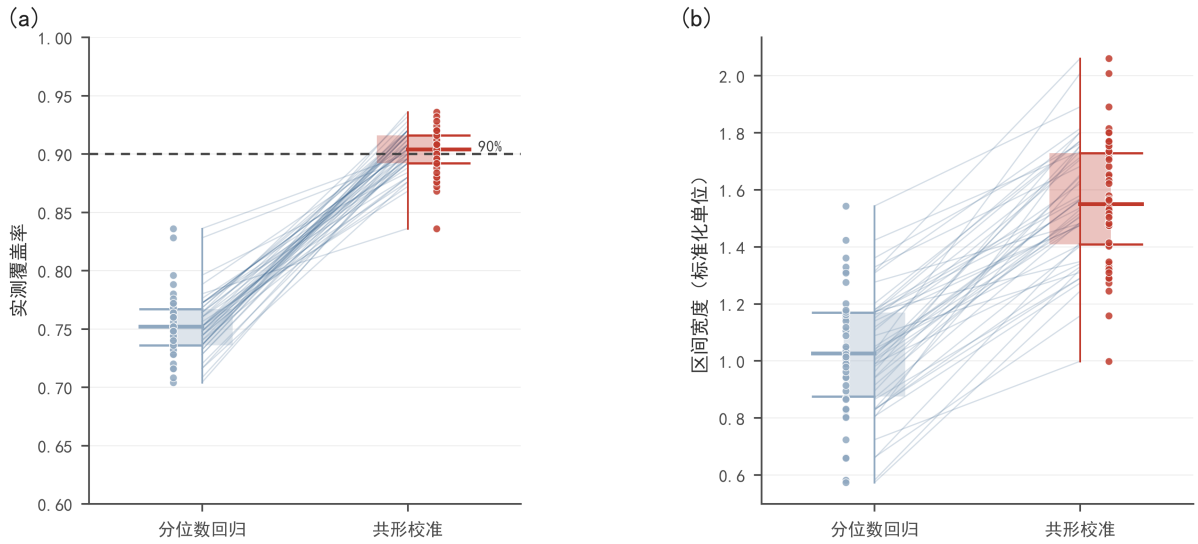


图 12　90% 预测区间的两种口径：覆盖率与宽度

总体覆盖率达标不等于每一维都达标。**图 12** 把 50 个维度逐一铺开：共形口径下的覆盖率落在 0.836–0.936 之间，其中 5 维低于 0.88——香气 • 木质（0.836）、香气 • 焦糖（0.868）、味 • 异丁酸乙酯（0.872）、味 • 酯（0.876）与味 • 果香酯（0.876）；最高的几维是香气 • 乙酸乙酯（0.936）、味 • 热带果（0.932）与畜栅味（0.928）。两口径的逐维中位数分别落在 0.752 与 0.904，几乎每一维都随共形校准上移（50/50 维改善），只是幅度在弱信号维上略小。偏差的方向与信号强度一致：覆盖率偏低的都是弱信号维，其标签分布集中、残差尾部难以由 30% 的校准集稳定刻画；而分位数回归在全部 50 维上都落在 0.704–0.836，从无一维达到名义水平，这也解释了为什么它的总体覆盖率只有 75.3%。

宽度一侧的分化更明显：最宽的是香气 • 酒花（2.060），最窄的是香气 • 木质（0.998），相差一倍。宽度的量级与该维的标签离散度、以及该维在模型中的可预测性同向——弱信号维需要更宽的区间才能覆盖 90% 的样本，这与图 9 的 R^2 排序互为印证。因此本文在交付 0–6 等级的同时，把逐维区间一并给出：使用者对弱信号维的预测应保留更大的不确定性余量。

7 问题二：化合物共表达图与关键化合物归因

7.1 共表达图构建与模块结构

问题二要为每个感官维度找出 Top-3 关键**化合物**，而化合物之间高度相关会干扰归因。为严格贴合找出关键化合物的题意，本文先把 231 个化学特征中的 16 个理化/过程参数（酒精度、色度、pH、苦度、二氧化碳压力、蛋白、甘油、未发酵糖等）与 4 个多化合物汇总列（总酯、酒花香气总量、总酸、含硫总量）排除，仅在 **211 个单一化合物构成的候选集** C（$|C| = 231 - 16 - 4 = 211$）内建图与归因；问题一的特征矩阵仍保留全部 231 列，因为理化指标对预测同样有用。借鉴基因共表达网络的建模思想[13-14]，本文以 C 中化合物为节点、以化合物相关系数为边权构建无向图，并按相关强度阈值化去除弱边：

$$E = \big\{(p,q) :\ p,q \in C,\ |R_{pq}| \geq \rho\big\}, \qquad w_{pq} = R_{pq}, \quad \rho = 0.5,\ |C| = 211. \tag{8}$$

关于相关系数口径：题面称附件 2 为 Pearson，但本文从 1.csv 逐对重算后发现它实际是 **Spearman**——重算的 Spearman 与附件 2 逐元素一致（最大差 7.8×10^{-16}），而同口径 Pearson 的最大差达 1.12、平均绝对差 0.088。故边权即附件 2 的秩相关值，无需换算；7.3 节的建图阈值灵敏度还说明结论对阈值选择不敏感。在所得图上做 Louvain 贪心模块度社区检测[15] 以识别化合物模块，模块度定义为

$$Q_{mod} = \frac{1}{2m} \sum_{p,q} \left(w_{pq} - \frac{k_p k_q}{2m} \right) \delta(c_p, c_q), \qquad k_p = \sum_{q} w_{pq}. \tag{9}$$

在阈值 $\rho = 0.5$ 下，共表达图含 **211 个节点、564 条边**，社区检测得到 **55 个社区**，模块度 $Q_{mod} = 0.625$，远高于随机网络的水平，表明化合物确实存在明显的模块化组织结构。

图 13(a) 中节点按 Louvain 社区着色、面积正比于度数，各社区沿全局质心方向外推后留出空白，主要模块标出枢纽化合物；可见同一酿造来源或同一代谢途径的化合物聚成一个模块，且模块之间有明确分界。图 13(b) 回答孤立节点的来源：以 $\rho = 0.5$ 建图时 44 个化合物没有达到阈值的伙伴，但它们的最大 $|r|$ 中位为 0.444、其中 11 个落在 0.48–0.50，说明孤立主要是硬阈值截断的结果，而非这些化合物与其余 210 个真正无关；阈值降到 0.45 时孤立数即从 44 降到 23。

社区规模分布显示 55 个社区高度不均衡：前 8 个大社区，各有 11–28 个化合物，已包含 159 个节点（约 75%），其余多为 1–2 个化合物的小簇。这一结构正是归因去冗余的依据：若不加约束，同一模块内可互相替代的化合物会把一个维度的 Top-3 名额占满，掩盖真正多样的驱动因素。因此下一步的关键度打分必须引入模块代表机制。在融合模型证据之前，先看化学与感官之间最直接的线性关联。

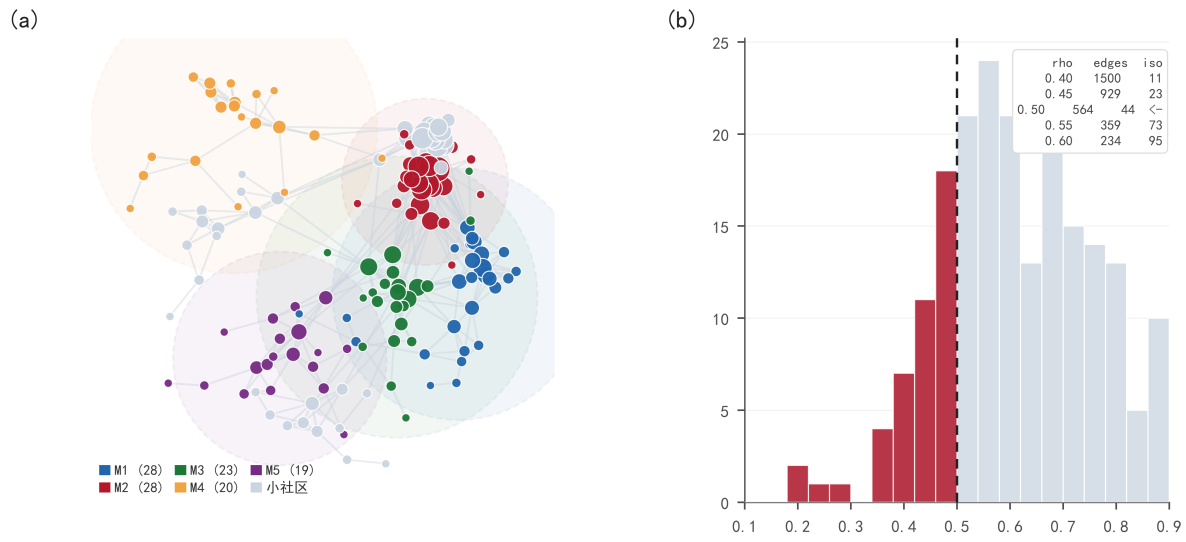


图 13　共表达网络的模块结构与孤立节点成因

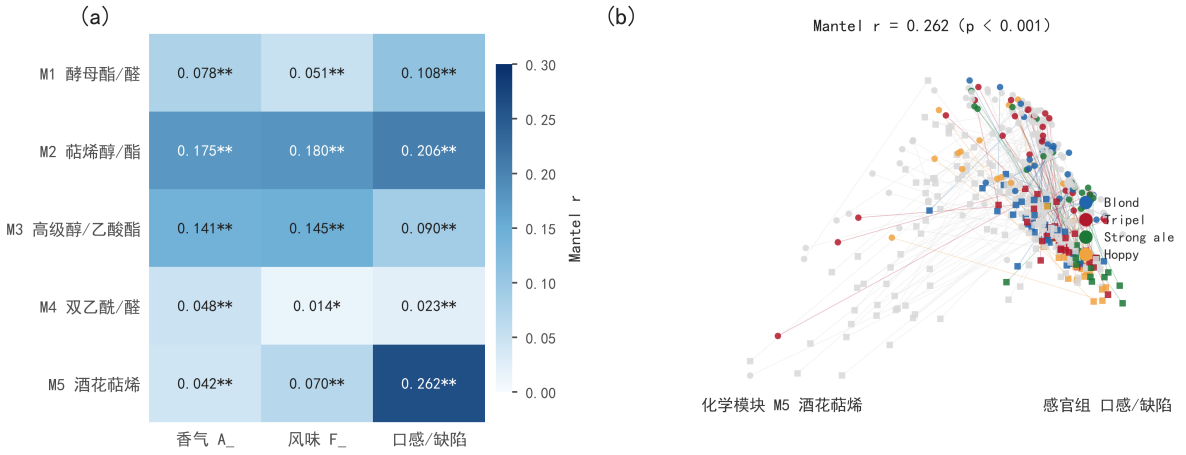


图 14　化学模块与感官组的 Mantel 关联

模块归属若只是算法产物，就不该与感官有系统关联。图 14 对 5 个 Louvain 大模块与三组感官分别做 Mantel 检验（各 999 次置换）：相关系数 0.014–0.262，全部 $p < 0.05$。最强的是 M5（酒花萜烯）与口感缺陷组（$r = 0.262$）；M2（萜烯醇/酯）对三组较均衡（0.175–0.206），承载整体风味强度；M4（双乙酰/醛）与香气组仅 0.048，与该模块检出稀疏一致。这一层补上了“整谱可分”与“单化合物相关”之间的空白。

两类混杂需要分别剥离，彼此不能替代。第一类是**风格间差异**：本文对每个风格先减去风格内均值，再对 44 化合物 × 50 感官的 2200 个配对重算 Spearman——全样本相关中位绝对值 0.113，去风格均值后降至 0.065，两者相关 0.649、符号一致率 70.8%，$|r| \geq 0.3$ 的配对由 251 个减到 36 个。第二类是**酒精度这一全局混杂因子**：乙醇既是发酵产物，又与麦芽汁浓度、酯醇生成共同变化，会把与之无关的化学-感官关联一同抬高。本文以乙醇为控制变量，对同一 2200 个配对计算偏 Spearman（对三者的秩做线性残差化后再求相关）：中位 $|r|$ 由 0.113 降至 **0.084**，$|r| \geq 0.3$ 的配对占比由 11.4% 降至 **4.3%**，

符号一致率 83.7%。分化合物看，收缩的程度恰好刻画了“是否被酒精度带出来”：乙醇自身与酒精、酒体的相关（0.817、0.719）在控制乙醇后几乎归零（-0.026、-0.013），属于同义重复；甘油—酒精由 0.625 降至 0.066、己酸乙酯—酒精由 0.619 降至 0.036，同样是酒精度驱动的表面关联；而**异 α-酸—苦味仅从 0.682 降到 0.646**、辛酸乙酯—苦味从 0.593 降到 0.401，方向与量级基本保留，说明它们是独立于酒精度的真实化学信号。这一结论直接支撑 7.5 节的来源判定：麦芽维 Top-3 落在酵母酯醇上，并非因为酯醇与麦芽香气有独立关联，而是二者都随发酵强度（含乙醇）同向变化——剔除酒精度后这些关联大幅收缩，正说明它们只是统计代理。

把相关矩阵按 Louvain 模块重排后，五个模块在对角线上形成成片的高相关方块：块内 $|r|$ 中位 0.353，块间仅 0.143，相差 2.47 倍。这直接解释了 Top-3 为何必须做模块去冗余。

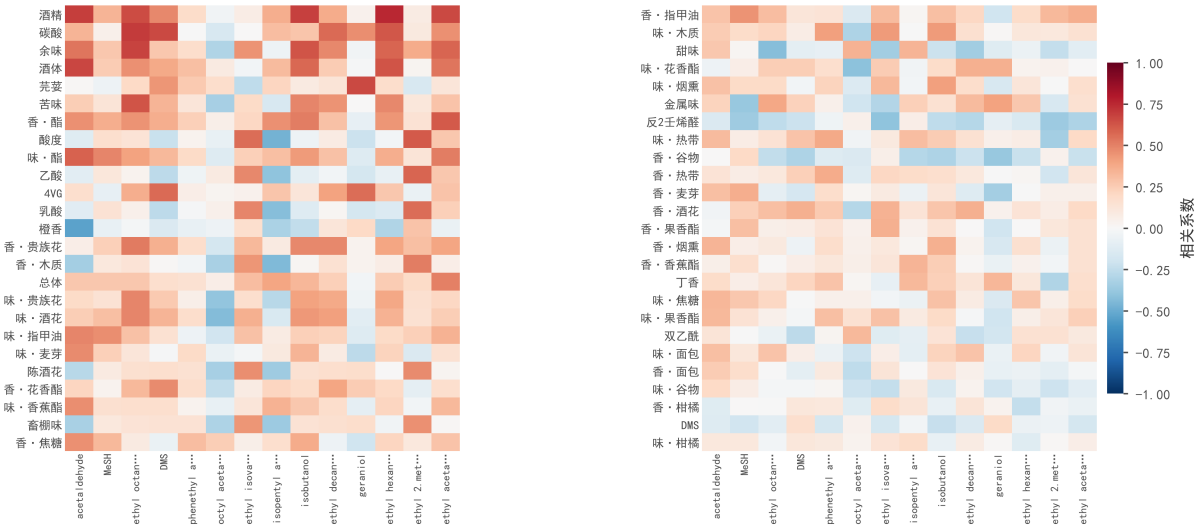


图 15　代表性化合物与 50 个感官维的交叉相关

图 15 把 14 个代表性化合物对 50 个感官维的线性关联铺在一张热力图上，行按各维最大绝对相关降序排列，香气、风味与口感缺陷三组共用同一色标与同一化合物列序，可逐列对照。主带清楚：酯类化合物与果香、酒花类维度呈较强正相关，硫化物与蔬菜硫味维度相关显著，这些条带状的强相关区域与酿造机理高度吻合，构成归因的线性证据一路。但线性相关无法捕捉非线性贡献，也无法识别共线性冗余，故需与模型的非线性归因联合使用。

7.2　多证据融合 Top-3 归因

对每个感官维度 j，本文融合三类证据给化合物 p 打关键度分：

$$\phi_{jp} = \alpha\,\widetilde{\mathrm{SHAP}}_{jp} + \beta\,\left|\tilde{C}_{pj}\right| + \gamma\,\mathrm{rep}_{jp}, \qquad \alpha+\beta+\gamma = 1. \tag{10}$$

其中 $\widetilde{\mathrm{SHAP}}_{jp}$ 是问题一模型对维度 j 的归一化 SHAP 值，刻画非线性预测贡献；$\tilde{C}_{pj}$

是化学与感官交叉相关的归一化绝对值，刻画线性关联；rep_{jp} 是模块代表加权，使同模块内多个可互替化合物只保留关键度最高者进入候选，避免 Top-3 被单一模块占满，这一簇代表的思路与稳健特征选择中的聚类代表方法一致[16]。按权重 $\alpha = 0.5, \beta = 0.3, \gamma = 0.2$ 取每维得分前三者：

$$\mathrm{Top3}(j) = \arg\operatorname*{top3}_{p}\ \phi_{jp}. \tag{11}$$

SHAP 值通过对问题一全量梯度提升模型使用树解释器逐样本计算得到，权重 α 最大体现了以预测贡献为主、相关与去冗余为辅的归因哲学。去冗余规则可写成筛选算子：设已入选集合为 $\mathcal{S}_j$，候选 p 同社区内已有强相关成员时被剔除，

$$\mathcal{A}_j = \Big\{ p \in C :\ \nexists\, q \in \mathcal{S}_j \text{ s.t. } c_p = c_q \neq -1,\ |R_{pq}| \geq 0.7 \Big\}, \tag{12}$$

于是贪心选取等价于在剩余候选上反复取最大，直至满 3 席：

$$\begin{aligned} p^{\star}_{j1} &= \arg\max_{p \in \mathcal{A}_j} \phi_{jp}, \\ p^{\star}_{j,m+1} &= \arg\max_{p \in \mathcal{A}_j \setminus \{p^{\star}_{j1}, \ldots, p^{\star}_{jm}\}} \phi_{jp}, \quad m = 1, 2, \end{aligned} \tag{13}$$

强制 Top-3 来自相互独立的化学证据，而非三个彼此近似的共表达冗余物，每个维度恰好交付 3 个化合物。证据分级再把每个候选 p 映射到 A/B/C 三档：

$$\mathrm{grade}_{jp} = \begin{cases} \mathrm{A}, & \sum_{m=1}^{4} \mathbb{1}\big[\text{条件}m\ \text{满足}\big] = 4, \\ \mathrm{B}, & \sum_{m=1}^{4} \mathbb{1}\big[\text{条件}m\ \text{满足}\big] = 3, \\ \mathrm{C}, & \text{否则}, \end{cases} \tag{14}$$

四个条件依次为 $f_{jp} \geq 0.8$、该维折外 $R^2 > 0$、条件增量在 5 折中至少 3 折为正、条件增量超过同维随机列置换的 95% 分位。

7.3 稳定性量化

阈值 ρ 不是随手取定的常数。图 16(a) 显示边数随 ρ 单调塌缩：0.40 时 1500 条边、最大分量 200 节点，0.60 时只剩 234 条边、86 节点；图 16(b) 给出另一侧代价：孤立节点从 11 升到 95，而模块度在 0.55–0.60 才见顶（0.684、0.704）后回落。ρ=0.5 是折中点：保留 159 节点的连通骨架、模块度 0.625。本文据此固定 ρ=0.5。

稳定性严格按题面指定的两种口径量化。第一种是 bootstrap 入选频率[17]：对样本做 $B = 500$ 次**按风格分层**的有放回重采样（样本量少于 5 折的风格合并为 `_rare` 一层，避免小风格被抽空），每次重算 Top-3，统计化合物 p 进入维度 j 的 Top-3 的频率

$$f_{jp} = \frac{1}{B} \sum_{b=1}^{B} \mathbb{1}\big[p \in \mathrm{Top3}^{(b)}(j)\big] \in [0, 1]. \tag{15}$$

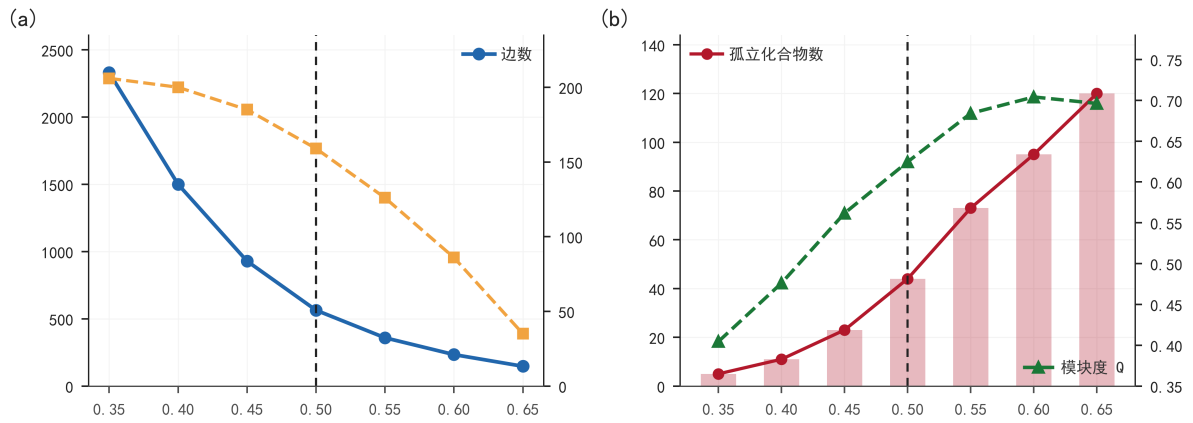


图 16　建图阈值 ρ 的灵敏度：边数、孤立节点与模块度的取舍

为确认 $B = 500$ 已收敛，本文另在 200 次与 300 次处设检查点：三个规模下 Top-1 频率均值为 0.9996/0.9997/0.9997，相对最终结果的 Top-1 选择**改变 0 维**，说明 500 次已充分稳定。

第二种是跨方法 Jaccard：对 SHAP 法交叉相关法随机森林重要性法三类方法两两比较其 Top-3 集合，

$$\mathrm{Jac}(A,B) = \frac{|A \cap B|}{|A \cup B|} \in [0,1]. \tag{16}$$

入选频率高说明单一方法内部稳健，Jaccard 高说明不同证据之间一致。为回答这样的稳定性是否显著优于随机，本文还构造了随机基线：在 211 个化合物集 C 上随机抽取 3 个作为 Top-3，重复 100000 次，计算随机 Top-3 与固定参照的 Jaccard 期望。两指标的全维分布如下图。

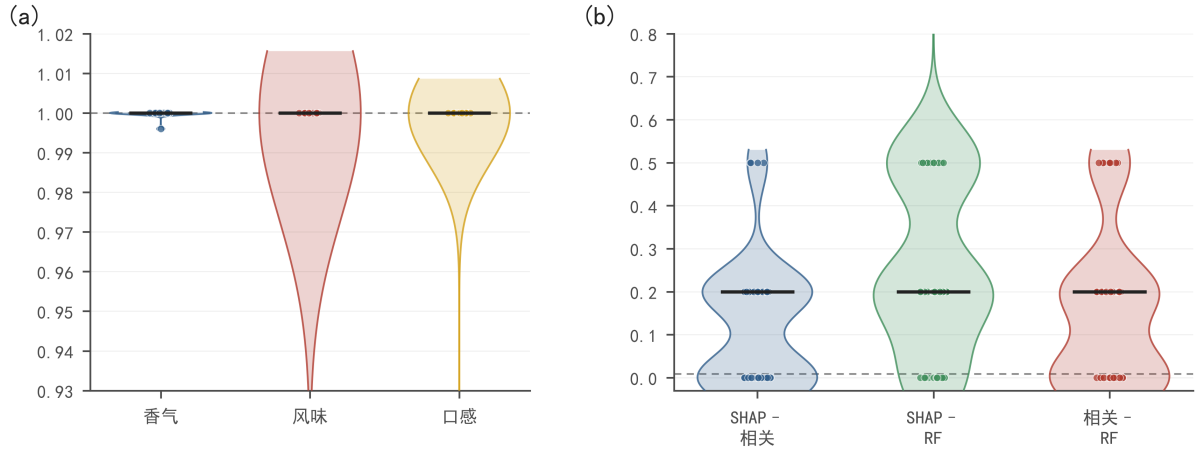


图 17　单方法稳定性饱和与跨方法一致性分散

图 17(a) 是单方法稳定性：把 50 个维度按香气、风味、口感缺陷三组排开，Top-1 入选频率几乎全部压在 1.000（47/50 维恰为 1.000、三组中位数均为 1.000），说明单方

法内部的 Top-1 选择极其稳健，饱和到在小提琴图上已经看不出组间差别。图 17(b) 换到跨方法一致性：三对方法的逐维 Jaccard 中位数都是 0.200，均值分别为 0.128、0.274、0.156，整体均值 **0.200**，即三类证据的 Top-3 集合平均约两成重叠。作为参照，10 万次随机抽取的 Jaccard 期望仅 **0.0086**，本文 0.200 是随机基线的 **23.3 倍**——三类证据视角互补、绝对 Jaccard 不高，但相对于随机抽取已高度显著，归因绝非偶然。这一高入选频率、中等 Jaccard、远高于随机的组合恰如实反映了 SHAP、线性相关与共表达三类证据侧重不同、各自内部稳定而彼此互补，而非虚高的一致。

全部 150 个上榜配对的入选频率中位数为 **1.000**、均值 0.960，其中 138 个（92.0%）不低于 0.8，106 个（70.7%）在 500 次重采样中每次都入选。抽样设计与候选集规模与同类研究不同，此处只作量级参照。

Jaccard 均值掩盖了”不一致”的形态。把三法 Top-3 集合逐维拆开比对后：三法有共同候选 21 维、两对各自重合 6 维、仅一对重合 16 维、完全互斥 7 维。可见一致性偏低主要来自第三种视角带进新候选，而非三法彼此无关，这正符合三路融合的设计意图。

为便于在稀疏的 Top-3 中判断哪个名次最先失稳，本文把三个名次的入选频率并排展开，见图 18。

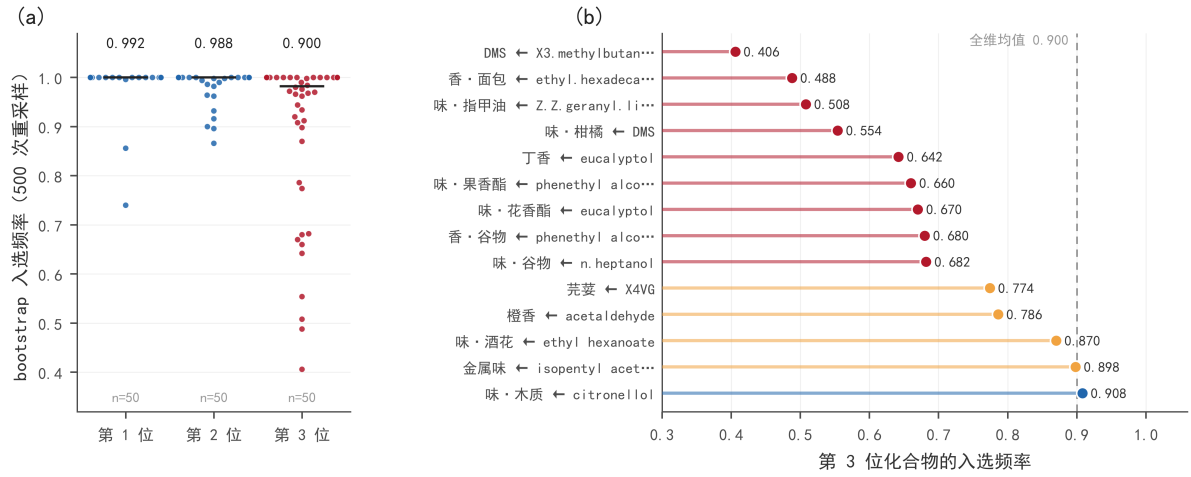


图 18　三个名次的 bootstrap 入选频率与其分化

图 18(a) 把 50 个维度在三个名次上的入选频率并排铺开，图 18(b) 单独列出最不稳的 14 维及其第三名化合物。第 1 位的平均入选频率为 0.992、其中 47/50 维恰为 1.000，第 2 位为 0.980，两者几乎饱和；真正区分维度的是第 3 位，平均 0.900、最低仅 0.406（DMS），其次是香 • 面包（0.470）与味 • 醋酸酯（0.506）。图 18(b) 把这批维度的第三名化合物一并写出，可见其成分在各维之间互不相同、缺乏共同的化学主题，说明弱信号维的“第三名”只是在一批可以互换的化合物中随机胜出；而强信号维的三个名次都接近 1.0，其 Top-3 集合本身是稳定的。

为检验“弱信号维不可预测”与“弱信号维归因不稳”是否为同一现象，本文把 50 个维度同时放到（问题一 QWK，问题二 Top-1 入选频率）平面上。两者相关系数仅

$r = 0.101$，说明可预测性与 Top-1 稳定性基本是两个独立维度：QWK 低的维度其 Top-1 仍可能 100% 稳定地选中同一化合物，只是这个化合物与目标感官的关联本身微弱。真正随可预测性变化的是第 3 名：弱信号维（QWK <0.30）的第 3 位入选频率中位数明显低于强信号维，说明弱信号维的“第三名”才是在一批可互换化合物中随机胜出的位置。这一分化也解释了表 9 中 A/B/C 分级为何多在第一名为 A、第三名落 B 或 C。

各维度的融合重要度热力进一步揭示关键化合物的分布，见图 19。



图 19　感官维与关键化合物的融合重要度热力

图 19 的融合重要度热力图把代表性感官维度对关键化合物的重要度平铺展开，热点并非均匀散布，而是集中在少数几个化合物列上——癸酸乙酯、乙醛、乙酸乙酯、异丁酸乙酯、二甲基硫醚等酵母酯、醇、醛类反复成为多个维度的关键驱动。由于候选集已限定为 211 个单一化合物，酒精度、苦度、色度、蛋白等理化/汇总列不再出现在 Top-3 中，归因结果严格回应找出关键化合物的题意。代表性维度的 Top-3 清单、稳定性指标与来源类别判定汇总见表 8，其中频率为 500 次 bootstrap 的 Top-1 入选频率，Jaccard 取三类方法两两均值，来源判定按 Top-3 是否落在期望来源类别。

7.4　融合增益消融与归因集中度

7.2 节的三路融合建立在两个未经检验的假设上：共表达模块代表的引入能让 Top-3 覆盖更多化学模块，以及三类证据的结合优于任一单方法。本节对这两个假设做消融，并进一步考察 Top-3 结果在维度间的集中程度。

表 8　代表性感官维度 Top-3 关键化合物、稳定性与来源类别判定（仅化合物集 $C = 211$）

感官维度	Top-1	Top-2	Top-3	Top-1 频率	Jaccard	期望来源	判定
酒精	ethyl_ octanoate	acetaldehyde	MeSH	1.000	0.400	Yeast	一致
苦味	ethyl_ octanoate	MeSH	DMS	1.000	0.667	Others	不一致
酒体	isobutanol	ethyl_ octanoate	MeSH	1.000	0.133	Unknown	不一致
味 · 酒花	ethyl_ octanoate	DMS	ethyl_ hexanoate	1.000	0.400	Hops	不一致
余味	ethyl_ octanoate	acetaldehyde	ethyl_ isovalerate	1.000	0.400	Unknown	不一致
味 · 麦芽	acetaldehyde	MeSH	ethyl_ decanoate	1.000	0.200	Malt	不一致
味 · 贵族花	ethyl_ octanoate	ethyl_ hexanoate	DMS	1.000	0.300	Hops	不一致
香 · 麦芽	acetaldehyde	octyl_acetate	MeSH	1.000	0.167	Malt	不一致
甜味	ethyl_ decanoate	octyl_acetate	alpha. humulene	1.000	0.200	Others	不一致
香 · 酒花	ethyl_ octanoate	DMS	linalool	1.000	0.200	Hops	部分一致
味 · 酯	ethyl_acetate	phenethyl_ alcohol	acetaldehyde	1.000	0.400	Yeast	一致
碳酸	ethyl_ octanoate	ethyl_ hexanoate	MeSH	1.000	0.500	Yeast	一致

消融实验保持去冗余规则、候选集 C 与 Top-3 基数完全不变，只替换证据来源，构造四个变体：仅 SHAP、仅交叉相关、SHAP 与相关两路融合，以及本文采用的三路融合。评价指标取“模块覆盖数”，即某一变体的 Top-3 落在多少个互不相同的 Louvain 社区内；覆盖数越高，说明选出的三个化合物越来自不同的化学模块，去冗余的意图越得到落实。

图 20(a) 把 150 个 Top-3 席位按化合物归并，累计曲线显示：仅 4 个化合物（acetaldehyde、MeSH、ethyl octanoate、DMS）就占据了 32% 的席位，而其余 26 个化合物各只出现一次。图 20(b) 把席位按化合物来源拆开，并与各感官维的期望来源对比：酵母代谢产物占了约 60% 的席位，而各感官维的期望来源中酵母仅占 24%；反之，麦芽来源的席位仅占 9%，而期望来源为麦芽的维度占 20%。这一偏离与后文的来源一致性检验相互印证：模型倾向于选出丰度高、检出稳定的酵母酯醇，而麦芽焙烤类化合物在成品中检出稀疏，难以在排序中进入前三。

三路融合的模块覆盖数为 2.92，接近满分 3，比仅用相关高出 27.0%，也比仅用 SHAP 高出 12.3%。这说明模块代表项确实在做它该做的事：若只依赖 SHAP，同一共表达模块里高度相关、可以互相替代的化合物会把 Top-3 名额占满；引入模块代表与同社区去冗余后，三个席位更可能分属不同化学证据。需要注意的是，仅 SHAP 的 Top-1 覆盖了 34 个不同化合物，看似更“分散”，但其 Top-3 的模块覆盖仅 2.60，说明这种分散来自对同一模块内不同成员的反复选择，而非跨模块的多样化。仅用交叉相关的覆盖

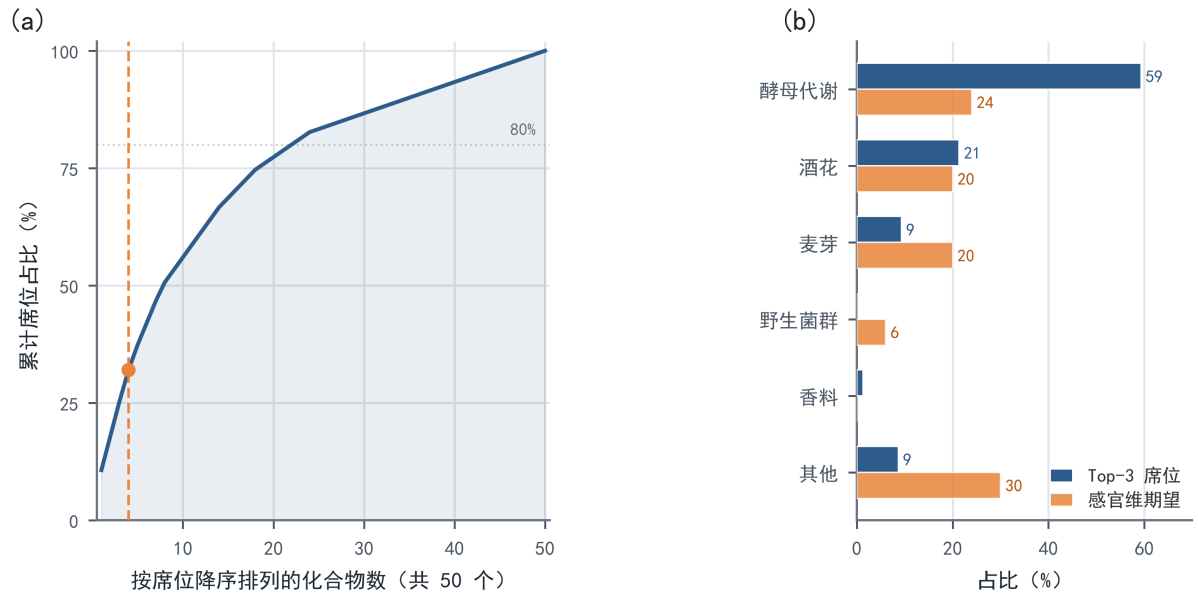


图 20　Top-3 归因的席位集中度与来源构成

最低（2.30），反映线性相关更容易被整体丰度共变主导。

接着考察归因结果在维度之间的集中程度。50 个维度共使用了 50 个不同的 Top-1 化合物，但分布极不均衡：acetaldehyde 出现在 16 个维度的 Top-3 中，MeSH 12 次、ethyl_octanoate 10 次、DMS 10 次；另一方面，26 个化合物只进入过 1 个维度。前四个化合物合计占据了 150 个 Top-3 席位中的 48 个。

这种集中有两种可能解释：一是这些化合物是多个感官维度共享的真实驱动，二是它们只是整体风味强度的统计代理，因与某些维度共同变化而被动入榜。为区分二者，本文计算每个维度 Top-1 化合物与 overall 维度的相关性：中位 $|r|$ 为 0.228，属于中等偏弱。若集中完全由整体强度造成，Top-1 应普遍与 overall 高度相关；实测的中等相关水平说明整体强度只能解释一部分集中现象，剩余部分应归因于化合物与特定感官维度的实质关联。这与 7.3 节的结果相互印证：Top-1 的 bootstrap 入选频率在 47/50 维上恰为 1.000，说明这些选择在重采样下高度稳定，并非偶然的共变假象。

本文把证据分级推广到全部 50 维、150 个候选，并按 benchmark 的四条件严格判定：（i）bootstrap 入选频率 ≥ 0.8；（ii）该维的折外 $R^2 > 0$；（iii）逐折条件增量在 5 折中至少 3 折为正；（iv）条件增量超过同维随机列置换的 95% 分位。四条全满足为 A，满足三条为 B，其余为 C（表 9 摘录六个代表维度）。结果为 **101 个 A、42 个 B、7 个 C**；50 个维度的第一名中 42 个为 A、8 个为 B，而 C 级全部落在 R^2 为负或条件增量未超零分布的候选上（如 A_esters_flower 的 geraniol、orange 的 acetaldehyde）。这说明” 第一名可作关键化合物、第三名需谨慎” 这一结论在全维范围内成立，而不只是六个代表维度的特例。完整 150 条分级见附录表 A.6，表 9 仅摘录六个代表维度。

150 个席位背后只有 50 个化合物，角色并不相同（图 20）：18 个是覆盖 ≥3 维的跨维枢纽（acetaldehyde、MeSH、ethyl octanoate、DMS 各覆盖 10 维以上），26 个只出现

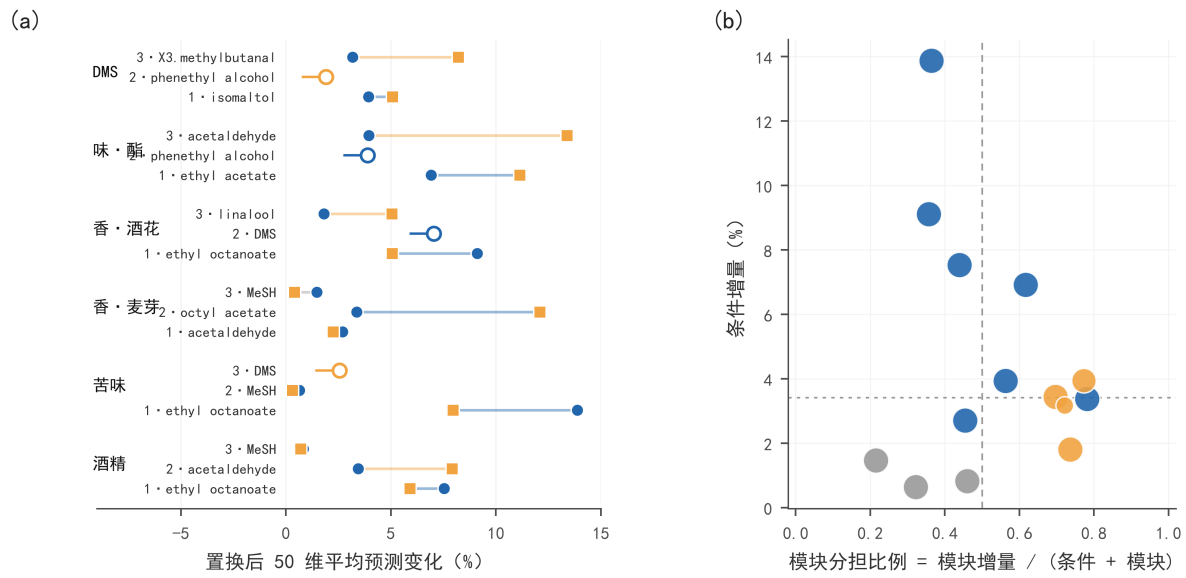


图 21　条件增量与模块增量：独立驱动或模块内替代

表 9　Top-3 候选的 A/B/C 证据分级（六个代表维度）

维度	名次	化合物	入选频率	条件增量	模块增量	分级
酒精	1	ethyl_octanoate	1.000	0.0345	0.0107	A
酒精	2	acetaldehyde	1.000	0.0075	0.0209	A
酒精	3	MeSH	1.000	0.0004	0.0003	B
苦味	1	ethyl_octanoate	1.000	0.0764	0.0218	A
苦味	2	MeSH	1.000	0.0003	0.0000	B
苦味	3	DMS	1.000	0.0029	—	A
香・麦芽	1	acetaldehyde	1.000	0.0056	0.0022	B
香・麦芽	2	octyl_acetate	1.000	0.0060	0.0460	A
香・麦芽	3	MeSH	1.000	0.0017	0.0001	B
香・酒花	1	ethyl_octanoate	1.000	0.0463	0.0118	A
香・酒花	2	DMS	1.000	0.0267	—	A
香・酒花	3	linalool	1.000	0.0029	0.0103	A
味・酯	1	ethyl_acetate	1.000	0.0367	0.0625	A
味・酯	2	phenethyl_alcohol	0.998	0.0103	—	A
味・酯	3	acetaldehyde	0.962	0.0136	0.0945	A
DMS	1	isomaltol	1.000	0.0135	0.0175	A
DMS	2	phenethyl_alcohol	1.000	0.0035	—	A
DMS	3	X3.methylbutanal	0.406	0.0098	0.0447	B

一次。后者并非不重要，而是在单一维度上不可替代、与其他维度不共变。

为区分“独立驱动”与“模块内可替代”，本文对 150 个候选各做两组置换：条件增量为单独打乱该化合物后的均方变化，模块增量为打乱其所在 Louvain 社区全部成员后的变化；两者均除以标签方差归一化，并各取 2.5%/97.5% 分位区间描述随机性。图 21(a) 把两者成对画出，连线越长说明作用越依赖同模块协同；图 21(b) 以“模块分担比例”为横轴重排，左上为独立驱动型、右下为模块内可替代者。酵母酯醇类（ethyl octanoate、ethyl acetate）两项增量同时较大而分担比例居中，兼具独立贡献与共表达支持；MeSH、DMS 等单点模块成员的模块增量无法定义，以空心圆标出，只能依赖条件增量与跨方

法一致性判断可信度。

7.5 化学合理性论证

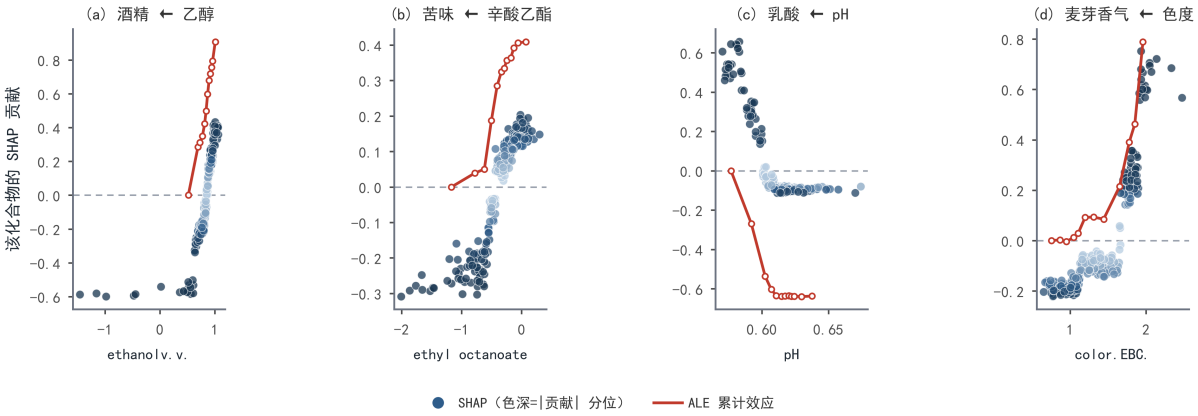


图 22　关键化合物的局部非线性响应（SHAP 与 ALE）

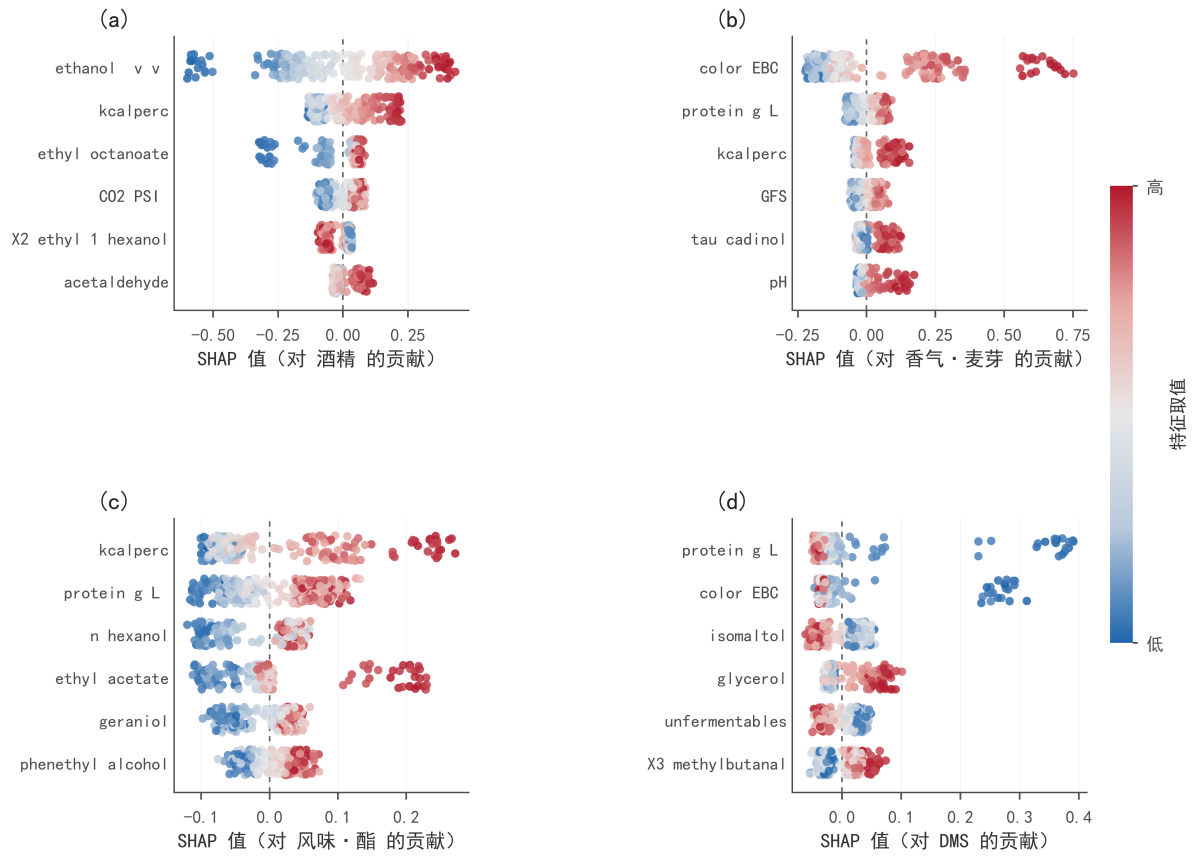


图 23　四个代表维度的 SHAP 蜂群：方向与量级

热力图与重要度排序只给强度，不给方向。图 23(a)–(d) 把 250 个样本逐点画出：横轴是该化合物的 SHAP 值，颜色是其自身取值高低。酒精维由乙醇主导（平均 |SHAP| 0.217），高乙醇样本几乎全在右侧；麦芽香气维由色度主导（0.201），深色点集中在高

色度样本，符合美拉德产物随色度上升的常识。而酯维的前几位是 kcalperc、protein 这类理化量而非具体酯，DMS 维同样由 protein、色度主导。这与 7.5 节的来源审计一致：检出不稳的维度上，模型只能借助稳定的理化代理量。

上述结论均基于全局重要度，而同一化合物在不同浓度区间的作用方向可能相反。图 22(a)–(d) 以四个代表维度为例，横轴为该化合物的实测浓度、纵轴为它对目标维度的 SHAP 贡献，红色曲线为 ALE 累计效应[18]。乙醇对酒精、色度对麦芽香气、辛酸乙酯对苦味均呈单调上升，符合官能强度随浓度增加的预期；而 pH 对乳酸维度在低 pH 端为正、随后转负，是真正的方向反转，属于局部非线性效应、单一线性归因无法表达的部分。

Top-3 结果需经得起酿造机理的检验。方法学上最具说服力的一例是酯香维度：异戊酯香气维 A_esters_isoaa 对应香蕉味，其 Top-1 关键化合物正是 isopentyl_acetate，即异戊基乙酸酯，它恰恰是公认的香蕉味酯，其 Top-3 三者，即异戊基乙酸酯、正己醇、苯甲醛，均为酵母发酵产物、bootstrap 频率均为 1.0、来源判定为一致；指甲油味酯维 A_esters_ethac 的 Top-1 是 ethyl_acetate，即乙酸乙酯与指甲油气味的主体，同样机理一致。这说明在因果清晰的维度上，数据驱动的归因确实命中了正确的分子。

为系统检验而非只举成功个例，本文借助 8.xlsx 的 Sensory thresholds 表对每个化合物标注来源，分为酵母、酒花、麦芽、香料、野生菌群、其他，按感官类别推断每个感官维的期望来源，逐维判定 Top-3 属于一致、部分一致还是不一致：三者全部来自期望来源为一致，至少一个来自期望来源为部分一致，无一个来自期望来源为不一致，并入图 24 的桑基图汇总感官类别到化合物来源的流向。

表 8 显示来源完全一致 6 维（12%，集中在酯香、酒精等酵母主导维度）、部分一致 17 维、不一致 27 维。最显眼的错位是麦芽感官：香/味麦芽的 Top-3 几乎全是乙醛、DMS、癸酸乙酯等酵母产物。原因有二：吡嗪、糠醛等麦芽焙烤香气物在成品酒中检出稀疏（阈值表标注麦芽来源仅 24 个），候选集 C 内缺稳定可选分子；而酵母酯醇丰度最高、最稳定，成为与麦芽甜香共变最强的可测载体——是统计代理而非直接分子。这类不一致是发酵后风味载体的真实反映，分离因果仍需受控实验（见 10.2 节）；弱信号维来源更分散，其可预测性本就接近噪声，两问结论互相印证。

8 问题三：风格条件生成与跨风格迁移

8.1 条件变分自编码器

问题三要学习一个以风格为条件的化学谱生成模型，并在小样本下保持风格可区分。本文采用条件变分自编码器[19]：编码器 $q_\phi(z \mid x, s)$ 把 231 维化学谱连同风格条件压缩进低维隐空间，解码器 $p_\theta(x \mid z, s)$ 从隐变量与风格条件重建化学谱。模型最大化证据下界

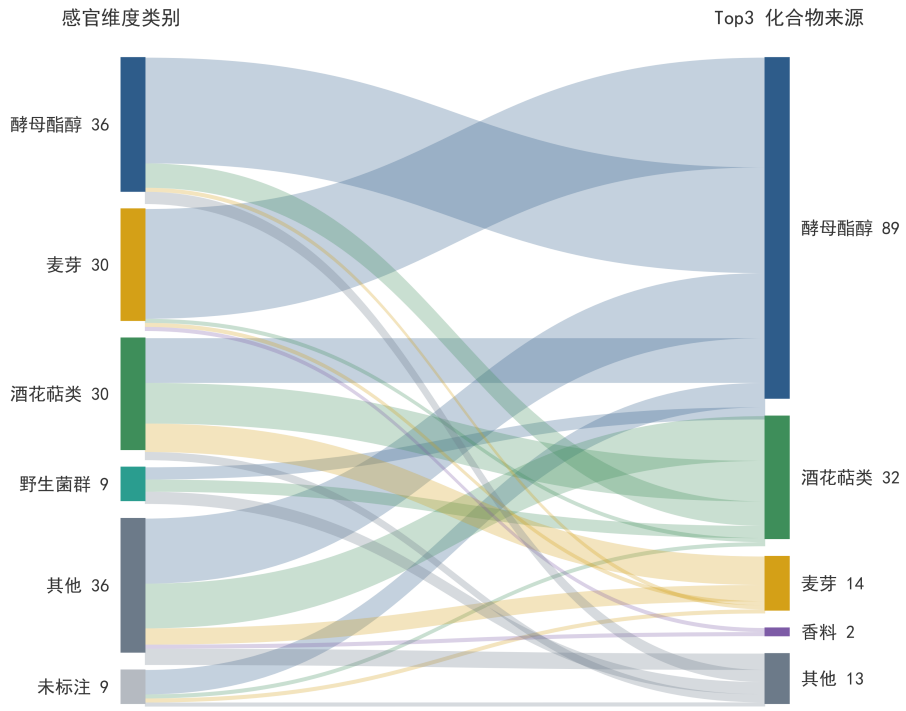


图 24　感官类别到 Top-3 化合物来源的桑基图

$$\mathcal{L}(\theta,\phi)=\mathbb{E}_{q_\phi(z|x,s)}\big[\log p_\theta(x\mid z,s)\big]-\beta_{KL}\,\mathrm{KL}\big(q_\phi(z\mid x,s)\,\big\|\,p(z)\big),\tag{17}$$

其中先验 $p(z)=\mathcal{N}(0,I)$，采用重参数化 $z=\mu_\phi+\sigma_\phi\odot\epsilon$ 使梯度可回传。为避免缺失位置污染梯度，重构项只对非缺失分量计算误差：

$$\log p_\theta(x\mid z,s)\;\propto\;-\tfrac{1}{2}\sum_{p:\,M_{ip}=0}\big(x_{ip}-\hat{x}_{ip}\big)^2.\tag{18}$$

隐维取 16 以适配 250 的小样本规模：维度过低时 231 列的重构压力全落在少数隐变量上、各风格趋于同一均值，过高则在 250 个样本上过拟合。编码器 E_ϕ 把化学谱与风格条件拼接后映射为对角高斯的参数，解码器 D_θ 再从隐变量与条件重建化学谱：

$$(\mu_\phi,\log\sigma_\phi^2)=E_\phi(x,s),\qquad \hat{x}=D_\theta(z,s),\qquad z=\mu_\phi+\sigma_\phi\odot\epsilon.\tag{19}$$

式 (17) 的 KL 项对对角高斯有闭式解，可直接逐维累加而不必采样估计：

$$\mathrm{KL}_d=\tfrac{1}{2}\Big(\mu_{\phi,d}^2+\sigma_{\phi,d}^2-1-\log\sigma_{\phi,d}^2\Big),\qquad d=1,\dots,16.\tag{20}$$

重构项按样本自身的观测位数归一化，使缺失比例不同的样本对总损失的贡献可比；若直接对 231 列求和，缺失多的样本会因观测位少而被系统性低估权重。由此得到训练所用的完整目标

$$\mathcal{J}(\theta,\phi)=\frac{1}{N}\sum_{i=1}^{N}\left[\frac{1}{|\mathcal{O}_i|}\sum_{p\in\mathcal{O}_i}\big(x_{ip}-\hat{x}_{ip}\big)^2+\frac{\beta_{KL}(t)}{16}\sum_{d=1}^{16}\max\big(\mathrm{KL}_d,\;0.5\big)\right],\tag{21}$$

其中 $\mathcal{O}_i = \{p : M_{ip} = 0\}$ 为样本 i 的非缺失位，除以 16 使 KL 项与逐列重构项量级相当，free-bits 下限 $\max(\cdot, 0.5)$ 阻止某一维 KL 塌到零。

这套生成器只是“能采样”，本问还要它“能定向改造”。跨风格迁移之所以在隐空间而不是在 231 维化学谱上直接做，是因为化学谱各列尺度相差数个数量级、且列间共表达结构强，直接在原空间加减会破坏相关结构；隐空间则把谱压缩成低维表示，风格差异近似为一个可估的平移方向。

训练初期曾出现后验坍塌：$\beta_{KL} = 1$ 时 KL 项迅速趋零、重构质量差，KS 距离约 0.6。本文把 β_{KL} 降至 0.1，并对 KL 项施加前 120 轮线性退火与每维 free-bits 下限，重构损失由 0.765 降至 0.255，KS 距离随之降到 0.36 至 0.41；退火系数取

$$\beta_{KL}(t) = 0.1 \cdot \min\Big(1,\ \frac{t}{120}\Big), \tag{22}$$

即前 120 轮由零线性升至 0.1，t 为当前轮次；此后再按早停取最优权重。该处理只改变优化过程、不改变题设与数据。解码后统一截断到各列训练观测区间，使生成谱不越界：

$$\hat{x}_{ip} \leftarrow \min\Big(u_p,\ \max\big(\ell_p,\ \hat{x}_{ip}\big)\Big), \qquad \ell_p = \min_i x_{ip},\ \ u_p = \max_i x_{ip}. \tag{23}$$

8.2 跨风格迁移与缺陷约束

跨风格迁移在隐空间以风格质心之差作为平移向量实现：

$$\Delta_{s\to t} = \bar{z}_t - \bar{z}_s, \qquad \hat{x}_t = p_\theta\big(z_s + \Delta_{s\to t} \,\big|\, \mathrm{onehot}(t)\big), \tag{24}$$

其中 $\bar{z}_c$ 为风格 c 所有样本隐编码的均值。该式是“把源点整体搬到目标质心”的最小位移解：若要求平移后的源质心恰为目标质心，则 $\bar{z}_s + \Delta = \bar{z}_t$，解得 $\Delta = \bar{z}_t - \bar{z}_s$；解码器同时接收目标风格 one-hot，使解码走的是目标风格的重建通路而非源风格通路。

$$x^{def}_{k,after} = \min\Big(\tilde{x}^{def}_{k,after},\ \min\big(x^{def}_{k,before},\ m^t_k\big)\Big), \tag{25}$$

其中 $\tilde{x}^{def}_{k,after}$ 为隐空间平移并解码得到的**无约束**值，$x^{def}_{k,before}$ 为该样本源风格 Pils/Lager 缺陷 k 的原始含量，m^t_k 为目标风格 Tripel 缺陷 k 的典型值（取中位）。该投影是一个带单侧上界的最近点问题：可行集为 $(-\infty, \min(x_{before}, m^t_k)]$，而欧氏投影到半直线上的解就是截断本身，故它在满足约束的所有取值中离无约束值最近，除约束之外不再额外改写含量。源款原值构成第一道防线，目标典型值构成第二道兜底。由于各化学维单位不可比、绝对阈值无法统一换算，本题不并入绝对阈值 τ^*_k，默认关闭；8.3 节以同一批样本不做投影的纯平移结果作对照，量化该约束不可或缺。

迁移谱的感官画像直接由问题一模型给出，$\hat{y}^{sens} = h_j(\hat{x}_t)$，由此把“化学上像 Tripel”与“感官上像 Tripel”两个层面的检验接在同一套底座上。

8.3 生成质量与结果分析

本文对 Tripel、Kriek、Lambic 三个代表风格各生成 30 条化学谱、共 90 条，并完成 11 条 Pils/Lager 到 Tripel 的迁移。为从多个独立角度证明生成质量，本文不只看分布距离，还训练了一个以真实 22 风格谱为输入的风格分类器，统计生成谱的 Top-3 风格识别率，并与随机猜测基线、真实谱自身 OOF 识别率对照，同时计算生成谱与同风格真实谱经问题一打分后的感官画像 Spearman 相关。生成质量概览见表 10：随机猜测的 Top-3 识别率基线为 13.6%，真实谱整体 OOF 识别率为 72.8%；KS 越小越接近真实分布，画像 Spearman 为生成谱与同风格真实谱画像的相关，Tripel 生成酯香 3.97、真实 3.21。

表 10　三代表风格生成质量（分布距离 + 风格识别率 + 画像相关）

风格	生成数	KS 距离	生成谱 Top-3 识别率	真实谱 Top-3 识别率	生成-真实画像 Spearman
Tripel	30	0.3511	100%	86%	0.653
Kriek	30	0.4075	100%	100%	0.924
Lambic	30	0.4110	100%	100%	0.751

仅有 KS 距离不足以说明生成模型的必要性，因为它只衡量“像不像”，不衡量“有没有生成新东西”，也不衡量能否执行条件迁移。为把这三件事分开，本文构造两个对照基线：**风格内重采样**（对真实样本有放回抽样，代表“只补样本量”的朴素做法）与**风格内高斯采样**（按该风格的均值与协方差独立采样，代表“能生成新点但不建模结构”的做法），并用三个维度评价三者。

第一个维度是分布保真，用逐列 KS 距离的均值衡量，越小越接近真实分布。第二个维度是新颖性，用生成样本到最近真实样本的标准化欧氏距离衡量：距离为 0 意味着它只是复制了已有样本，距离过大则意味着偏离了真实流形。第三个维度是结构保真，用生成谱内部 Spearman 相关矩阵与真实相关矩阵的平均绝对差衡量，它检验模型是否学到了化合物之间的共表达结构。

表 11　三种生成方式的对照（三个代表风格的平均）

方法	KS 距离	新颖性	重复率	相关结构差异	观测区间内
风格内重采样	**0.098**	0.000	**100%**	**0.111**	99.9%
风格内高斯	0.312	18.14	0%	0.309	80.5%
CVAE（本文）	0.388	**350.27**	0%	0.275	90.5%

表 11 的 KS 为每风格 231 列逐列 KS 的均值（三风格合并共 693 列）、生成谱已按训练观测区间截断，新颖性为标准化空间中生成样本到最近真实样本距离的中位数，相关结构差异为两相关矩阵上三角元素的平均绝对差，观测区间内指取值落在训练集该列

[min, max] 的比例；三方式每风格同为 30 条，且基于另一批生成谱，与表 10 的分风格 KS 口径不同，两表不作逐位比较。三者各有强弱。重采样分布保真最好、KS 仅 0.098；但重复率 **100%**、新颖性恒为 0，只能补样本量而不能产生新谱。高斯采样新颖性 18.1，却假设各化合物独立，相关结构差异 0.309 为三者最差、仅 80.5% 落在观测区间。CVAE 的 KS 为 0.388，新颖性中位 40–657、相关结构差异 0.275，是唯一同时满足“生成新谱”与“保留共表达结构”的方案。

这一对照给出的结论不是“CVAE 全面占优”，而是**三种方法对应不同的任务需求**。若任务只是补足样本量，风格内重采样在分布意义上更可靠；但本题要求的是条件生成与可控迁移，即在给定风格下生成新的化学谱、并在隐空间中把源风格沿特定方向推向目标风格。重采样无法产生新谱，高斯采样不具备可解释的隐空间方向，只有 CVAE 能同时提供这两项能力。本文因此选择 CVAE，并把分布保真上的劣势如实列出，而不是以单一 KS 指标宣称生成质量全面领先。

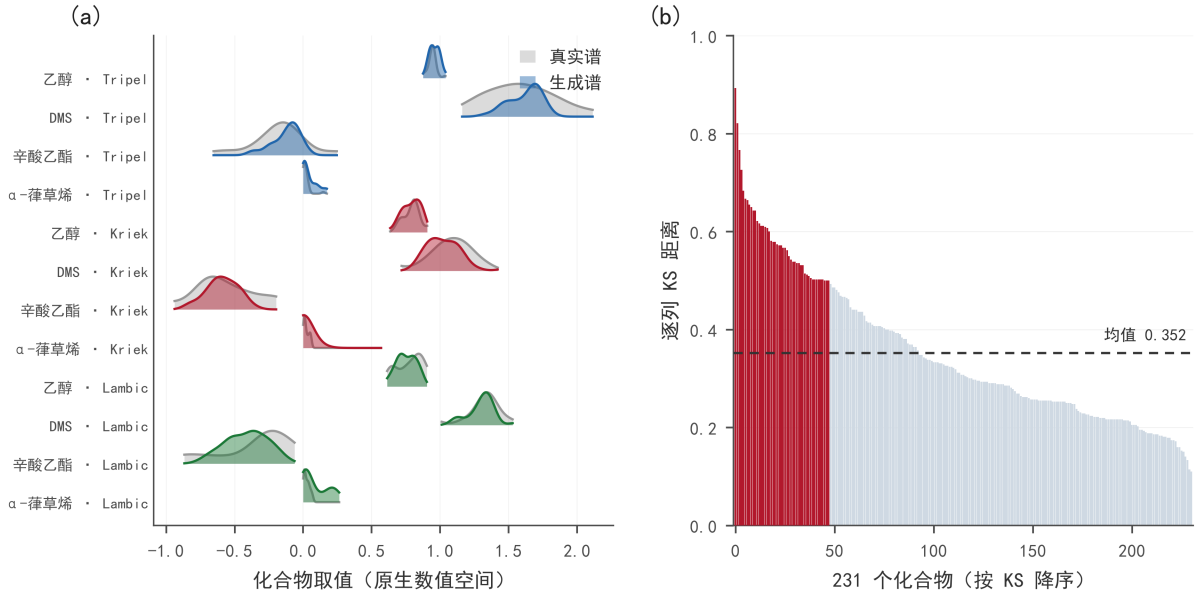


图 25　代表化合物分布形状与逐列 KS 偏离

表 10 的 KS 是 231 列的平均，容易误读为“每列都偏”。图 25(b) 把 Tripel 的 231 列逐列排开：均值为 0.352，其中 **48 列**（约 20.8%）的 KS ≥0.5，超过一半的列 KS <0.2，偏离集中在少数列而非整体系统漂移；这 48 列与该风格的未检出比例高度相关，高 KS 列正是大量样本卡在检出限的稀疏列，与 5.4 节的左删失结构一致。

但 KS 是标量，看不出形状怎么变。图 25(a) 把四个代表化合物在三个风格下的真实分布（灰）与生成分布（彩色）叠成山脊：乙醇与辛酸乙酯保持单峰、位置略偏；DMS 在 Tripel 下被压成更窄的单峰，而真实谱是带长尾的宽分布；α-蒎草烯在 Lambic 下出现双峰，说明解码器学到了两个分离模式。两者合看可得一个一致的图景：多数列（含乙醇、辛酸乙酯）的生成分布形状与位置都接近真实，偏离主要由少数稀疏列贡献，其中最典型的是 α-蒎草烯——它的双峰结构正是其逐列 KS 偏高的来源。

CVAE 在个别化合物上会外推到训练观测范围之外，未截断时 Lambic 有单列偏离真实中位数达数百个标准差；按训练观测区间截断后，落在区间内的比例由 89.1% 升至 90.5%，越界单元格占 767/23331（3.29%）；截断只压平越界值，不改变未越界分量的分布，故截断前后的 KS 均值分别为 0.389 与 0.388，变化可忽略。这是 250 样本、16 维隐空间下容量与过拟合的固有取舍。

真实谱与生成谱经主成分降维[20] 后的重叠可直观验证风格可分性。

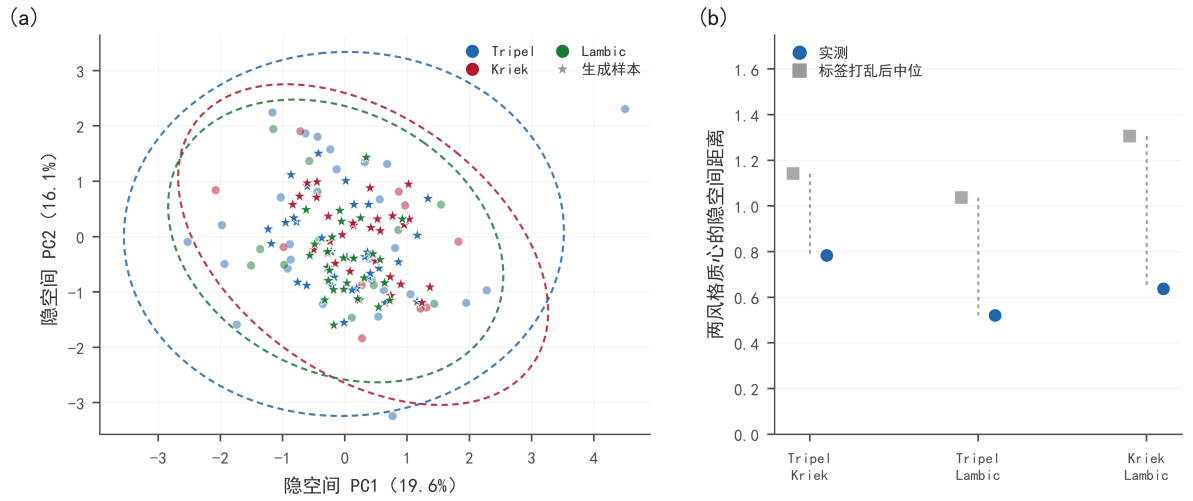


图 26　隐空间：质心位置与置换检验

化学谱 PCA 能分开风格（图 2），但生成模型真正工作的空间是隐空间。图 26(a) 对编码出的 16 维隐向量做 PCA：三个风格的真实样本各有椭圆，生成样本（星号）落在对应椭圆内。但置换检验给出相反结论（图 26(b)）：风格标签随机打乱后，两组质心间距中位为 1.04–1.31，反而大于实测的 0.52–0.78（$p = 0.92/0.99/1.00$）；逐样本也只有约三成生成谱离“本风格质心”更近。这说明 16 维隐空间里不存在超出噪声的风格结构：判别信息留在 231 维化学谱里，CVAE 为重建全部列，把风格条件压缩成很小的平移量。跨风格迁移正基于此平移量，缺陷投影因此不可或缺。本文把这条列为问题三的主要局限，要真正成形需要显式的风格判别损失或更大样本量。

由图 26 可见，生成样本在主成分平面上落入对应真实风格簇的邻近区域、而非彼此混为一团，表明不同风格条件确实产出了可区分的分布，问题三风格条件生成的目标达成。生成谱经问题一模型打分后的感官画像进一步从感官层面印证了风格特征。

图 27 把三种风格的 50 维画像完整铺开：横轴按香气、风味、口感与缺陷三组排列，格内为生成谱经问题一模型打分后的平均等级。可见 Tripel 在酒精与体重维上明显偏高，Kriek 与 Lambic 在酸味维上突出，而三者的缺陷维都处于较低水平，说明生成谱在感官层面是合理的。

除全局 KS 外，本文还按风格分别计算了 Wasserstein-1 距离（表 12，KS 与表 10 同源，W1 同时给出中位与均值）。Tripel 的 KS 0.351、W1 中位 0.391，Kriek 为 0.408 与 0.269，Lambic 为 0.411 与 0.244。两个指标的排序并不完全一致：Kriek 和 Lambic 的 KS

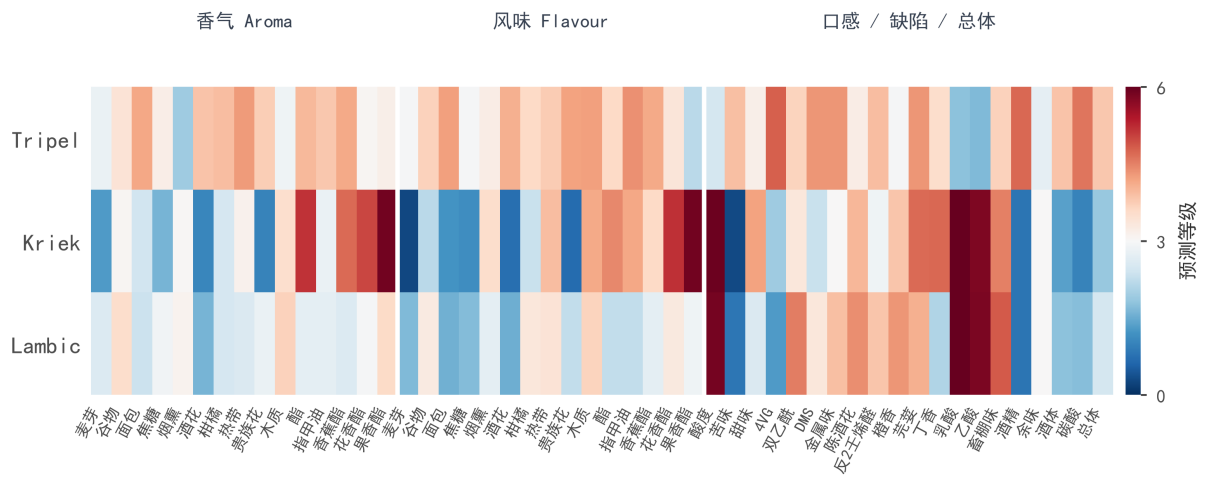


图 27　三代表风格生成谱的 50 维感官画像

表 12　分风格的生成质量评估（KS 与 Wasserstein-1）

风格	真实样本	KS 距离	W1 中位	W1 均值
Tripel	28	0.3511	0.3912	1.6147
Kriek	10	0.4075	0.2686	8.5349
Lambic	11	0.4110	0.2435	1.5476

略大，但 W1 中位反而更小，说明它们的偏离集中在少数列的分布尾部，而不是整体系统性偏移。与此同时，W1 均值显著高于中位（Kriek 达 8.53），是少数长尾列拉高了均值，因此本文以中位作为主报告口径。

为检验生成质量不是单一种子的偶然结果，本文用同一配置跑了 5 个随机种子（42/7/2024/1234/99），每风格每次 30 条，与主表同口径。KS 的均值 ± 标准差为 Tripel 0.344±0.012、Kriek 0.394±0.014、Lambic 0.393±0.015，风格 Top-3 识别率在全部 5 个种子上恒为 100%，说明结论不依赖初始化。同期补算的能量距离（逐列一维、按真实谱标准化）中位为 0.329/0.433/0.437，与 KS 的排序一致；生成谱与真实谱的 50 维画像 MAE 为 0.456/0.579/0.446 级，即平均偏差不到半级，其中 Kriek 最大——它的真实样本仅 10 条，画像本身波动较大。

为证明式 (26) 的约束不可或缺，本文对同一批 11 条 Pils/Lager 到 Tripel 迁移做了**无约束纯平移对照**：若隐空间平移解码后不做任何投影，44 个缺陷-样本检查中有 32 个、即 72.7% 的缺陷浓度高于源款；施加式 (26) 后，缺陷升高数为 0、合规率 100%。逐缺陷的迁移前后、无约束对照与典型阈值见表 13。

表中数值均为标准化含量，无约束升高数列给出该缺陷在 11 条样本中无约束时高于源值的条数。四个缺陷化合物在 11 条迁移样本上逐一检查，受约束后合规数均为 11/11、整体合规率 **100%**，即 44/44。DMS 是最典型的对照：无约束纯平移会把 DMS 由源值 1.158 拉高到 1.598，11/11 条全部升高，而 min 投影将其压回源值 1.158，$\Delta = 0$，恰

表 13　Pils/Lager 到 Tripel 迁移中 4 个缺陷化合物的严格合规（min 投影）

缺陷化合物	迁移前	迁移后	Δ = 后 − 前	无约束纯平移后	无约束升高数	典型阈值 m_t	合规
DMS	1.158	1.158	+0.000	1.598	11/11	1.587	11/11
Diacetyl	0.169	0.056	-0.113	0.941	4/11	0.290	11/11
4VG	-1.879	-2.013	-0.134	-1.805	8/11	-2.013	11/11
trans-2-nonenal	0.004	0.004	-0.000	0.232	9/11	0.011	11/11

好满足迁移后不高于源款；Diacetyl 即双乙酰，由 0.169 压到 0.056，$\Delta = -0.113$，4VG、反式-2-壬烯醛同样不升高；若取源值与目标典型值中较大者，DMS 会被抬到 1.56 以上却仍宣称合规，min 口径修正了这一矛盾。Stale hops 在化学谱中无对应列，属陈化标记，仅记录不投影。式 (13) 保证的是**相对不恶化**，不等价于绝对安全：按 5.3 节核实的尺度把迁移谱换算回真实浓度后与阈值表比较，结果如下。

绝对口径的结果需要与目标风格本身的化学特征一并解读，否则容易误读为投影失效。Tripel 的 28 条真实谱中有 25 条 DMS 高于 19 μg/L、18 条 Diacetyl 高于 0.09 mg/L。也就是说，本题的目标风格在数据层面本就以较高 DMS 为特征；若强行把全部迁移样本压到阈值以下，生成谱将不再像 Tripel，与“迁移为 Tripel 风格”的任务目标冲突。本文因此选择相对口径作为硬约束，它可逐样本审计且必然成立；同时把绝对阈值作为诊断指标如实报告，而不宣称已实现绝对意义上的缺陷安全。这一取舍也说明：在真实数据上，风格迁移与缺陷达标并不总能同时满足，二者的张力应由使用者在具体场景中加权。

第五类缺陷 Stale hops 在化学谱中没有对应测量列，无法施加浓度投影。本文改用问题一模型对迁移谱打感官分作为代理：11 条迁移样本的 Stale hops 等级为 2 至 5、中位 3，与其源款等级分布一致，未出现系统性上升。需要说明这只是感官代理，不是对 Stale hops 相关化合物的直接浓度约束；要给出化学层面的保证，仍需该类陈化标志物的实测列。

上述只看四个缺陷化合物，而迁移到底改动了哪些化合物、改了多少并不清楚。图 28 将 11 条迁移样本的 12 个关键化合物相对源风格均值的变化按标准差归一化后并列，横向看可读出哪些成分被系统性上调（酵母酯醇类）、哪些被下调；右侧条形给出各化合物的平均位移。深色框标出四个缺陷化合物，它们的平均位移接近于零、个别为负，即约束确实用于阻止这些列被拉高。

隐空间平移是黑箱，因此本文在化学层给出可解释的方向对照。以”Tripel 真实均值 − Pils/Lager 真实均值” 为参照方向，与 11 条迁移谱的实际位移逐列比较：12 个关键调节化合物的符号全部一致（kcalperc +7.60 对 +7.74、乙醇 +7.33 对 +7.24、乙酸乙酯 +5.18 对 +5.29 等），全 231 列的符号一致率 92.2%，但余弦相似度仅 0.34——方向大体正确，幅度与部分列不一致。这个量化的” 方向对、幅度不齐” 正是需要缺陷投影兜底

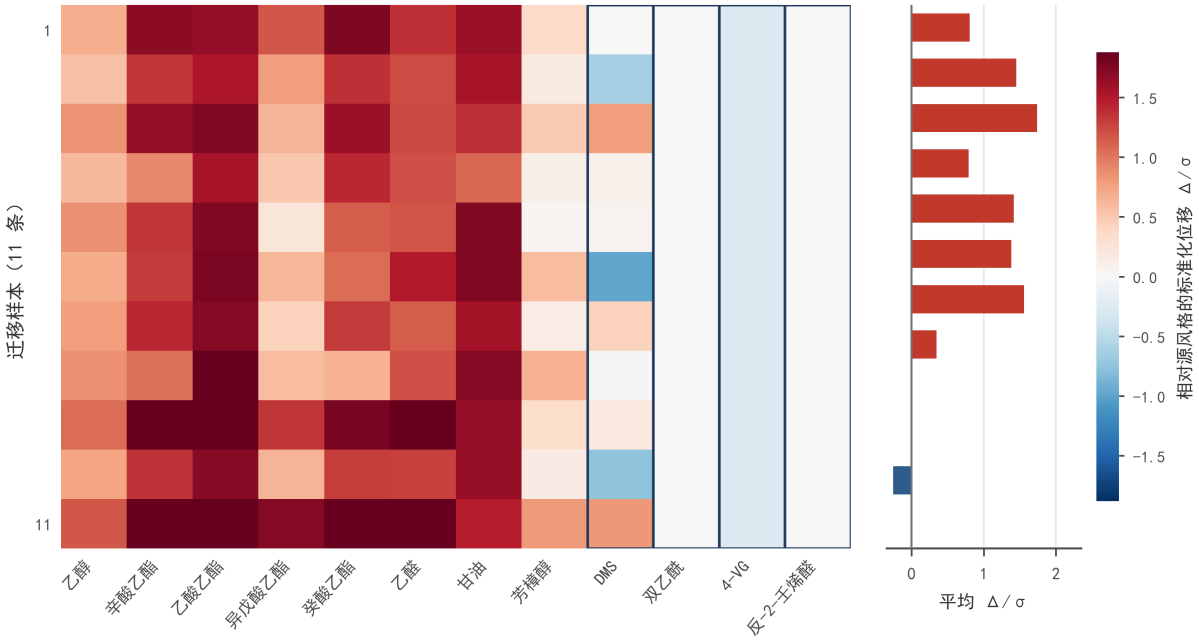


图 28　迁移对各化合物的影响方向与幅度

的原因：若只靠隐空间平移，少数列会被推过目标风格的真实水平，其中就包含缺陷化合物。

9　模型检验与灵敏度分析

9.1　验证方案与防泄漏

三问的可信度都建立在独立的验证之上，且全程贯彻防泄漏纪律。问题一采用按风格分层的 5 折交叉验证，分箱分位点与标准化参数只在训练折估计、再施加到验证折，杜绝了在全量数据上估分箱这一最隐蔽的泄漏。问题二以 500 次按风格分层的 bootstrap 给出单方法稳健性（200/300/500 三次检查点 Top-1 无变化）、以三法 Jaccard 给出方法间一致性，化学合理性再以交叉相关与酿造机理双重佐证。问题三对生成以分布距离与降维簇重叠评估，对迁移以缺陷合规率这一硬指标评估，并用问题一感官画像核验风格特征。本题没有隐藏测试集，所有数字都如实标注为交叉验证或分布距离的内部估计。

本文系统排查了六类泄漏并逐一封堵：分箱与标准化参数折内估计；主办方模型的参考重要性只作问题二旁证、不进入问题一训练特征；样本主键与风格标签不进入问题一特征矩阵；不对风格做目标编码。此外，附件 2 与 1.csv 的关联经核验只能按 `beer` 名称与行序对齐，按 `beer_id` 会因精度丢失只剩 37/250 行，本文对此显式断言而非静默合并。

9.2 方法增益的消融汇总

第 6 至 8 章的每处设计均配有对照，本节集中列出，量纲不同故统一换算为相对百分比。

各环节的增益排序与预期一致，但性质不同：融合与分维选型是实质性改进——模块覆盖 2.30→2.92，折外 QWK 0.3663→0.3830（+4.6%）且增益完全集中在 5 个退化维上，与 6.2 节的退化诊断相互印证；缺失处理（+0.3%）与值域截断（+1.6%）则属正确性修正，前者的价值在于不删样本、把缺失当作可用信息，后者在于消除解码器外推造成的量级失控。

9.3 模型层的两项对照实验

本节报告两项离线对照：问题一的分组共享多输出（方案 A），以及问题三的判别辅助损失与按风格留出。两者都不改变主结果——主模型 0.3830、提交用的生成谱与迁移谱均保持原样，对照只用于回答“共享表示是否值得”与“隐空间能否被修好”这两个方法层面的问题。

9.3.1 问题一：分组共享多输出（方案 A）

主模型对 50 个维度各自独立训练。若同一组内的感官维确实共享化学驱动，把同组其他维的折内预测当作附加特征，应能借助组内相关性降低方差。本文按香气（15）/ 风味（15）/ 口感缺陷（20）三组实现这一思路：在每个训练折内，先用组内 5 折 OOF 预测构造“组画像特征”（只用训练折样本，防泄漏），再把每个目标重新训练为“231 原始特征 + 同组其余 $k-1$ 个组画像特征”；分箱退化维仍用类加权有序回归，与主模型同一判据、同一实现。

结果与预期相反：该方案宏平均 QWK 为 **0.3759**，低于主模型的 0.3830。配对 bootstrap 2000 次给出 $\Delta\text{QWK} = +0.0070$、95% 区间 $[0.0001, 0.0139]$，主模型在 97.7% 的重采样中更优。分组看更清楚：香气由 0.322 降至 0.305、风味由 0.400 降至 0.394，两组都退步；只有口感缺陷组基本持平（0.416 降至 0.415）。

这一负结果本身有信息量。结合 6.2 节的相关矩阵可知：真正强的相关是“同名维的跨通道配对”（香气 • 酯与风味 • 酯 0.836、香气 • 酒花与风味 • 酒花 0.828），而不是“组内维之间”（香气组内中位 $|r| = 0.124$）。按通道分组恰好把最相关的配对（A_ 与同名 F_）切开，组画像特征因此只能提供弱信息，却额外引入 14–19 个含噪特征，在 250 样本上放大了过拟合。换言之，组内共享表示的收益取决于相关结构是否与分组边界对齐，而本题的结构恰好不对齐。本文因此保留逐维独立建模。

9.3.2 问题三：判别辅助损失能否修复隐空间塌缩

问题三已报告一个关键局限：三风格隐质心的置换检验 $p = 0.92/0.99/1.00$，即 16 维隐空间里不存在超出噪声的风格结构。本文在编码器输出 z 上加一个线性风格分类

头，把总损失改为 $L = L_{\text{recon}} + \beta_{KL} \cdot \text{KL} + \lambda \cdot \text{CE}(s \mid z)$，其余设定（KL 退火、free-bits、截断、隐维 16、600 轮）完全不变，只扫 $\lambda \in \{0, 0.02, 0.1, 0.3, 0.5\}$。

结果是一条清晰的双面板权衡曲线（图 29）：图 29(a) 看隐空间是否被修好，图 29(b) 看保真付出的代价。$\lambda = 0$ 即现状：置换检验 $p = 1.00$、隐空间线性分类准确率 3.2%（随机基线 4.5%）。只要加入判别项，隐空间立刻可分：$\lambda = 0.02$ 时 $p = 0.000$、分类 54%；$\lambda \geq 0.1$ 时分类接近 100%。但代价同步上升：生成谱 KS 由 0.373 依次升至 0.392 / 0.411 / 0.445 / 0.468，重构 MSE 由 0.266 升至 0.284 / 0.340 / 0.397 / 0.429。两条曲线的走向相反——左侧在 0.1 之前陡升、右侧持续上行，判别约束确实修好了“风格在隐空间不可辨识”这一缺陷，但收益建立在分布保真之上。

本文不把判别头并入主模型，因为任务目标是生成像真实的化学谱，而不是让隐空间可分；为一个诊断指标牺牲 KS 与重构质量，与任务目标不一致。这一对照的价值在于把局限的性质说清：隐空间塌缩不是训练不足或超参没调好，而是“重构全部 231 列”这一目标本身的取舍——加入显式风格判别项即可改变，但代价可量化。若后续任务更看重风格可控性（例如按风格插值），本文推荐 $\lambda = 0.02$ 这一折中档：风格已显著可分，而 KS 只上升 0.019。该结论在 seed 7 上复现（$\lambda = 0$：$p = 1.00$、分类 5.2%；$\lambda = 0.1$：$p = 0.000$、分类 99.2%）。

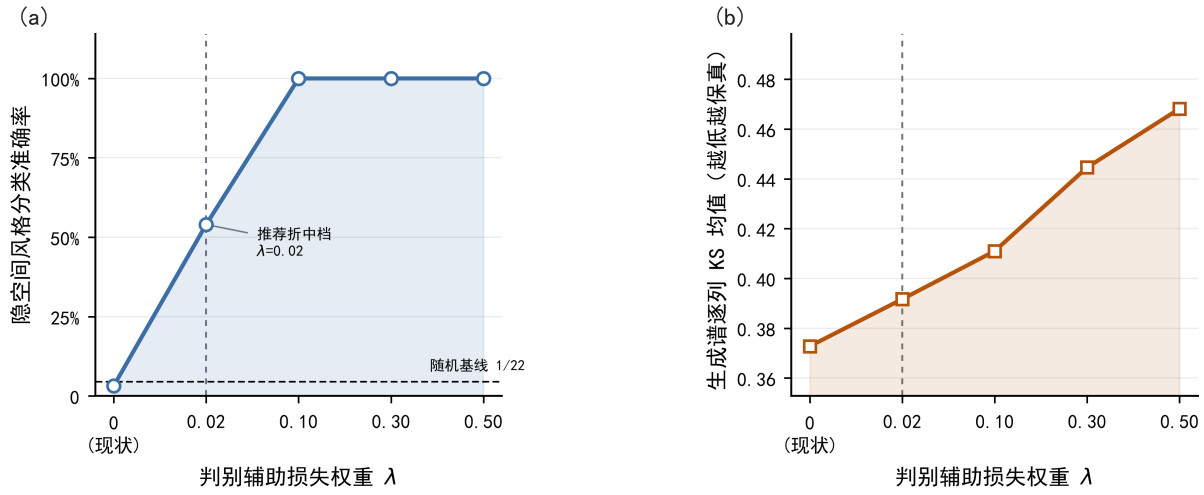


图 29　判别辅助损失的权衡：隐空间风格可分性与生成谱保真

9.3.3　问题三：按风格留出的生成对照

表 11 是静态对照（用全部真实谱拟合生成器，再与同一批真实谱比较）。更能反映泛化的是留出口径：每折只用训练折拟合生成器、留出折作参照分布。本文对三种生成器（CVAE、风格内多元高斯、风格内重采样）做同一处理，每风格每折生成 30 条。折数按风格样本量自适应，以保证每折留出不少于 5 条（Tripel 5 折，Kriek 与 Lambic 各 2 折）；解读绝对值时必须考虑这一点。

结果见表 14；该表每折用训练折拟合、留出折作参照，KS 取逐列均值，W1 与能量距

离取中位。三者的逐列 KS 为 CVAE 0.493±0.025、高斯 0.447±0.019、重采样 0.404±0.029。值得注意的是**连重采样也有 0.404**：它生成的每一条都是训练折真实样本的复制，理应最接近真实分布；之所以仍有 0.404，是因为留出折只有 5–6 条样本，经验分布本身的抽样噪声就有这个量级。这说明在小留出集上 KS 的绝对值主要由折间抽样噪声决定，不宜直接与表 11 的 0.098 相比；可比的是三者相对顺序，而该顺序与静态口径一致（重采样 < 高斯 < CVAE）。

结构保真一侧的分化更稳定：W1 中位为 CVAE 0.435、高斯 0.586、重采样 0.406；画像 Spearman 为 0.506 / 0.441 / 0.460。高斯采样在 W1 上明显最差，与它假设各化合物独立、破坏共表达结构一致，这一结论在留出口径下依然成立。分风格看，CVAE 在 Tripel 上的画像相关最高（0.343 对高斯的 0.203），在 Kriek 与 Lambic 上与重采样接近（0.84 / 0.59 附近），说明 CVAE 的优势主要体现在样本量最大的风格上。

表 14　按风格留出的生成对照（每风格每折 30 条，均值 ± 标准差）

生成器	逐列 KS	W1 中位	能量距离	画像 Spearman
风格内重采样	0.404±0.029	**0.406**	**0.551**	0.460
风格内高斯	0.447±0.019	0.586	0.569	0.441
CVAE（本文）	0.493±0.025	0.435	0.619	**0.506**

9.4　关键参数的灵敏度

分箱口径会改变各等级的样本数，从而影响 Kappa 的绝对量级（详见 6.2 节）：等距分箱 QWK 0.4013 略高于主口径，但产生 8 个空等级、等级计数变异系数 1.155，故不采用。

对数底经 5.3 节核实为混合尺度（37 列常用对数、33 列原值），树模型对单调变换不敏感，故不影响前两问结论、仅影响浓度的叙述性换算。建图阈值扫描 0.4–0.6（图 16）：过高使图断裂、模块过碎，过低趋于全连通，取 0.5 结构最清晰。隐维取 8–16：过小会后验坍塌、各风格雷同，过大则小样本过拟合，取 16 并配合 KL 退火与 free-bits 后生成分布稳定、风格可分。

正文给出的两组特征增广对照（完整的 43 个阈值列与 8 个模块 PC1 见附录表 A.3、A.4）：43 个阈值字段换算到同一尺度后生成” 是否超阈” 二值列与超阈比例列，或并入 8 个共表达模块的第一主成分，折外 QWK 分别降至 0.3760 与 0.3747，均低于 0.3830，故保留原 231 列。

9.5　鲁棒性

固定种子 42 下问题一完全可复现；问题二 47/50 维的 Top-1 频率恰为 1.000；问题三在 5 个种子下均保持风格可分，50 维全部获得预测。本节的四项对照（分组共享多输

出、判别辅助损失、按风格留出、特征增广）都在同一折、同一分箱、同一指标下完成，其中两项为负结果（共享表示退步 0.0070、判别头以 KS 换可分性），均已如实列出。

10 模型评价与推广

10.1 优点与创新

第一，以共享的化学到感官预测底座贯通三问：同一套经交叉验证的模型既是问题二的 SHAP 归因对象，又是问题三生成谱的感官打分器，预测、归因与生成三者联动。

第二，归因限定为 211 个单一化合物，并以模块代表加权与同社区去冗余；三路融合把单维 Top-3 命中的模块数由 2.30 提到 2.92（满分 3），跨方法 Jaccard 0.200 为随机基线 0.0086 的 23.3 倍，并以配对 bootstrap 与 A/B/C 分级给出可信度。

第三，把缺陷不恶化形式化为 $\min(\tilde{x}_{after}, x_{before}, m_t)$ 逐样本投影，配无约束对照（72.7% 本会升高）；另用真实浓度阈值做绝对口径审计，区分“相对不恶化”与“绝对达标”。

第四，识别出分位分箱在标签分布高度集中时失效的隐性前提，据此只在退化维改用类加权有序回归，折外 QWK 由 0.3663 升至 0.3830（+4.6%）；并对“更强的表示”与“更可分的隐空间”两条路线做了严格对照、如实报告负结果，使方法选择有可复核依据。

10.2 不足与改进

其一，0-6 分级由连续值单调映射重建而非原始品评卡复现，分级绝对值带有映射口径的印记；250 样本下增维（阈值列、模块 PC1、分组共享）亦未兑现精度。

其二，生成谱需按观测区间截断、迁移依赖缺陷投影兜底，判别头以 KS 上升换取隐空间可分；来源一致率仅 12%，高删失列未建显式删失似然。

10.3 推广

本文框架可推广到其他成分谱与感官建模场景：缺失感知有序预测适用于品评缺测数据，共表达图加多证据归因适用于高共线性组学或光谱筛选，带硬约束的条件生成可用于规避有害成分的配方设计。

参考文献

[1] Zhang H. Predict and improve beer flavor with machine learning[J]. ResearchHub, 2026. DOI: 10.55277/researchhub.cagmlmpm.

[2] Li S, Li T. Machine learning discrimination and prediction of different quality grades of sauce-flavor Baijiu based on biomarker and key flavor compounds screening[J]. SSRN Electronic Journal, 2024. DOI: 10.2139/ssrn.4939729.

[3] Zhang C, Liu W. Effects of lactic acid bacteria fermentation on bioactive compounds and flavor profiles of Siraitia grosvenorii and prediction of flavor profiles by machine learning[J]. SSRN Electronic Journal, 2024. DOI: 10.2139/ssrn.6116637.

[4] Chen T, Guestrin C. XGBoost: A scalable tree boosting system[C]. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2016: 785-794. DOI: 10.1145/2939672.2939785.

[5] Ke G, Meng Q, Finley T, et al. LightGBM: A highly efficient gradient boosting decision tree[C]. Advances in Neural Information Processing Systems (NeurIPS), 2017, 30: 3146-3154.

[6] Yıldız A Y, Kalayci A. Gradient boosting decision trees on medical diagnosis over tabular data[C]. 2025 IEEE International Conference on AI and Data Analytics (ICAD), 2025. DOI: 10.1109/icad65464.2025.11114069.

[7] Polozoff S. Top Beer Information (Kaggle dataset)[DB/OL]. Kaggle, 2024. https://www.kaggle.com/datasets/stephenpolozoff/top-beer-information.

[8] Hoerl A E, Kennard R W. Ridge regression: Biased estimation for nonorthogonal problems[J]. Technometrics, 1970, 12(1): 55-67. DOI: 10.1080/00401706.1970.10488634.

[9] Wold S, Sjöström M, Eriksson L. PLS-regression: a basic tool of chemometrics[J]. Chemometrics and Intelligent Laboratory Systems, 2001, 58(2): 109-130. DOI: 10.1016/S0169-7439(01)00155-1.

[10] Breiman L. Random forests[J]. Machine Learning, 2001, 45(1): 5-32. DOI: 10.1023/A:1010933404324.

[11] Troyanskaya O, Cantor M, Sherlock G, et al. Missing value estimation methods for DNA microarrays[J]. Bioinformatics, 2001, 17(6): 520-525. DOI: 10.1093/bioinformatics/17.6.520.

[12] Schreurs M, Piampongsant S, Roncoroni M, et al. Predicting and improving complex beer flavor through machine learning[J]. Nature Communications, 2024, 15: 2596. DOI: 10.1038/s41467-024-46346-0.

[13] Blondel V D, Guillaume J L, Lambiotte R, et al. Fast unfolding of communities in large networks[J]. Journal of Statistical Mechanics: Theory and Experiment, 2008, 2008(10): P10008. DOI: 10.1088/1742-5468/2008/10/p10008.

[14] Melo D, Pallares L F. Reassessing the modularity of gene co-expression networks using the stochastic block model[J]. PLoS Computational Biology, 2024, 20(7): e1012300. DOI: 10.1371/journal.pcbi.1012300.

[15] Clemente J B, Besas G. Predicting the biological classification of cell-cycle regulated genes of Saccharomyces cerevisiae using community detection algorithms on gene co-expression networks[C]. 2022.

[16] Gauraha N. Stability feature selection using cluster representative LASSO[C]. Proceedings of the 5th International Conference on Pattern Recognition Applications and Methods, 2016: 381-386. DOI: 10.5220/0005827003810386.
[17] Efron B, Tibshirani R J. An Introduction to the Bootstrap[M]. New York: Chapman and Hall, 1993.
[18] Apley D W, Zhu J. Visualizing the effects of predictor variables in black box supervised learning models[J]. Journal of the Royal Statistical Society: Series B, 2020, 82(4): 1059-1086. DOI: 10.1111/rssb.12377.
[19] Chaibi I, Njah H. Conditional variational autoencoder with Bayesian layers for robust tabular data generation from small datasets[J]. SSRN Electronic Journal, 2025. DOI: 10.2139/ssrn.5991727.
[20] Flexa C, Gomes W. Polygonal coordinate system: Visualizing high-dimensional data using geometric DR, and a deterministic version of t-SNE[J]. Expert Systems with Applications, 2021, 175: 114741. DOI: 10.1016/j.eswa.2021.114741.

附录 A　数据附件概况与口径核对

本附录汇总主办方 8 个附件的实测概况与用途（表 A.1），以及题面表述与附件实测的差异核对（表 A.2），行列数均以本文程序实际读取为准。

表 A.1　八个附件的实测概况与用途

附件	内容	实测规模（行 × 列 / sheet）	本文用途
1.csv	化学组成谱（含主键与风格）	250 × 234（3 元列 + 231 化学特征）	Q1 特征矩阵、Q2 建图、Q3 生成
2.csv	化合物相关系数矩阵（Spearman）	231 × 232（首列为化合物名）	Q2 共表达边权（口径见 7.1）
3.xlsx	12 张空白评分卡 + 1 个汇总表	13 sheet（beer_1. . .beer_12 各 100×33；summary 全 0）	Q1 的 0–6 分填分模板
4.csv	品评小组标准化分	250 × 53（3 元列 + 50 感官维）	Q1 训练标签
5.csv	感官维度之间相关	50 × 51（首列为维名）	感官分组与冗余参考
6.csv	化学-感官交叉相关	44 化学行 × 50 感官列（44×51）	Q2 归因的线性证据
7.csv	论坛/评论文本属性	250 × 189（其中 3 列全缺失）	文本数据，三问均不使用
8.xlsx	综合参考表	7 个 sheet（见下注）	仅作旁证：阈值、校准浓度、来源、MDI

注：8.xlsx 七个 sheet 分别为 Sensory thresholds（261×11，感官阈值与化合物来源）、Sensory names（101×8，感官维类别）、GBM importance MDI（231×2，主办方模型的不纯度重要性）、GBM SHAP Values（500×236）、Calibrated chemical dataset（250×73，含 3 元列与 70 列校准绝对浓度）、Beer Prices（250×11）、Sheet2（空表）。其中 MDI 与 SHAP 仅作问题二的旁证，不进入问题一特征，以防用答案预测答案的泄漏。数据来源：1.csv、2.csv、3.xlsx、4.csv、5.csv、6.csv、7.csv、8.xlsx 实测

A.1　特征与归因的完整明细

本节给出正文中只报摘要数字、而明细较长的四张支撑表：阈值超限列清单（表 A.3）、8 个模块的第一主成分（表 A.4）、55 个 Louvain 社区的成员构成（表 A.5），以及全部 150 个 Top-3 候选的证据分级（表 A.6）。所有数字由 code/analysis/ 下的脚本从 figures/derived/ 的结果文件直接生成，未手工填写。

表 A.2　题面表述与附件实测的差异核对

题面表述	附件实测	处理方式
226 种啤酒	1.csv 实为 250 个样本（4.csv 同为 250 行）	以实测 $N = 250$ 为准
附件 2 为 Pearson 相关	题面称 Pearson，实测为 Spearman；从 1.csv 重算的 Spearman 与附件 2 逐元素一致（最大差 7.8×10^{-16}），而同口径 Pearson 的最大差 1.12、平均绝对差 0.088	以附件 2 数值作 Spearman 边权
3.xlsx 为评分卡	12 张空白评分卡（100×33 模板）+ 1 个全 0 的 summary	原始 0–6 分数不可用，仅作填分模板，训练标签改用 4.csv 中心化连续值
评分卡含 Acetaldehyde	Aroma 与 Flavour 两栏各有 Acetaldehyde（青苹果），但 4.csv 的 50 列中无对应维度，8.xlsx 的 Trained panel 50 行也与 4.csv 一一对应	该两项不进入建模；乙醛在化学侧以 `acetaldehyde` 列参与问题一与问题二，仅缺“青苹果”这一感官靶，如实登记为数据缺口
化学-感官交叉相关	6.csv 实为 44 个化学行 × 50 个感官列	按实测维度使用，不臆测其行列数
7.csv 论坛文本	250×189，其中 palate_acetaldehyde、palate_acetate、palate_dentist 三列完全缺失	文本数据不进入三问建模，全缺失列仅登记
8.xlsx 参考表	实为 7 个 sheet（含校准浓度、价格等）	逐 sheet 登记用途，仅作旁证、不进训练

表 A.3　43 个阈值超限列的清单与超阈比例

字段（1.csv 列名）	来源类别	阈值（1.csv 尺度）	超阈比例
protein.g.L.	—	0.010	99.6%
linalool	—	0.027	98.4%
ethanol..v.v.	—	0.245	97.6%
citronellol	—	0.025	92.4%
H2S	—	0.544	92.0%
ammonia.mg.L.	—	0.415	87.6%
bitterness	—	0.699	86.4%
isopentyl_acetate	—	-0.219	84.4%
geraniol	—	0.032	76.0%

43 个阈值超限列的清单与超阈比例（续）

字段	来源类别	阈值	超阈比例
DMS	—	1.237	67.2%
ethyl_acetate	—	1.380	65.6%
acetic_acid.g.L.	—	-0.853	61.6%
isoamyl_alcohol	—	1.602	51.6%
ethyl_hexanoate	—	-0.638	51.6%
iron	—	-1.000	47.6%
X2.3.butanedione	—	0.299	46.5%
ethyl_octanoate	—	-0.155	26.4%
DES	—	0.079	18.4%
GFS	—	0.462	18.0%
lactic_acid.mg.L.	—	2.620	17.2%
X1.alpha.terpineol	—	1.500	10.4%
ethyl_2.methyl_butyrate	—	-1.569	6.8%
X4VG	—	-0.685	6.4%
E.caryophyllene	—	0.280	5.6%
ethyl.butyrate	—	0.450	3.2%
glycerol	—	0.647	2.8%
phenethyl_alcohol	—	1.544	2.4%
alpha.humulene	—	0.625	2.0%
ethyl_isovalerate	—	-1.000	0.8%
isobutanol	—	1.903	0.0%
acetaldehyde	—	1.699	0.0%
furfural	—	60.000	0.0%
ethyl_decanoate	—	0.015	0.0%
ethyl.isobutyrate	—	2.600	0.0%
ethyl.nicotinate	—	6.000	0.0%
ethyl_propionate	—	1.000	0.0%
isobutyl_acetate	—	0.000	0.0%
octyl_acetate	—	-0.301	0.0%
phenethyl_acetate	—	0.246	0.0%
methylpyrazine	—	1.000	0.0%
CS2	—	1.699	0.0%
SO2.mg.L.	—	1.186	0.0%

43 个阈值超限列的清单与超阈比例（续）

字段	来源类别	阈值	超阈比例
Z.nerolidol	—	25.000	0.0%

注：阈值已按 5.3 节核实的尺度换算到 1.csv 取值空间（常用对数列取 $\log_{10}$）；超阈比例为该列取值不低于阈值的样本占比，与 9.3 节特征增广实验同一取数口径。数据源 `figures/derived/q1_threshold_cols.json`。

表 A.4　8 个共表达模块的第一主成分（成员 ≥ 5）

模块	成员数	代表成员（按度排序前 3）	PC1 解释率
15	28	ethyl.phenylacetate、prenyl.isobutyrate、ethyl.5.methylhexanoate	0.333 ± 0.014
19	28	nerol.oxide、alpha.calacorene、caryophylla.4.12..8.13..dien.5.alpha.ol	0.303 ± 0.016
49	23	X3.methyl.2.hexanol、X3.furanmethanol、n.nonanol	0.285 ± 0.024
27	20	X2.3.butanedione、X2.methyl.1.butanol、X1.propanol	0.716 ± 0.160
35	19	ethyl..E..linalool、isoborneol、terpinen.4.ol	0.472 ± 0.025
5	18	trans.dihydro.alpha.terpinyl.acetate、isopentyl.hexanoate、X1.2.dihydro.8.hydroxy..2E..linalool	0.537 ± 0.011
0	12	ethyl_acetate、ethyl_hexanoate、isopentyl_acetate	0.678 ± 0.011
20	11	X2Z.6E.farnesol、n.decanol、E.nerolidol	0.343 ± 0.018

注：PC1 解释率在每个训练折内单独拟合 PCA、取五折均值 ± 标准差，与 9.3 节模块 PC1 增广实验同一防泄漏口径。模块编号为共表达网络的社区 id。数据来源：figures/derived/q1_pc1_modules.json

表 A.5　55 个 Louvain 社区的成员构成（$\rho = 0.5$，211 节点）

模块	成员数	成员（按度降序）
M01	28	ethyl.phenylacetate、prenyl.isobutyrate、ethyl.5.methylhexanoate、ethyl.benzoate、neryl.formate、isomaltol、nonan.2.ol、ethyl.furoate、perillyl.acetate、X2.acetylfuran、germacrene.D、X4.ethyl.guaiacol、X.E..alpha.ionone、ethyl_isovalerate、X5.methylfurfural、X2.acetylpyrrole、isoamyl.lactate、X4.ethyl.phenol、ethyl_2.methyl_butyrate、methylpyrazine、X2.6.dimethyl.pyrazine、ethyl.hex..3E..enoate、ethyl.hydrocinnamate、furfural、ethyl.tiglate、ethyl..E..cinnamate、octyl_acetate、X4.methoxysalicylaldehyde
M02	28	nerol.oxide、alpha.calacorene、caryophylla.4.12..8.13..dien.5.alpha.ol、alpha.muurolol、alloaromadendrene.epoxide、X1.10.di.epi.cubenol、X1.octen.3.ol、ethyl.hex..2E..enoate、X2.undecanol、neryl.propanoate、humulene.epoxide.II、methyl.geranate、X.E..beta.ionone、tau.muurolol、caryophyllene.oxide、caryophyllene.alcohol、selin.11.en.4.alpha.ol、y.methyl.1.octanol、ambroxide、cis.dihydro.beta.terpineol、X.E..ortho.methoxy.cinnamaldehyde、isopentyl.butanoate、terpinen.4.ol.acetate、neryl.isobutanoate、neryl.isovalerate、geosmin、spathulenol、benzyl.benzoate
M03	23	X3.methyl.2.hexanol、X3.furanmethanol、n.nonanol、ortho.cresol、X4.methyl.1.pentanol、n.octanol、n.heptanol、n.dodecanol、alpha.terpinyl.isobutanoate、n.tetradecanol、manool、X2.ethyl.1.hexanol、x.methyl.1.octanol、X9.epi..E..caryophyllene、isopropyl.tetradecanoate、isopropyl.hexadecanoate、ethyl.isobutyrate、dimethoxy..E..citral、methyl.hexadecanoate、butyl.acetate、X2.furanmethanol、car.3.en.2.one、manool.oxide

55 个 Louvain 社区的成员构成（续）

模块	成员数	成员
M04	20	X2.3.butanedione、X2.methyl.1.butanol、X1.propanol、n.pentanol、isopentyl.formate、X3.methyl.2.butenal、ethyl.pentanoate、diethyl.succinate、X.E.E..2.4.decadienal、propyl.acetate、gamma.nonalactone、benzaldehyde、ethyl.nicotinate、X14.hydroxy.9.epi..E..caryophyllene、X3.methylbutanal、amyl.acetate、benzyl.alcohol、X.E..beta.damascenone、alpha.humulene、gamma.eudesmol
M05	19	ethyl..E..linalool、isoborneol、terpinen.4.ol、beta.phellandrene、terpinolene、linalool、X2.methyl.benzofuran、X1.alpha.terpineol、E.ocimenone、alpha.phellandrene、limonene、cumin.aldehyde、X.E..beta.ocimene、camphor、citronellol、phenylacetaldehyde、nerol、hydroxy.methyl.furfural、geraniol
M06	18	trans.dihydro.alpha.terpinyl.acetate、isopentyl.hexanoate、X1.2.dihydro.8.hydroxy..2E..linalool、pentyl.octanoate、isobutyl.hexanoate、X.Z..beta.farnesene、X2.methylbutyl.octanoate、ethyl.tetradecanoate、ethyl.pentadecanoate、X2.butyloctanoate、ethyl..9..decenoate、X2.phenyl.ethyl.butyrate、ethyl.hexadecanoate、ethyl_decanoate、X.E..2.nonenal、ethyl_octanoate、Z.Z.geranyl.linalool、ethyl.octadecanoate
M07	12	ethyl_acetate、ethyl_hexanoate、isopentyl_acetate、isobutyl_acetate、isoamyl_alcohol、phenethyl_acetate、E.cinnamaldehyde、acetaldehyde、isobutanol、n.hexanol、ethyl.butyrate、heptyl.acetate
M08	11	X2Z.6E.farnesol、n.decanol、E.nerolidol、X2.3.dihydro.farnesol、dihydroisocaryophyllene.epoxide、X2E.6Z.farnesal、X2.pentyl.furan、beta.cyclohomocitral、X.E..beta.farnesene、X2Z.6E.farnesal、X3.methylthio.propanol
M09	3	MeSH、DES、H2S
M10	3	butylated.hydroxytoluene、E.methyl.isoeugenol、X.Z..dihydro.apofarnesal
M11	2	neo.allo.ocimene、X13.epi.manool.oxide
M12	1	CS2
M13	1	DMS
M14	1	ethyl_propionate
M15	1	phenethyl_alcohol
M16	1	X4VG
M17	1	propylene.glycol
M18	1	X2.methyltetrahydrofuran.3.one
M19	1	ethyl.lactate
M20	1	X3Z.hexenol
M21	1	styrene
M22	1	X6.methyl.5.hepten.2.one
M23	1	dehydroxy.cis.linalool.oxide
M24	1	hexyl.acetate
M25	1	eucalyptol
M26	1	cis.linalool.oxide
M27	1	meta.cymenene
M28	1	n.nonanal
M29	1	trans.dihydro.beta.terpineol
M30	1	cis.beta.terpineol
M31	1	vinyl.caprylate
M32	1	X2.undecanone
M33	1	delta.terpinyl.acetate

55 个 Louvain 社区的成员构成（续）

模块	成员数	成员
M34	1	eugenol
M35	1	methyl.para.anisate
M36	1	vanillin
M37	1	dodecanal
M38	1	X4.8.alpha.epoxy.caryophyllane
M39	1	E.caryophyllene
M40	1	beta.humulene
M41	1	linalool.isovalerate
M42	1	valencene
M43	1	X.E..dihydro.apofarnesal
M44	1	Z.nerolidol
M45	1	isopropyl.laurate
M46	1	tau.cadinol
M47	1	alpha.eudesmol
M48	1	foeniculin
M49	1	cadalene
M50	1	caryophyllene.acetate
M51	1	X14.hydroxy.alpha.humulene
M52	1	X2Z.6Z.farnesol
M53	1	X2E.6E.methyl.farnesoate
M54	1	X2.ethylhexylsalicylate
M55	1	X2.ethyl.3.methylpyrazine

注：M01–M55 按成员数降序重新编号，其中 M01–M08 即表 A.4 的 8 个 PC1 模块。另有 44 个度为 0 的孤立节点未归入任何社区：CS2、DMS、ethyl_propionate、phenethyl_alcohol、X4VG、propylene.glycol、X2.methyltetrahydrofuran.3.one、ethyl.lactate、X3Z.hexenol、styrene、X6.methyl.5.hepten.2.one、dehydroxy.cis.linalool.oxide、hexyl.acetate、eucalyptol、cis.linalool.oxide、meta.cymenene、n.nonanal、trans.dihydro.beta.terpineol、cis.beta.terpineol、vinyl.caprylate、X2.undecanone、delta.terpinyl.acetate、eugenol、methyl.para.anisate、vanillin、dodecanal、X4.8.alpha.epoxy.caryophyllane、E.caryophyllene、beta.humulene、linalool.isovalerate、valencene、X.E..dihydro.apofarnesal、Z.nerolidol、isopropyl.laurate、tau.cadinol、alpha.eudesmol、foeniculin、cadalene、caryophyllene.acetate、X14.hydroxy.alpha.humulene、X2Z.6Z.farnesol、X2E.6E.methyl.farnesoate、X2.ethylhexylsalicylate、X2.ethyl.3.methylpyrazine。

表 A.6　全部 50 维 × 3 个候选的证据分级（101 A / 42 B / 7 C）

感官维	名次	化合物	频率	条件增量	模块增量	正折数	级
A_malt_all	1	acetaldehyde	1.000	0.0056	0.0022	5	B
A_malt_all	2	octyl_acetate	1.000	0.0060	0.0460	5	A
A_malt_all	3	MeSH	1.000	0.0017	0.0001	5	B
A_malt_grain	1	Z.nerolidol	1.000	0.0138	—	5	B
A_malt_grain	2	terpinen.4.ol	1.000	0.0206	0.0316	5	B
A_malt_grain	3	phenethyl_alcohol	0.680	0.0046	—	5	C
A_malt_bread	1	acetaldehyde	1.000	0.0090	0.0045	5	A
A_malt_bread	2	octyl_acetate	1.000	0.0082	0.0621	5	A
A_malt_bread	3	ethyl.hexadecanoate	0.488	0.0158	0.0275	5	B
A_malt_cara	1	octyl_acetate	1.000	0.0063	0.0525	5	A
A_malt_cara	2	acetaldehyde	1.000	0.0002	0.0054	5	B

全部 50 维 × 3 个候选的证据分级（续）

感官维	名次	化合物	频率	条件增量	模块增量	正折数	级
A_malt_cara	3	MeSH	0.966	0.0004	0.0004	5	B
A_malt_burn	1	isobutanol	1.000	0.0005	0.0020	5	B
A_malt_burn	2	MeSH	0.900	0.0033	0.0002	5	A
A_malt_burn	3	ethyl_propionate	0.920	0.0003	—	5	B
A_hops_all	1	ethyl_octanoate	1.000	0.0463	0.0118	5	A
A_hops_all	2	DMS	1.000	0.0267	—	5	A
A_hops_all	3	linalool	1.000	0.0029	0.0103	5	A
A_hops_citrus	1	citronellol	1.000	0.0068	0.0192	5	A
A_hops_citrus	2	ethyl_decanoate	1.000	0.0011	0.0313	5	B
A_hops_citrus	3	E.caryophyllene	0.972	0.0055	—	5	A
A_hops_tropical	1	DMS	1.000	0.0217	—	5	A
A_hops_tropical	2	isopentyl.butanoate	1.000	0.1005	0.0826	5	A
A_hops_tropical	3	geraniol	0.944	0.0011	0.0160	5	B
A_hops_noble	1	ethyl_octanoate	1.000	0.0856	0.0254	5	A
A_hops_noble	2	DMS	1.000	0.0043	—	5	A
A_hops_noble	3	ethyl_hexanoate	1.000	0.0022	0.0098	5	B
A_hops_woody	1	alloaromadendrene.epoxide	1.000	0.0582	0.1027	5	A
A_hops_woody	2	ethyl_2.methyl_butyrate	1.000	0.0078	0.0251	5	A
A_hops_woody	3	isobutanol	0.970	0.0156	0.0032	5	A
A_esters_all	1	n.hexanol	1.000	0.0784	0.0690	5	A
A_esters_all	2	acetaldehyde	0.982	0.0105	0.1429	5	A
A_esters_all	3	phenethyl_alcohol	0.968	0.0101	—	5	A
A_esters_ethac	1	ethyl_acetate	1.000	0.0235	0.0215	5	A
A_esters_ethac	2	phenethyl_alcohol	1.000	0.0114	—	5	A
A_esters_ethac	3	X2.methyl.1.butanol	0.990	0.0110	0.0321	5	A
A_esters_isoaa	1	isopentyl_acetate	1.000	0.0426	0.0791	5	A
A_esters_isoaa	2	n.hexanol	1.000	0.0640	0.0579	5	A
A_esters_isoaa	3	benzaldehyde	1.000	0.0319	0.0157	5	A
A_esters_flower	1	ethyl.lactate	0.996	0.0357	—	5	B
A_esters_flower	2	geraniol	0.998	0.0026	0.0559	5	C
A_esters_flower	3	isobutyl_acetate	0.984	0.0021	0.0140	5	C
A_esters_fruity	1	beta.phellandrene	1.000	0.0723	0.0135	5	A
A_esters_fruity	2	ethyl_isovalerate	1.000	0.0005	0.0466	5	B
A_esters_fruity	3	MeSH	0.934	0.0058	0.0016	5	A
F_malt_all	1	acetaldehyde	1.000	0.0132	0.0025	5	A
F_malt_all	2	MeSH	1.000	0.0001	0.0003	5	B
F_malt_all	3	ethyl_decanoate	1.000	0.0007	0.0046	5	B
F_malt_grain	1	acetaldehyde	1.000	0.0088	0.0219	5	B
F_malt_grain	2	octyl_acetate	0.866	0.0060	0.0273	5	B
F_malt_grain	3	n.heptanol	0.682	0.0242	0.0099	5	C
F_malt_bread	1	MeSH	1.000	0.0073	0.0005	5	A
F_malt_bread	2	acetaldehyde	1.000	0.0026	0.0107	5	A
F_malt_bread	3	X2.acetylpyrrole	1.000	0.0278	0.0380	5	A
F_malt_cara	1	acetaldehyde	1.000	0.0100	0.0064	5	A
F_malt_cara	2	DES	1.000	0.0031	0.0009	5	B

全部 50 维 × 3 个候选的证据分级（续）

感官维	名次	化合物	频率	条件增量	模块增量	正折数	级
F_malt_cara	3	octyl_acetate	1.000	0.0056	0.0520	5	B
F_malt_burn	1	MeSH	1.000	0.0003	0.0013	5	B
F_malt_burn	2	acetaldehyde	1.000	0.0015	0.0040	5	A
F_malt_burn	3	ethyl_decanoate	1.000	0.0006	0.0095	5	B
F_hops_all	1	ethyl_octanoate	1.000	0.0539	0.0069	5	A
F_hops_all	2	DMS	1.000	0.0076	—	5	B
F_hops_all	3	ethyl_hexanoate	0.870	0.0019	0.0081	5	B
F_hops_citrus	1	citronellol	1.000	0.0061	0.0182	5	A
F_hops_citrus	2	E.caryophyllene	0.994	0.0043	—	5	A
F_hops_citrus	3	DMS	0.554	0.0027	—	5	B
F_hops_tropical	1	DMS	1.000	0.0097	—	5	A
F_hops_tropical	2	nerol.oxide	0.990	0.0245	0.0794	5	A
F_hops_tropical	3	germacrene.D	0.980	0.0267	0.0295	5	A
F_hops_noble	1	ethyl_octanoate	1.000	0.0717	0.0179	5	A
F_hops_noble	2	ethyl_hexanoate	1.000	0.0025	0.0097	5	A
F_hops_noble	3	DMS	1.000	0.0040	—	5	A
F_hops_woody	1	isobutanol	1.000	0.0766	0.0120	5	A
F_hops_woody	2	X.E..2.nonenal	0.964	0.0423	0.0112	5	A
F_hops_woody	3	citronellol	0.908	0.0021	0.0067	5	B
F_esters_all	1	ethyl_acetate	1.000	0.0367	0.0625	5	A
F_esters_all	2	phenethyl_alcohol	0.998	0.0103	—	5	A
F_esters_all	3	acetaldehyde	0.962	0.0136	0.0945	5	A
F_esters_ethac	1	ethyl_acetate	1.000	0.0540	0.0378	5	A
F_esters_ethac	2	acetaldehyde	1.000	0.0199	0.0743	5	A
F_esters_ethac	3	Z.Z.geranyl.linalool	0.508	0.0229	0.0145	5	B
F_esters_isoaa	1	isopentyl_acetate	0.740	0.0162	0.0408	5	B
F_esters_isoaa	2	phenethyl_alcohol	1.000	0.0128	—	5	A
F_esters_isoaa	3	neryl.propanoate	0.976	0.0121	0.0380	5	A
F_esters_flower	1	delta.terpinyl.acetate	1.000	0.0245	—	5	B
F_esters_flower	2	ethyl_2.methyl_butyrate	0.932	0.0067	0.0357	5	C
F_esters_flower	3	eucalyptol	0.670	0.0134	—	5	C
F_esters_fruity	1	MeSH	1.000	0.0170	0.0036	5	A
F_esters_fruity	2	octyl_acetate	0.916	0.0054	0.0445	5	A
F_esters_fruity	3	phenethyl_alcohol	0.660	0.0197	—	5	B
acidity	1	ethyl_isovalerate	1.000	0.0147	0.0381	5	A
acidity	2	isopentyl_acetate	1.000	0.0015	0.0024	5	A
acidity	3	geraniol	1.000	0.0026	0.0086	5	A
bitternes	1	ethyl_octanoate	1.000	0.0764	0.0218	5	A
bitternes	2	MeSH	1.000	0.0003	0.0000	5	B
bitternes	3	DMS	1.000	0.0029	—	5	A
sweetness	1	ethyl_decanoate	1.000	0.0207	0.0276	5	A
sweetness	2	octyl_acetate	1.000	0.0002	0.0169	5	B
sweetness	3	alpha.humulene	1.000	0.0026	0.0083	5	A
X4vg	1	X4VG	1.000	0.2155	—	5	A
X4vg	2	delta.terpinyl.acetate	1.000	0.1268	—	5	A

全部 50 维 × 3 个候选的证据分级（续）

感官维	名次	化合物	频率	条件增量	模块增量	正折数	级
X4vg	3	ethyl_isovalerate	1.000	0.0022	0.0419	5	A
diacetyl	1	eugenol	1.000	0.1161	—	5	A
diacetyl	2	ethyl_octanoate	1.000	0.0173	0.0784	5	A
diacetyl	3	X1.alpha.terpineol	1.000	0.0029	0.0217	5	A
dms	1	isomaltol	1.000	0.0135	0.0175	5	A
dms	2	phenethyl_alcohol	1.000	0.0035	—	5	A
dms	3	X3.methylbutanal	0.406	0.0098	0.0447	5	B
metallic	1	ethyl_isovalerate	1.000	0.0181	0.0688	5	A
metallic	2	alpha.calacorene	1.000	0.0506	0.0183	5	A
metallic	3	isopentyl_acetate	0.898	0.0047	0.0080	5	A
stale_hops	1	alloaromadendrene.epoxide	1.000	0.0666	0.0448	5	A
stale_hops	2	ethyl_2.methyl_butyrate	1.000	0.0015	0.0193	5	B
stale_hops	3	linalool	1.000	0.0048	0.0113	5	B
t2n	1	geraniol	1.000	0.0045	0.0410	5	A
t2n	2	phenethyl_alcohol	1.000	0.0062	—	5	A
t2n	3	H2S	0.912	0.0094	0.0029	5	A
orange	1	ethyl..E..linalool	1.000	0.1290	0.1214	5	A
orange	2	DMS	0.896	0.0110	—	5	A
orange	3	acetaldehyde	0.786	0.0000	0.0008	5	C
coriander	1	ethyl..E..linalool	0.856	0.0813	0.1290	5	A
coriander	2	acetaldehyde	0.986	0.0034	0.0016	5	A
coriander	3	X4VG	0.774	0.0029	—	5	B
clove	1	X2.3.butanedione	1.000	0.0108	0.0028	5	A
clove	2	X4VG	0.962	0.0132	—	5	A
clove	3	eucalyptol	0.642	0.0366	—	5	B
lactic	1	isopentyl_acetate	1.000	0.0106	0.0008	5	A
lactic	2	ethyl_isovalerate	1.000	0.0002	0.0592	5	B
lactic	3	Z.nerolidol	1.000	0.0002	—	5	B
acetic	1	ethyl_isovalerate	1.000	0.0357	0.0150	5	A
acetic	2	isopentyl_acetate	1.000	0.0013	0.0023	5	A
acetic	3	Z.nerolidol	1.000	0.0002	—	5	B
barnyard	1	alloaromadendrene.epoxide	1.000	0.0832	0.0390	5	A
barnyard	2	ethyl_2.methyl_butyrate	1.000	0.0000	0.0186	5	B
barnyard	3	acetaldehyde	1.000	0.0068	0.0240	5	A
alcohol	1	ethyl_octanoate	1.000	0.0345	0.0107	5	A
alcohol	2	acetaldehyde	1.000	0.0075	0.0209	5	A
alcohol	3	MeSH	1.000	0.0004	0.0003	5	B
aftertaste	1	ethyl_octanoate	1.000	0.0411	0.0164	5	A
aftertaste	2	ethyl_isovalerate	1.000	0.0242	0.0205	5	A
aftertaste	3	acetaldehyde	1.000	0.0084	0.0180	5	A
body	1	isobutanol	1.000	0.0103	0.0134	5	A
body	2	ethyl_octanoate	1.000	0.0049	0.0039	5	A
body	3	MeSH	1.000	0.0057	0.0000	5	A
co2	1	ethyl_octanoate	1.000	0.0750	0.0161	5	A
co2	2	ethyl_hexanoate	1.000	0.0143	0.0245	5	A

全部 50 维 × 3 个候选的证据分级（续）

感官维	名次	化合物	频率	条件增量	模块增量	正折数	级
co2	3	DMS	1.000	0.0027	—	5	A
overall	1	ethyl_acetate	1.000	0.0186	0.0067	5	A
overall	2	DMS	1.000	0.0074	—	5	A
overall	3	cis.linalool.oxide	0.998	0.0207	—	5	A

注：频率为 500 次按风格分层 bootstrap 的入选频率；条件增量与模块增量均已除以标签方差归一化；正折数为 5 折中条件增量为正的折数；模块增量为 — 表示该化合物所在社区只有它自己，模块增量无法定义。分级按正文的四条件判定，A = 全满足、B = 满足三条、C = 其余。

附录 B　软件环境与运行命令

本文全部计算使用 Python 3.11.9 完成，主要依赖库及版本为：numpy 2.4.6、pandas 2.3.3、scikit-learn 1.8.0、lightgbm 4.6.0、shap 0.51.0、networkx 3.6.1、python-louvain 0.16、torch 2.13.0（CPU 版）、scipy 1.17.1、matplotlib 3.10.8、joblib 1.5.3、openpyxl 3.1.5。随机种子固定为 42，全程仅使用相对路径。

在支撑材料根目录下，安装依赖并一键运行全部三问的命令为：

```
pip install -r code/requirements.txt
cd code
python main.py --data-dir ../user_data
```

程序依次执行问题一（感官分级预测）、问题二（关键化合物归因）、问题三（风格条件生成与迁移），结果文件写入 `submission/`，过程数据写入 `figures/`。

附录 C　支撑材料文件清单

路径	内容
`code/main.py`	一键入口，串联三问并汇总结果
`code/params.py`	全局常数（种子、维度、缺陷列、风格、超参）
`code/utils.py`	数据加载、0-6 分箱映射、二次加权 Kappa、检查点
`code/data_check.py`	数据读取与维度对齐自检
`code/problem1.py`	问题一：缺失感知梯度提升 + 分箱 + 分层交叉验证
`code/problem2.py`	问题二：化合物集 C=211 共表达图 + 社区检测 + 多证据 Top-3（去冗余）+ bootstrap/Jaccard + 来源判定 + 随机基线
`code/problem3.py`	问题三：CVAE 条件生成 + 风格识别率/画像评估 + 隐空间迁移 + min 缺陷投影 + 无约束对照
`code/constraint_audit.py`	从落盘结果重算硬约束
`code/sanity_check.py`	结果数值自动审查
`figures/supp_prep_eda.py`	预处理实证：附件概况/差异、对数底核实、未检出-缺失分类、三类划分
`figures/supp_kaggle.py`	Kaggle 公开集外部旁证（风格 ABV/IBU 宏观对照，不进建模）

续下页

路径	内容
figures/gen_fig_*.py、figures/gen_tables.py	全部图表与三线表的生成脚本（数值均读结果 JSON）
figures/problem_1/2/3_results.json、all_results.json	三问全部量化指标（QWK/Spearman/±1、图统计、来源类别、KS/识别率/缺陷 Δ）
figures/supp_preprocess.json、supp_kaggle.json	预处理实算结果与 Kaggle 旁证统计
submission/q1_sensory_scores.csv	问题一 250×50 维 0-6 分级
submission/q2_top3_compounds.csv	问题二每维 Top-3（仅化合物集 C）+ 稳定性 + 来源判定
submission/q3_generated_profiles.csv	问题三 90 条生成谱 + 11 条迁移 + 感官画像 + 缺陷 min 投影对照

附录 D　核心源程序

本附录只列三问的核心实现，完整可运行代码见支撑材料 code/ 目录；工具函数（数据加载、分箱、Kappa、检查点）与参数表不再重复排印。

code/problem1.py——问题一：缺失感知回归与有序回归

```python
def _fit_lgb(Xtr, ytr):
    m = lgb.LGBMRegressor(**LGB_PARAMS)
    m.fit(Xtr, ytr)
    return m


# ---------- 有序分支：分箱退化诊断 + 类加权阈值分解 ----------
CLF_PARAMS = dict(
    n_estimators=120, num_leaves=8, learning_rate=0.05,
    min_child_samples=15, feature_fraction=0.6, bagging_fraction=0.8,
    bagging_freq=1, lambda_l2=1.0, random_state=P.SEED, n_jobs=-1, verbose=-1,
)
DEGEN_SPAN = 0.05      # 前 5 个分位切点跨度 < 极差的 5% 判为退化
ORD_MIN_FRAC = 0.10    # 阈值两侧任一类占比低于 10% 时不做二分类

def binning_degenerate(ytr, span_th=DEGEN_SPAN):
    """判断该维的分位分箱是否退化：切点挤在极窄区间内，等级在原始尺度上不可分。"""
    y = np.asarray(ytr, dtype=float)
    y = y[np.isfinite(y)]
    if y.size < 20:
        return False
    rng = float(y.max() - y.min())
    if rng <= 0:
        return True
    edges = U.Binner().fit(y).edges
```

```
    return bool((edges[4] - edges[0]) / rng < span_th)

def _fit_ordinal(Xtr, ytr, Xva, n_levels=P.N_LEVELS):
    """类加权阈值分解：对每个内部阈值训练一个「y > t」二分类器，概率累加后取整。

    与直接回归再分箱相比，它不依赖切点位置，因而能绕开密集分布下切点重合的问题；
    阈值两侧样本不均衡时按类频率反比加权，避免多数类主导。
    """
    ytr = np.asarray(ytr, dtype=float)
    edges = np.quantile(ytr, np.linspace(0, 1, n_levels + 1)[1:-1])
    edges = np.maximum.accumulate(edges)
    acc = np.zeros(len(Xva))
    for t in edges:
        z = (ytr > t).astype(int)
        frac = float(z.mean())
        if frac < ORD_MIN_FRAC or frac > 1 - ORD_MIN_FRAC:
            acc += frac                       # 无区分度的阈值直接用先验
            continue
        w = np.where(z == 1, 1.0 / max(frac, 1e-6), 1.0 / max(1.0 - frac, 1e-6))
        clf = lgb.LGBMClassifier(**CLF_PARAMS)
        clf.fit(Xtr, z, sample_weight=w)
        acc += clf.predict_proba(Xva)[:, 1]
    return np.clip(np.round(acc), P.LEVEL_MIN, P.LEVEL_MAX).astype(int)
```

code/problem2.py——问题二：三路证据融合与稳定性

```
def _corr_evidence(C6, comp_rows6, comp_names, feat_cols, sens_cols):
    """6.csv 交叉相关 → 231 位置 × 50 感官的 |corr| 证据（未覆盖化合物记 0）。

    两个都必须按名映射，不能按位置：
      - 化合物行：6.csv 用英文全名，2.csv 用原始列名。
      - 感官列：6.csv 前 46 列顺序与 4.csv 一致，但第 47-50 位不同
        （6.csv: Carbonation/Aftertaste/Body/Overall;
         4.csv: aftertaste/body/co2/overall），按位置对齐会把
        aftertaste、body、co2 三列的证据错位。
    """
    J, Pn = len(sens_cols), len(feat_cols)
    evid = np.zeros((J, Pn))
    name2pos = {name: i for i, name in enumerate(comp_names)}
    Cv = C6.values.astype(float)

    # 感官列按名映射：C6 的第 k 列 → 4.csv 的某个短名
    col_targets = U.align_sensory_cols(list(C6.columns))
    sens_pos = {s: j for j, s in enumerate(sens_cols)}
    col_to_j = []
    for short in col_targets:
        if short not in sens_pos:
            raise KeyError(f"6.csv 感官列映射到未定义的维度: {short}")
```

```
        col_to_j.append(sens_pos[short])

    n_mapped = 0
    for ri, r in enumerate(comp_rows6):
        pos = name2pos.get(r, None)
        if pos is None:
            continue
        n_mapped += 1
        for k, j in enumerate(col_to_j):
            v = Cv[ri, k]
            evid[j, pos] = abs(v) if np.isfinite(v) else 0.0
    print(f"[Q2] 6.csv 交叉相关映射化合物 {n_mapped}/{len(comp_rows6)} → 231 位置; "
          f"感官列按名映射 {len(set(col_to_j))}/50")
    return evid

def _module_rep(base_scores, comm_arr):
    """模块代表加权：同社区（仅 C，comm!=-1）内按 base 排名，第 1 名 rep=1，第 2=1/2…

    非 C 位置 comm=-1 直接跳过（rep 保持 0），促进 Top-3 跨模块多样。
    """
    rep = np.zeros_like(base_scores, dtype=float)
    for ci in np.unique(comm_arr):
        if ci == -1:
            continue                        # 非 C 节点不参与模块代表
        idx = np.where(comm_arr == ci)[0]
        order = idx[np.argsort(-base_scores[idx])]
        for rank, p in enumerate(order, 1):
            rep[p] = 1.0 / rank
    return rep

def _fuse_and_stability(sens_cols, feat_cols, shap_imp, corr_evid, rf_imp,
                        abs_shap_list, comm_arr, c_mask, R, styles):
    """多证据融合 + 去冗余 Top-3 + bootstrap 入选频率 + 跨方法 Jaccard（全部只在 C 内取）。"""
    J, Pn = len(sens_cols), len(feat_cols)
    a, b, g = P.FUSE_ALPHA, P.FUSE_BETA, P.FUSE_GAMMA
    per_dim = {}
    top3_idx = {}
    # 点估计：φ=0.5SHAP+0.3|corr|+0.2module_rep，module_rep 仅在 C 社区内
    shap_n_all = np.vstack([_norm(shap_imp[j]) for j in range(J)])
    corr_n_all = np.vstack([_norm(corr_evid[j]) for j in range(J)])
    rf_n_all = np.vstack([_norm(rf_imp[j]) for j in range(J)])
    phi_all = np.zeros((J, Pn))
    for j in range(J):
        base = a * shap_n_all[j] + b * corr_n_all[j]
        rep = _module_rep(base, comm_arr)          # 仅 C 社区
        phi = base + g * rep
        phi_all[j] = phi
        # 去冗余 Top-3（phi 先掩码到 C）
```

```
        top3_idx[j] = _select_topk(_mask_c(phi, c_mask), R, comm_arr)
    # bootstrap 入选频率：**按风格分层**有放回重采样 → 重算 SHAP → 同一融合+去冗余流程（只在 C 内）。
    # 分层可避免小样本风格在重采样中整体缺席，使频率反映"同风格内"的稳定性。
    rng_bt = np.random.default_rng(P.SEED)
    N = abs_shap_list[0].shape[0]
    style_arr = np.asarray(styles)
    strata = [np.where(style_arr == s)[0] for s in pd.unique(style_arr)]
    freq = np.zeros((J, Pn))
    B = P.N_BOOTSTRAP
    conv_trace = {}          # 200/300/500 收敛检查
    for bi in range(B):
        parts = [rng_bt.choice(idx, size=len(idx), replace=True) for idx in strata if len(idx)]
        idx = np.concatenate(parts)
        for j in range(J):
            shap_b = _norm(abs_shap_list[j][idx].mean(axis=0))
            base_b = a * shap_b + b * corr_n_all[j]
            phi_b = base_b + g * _module_rep(base_b, comm_arr)
            for p in _select_topk(_mask_c(phi_b, c_mask), R, comm_arr):
                freq[j, p] += 1
        if (bi + 1) in (200, 300, 500):
            snap = freq / (bi + 1)
            top1 = [int(np.argmax(snap[j])) for j in range(J)]
            conv_trace[str(bi + 1)] = {
                "mean_top1_freq": round(float(np.mean([snap[j, top1[j]] for j in range(J)])), 4),
                "n_top1_changed_vs_final": None,   # 稍后填
                "top1": top1,
            }
            print(f"[Q2] bootstrap {bi+1}/{B}  mean_top1={conv_trace[str(bi+1)]['mean_top1_freq']:.4f}")
    freq /= B
    # 跨方法 Jaccard（SHAP / 6.csv相关 / RF；各方法 Top-3 只在 C 内取）
    jac_dim = {}
    for j in range(J):
        ts = _topk_masked(shap_n_all[j], c_mask)
        tc = _topk_masked(corr_n_all[j], c_mask)
        tr = _topk_masked(rf_n_all[j], c_mask)
        pj = np.mean([_jaccard(ts, tc), _jaccard(ts, tr), _jaccard(tc, tr)])
        jac_dim[sens_cols[j]] = round(float(pj), 4)

    for j, col in enumerate(sens_cols):
        t3 = top3_idx[j]
        per_dim[col] = {
            "top3": [feat_cols[p] for p in t3],
            "top3_idx": [int(p) for p in t3],
            "phi": [round(float(phi_all[j, p]), 4) for p in t3],
            "shap_norm": [round(float(shap_n_all[j, p]), 4) for p in t3],
            "corr_abs": [round(float(corr_n_all[j, p]), 4) for p in t3],
```

```
            "select_freq": [round(float(freq[j, p]), 4) for p in t3],
            "module": [int(comm_arr[p]) for p in t3],
            "jaccard_cross_method": jac_dim[col],
        }
    # 收敛检查：200/300 次的 Top-1 与最终（500 次）Top-1 差异维数
    final_top1 = [int(np.argmax(freq[j])) for j in range(J)]
    for k in conv_trace:
        prev = conv_trace[k]["top1"]
        conv_trace[k]["n_top1_changed_vs_final"] = int(sum(1 for a_, b_ in zip(prev, final_top1) if
    a_ != b_))
        conv_trace[k].pop("top1", None)
    print("[Q2] 收敛检查:", {k: (v["mean_top1_freq"], v["n_top1_changed_vs_final"]) for k, v in
    conv_trace.items()})

    mean_top1_freq = float(np.mean([per_dim[c]["select_freq"][0] for c in sens_cols]))
    mean_jac = float(np.mean(list(jac_dim.values())))
    n_high_stable = int(sum(1 for c in sens_cols if per_dim[c]["select_freq"][0] >= 0.7))
    print(f"[Q2] 平均Top-1入选频率={mean_top1_freq:.4f} 平均跨方法Jaccard={mean_jac:.4f} "
          f"高稳定维={n_high_stable}")
    return {
        "problem": 2,
        "method": ("共表达图(networkx+louvain,仅C 211项) + SHAP/相关/模块代表融合(ϕ=0.5/0.3/0.2) "
                   "+ 同社区|R|>=0.7去冗余 + bootstrap频率 + 跨方法Jaccard + 随机基线对照"),
        "candidate_set": {"name": "C", "n": int(c_mask.sum()),
                          "excluded_physicochem": sorted(P.PHYSICOCHEM_COLS),
                          "excluded_aggregate": sorted(P.AGG_COLS)},
        "summary": {"n_dims": J, "n_bootstrap": B, "topn": P.TOPN,
                    "mean_top1_select_freq": round(mean_top1_freq, 4),
                    "mean_cross_method_jaccard": round(mean_jac, 4),
                    "n_high_stable_dims": n_high_stable,
                    "redun_rho": REDUN_RHO,
                    "fuse_weights": {"alpha": a, "beta": b, "gamma": g},
                    "bootstrap_stratified_by_style": True,
                    "bootstrap_convergence": conv_trace},
        "per_dim": per_dim, "sensory_cols": sens_cols,
    }
```

code/problem3.py——问题三：CVAE 与缺陷投影迁移

```
def _elbo_loss(xhat, x, mask, mu, logvar, beta_kl, free_bits=P.FREE_BITS):
    # 掩码重构（只对非缺失分量计 MSE，式11）
    diff2 = ((xhat - x) ** 2) * mask
    recon = diff2.sum() / mask.sum().clamp(min=1.0)
    # 逐维 KL + free-bits（每维 KL 低于 free_bits 时不再惩罚，防后验坍塌）
    kld_dim = -0.5 * (1 + logvar - mu.pow(2) - logvar.exp())   # [B, d]
    kld_dim = torch.clamp(kld_dim.mean(dim=0), min=free_bits)
    kld = kld_dim.sum()
    return recon + beta_kl * kld, recon.item(), float(kld.item())
```

```python

def _train_cvae(Xstd, mask, onehot, device):
    model = CVAE(Xstd.shape[1], onehot.shape[1]).to(device)
    opt = torch.optim.Adam(model.parameters(), lr=P.CVAE_LR)
    Xt = torch.tensor(Xstd, dtype=torch.float32, device=device)
    Mt = torch.tensor(mask, dtype=torch.float32, device=device)
    St = torch.tensor(onehot, dtype=torch.float32, device=device)
    N = Xt.shape[0]
    best, best_state, patience, bad = 1e18, None, 60, 0
    rng = np.random.default_rng(P.SEED)
    for ep in range(1, P.CVAE_EPOCHS + 1):
        model.train()
        perm = rng.permutation(N)
        ep_loss = ep_rec = ep_kl = 0.0
        for st in range(0, N, P.CVAE_BATCH):
            bidx = perm[st:st + P.CVAE_BATCH]
            xb, mb, sb = Xt[bidx], Mt[bidx], St[bidx]
            opt.zero_grad()
            xhat, mu, lv = model(xb, sb)
            beta = P.BETA_KL * min(1.0, ep / max(1, P.KL_ANNEAL_EPOCHS))  # KL 退火
            loss, rec, kl = _elbo_loss(xhat, xb, mb, mu, lv, beta)
            loss.backward()
            opt.step()
            ep_loss += loss.item() * len(bidx); ep_rec += rec * len(bidx); ep_kl += kl * len(bidx)
        ep_loss /= N
        if ep <= P.KL_ANNEAL_EPOCHS:
            if ep % 50 == 0 or ep == 1:
                print(f"[Q3] CVAE epoch {ep}/{P.CVAE_EPOCHS}(退火) loss={ep_loss:.4f} "
                      f"recon={ep_rec/N:.4f} kl={ep_kl/N:.4f}")
            continue   # 退火阶段不计入早停
        if ep_loss < best - 1e-4:
            best, best_state, bad = ep_loss, {k: v.detach().clone() for k, v in model.state_dict().
    items()}, 0
        else:
            bad += 1
        if ep % 50 == 0 or ep == 1:
            print(f"[Q3] CVAE epoch {ep}/{P.CVAE_EPOCHS} loss={ep_loss:.4f} "
                  f"recon={ep_rec/N:.4f} kl={ep_kl/N:.4f}")
        if bad >= patience:
            print(f"[Q3] 早停于 epoch {ep}（best loss={best:.4f}）")
            break
    if best_state is not None:
        model.load_state_dict(best_state)
    model.eval()
    return model

def _transfer(model, style_list, s2i, S, Xstd, Xv, styles, feat_cols, mu_f, sd_f,
              device, lo=None, hi=None):
```

```
    """Pils/Lager → Tripel 隐空间平移 + 缺陷投影（式12/13）。"""
    tgt = P.TRANSFER_TARGET
    zt, _ = _style_latent_mean(model, Xstd, styles, tgt, s2i, S, device)
    # 目标风格缺陷典型值 m^t（native 中位）
    tgt_idx = np.where(styles == tgt)[0]
    col_med_all = np.nanmedian(Xv, axis=0)
    defect_pos = {d: feat_cols.index(c) for d, c in P.DEFECT_COL_MAP.items()}
    m_t = {d: float(np.nanmedian(Xv[tgt_idx, pos])) for d, pos in defect_pos.items()}

    records = []
    before = {d: [] for d in defect_pos}
    after = {d: [] for d in defect_pos}
    cap_rec = {d: [] for d in defect_pos}
    raw_after = {d: [] for d in defect_pos}   # 无约束纯平移对照（缺陷投影前的解码值）
    for src in P.TRANSFER_SOURCES:
        if src not in s2i:
            print(f"[Q3] 迁移源 {src} 不存在，跳过")
            continue
        zs, sidx = _style_latent_mean(model, Xstd, styles, src, s2i, S, device)
        delta = zt - zs
        # 逐源样本编码 -> 平移 -> 用目标风格解码
        oh_src = np.zeros((len(sidx), S)); oh_src[:, s2i[src]] = 1
        with torch.no_grad():
            mu_s, _ = model.encode(torch.tensor(Xstd[sidx], dtype=torch.float32, device=device),
                                   torch.tensor(oh_src, dtype=torch.float32, device=device))
            z_moved = mu_s.cpu().numpy() + delta
            oh_t = np.zeros((len(sidx), S)); oh_t[:, s2i[tgt]] = 1
            xhat = model.decode(torch.tensor(z_moved, dtype=torch.float32, device=device),
                                torch.tensor(oh_t, dtype=torch.float32, device=device)).cpu().numpy
    ()
        native = xhat * sd_f + mu_f
        if lo is not None and hi is not None:
            native = _clip_to_observed(native, lo, hi)
        for row, si in enumerate(sidx):
            x_after_vec = native[row].copy()
            for d, pos in defect_pos.items():
                xb = Xv[si, pos]
                if not np.isfinite(xb):
                    xb = float(col_med_all[pos])
                raw_val = float(x_after_vec[pos])           # 无约束纯平移的缺陷取值（对照）
                raw_after[d].append(raw_val)
                # 严格不恶化：迁移后缺陷既不得高于源款原值 xb，也不高于目标典型安全值 m_t，取严
                cap = min(xb, m_t[d])
                if P.USE_ABS_THRESHOLD:
                    pass  # 可换算时此处并入 τ 上界（本题单位不可比，默认关闭）
                # 缺陷列逐样本投影回安全区（式13，np.minimum 下截断）
                xa = float(np.minimum(raw_val, cap))
                x_after_vec[pos] = xa
```

```
                before[d].append(float(xb)); after[d].append(xa); cap_rec[d].append(cap)
            records.append({"style": f"{src}->{tgt}", "sample_type": "transfer",
                            "src_beer_row": int(si), "_native": x_after_vec})
        print(f"[Q3] 迁移 {src}->{tgt}: {len(sidx)} 条")
    # 合规率（式13: x_after <= min(xb, m_t)）
    n_tot = n_ok = 0
    n_rise_raw = n_rise_constrained = 0
    per_defect = {}
    for d in defect_pos:
        bf = np.array(before[d]); af = np.array(after[d]); cp = np.array(cap_rec[d])
        raw = np.array(raw_after[d])
        ok = int((af <= cp + 1e-9).sum())
        rise_raw = int((raw > bf + 1e-9).sum())    # 无约束时缺陷升高的样本数
        rise_c = int((af > bf + 1e-9).sum())       # 严格约束后缺陷升高数（应为 0）
        n_tot += len(af); n_ok += ok
        n_rise_raw += rise_raw; n_rise_constrained += rise_c
        per_defect[d] = {"n": len(af), "n_compliant": ok,
                         "before_mean": round(float(bf.mean()), 4),
                         "after_mean": round(float(af.mean()), 4),
                         "raw_after_mean": round(float(raw.mean()), 4),
                         "m_t": round(m_t[d], 4),
                         "delta_mean": round(float((af - bf).mean()), 4),
                         "delta_raw_mean": round(float((raw - bf).mean()), 4),
                         "n_rise_unconstrained": rise_raw,
                         "n_rise_constrained": rise_c}
    rate = n_ok / n_tot if n_tot else 1.0
    info = {"compliance_rate": round(rate, 6), "n_checks": n_tot, "n_compliant": n_ok,
            "per_defect": per_defect, "defect_cols": list(P.DEFECT_COL_MAP.values()),
            "defect_no_chem": P.DEFECT_NO_CHEM, "m_t": {k: round(v, 4) for k, v in m_t.items()},
            "unconstrained_control": {
                "description": "同批迁移仅做隐空间平移、不做缺陷投影（对照），量化约束必要性",
                "n_defect_rise_unconstrained": n_rise_raw, "n_total": n_tot,
                "rise_frac_unconstrained": round(n_rise_raw / n_tot, 4) if n_tot else None,
                "n_defect_rise_constrained": n_rise_constrained,
                "rise_frac_constrained": round(n_rise_constrained / n_tot, 4) if n_tot else None}}
    print(f"[Q3] 缺陷合规率={rate:.4f}（{n_ok}/{n_tot}）；无约束升高 {n_rise_raw}/{n_tot}，"
          f"严格约束后升高 {n_rise_constrained}/{n_tot}")
    return records, info
```