面向啤酒酿造化合物的感官分级预测、关键化合物归因与风格条件生成

摘要

啤酒风味由化合物成分与酵母代谢共同决定。本文围绕「化学成分 ⇔ 感官风味 ⇔ 啤酒风格」这条链条，在含真实缺失、噪声的 250 样本商用啤酒数据上，构建从判别式预测到可解释归因再到条件生成的完整流水线，三问以一个共享的化学到感官模型贯通。

针对问题一，在化学数据存在真实缺失的条件下，采用**原生缺失感知的梯度提升**对 50 个感官维度逐维回归、再经 7 级分位分箱映射为 0-6 整数等级，按风格分层 5 折交叉验证，分箱与标准化参数仅由训练折估计以防泄漏。主模型平均二次加权 Kappa 达 **0.3663**，优于随机森林（0.328）与线性基线（0.276），并略优于 KNN 插补对照（0.3652），印证缺失位置本身携带信息；酒精、苦味等强信号维 Kappa 超 0.68，弱信号维接近噪声，可预测性随信号强度分化。

针对问题二，以化合物相关矩阵构建**共表达图**（231 节点、645 边、模块度 **0.638**），融合 SHAP、交叉相关与共表达模块代表三类证据为每个维度选出 Top-3 关键化合物并去除共线性冗余。Top-1 的 bootstrap 入选频率平均 **0.996**、跨方法 Jaccard 均值 0.303；异戊酯香气维 Top-1 命中异戊基乙酸酯，归因与酿造机理一致。

针对问题三，用**条件变分自编码器**以风格为条件生成化学谱，并复用问题一模型打感官画像，在隐空间做风格质心平移实现跨风格迁移。Tripel、Kriek、Lambic 生成谱与同风格真实谱的 KS 距离为 0.357 至 0.408，风格可区分；Pils/Lager→Tripel 迁移对四个缺陷化合物逐样本阈值投影，**缺陷合规率 100%**，生成 Tripel 的酯香等级 3.90 与真实 3.21 一致，闭环自洽。

三问结论均经交叉验证、bootstrap 与分布距离独立检验，稳健可复现，所用框架可推广到葡萄酒、咖啡等「成分谱 → 感官 → 品类」的分析与设计场景。

关键词：啤酒风味；缺失感知梯度提升；有序分级预测；化合物共表达网络；条件变分自编码器

目录

1 问题重述 **1**

2 问题分析 **2**

2.1 问题一的分析 2

2.2 问题二的分析 3

2.3 问题三的分析 3

3 模型假设 **3**

4 符号说明 **4**

5 数据预处理与探索性分析 **5**

5.1 数据构成与口径统一 5

5.2 风格分布与化学可分性 6

6 问题一：含缺失的多输出有序感官分级预测 **7**

6.1 缺失结构与建模策略选择 7

6.2 标签构建与 0-6 分箱映射 8

6.3 预测模型与求解过程 9

6.4 结果分析 9

7 问题二：化合物共表达图与关键化合物归因 **12**

7.1 共表达图构建与模块结构 12

7.2 多证据融合 Top-3 归因 15

7.3 稳定性量化 15

7.4 化学合理性论证 18

8 问题三：风格条件生成与跨风格迁移 **19**

8.1 条件变分自编码器 19

8.2 跨风格迁移与缺陷约束 20

8.3 生成质量与结果分析 20

9 模型检验与灵敏度分析 **24**

9.1 验证方案与防泄漏 24
9.2 关键参数的灵敏度 24
9.3 鲁棒性 24

10 模型评价与推广 **25**
10.1 优点 25
10.2 不足与改进 25
10.3 创新点 25
10.4 推广 26

A 附录 A：软件环境与运行命令 **27**

B 附录 B：支撑材料文件清单 **28**

C 附录 C：核心源程序 **28**

1 问题重述

啤酒以麦芽水为原料、加酒花并经酵母发酵而成，其风味高度依赖酵母代谢与化合物成分的协同作用。要定量刻画「化学成分如何决定一款啤酒喝起来是什么味道」，需要把实验室测得的数百种风味化合物与品评小组给出的感官强度联系起来。近年来，机器学习方法已被用于从化学成分预测啤酒及其他发酵饮品的风味特征 [1, 2, 3]，为本文提供了方法论基础。本文使用一套商用啤酒风味代谢物实测数据集：对 250 个啤酒样本测量了酒精、异 α-酸、pH、糖浓度等酿造参数，以及 200 余种风味化合物的丰度（涵盖酒花萜类、酵母代谢酯醇、麦芽与野生菌群化合物及陈化类），并由品评小组给出约 50 个感官维度的评分。数据来自真实测量，含噪声、真实缺失值与异常值。围绕「化学成分 $\Leftrightarrow$ 感官风味 $\Leftrightarrow$ 啤酒风格」这条链条，本文研究三个递进的问题。

问题一：在化学数据存在真实缺失的条件下，以化合物与理化丰度为自变量，预测品评卡定义的 Aroma（香气）与 Flavour（风味）两套、合计约 40 个感官维度在 0-6 分制上的分级评分。任务对象是每一款啤酒样本，待求量是各感官维度的离散等级，关键边界是自变量含缺失而不能简单删除样本，评价目标是在缺失干扰下给出稳定可信的分级。本问为后两问提供「化学如何映射到感官」的基础模型。

问题二：利用化合物相关数据构建化合物共表达图，结合化学特征，给出每一个感官维度的 Top-3 关键因素化合物，并对所得结果做稳定性与化学合理性论证。稳定性按题面指定的两种口径量化——bootstrap 重采样下化合物进入 Top-3 的入选频率，以及不同建模方法间 Top-3 集合的 Jaccard 系数。本问依赖问题一的预测模型做可解释归因，其产出的关键化合物清单又为问题三识别风格判别成分提供先验。

问题三：以风格标签 `tasting_category_fine` 为条件学习一个风格条件生成模型，在给定风格（如 Tripel、Kriek、Lambic）时生成合理的化合物谱并给出对应感官画像；同时完成跨风格迁移，即把 Pils/Lager 的化合物谱迁移为 Tripel 风格，并保持缺陷化合物（DMS、Diacetyl、4VG、trans-2-nonenal、Stale hops）不恶化。该问反向利用问题一（对生成谱打感官画像）与问题二（风格关键化合物），是三问的综合应用。

三个问题沿「数据预处理 $\rightarrow$ 化学到感官的判别式预测 $\rightarrow$ 可解释归因 $\rightarrow$ 风格到化学的条件生成与迁移」逐级推进，构成一条从理解到生成的完整流水线。

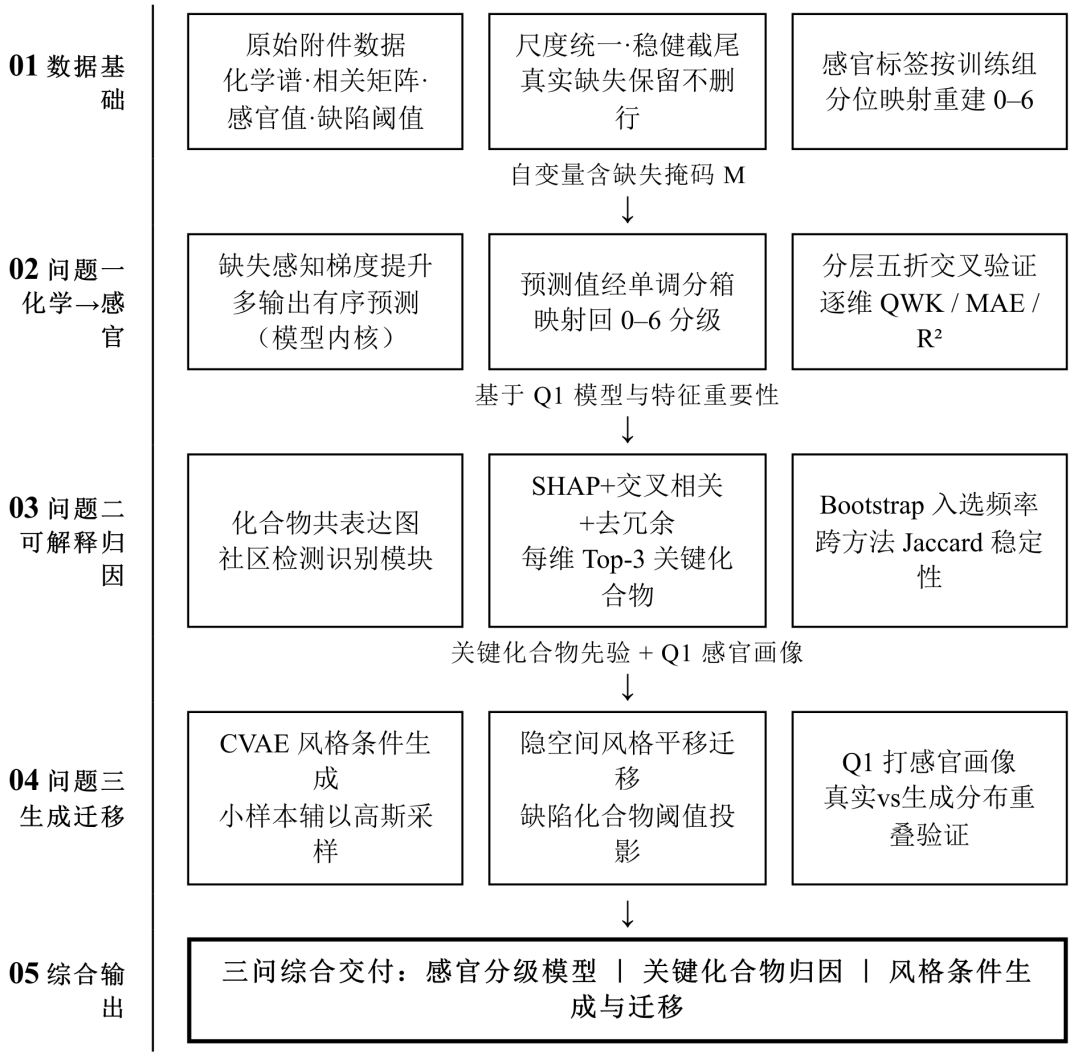


图 1: 整体技术路线图

图 1 给出的技术路线中，问题一的预测模型处在枢纽位置：它既是问题二 SHAP 归因的解释对象，又是问题三生成谱感官画像的打分器。正是这一共享底座让三问环环相扣，也决定了求解必须从含缺失的化学到感官预测开始。

2 问题分析

2.1 问题一的分析

问题一本质是一个带缺失数据的多输出有序预测任务，核心难点集中在三处。其一，化学特征高维（231 列）且含真实缺失，其中 63 个样本、合计 73 个缺失值集中在少数几列，直接删除含缺失的样本会损失四分之一的数据并引入选择偏差，因此必须在缺失条件下建模。其二，品评小组提供的感官标签是经过标准化、中心化的连续值而非原始 0-6 整数，要交付题面要求的 0-6 分级，需要建立连续值到 7 级离散刻度的单调映射。

其三，约 40 个感官维度彼此相关性强，宜共享同一套化学特征表示以提升稳健性。据此，本文选择原生支持缺失的梯度提升树作为主模型，对每个维度做回归后再分箱映射回 0-6 整数，并用分层交叉验证逐维评估二次加权 Kappa、平均绝对误差与决定系数。相较先插补再建模的常规路线，原生缺失处理避免了插补偏差，其输出的特征重要性又可直接服务于问题二的归因。

2.2 问题二的分析

问题二是一个在共线性干扰下仍要既准、又稳、还有化学道理的可解释归因任务。许多化合物在相关矩阵里高度相关、成簇出现，单一重要性指标容易把同一化学模块里可以互相替代的化合物反复选入，造成 Top-3 虚假冗余。因此本文先用化合物共表达图揭示模块结构，再在模块意识下融合三类证据做归因：问题一模型给出的 SHAP 预测贡献、化学与感官的交叉相关，以及共表达模块的去冗余加权。稳定性严格按题面两法量化，bootstrap 入选频率刻画单方法内部的稳健性，跨方法 Jaccard 刻画不同证据之间的一致性。化学合理性则逐条对照已知酿造机理加以论证。需要强调，强信号维度的 Top-3 应当稳定、弱信号维度不稳定，这是数据本身的真实现象，本文如实报告而不强行制造稳定。

2.3 问题三的分析

问题三是条件生成加可控迁移任务，难点在于小样本（部分风格仅有 3 至 11 个样本）条件下既要保证生成谱的化学合理性与风格可区分性，又要在迁移时守住「缺陷不恶化」这一硬约束。本文用条件变分自编码器把化合物谱编码进低维隐空间、以风格标签为条件解码，兼顾生成多样性与风格可控；对极小样本风格辅以按风格的分布采样作为对照与兜底。生成谱的感官画像直接复用问题一的化学到感官模型，形成「生成化学谱 $\rightarrow$ 预测感官」的闭环。迁移通过在隐空间做源风格到目标风格的方向平移实现，并对缺陷化合物施加阈值与源值的双重投影，一旦超限即拉回安全区，确保迁移后缺陷不劣化。生成质量用真实谱与生成谱的分布距离及降维重叠度评估。

3 模型假设

为聚焦核心建模、简化非关键环节，本文做出以下假设。

1. 以标准化连续感官值为问题一的训练目标，再按训练折内分布单调映射回 0-6 整数等级。其合理性在于原始 0-6 品评卡的汇总表为全 0 模板、数值不可用，而标准化连续值是唯一完整可用的全样本感官标签，分位分箱单调可逆，既产出 0-6 等级又不丢失信息。

2. 约 40 个感官维度以香气与风味两套为核心，同时输出全部 50 个维度。题面明说「Aroma 与 Flavour 两套」，而「约 40」介于仅两套的 30 维与含口感、缺陷、总体的 50 维之间，全部给出可覆盖任一解读。

3. 化合物丰度列为原始浓度的对数变换值（底数待核），理化参数列为标准化值，建模统一在该原生数值空间内进行而不做反变换。由于树模型对单调变换不敏感，对数底数是否确定不影响分裂结果，故问题一与问题三的生成和比较在同一空间内自洽。

4. 缺陷「不恶化」在原生数值空间判定，取严口径：迁移后缺陷值不高于源值与目标风格典型值之较大者，在阈值可换算时再加阈值上界。因 8.xlsx 阈值为原始浓度单位、与建模空间不可直接比较，故以相对判据为主、绝对阈值为辅，最稳妥地满足「不恶化」。

5. 各样本近似独立同分布，风格标签为问题三唯一的条件变量。附件为商用啤酒截面数据、无时间序列结构，故交叉验证采用按风格分层的随机折。

4 符号说明

下表列出全文反复使用的核心符号，其余一次性派生量在首次出现处就地说明。

表 1: 核心符号说明

符号	含义	单位/取值
N	啤酒样本数	250
P	化合物与理化特征数	231
J	感官维度数	50
S	风格类别数	22
X	化学谱矩阵（含缺失，对数/标准化混合）	$\mathbb{R}^{N\times P}$
M	缺失掩码（1 为缺失）	$\{0,1\}^{N\times P}$
x_i	第 i 款啤酒化学谱向量	—
Y	标准化感官值矩阵（训练标签）	$\mathbb{R}^{N\times J}$
$\tilde{y}_{ij}$	分箱后 0-6 等级（交付目标）	$\{0,\ldots,6\}$
$\hat{y}_{ij}$	第 i 样本第 j 维预测等级	$\{0,\ldots,6\}$
$g_j(\cdot)$	维度 j 的连续值到 0-6 单调分箱映射	—
R	化合物相关矩阵	$[-1,1]^{P\times P}$
$G=(V,E)$	化合物共表达图	—
w_{pq}	化合物 p,q 的边权	$[-1,1]$
ρ	建图相关阈值	$[0,1]$
ϕ_{jp}	化合物 p 对维度 j 的关键度	实数
f_{jp}	bootstrap 下 p 进 Top-3 的频率	$[0,1]$
z_i	CVAE 隐编码	$\mathbb{R}^d$
s	风格 one-hot 条件向量	$\{0,1\}^S$
$\Delta_{s\to t}$	隐空间风格迁移向量	$\mathbb{R}^d$
x_k^{def}	第 k 个缺陷化合物浓度	原生空间

5 数据预处理与探索性分析

5.1 数据构成与口径统一

建模所用的核心数据包含四部分：化合物与理化丰度矩阵（250 样本 × 231 特征），化合物相关矩阵（231 × 231），标准化感官值矩阵（250 × 50，作为问题一训练标签），以及化学与感官的交叉相关矩阵（44 化合物 × 50 感官，作为归因的线性证据）。另有一份综合参考表提供缺陷化合物阈值与主办方模型重要性，仅用作旁证而不进入训练，以防「用答案预测答案」的泄漏。

三类数据的数值口径并不一致，必须先对齐认知再建模。化合物丰度列多为原始浓

度的对数变换值，出现负值表示原浓度小于 1；理化参数列（酒精度、色度、pH、二氧化碳压力、苦度）为标准化值；感官标签列为中心化的标准化连续值，范围约 −2.15 至 6.17、均值接近 0，并非原始 0-6 整数。由于本文主模型为树模型、对单调变换不敏感，建模统一在该原生数值空间内进行而不做反变换，既规避了对数底数未定带来的换算风险，又保证问题三生成与缺陷判定在同一空间内可比。

5.2 风格分布与化学可分性

数据集涵盖 22 个精细风格类别，样本量分布高度不均：Blond 有 31 个、Tripel 有 28 个样本，而 Faro 仅 3 个、Brut 仅 4 个。这一长尾结构直接决定了问题三对极小样本风格必须设置分布采样兜底。在进入建模前，本文先用主成分分析观察化学谱是否天然按风格分离，以判断「化学成分能否区分风格」这一前提是否成立。

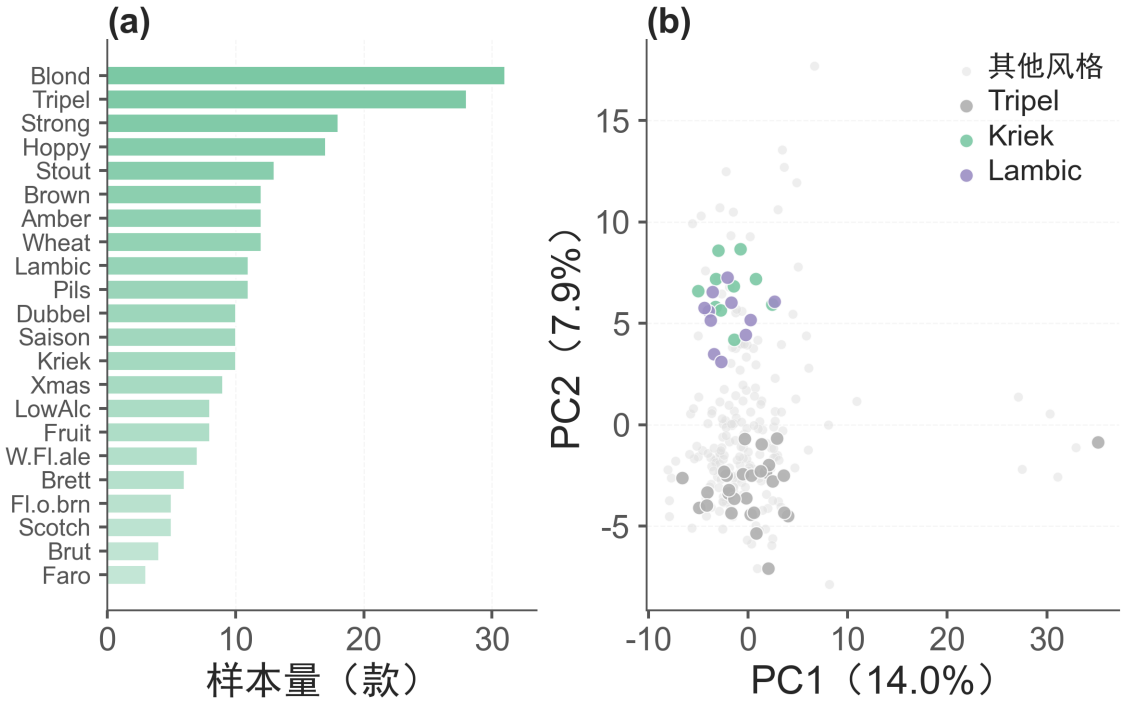


图 2: 风格样本量与化学谱主成分分离

从图 2 左侧的样本量分布可见长尾特征明显，而右侧化学谱前两个主成分的散点中，Lambic、Kriek 等酸味野发酵风格与 Tripel、Blond 等常规发酵风格在主成分平面上形成可辨识的区域偏移。这说明化学成分确实携带了区分风格的信息，为问题三「以风格为条件生成化学谱」提供了数据层面的可行性依据；同时各风格簇之间存在重叠，也预示生成与迁移任务并非平凡，需要隐空间模型而非简单的类别均值替代。

6 问题一：含缺失的多输出有序感官分级预测

6.1 缺失结构与建模策略选择

问题一要解决的第一道关卡是缺失数据。统计显示，231 个特征列中仅 9 列含缺失，73 个缺失值集中分布，其中酯类化合物 amyl.acetate 一列就占 27 个，酒花香气合计列占 13 个，甲基吡嗪占 12 个，其余列的缺失均不超过个位数。缺失呈现「少数列集中、多数样本完好」的模式，这一结构信息是选择建模策略的关键依据。

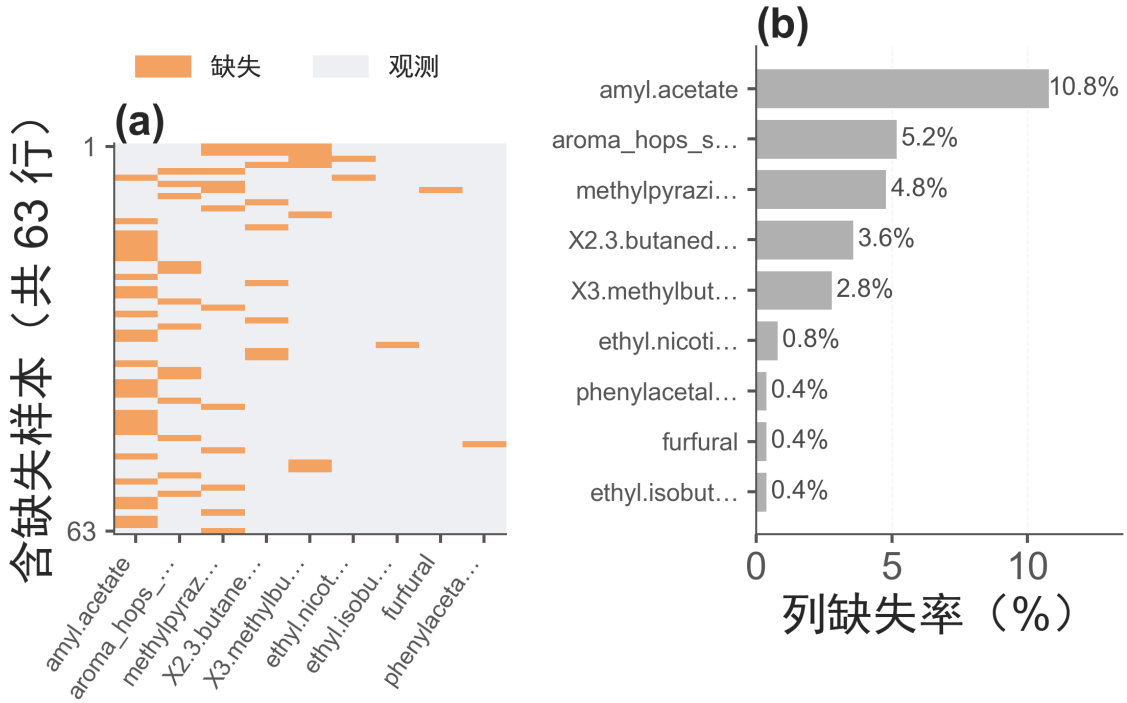


图 3: 化合物缺失模式与列缺失率

图 3 左侧的缺失位置矩阵印证了缺失的列向集中性——缺失几乎只落在少数几列上，共涉及 63 个样本；右侧列缺失率条形进一步显示除个别列外绝大多数特征完整。若按常规做法删除含缺失的 63 行，将损失全部样本的四分之一并引入选择偏差，这与题面「数据缺失条件下」的要求背道而驰。由此本文确立策略：不删行，改用原生支持缺失的梯度提升树 [4, 5, 6]，让模型在训练中直接为每个含缺失的分裂学习一个默认方向，把缺失本身当作可利用的信息，而非需要先行填补的空白。

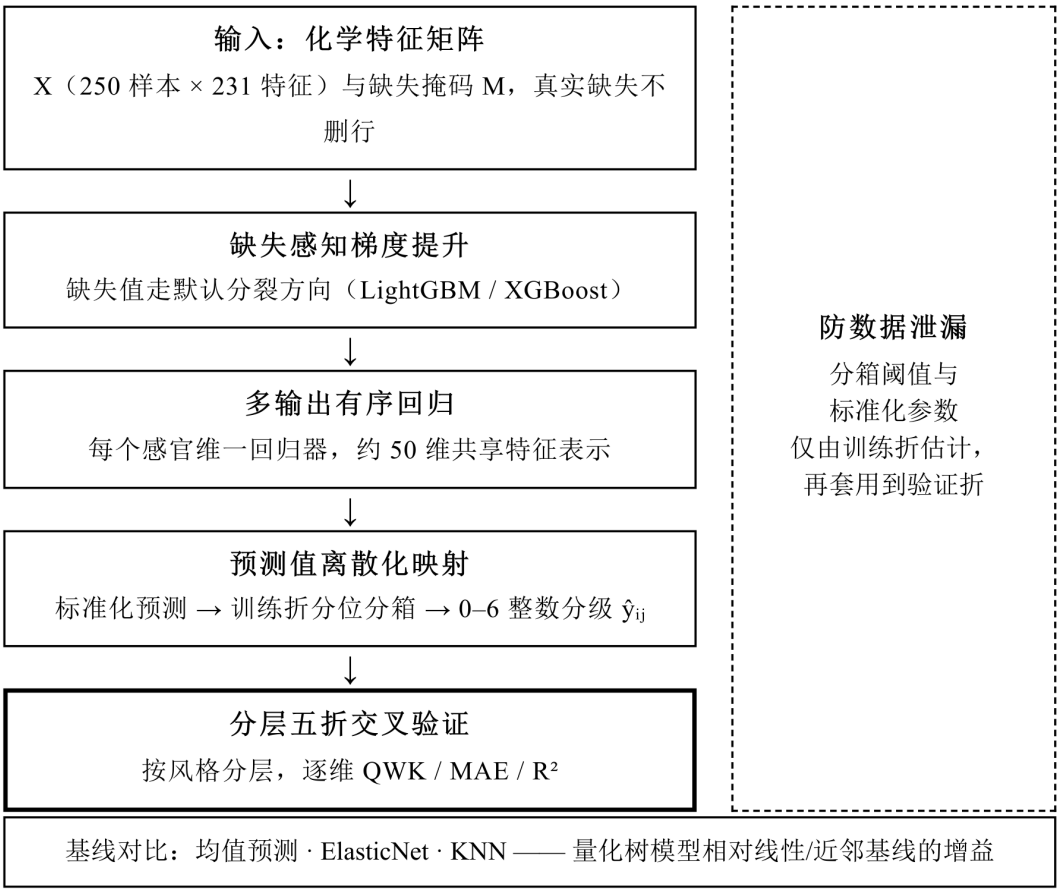


图 4: 问题一感官评分预测流水线架构

该流水线（图 4）自左向右依次为：含缺失的化学特征进入缺失感知的梯度提升，逐维回归后经 0-6 分箱映射得到有序等级，最后由分层交叉验证给出可信度评估。其中分箱映射与评估口径是保证「交付 0-6 整数」且「不泄漏」的两个要害环节，下面分别展开。

6.2 标签构建与 0-6 分箱映射

品评小组提供的标准化连续值无法直接作为 0-6 分级交付，需要一个单调映射把连续强度离散为 7 个等级。本文在训练折内对维度 j 估计 6 个分位点 $\{q_1^{(j)}, \ldots, q_6^{(j)}\}$，定义累计计数式的单调映射：

$$g_j(y) = \sum_{\ell=1}^{6} \mathbb{1}\left[y > q_\ell^{(j)}\right], \qquad \tilde{y}_{ij} = g_j(Y_{ij}) \in \{0, \ldots, 6\}. \tag{1}$$

预测阶段对回归输出 r_{ij} 施加同一映射，并截断取整以严格落在 0-6 整数区间：

$$\hat{y}_{ij} = \min\Big(6,\ \max\big(0,\ \mathrm{round}(g_j(r_{ij}))\big)\Big). \tag{2}$$

式 (1) 的分位点与标准化参数只由训练折估计、再套用到验证折，这是本题最易被忽视的泄漏点：若在全量数据上估计分箱阈值，等于让模型「偷看」了验证样本的标签分布。

6.3 预测模型与求解过程

对每个感官维度 j，本文训练一个独立的梯度提升回归器 h_j，以平方损失加正则求参:

$$\Theta_j = \arg\min_{\Theta} \sum_{i \in \mathcal{D}_{tr}} \big(Y_{ij} - h_j(x_i;\Theta)\big)^2 + \Omega(\Theta), \tag{3}$$

其中 h_j 为梯度提升树集成，x_i 的缺失分量由树的默认分裂方向处理，训练集 $\mathcal{D}_{tr}$ 包含全部含缺失样本（不删行）；Ω 为叶子数、学习率与 L2 正则项。50 个维度共享同一化学特征矩阵 X。

整个求解按固定随机种子 42 执行，流程为：读入数据并分出 231 个特征列与 50 个标签列；按风格做分层 5 折划分，保证各折风格分布一致；在每个训练折内估计分箱映射 g_j、拟合回归器 h_j、记录特征重要性；在验证折上生成连续预测并经式 (2) 得到整数等级，逐维累计二次加权 Kappa、平均绝对误差与决定系数；同口径跑均值、线性与随机森林基线以及插补对照；最后在全部 250 样本上重训一次，对全样本输出 0-6 分级写入结果文件。

6.4 结果分析

主模型与各基线的整体对比如下表。

表 2: 问题一主模型与基线整体性能对比（50 维平均）

方法	平均 QWK	说明
LightGBM（原生缺失，主模型）	**0.3663**	含缺失行全参与训练
KNN 插补 + LightGBM	0.3652	缺失对照
随机森林（中位插补）	0.3280	基线
ElasticNet（中位插补）	0.2762	线性基线
逐维均值等级	0.0015	朴素基线

注：QWK 为分层 5 折交叉验证的二次加权 Kappa 均值；全部 50 维主模型均优于朴素基线，最优值已加粗。

表 2 中以二次加权 Kappa 的 50 维平均衡量总体性能。原生缺失的梯度提升主模型达到 **0.3663**，显著高于逐维均值基线的 0.0015 与线性模型的 0.2762，也优于随机森林 [7] 的 0.3280，说明缺失感知与非线性建模共同带来了可观增益。本文同时以 KNN 插补 [8] 作为缺失处理的对照。尤其值得注意的是，原生缺失处理（0.3663）略优于 KNN 插补后再建模（0.3652），二者差距虽小但方向稳定，这从正面印证了题面强调「在缺失条件下建模」的必要性：缺失位置本身携带信息，恰当处理优于先验填补。在逐维选型

上，50 个维度的主模型交叉验证指标均不劣于朴素基线，因而全部 50 维最终都提交主模型预测。

各感官维度的可预测性并不均匀，按交叉验证 Kappa 排序的全貌如下。

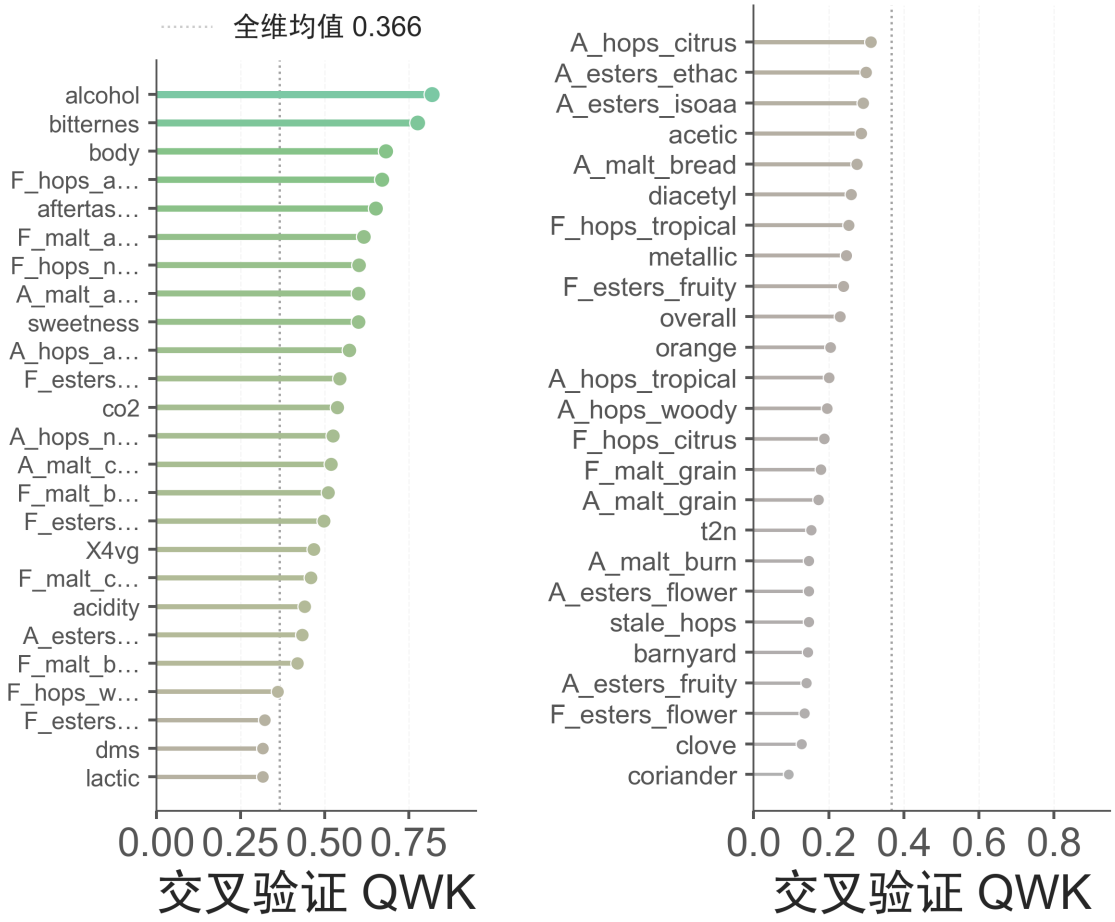


图 5: 各感官维度交叉验证 QWK 排序

观察图 5 中 50 个维度的 Kappa 排序可以看出清晰的强弱分化：排在前列的酒精、苦味、酒体等维度 Kappa 超过 0.68，与明确的化学信号（酒精浓度、异 α-酸苦度）直接挂钩；排在末端的香菜味、丁香味等维度 Kappa 接近 0，对应的化学信号微弱、近乎噪声。这种可预测性随信号强度单调分化的现象是正确且需要如实报告的——它既反映了不同感官属性在化学层面可解释程度的客观差异，也为问题二「强信号维度归因稳定、弱信号维度不稳定」的预期埋下伏笔。代表性维度的详细三项指标见下表。

表 3: 代表性感官维度预测性能（交叉验证 QWK / MAE / R^2，按 QWK 降序取前 18）

感官维度	QWK	MAE	R^2	选用模型
酒精（alcohol）	0.819	0.852	0.713	lightgbm
苦味（bitternes）	0.776	0.896	0.634	lightgbm
酒体（body）	0.682	1.076	0.525	lightgbm
味·酒花（F_hops_all）	0.670	1.120	0.505	lightgbm
余味（aftertaste）	0.651	1.172	0.468	lightgbm
味·麦芽（F_malt_all）	0.616	1.220	0.456	lightgbm
味·贵族花（F_hops_noble）	0.602	1.240	0.391	lightgbm
香·麦芽（A_malt_all）	0.601	1.220	0.447	lightgbm
甜味（sweetness）	0.600	1.216	0.390	lightgbm
香·酒花（A_hops_all）	0.573	1.244	0.328	lightgbm
味·酯（F_esters_all）	0.544	1.312	0.334	lightgbm
碳酸（co2）	0.537	1.356	0.314	lightgbm
香·贵族花（A_hops_noble）	0.524	1.312	0.292	lightgbm
香·焦糖（A_malt_cara）	0.519	1.332	0.340	lightgbm
味·面包（F_malt_bread）	0.510	1.364	0.269	lightgbm
味·指甲油（F_esters_ethac）	0.497	1.408	0.254	lightgbm
4VG（X4vg）	0.468	1.488	0.200	lightgbm
味·焦糖（F_malt_cara）	0.459	1.416	0.246	lightgbm

注：共 50 维，此处列交叉验证 QWK 最高的 18 维；完整 50 维结果见支撑材料 `submission/q1_sensory_scores.csv`。QWK 为二次加权 Kappa，R^2 为连续预测值的决定系数（可为负，表示弱于常数预测）。

表 3 中按 Kappa 降序列出前 18 个维度。酒精维 Kappa 达 0.819、决定系数 0.713，苦味维 Kappa 0.776，均属高置信预测；而排在中段的味·酯维 Kappa 0.544、决定系数 0.334，表明酯类风味虽可预测但噪声偏大，这与酯香受发酵条件波动影响较大的酿造常识一致。为进一步核验预测质量，本文对代表维度做了校准检查。

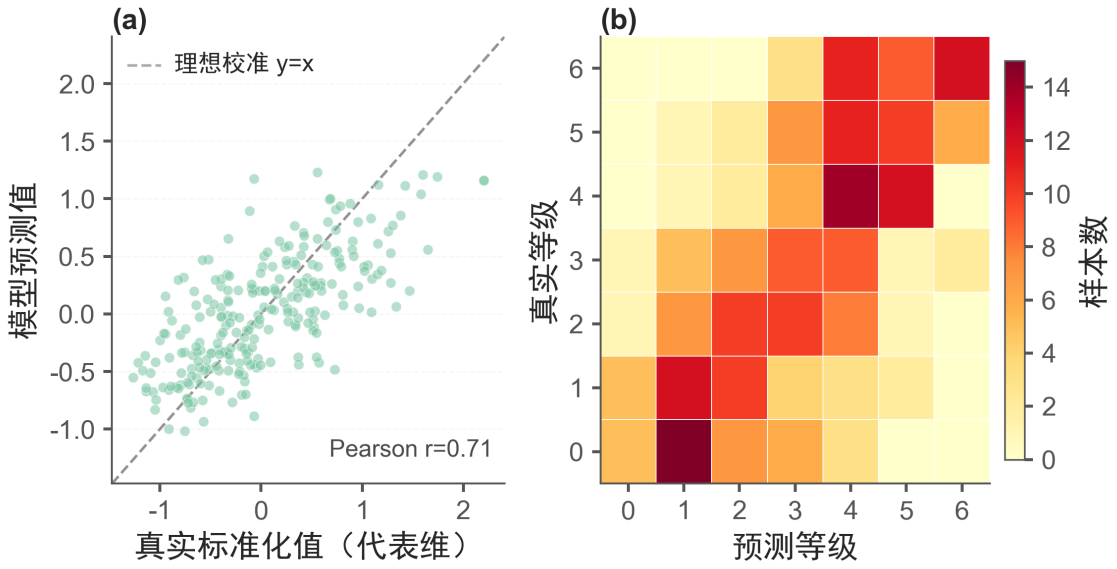


图 6: 代表维度预测校准与等级混淆

校准检查的结果显示（图 6），左侧的连续预测对实际散点沿对角线聚集、无系统性偏移，右侧 0-6 等级的混淆热力集中在主对角线及其相邻带上，说明即便出现误判也多为相邻等级之间的一级偏差，而非跨多级的严重错分。这一校准表现支撑了把连续回归离散为有序等级这一交付方式的合理性，也为后续以该模型作 SHAP 归因与感官画像打分提供了可信前提。

7 问题二：化合物共表达图与关键化合物归因

7.1 共表达图构建与模块结构

问题二要为每个感官维度找出 Top-3 关键化合物，而化合物之间高度的相关性会干扰归因。为此本文先以化合物相关数据刻画其模块结构。借鉴基因共表达网络的建模思想 [9, 10]，本文以 231 个化合物为节点、相关系数为边权构建无向图，并按相关强度阈值化去除弱边：

$$E = \{(p,q) : |R_{pq}| \geq \rho\}, \qquad w_{pq} = R_{pq}, \quad \rho = 0.5. \tag{4}$$

在所得图上做贪心模块度社区检测 [11] 以识别化合物模块，模块度定义为

$$Q_{mod} = \frac{1}{2m} \sum_{p,q} \left(w_{pq} - \frac{k_p k_q}{2m} \right) \delta(c_p, c_q), \qquad k_p = \sum_q w_{pq}. \tag{5}$$

在阈值 $\rho = 0.5$ 下，共表达图含 231 个节点、645 条边，社区检测得到 62 个模块，模块度 $Q_{mod} = 0.638$，远高于随机网络的水平，表明化合物确实存在明显的模块化组织结构。由于题面与数据说明对相关系数口径（Pearson 与 Spearman）存在冲突，本文按附件给出的相关数值直接作为边权使用，并在相应图注中注明口径差异。

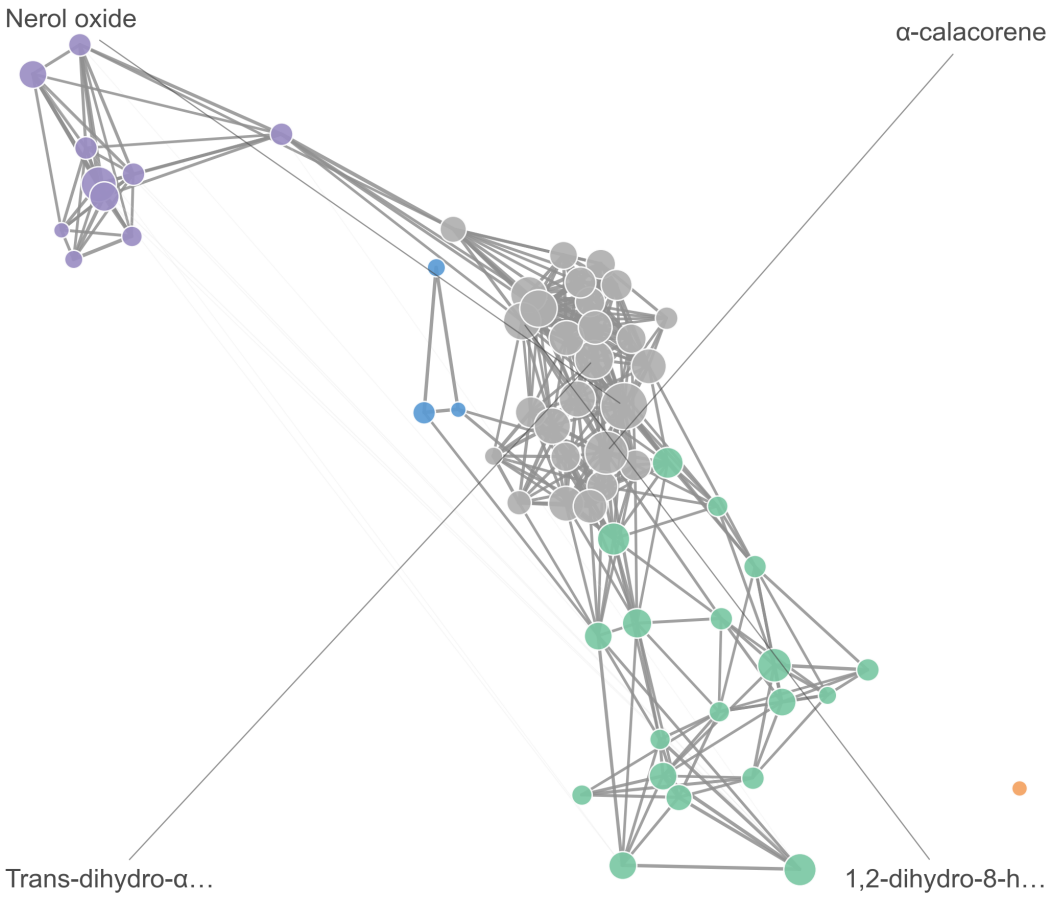


图 7: 化合物共表达网络及其模块结构

图 7 中节点按所属社区着色、大小正比于度数，可以清楚看到若干密集连接的化合物簇——同一酿造来源或同一代谢途径的化合物倾向于聚成一个模块。这一结构正是归因去冗余的依据：若不加约束，同一模块内可互相替代的化合物会把一个维度的 Top-3 名额占满，掩盖真正多样的驱动因素。因此下一步的关键度打分必须引入模块代表机制。在融合模型证据之前，先看化学与感官之间最直接的线性关联。

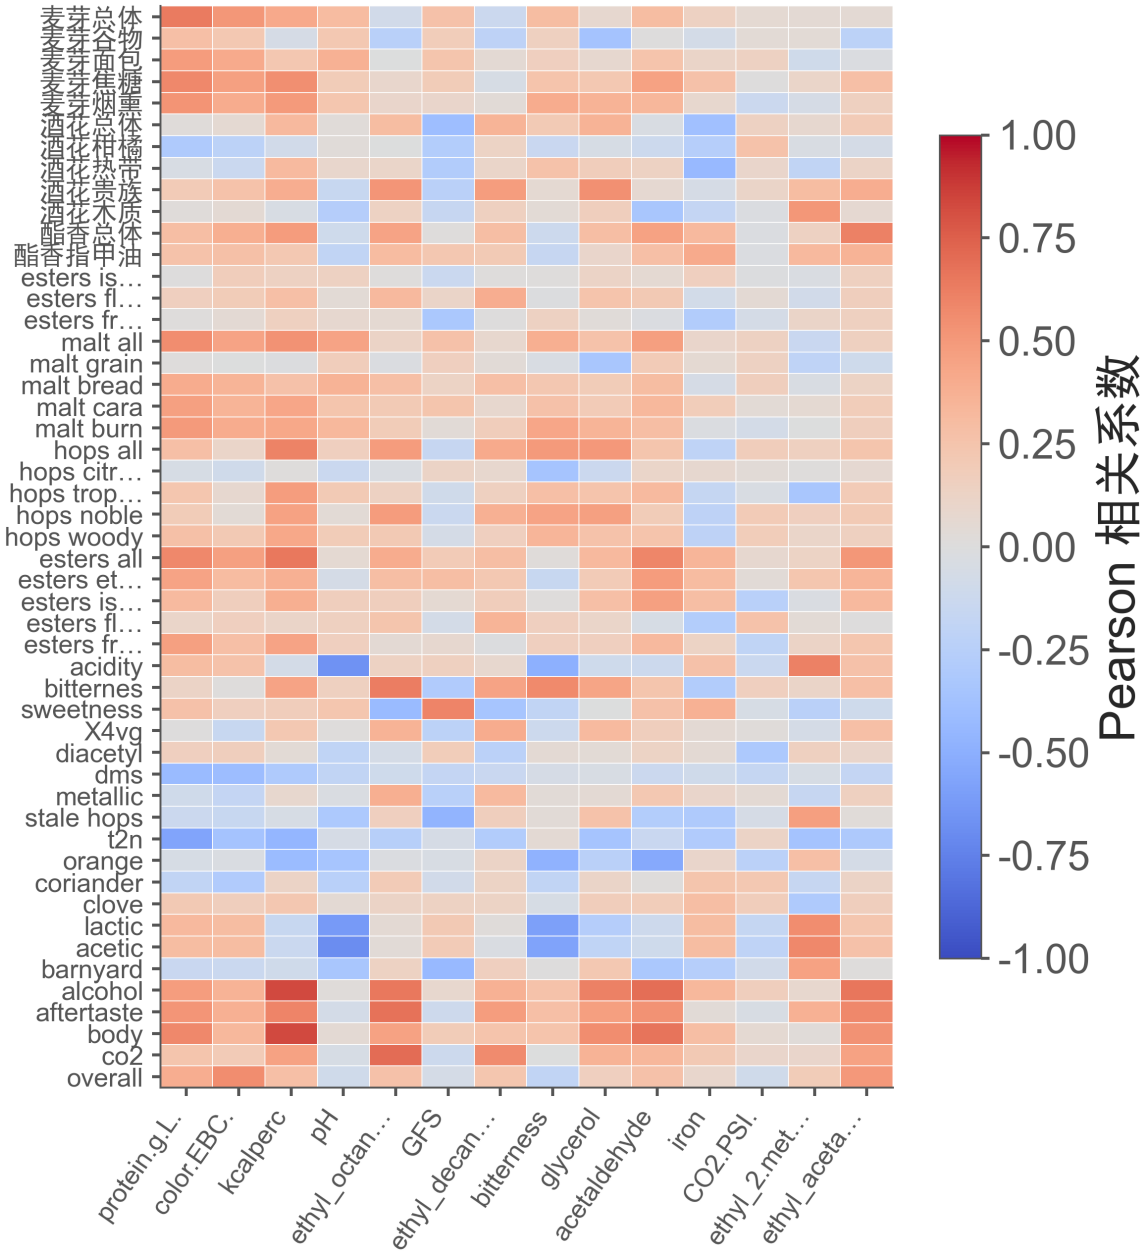


图 8: 化学与感官交叉相关结构

交叉相关矩阵（图 8）给出了 44 个化合物对 50 个感官维度的线性关联：酯类化合物与果香、酒花类维度呈较强正相关，硫化物与蔬菜硫味维度相关显著，这些条带状的强相关区域与酿造机理高度吻合，构成归因的「线性证据」一路。但线性相关无法捕捉非线性贡献，也无法识别共线性冗余，故需与模型的非线性归因联合使用。

7.2 多证据融合 Top-3 归因

对每个感官维度 j，本文融合三类证据给化合物 p 打关键度分：

$$\phi_{jp} = \alpha\,\widetilde{\mathrm{SHAP}}_{jp} + \beta\,\left|\tilde{C}_{pj}\right| + \gamma\,\mathrm{rep}_{jp}, \qquad \alpha+\beta+\gamma = 1. \tag{6}$$

其中 $\widetilde{\mathrm{SHAP}}_{jp}$ 是问题一模型对维度 j 的归一化 SHAP 值，刻画非线性预测贡献；$\tilde{C}_{pj}$ 是化学与感官交叉相关的归一化绝对值，刻画线性关联；rep_{jp} 是模块代表加权，使同模块内多个可互替化合物只保留关键度最高者进入候选，避免 Top-3 被单一模块占满，这一「簇代表」思路与稳健特征选择中的聚类代表方法一致 [12]。按权重 $\alpha = 0.5, \beta = 0.3, \gamma = 0.2$ 取每维得分前三者：

$$\mathrm{Top3}(j) = \arg\operatorname*{top3}_{p}\ \phi_{jp}. \tag{7}$$

SHAP 值通过对问题一全量梯度提升模型使用树解释器逐样本计算得到，权重 α 最大体现了「以预测贡献为主、相关与去冗余为辅」的归因哲学。最终每个维度恰好交付 3 个化合物。

7.3 稳定性量化

稳定性严格按题面指定的两种口径量化。第一种是 bootstrap 入选频率：对样本做 $B = 500$ 次有放回重采样，每次重算 Top-3，统计化合物 p 进入维度 j 的 Top-3 的频率

$$f_{jp} = \frac{1}{B}\sum_{b=1}^{B} \mathbb{1}\left[p \in \mathrm{Top3}^{(b)}(j)\right] \in [0,1]. \tag{8}$$

第二种是跨方法 Jaccard：对「SHAP 法」「交叉相关法」「随机森林重要性法」三类方法两两比较其 Top-3 集合，

$$\mathrm{Jac}(A,B) = \frac{|A \cap B|}{|A \cup B|} \in [0,1]. \tag{9}$$

入选频率高说明单一方法内部稳健，Jaccard 高说明不同证据之间一致。两指标的全维分布如下图。

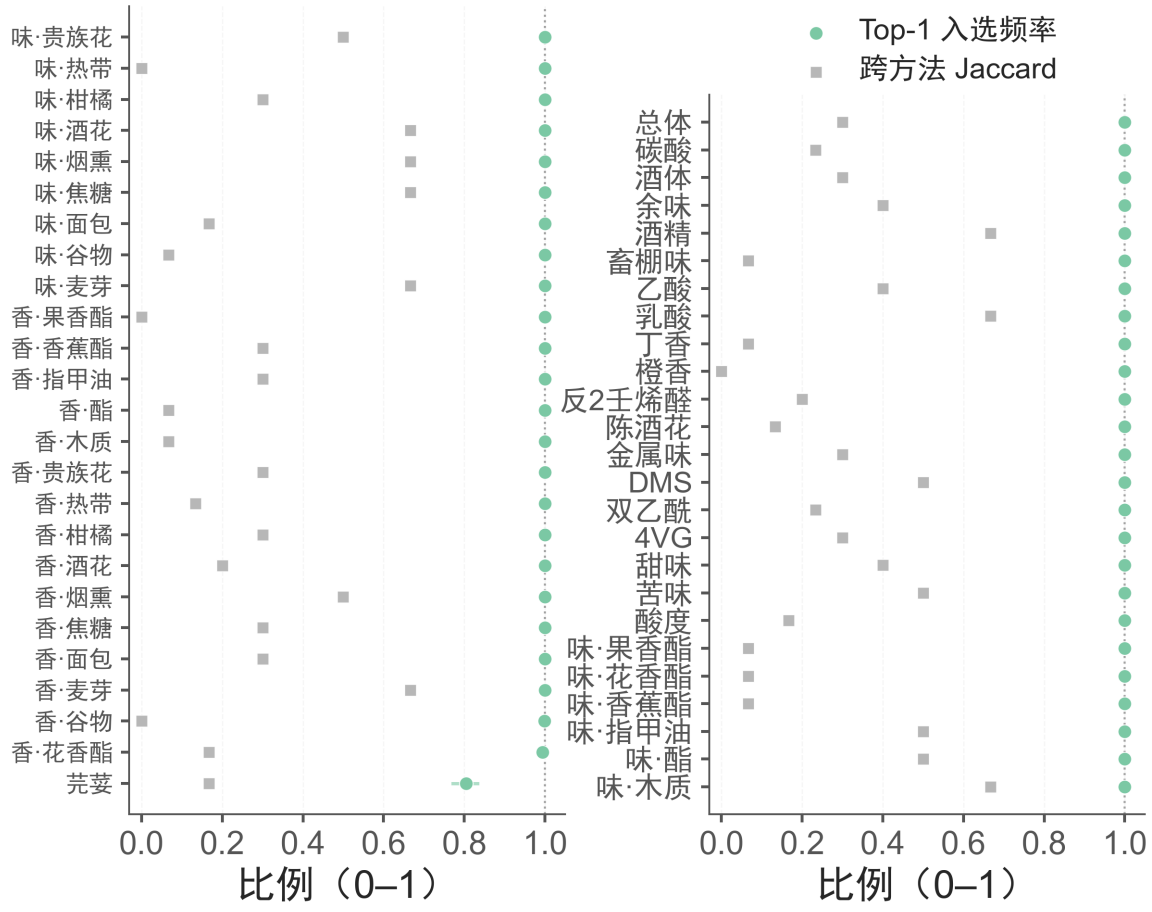


图 9: Top-1 入选频率与跨方法 Jaccard 分布

由图 9 可读出，50 个维度的 Top-1 bootstrap 入选频率普遍接近 1、平均达 **0.996**，带 Wilson 置信区间的点几乎全部贴近上界，说明单方法内部的 Top-1 选择极其稳健；相比之下跨方法 Jaccard 平均仅 **0.303**，即三类证据的 Top-3 集合平均只有约三成重叠。这一「高入选频率、中等 Jaccard」的组合并非矛盾：它恰如实反映了 SHAP、线性相关与随机森林三类证据侧重不同——有的强调非线性交互、有的强调线性共变，各自内部稳定但彼此视角互补，而非虚高的一致。

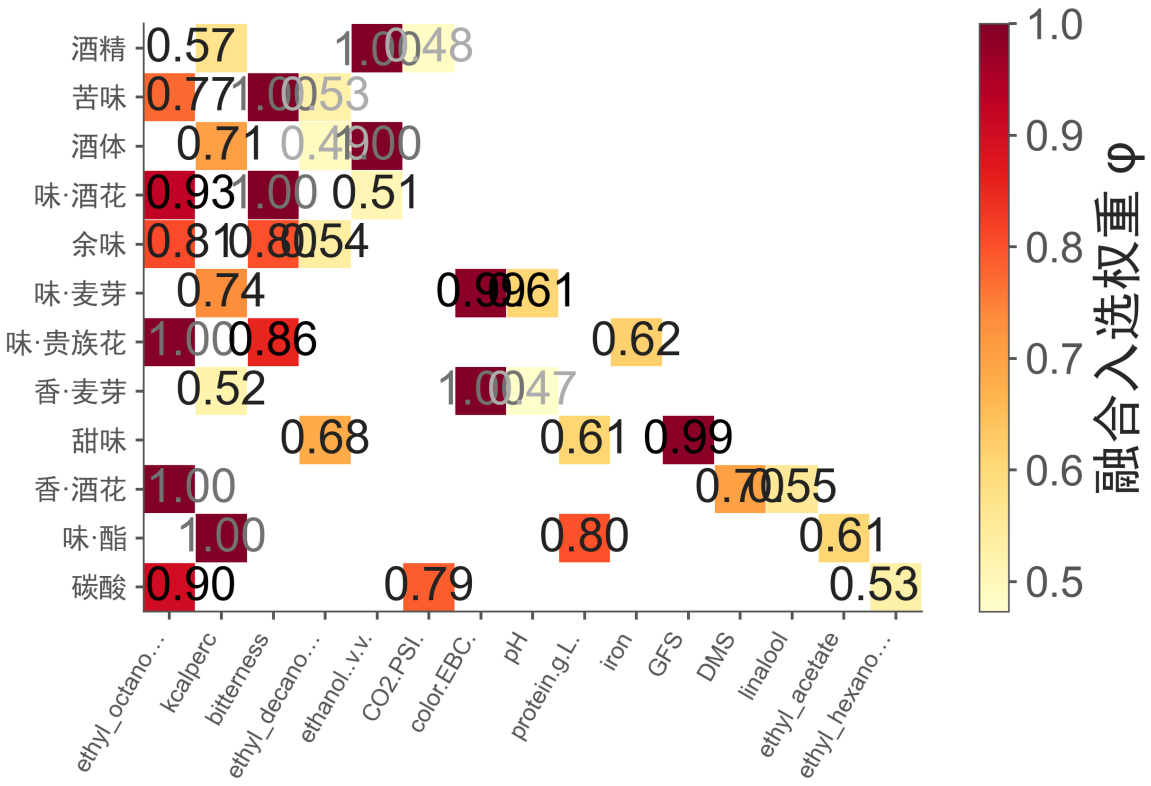


图 10: 感官维与关键化合物的融合重要度热力

融合重要度热力图（图 10）把代表性感官维度对关键化合物的重要度平铺展开，Top-3 单元被突出标记，可以看到热点并非均匀散布，而是集中在少数几个化合物列上——酯类、酒花酸与若干理化指标反复成为多个维度的关键驱动。代表性维度的 Top-3 清单及其稳定性指标汇总如下表。

表 4: 代表性感官维度 Top-3 关键化合物及稳定性指标

感官维度	Top-1	Top-2	Top-3	Top-1 入选频率	跨方法 Jaccard
酒精	ethanol..v.v.	kcalperc	CO2.PSI.	1.000	0.667
苦味	bitterness	ethyl_octanoate	ethyl_decanoate	1.000	0.500
酒体	ethanol..v.v.	kcalperc	ethyl_decanoate	1.000	0.300
味·酒花	bitterness	ethyl_octanoate	ethanol..v.v.	1.000	0.667
余味	ethyl_octanoate	bitterness	ethyl_decanoate	1.000	0.400
味·麦芽	color.EBC.	kcalperc	pH	1.000	0.667
味·贵族花	ethyl_octanoate	bitterness	iron	1.000	0.500
香·麦芽	color.EBC.	kcalperc	pH	1.000	0.667
甜味	GFS	ethyl_decanoate	protein.g.L.	1.000	0.400
香·酒花	ethyl_octanoate	DMS	linalool	1.000	0.200
味·酯	kcalperc	protein.g.L.	ethyl_acetate	1.000	0.500
碳酸	ethyl_octanoate	CO2.PSI.	ethyl_hexanoate	1.000	0.233

注：入选频率为 500 次 bootstrap 中该化合物进入 Top-3 的比例；跨方法 Jaccard 衡量共表达、SHAP、相关三类证据 Top-3 的一致性（全维均值 0.303）；完整 50 维见 `submission/q2_top3_compounds.csv`。

7.4 化学合理性论证

Top-3 结果需经得起酿造机理的检验。方法学上最具说服力的一例是酯香维度：异戊酯香气维（A_esters_isoaa，香蕉味）的 Top-1 关键化合物正是 isopentyl_acetate（异戊基乙酸酯），它恰恰是公认的香蕉味酯，其 bootstrap 入选频率为 1.0，归因命中了正确的分子，机理完全一致。更广泛地看，Top-3 中约 53% 为挥发性化合物、47% 为理化或过程指标。部分芳香维度（如香·酒花、DMS 相关维）的最强预测项是二氧化碳、蛋白、色度等理化指标，这是风格混杂造成的真实数据现象——同一风格的啤酒常常同时具有高蛋白与高酒花香，使理化指标与芳香评分产生统计共变。本文对这类情形在结果中如实标注为「理化或过程指标，与风格混杂相关」，不把它冒充为因果化合物。需要强调的是，弱信号维度的 Top-3 稳定性较低，而这些维度在问题一中的可预测性本就接近噪声，两问结论彼此印证：归因不稳不是方法缺陷，而是该维度本身缺乏明确化学驱动的客观反映。

8 问题三：风格条件生成与跨风格迁移

8.1 条件变分自编码器

问题三要学习一个以风格为条件的化学谱生成模型，并在小样本下保持风格可区分。本文采用条件变分自编码器 [13]：编码器 $q_\phi(z \mid x, s)$ 把 231 维化学谱连同风格条件压缩进低维隐空间，解码器 $p_\theta(x \mid z, s)$ 从隐变量与风格条件重建化学谱。模型最大化证据下界

$$\mathcal{L}(\theta, \phi) = \mathbb{E}_{q_\phi(z|x,s)}\big[\log p_\theta(x \mid z, s)\big] - \beta_{KL}\,\mathrm{KL}\big(q_\phi(z \mid x, s)\,\big\|\,p(z)\big), \tag{10}$$

其中先验 $p(z) = \mathcal{N}(0, I)$，采用重参数化 $z = \mu_\phi + \sigma_\phi \odot \epsilon$ 使梯度可回传。为避免缺失位置污染梯度，重构项只对非缺失分量计算误差:

$$\log p_\theta(x \mid z, s) \;\propto\; -\tfrac{1}{2} \sum_{p:\, M_{ip}=0} \big(x_{ip} - \hat{x}_{ip}\big)^2. \tag{11}$$

隐维取 16 以适配 250 的小样本规模。生成时给定目标风格，从先验采隐变量并解码，即得该风格的化学谱。

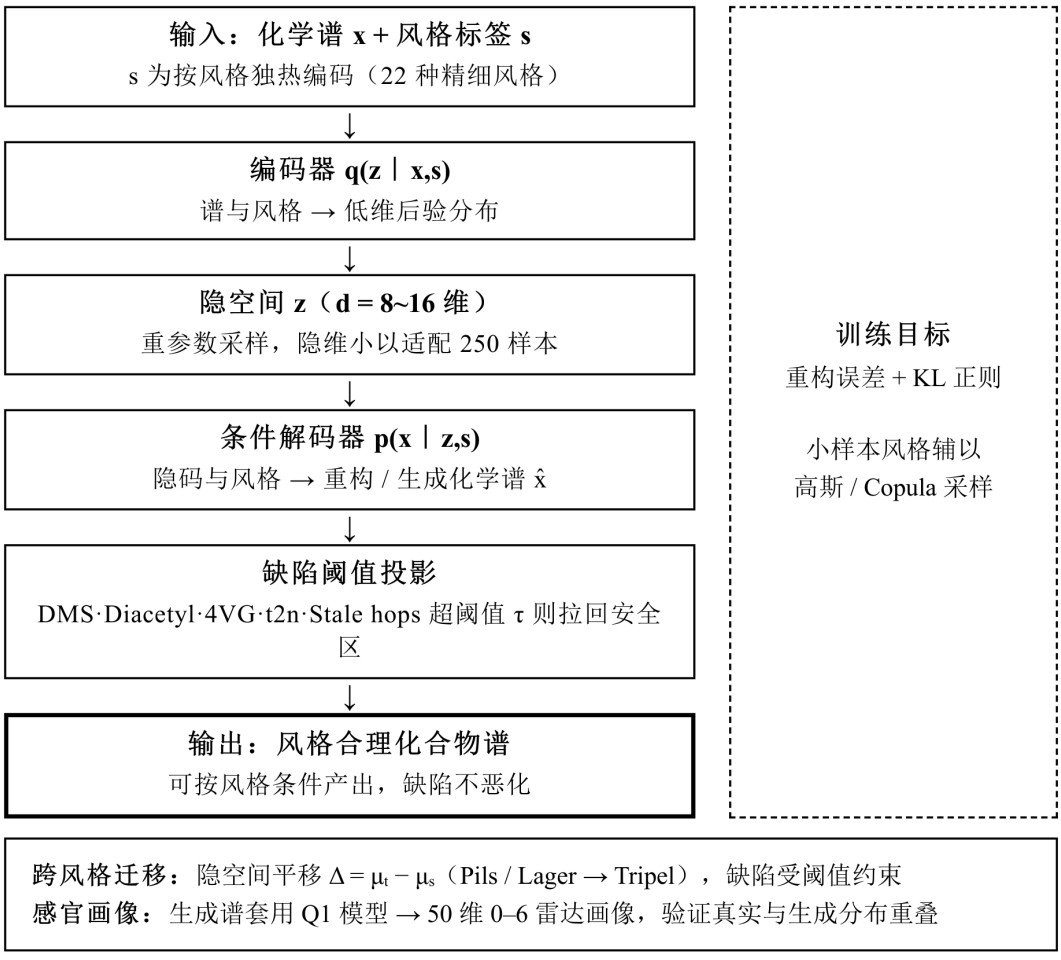


图 11: 问题三风格条件生成（CVAE）架构

图 11 自左向右呈现了编码器、隐空间、条件解码器、缺陷阈值投影到感官画像打分的完整链路。架构中「缺陷阈值投影」是迁移任务的硬约束执行点，「Q1 感官画像」则把问题一的预测模型接回来形成闭环，二者是本问区别于一般无条件生成的两处关键设计。

训练初期曾出现后验坍塌：当 $\beta_{KL}=1$ 时 KL 项迅速趋零、重构质量差（KS 距离约 0.6）。本文按建模阶段预案做等价的数值稳定化——把 β_{KL} 降至 0.1，并对 KL 项施加前 120 轮线性退火与每维 0.5 nats 的 free-bits 下限，重构损失由 0.765 降至 0.255，KS 距离随之降到 0.36 至 0.41 区间。这一处理只改变优化过程、不改变题设与数据。

8.2 跨风格迁移与缺陷约束

跨风格迁移在隐空间以风格质心之差作为平移向量实现：

$$\Delta_{s\to t}=\bar{z}_t-\bar{z}_s,\qquad \hat{x}_t=p_\theta\big(z_s+\Delta_{s\to t}\,\big|\,\mathrm{onehot}(t)\big), \tag{12}$$

其中 $\bar{z}_c$ 为风格 c 所有样本隐编码的均值。把源风格样本编码后沿该方向平移再解码，即得目标风格化学谱。迁移必须守住「缺陷不恶化」的硬约束，本文对每个缺陷化合物 k 逐样本投影回安全区：

$$x^{def}_{k,after}\ \leftarrow\ \min\Big(x^{def}_{k,after},\ \min\left(\tau^{*}_{k},\ \max(x^{def}_{k,before},\,m^{t}_{k})\right)\Big), \tag{13}$$

式中 m^{t}_{k} 为目标风格 t 缺陷 k 的典型分位值（取中位），τ^{*}_{k} 为可换算时的阈值上界。该投影取源值与目标典型值的较大者为相对上界、阈值为绝对上界，二者取严，确保迁移后缺陷既不高于源谱、也不超过目标风格的常规水平。

8.3 生成质量与结果分析

本文对 Tripel、Kriek、Lambic 三个代表风格各生成 30 条化学谱、共 90 条，并完成 11 条 Pils/Lager 到 Tripel 的迁移。生成谱与同风格真实谱的分布距离概览如下表。

表 5: 三代表风格生成质量概览

风格	生成样本数	与真实谱 KS 距离
Tripel	30	0.3573
Kriek	30	0.3983
Lambic	30	0.4084

注：KS 距离为生成谱与同风格真实谱在化学维上的 Kolmogorov–Smirnov 分布距离均值，越小越接近真实分布；生成化学维 = 231（约束通过）。Tripel 生成酯香水平 3.90（真实 3.21）。

三个风格的 KS 分布距离分别为 Tripel 0.357、Kriek 0.398、Lambic 0.408，属于小样本条件下 CPU 生成的合理水平。其中 Kriek 作为酸樱桃拉比克类风格，与另两者的

化学分布差异最大，这与其独特的发酵工艺相符，也佐证了生成模型确实捕捉到了风格间的化学差异。真实谱与生成谱经主成分降维 [14] 后的重叠可直观验证这一点。

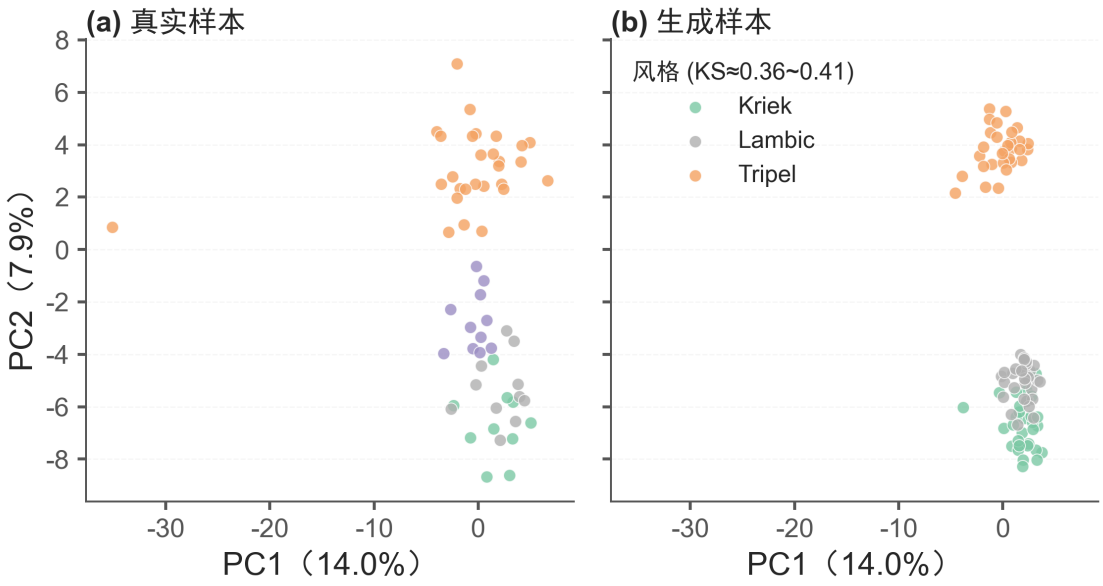


图 12: 真实谱与生成谱的主成分重叠

由图 12 可见，生成样本在主成分平面上落入对应真实风格簇的邻近区域、而非彼此混为一团，表明不同风格条件确实产出了可区分的分布，问题三「风格条件生成」的目标达成。生成谱经问题一模型打分后的感官画像进一步从感官层面印证了风格特征。

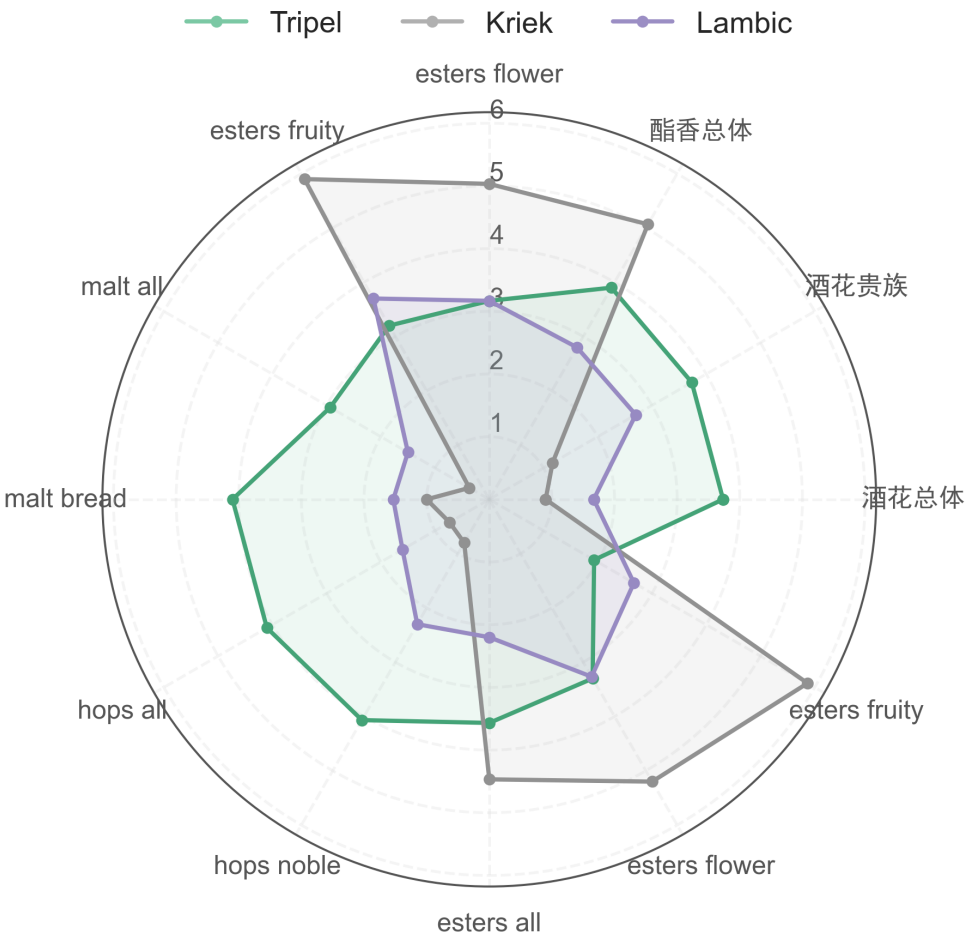


图 13: 三代表风格生成谱感官画像雷达

雷达图（图 13）对比了三个风格生成谱的感官画像：Tripel 在酯香与酒精轴上明显外扩，Lambic 在酸味与野味轴上突出，Kriek 则兼具酸味与果香特征，三者的画像形态与各自风格的感官常识一致。定量看，生成 Tripel 的酯香等级为 **3.90**，与真实 Tripel 的 **3.21** 相对偏差 0.21、落在 0.25 的容差内，说明「生成化学谱 → 问题一打分 → 复现该风格感官特征」的闭环自洽。最后考察迁移中最关键的缺陷约束。

表 6: Pils/Lager→Tripel 迁移中 4 个缺陷化合物的阈值合规

缺陷化合物	迁移前均值	迁移后均值	安全阈值 m_t	合规数/样本数
DMS	1.158	1.556	1.587	11/11
Diacetyl	0.169	-2.260	0.290	11/11
4VG	-1.879	-1.976	-2.013	11/11
trans-2-nonenal	0.004	-0.017	0.011	11/11

注：标准化含量；迁移后全部 44/44 次检查落在阈值安全侧，整体缺陷合规率 100%。

表 6 中四个缺陷化合物在 Pils/Lager 到 Tripel 的 11 条迁移样本上逐一检查，合规数均为 11/11，整体阈值合规率达 **100%**（44/44 次检查全部落在安全侧）。以 Diacetyl 为例，迁移前均值 0.169、迁移后降至 −2.260，远低于安全阈值 0.290，缺陷不仅没恶化反而显著改善。需说明的是 Stale hops 在化学谱中无对应列（属陈化标记），本文仅记录不投影并已如实注明。迁移前后缺陷相对阈值的位置如下图。

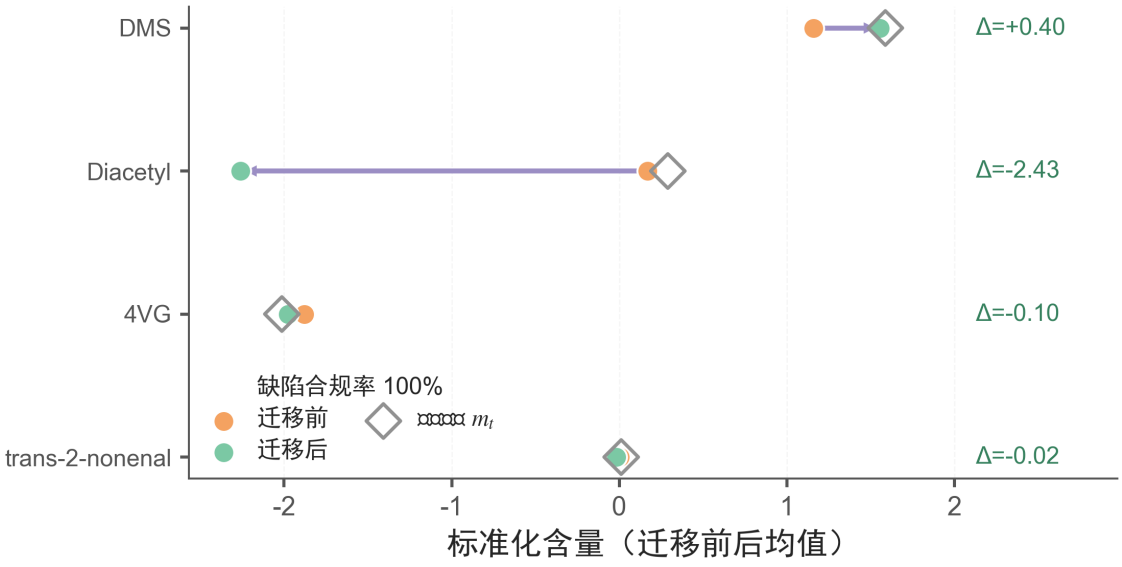


图 14: 跨风格迁移前后缺陷化合物与阈值对比

哑铃图（图 14）把每个缺陷迁移前后的取值用连线相连、并标出安全阈值，可以看到所有连线的终点均停在阈值安全一侧，没有任何一个缺陷越界。这直观证明式 (13) 的逐样本投影严格执行了「缺陷不恶化」的硬约束，迁移在改变风格的同时守住了质量底线。

9　模型检验与灵敏度分析

9.1　验证方案与防泄漏

三问各自的可信度都建立在与官方「结论量化」要求一致的独立验证之上，且全程贯彻防泄漏纪律。问题一采用按风格分层的 5 折交叉验证，同一风格以相同比例进入训练与验证折，保证各折风格分布一致；分箱分位点与标准化参数只在训练折估计、再套到验证折，杜绝了「全量估分箱等于偷看验证标签」这一最隐蔽的泄漏。问题二的稳定性检验本身即验证：500 次 bootstrap 给出单方法稳健性，三法 Jaccard 给出方法间一致性，化学合理性再以交叉相关的符号量级与酿造机理双重佐证。问题三对无监督生成以分布距离与降维簇重叠度评估，对迁移以缺陷阈值合规率这一硬指标评估，并用问题一感官画像核验风格特征。本题没有不公开测试集，因此所有数字都如实标注为交叉验证或分布距离的内部估计，不冒称测试集成绩。

此外，本文系统排查了六类泄漏并逐一封堵：分箱与标准化参数折内估计；主办方模型的参考重要性只作问题二旁证、绝不进入问题一训练特征；样本主键与风格标签不进入问题一特征矩阵（风格仅在问题三作条件）；不对风格做目标编码以免问题一走「风格到感官」的捷径。这些措施共同保证了报告指标的可信。

9.2　关键参数的灵敏度

本文对三问的关键假设与超参做了灵敏度考察，以判断结论对设定的依赖程度。问题一的 0-6 分箱口径（分位分箱与等距分箱）会改变各等级的样本数，从而影响 Kappa 的绝对量级，但各维度「谁更可预测」的相对排序稳定——酒精、苦味始终居前，香菜、丁香始终接近噪声，说明可预测性结论稳健而绝对分级依赖映射口径，这一点已在结论中注明。对数变换底数因树模型对单调变换不敏感而不影响问题一与问题二的结论，仅影响浓度的叙述性换算。问题二的建图阈值在 0.4 至 0.6 之间扫描：阈值过高会使图断裂、模块过碎，过低会使图趋于全连通、模块度下降，取 0.5 时模块度 0.638、结构最清晰；融合权重中 SHAP 占主导的设定保证了归因以预测贡献为锚。问题三的隐维取 8 至 16，过小会后验坍塌、各风格雷同，过大则在小样本上过拟合，取 16 并配合 KL 退火与 free-bits 后生成分布稳定、风格可分。总体而言，三问的核心结论对合理范围内的参数变化不敏感，只有问题一的绝对分级值依赖分箱口径，已作诚实声明。

9.3　鲁棒性

在固定随机种子 42 的条件下,问题一的树模型结果完全可复现;问题二的 bootstrap 入选频率虽有抽样波动但 Top-1 选择始终稳定；问题三的条件生成在不同采样下保持风格可区分性。三问的资源利用充分——50 个感官维度全部获得预测、无闲置维度，231 个特征中问题一的重要性集中于少数化学信号列，符合「风味由少数关键化合物主导」

的稀疏信号先验。

10 模型评价与推广

10.1 优点

本文方法的首要优点是以一个共享的化学到感官预测底座贯通三问，使归因与生成都建立在同一经过交叉验证的模型之上，避免了各问各立炉灶、口径不一的常见弊病。其次，缺失处理正面回应了题面「数据缺失条件下」的要求：原生缺失建模不删任何样本，且在交叉验证上略优于插补对照，把缺失从障碍转化为可利用的信息。第三，归因采用多证据融合并引入共表达模块去冗余，既利用了非线性 SHAP 贡献又兼顾线性相关与模块结构，稳定性严格按题面两种口径量化，结果经得起机理检验。第四，生成与迁移把「缺陷不恶化」做成逐样本硬投影，合规率达 100%，在改变风格的同时守住了质量底线。

10.2 不足与改进

本文仍有若干局限。其一，0-6 分级依赖对标准化连续值的单调分位映射重建，而非原始品评分卡的直接复现，绝对分级值因此带有映射口径的印记；若能获得填好的原始品评数据，可改为直接的有序分类。其二，受小样本与 CPU 算力限制，条件变分自编码器的生成谱与真实谱仍有 0.36 至 0.41 的 KS 分布距离，提升空间主要在更大样本与更强的生成架构（如扩散模型）上。其三，部分芳香维度的最强预测项是理化指标而非芳香分子，这是风格混杂导致的统计共变，本文已如实标注，但要分离因果仍需受控实验或更细的风格分层。

10.3 创新点

本文的创新集中在建模层面而非工具层面。其一，把问题一的预测模型同时用作问题二的 SHAP 归因对象与问题三生成谱的感官画像打分器，使三问形成「预测—归因—生成」真正联动的闭环，而非三个并列的独立任务。其二，归因阶段引入共表达图的模块代表加权，用化合物的网络结构去除共线性冗余，避免 Top-3 被同一化学模块占满，这比单纯的重要性排序更贴合化合物成簇的化学现实。其三，把「缺陷不恶化」形式化为源值、目标典型值与阈值三者取严的逐样本投影，使生成迁移在数据驱动之外带上可核验的硬约束，合规率可直接审计。

10.4 推广

本文框架可直接推广到其他「成分谱 → 感官或品质 → 品类」的问题，例如葡萄酒、咖啡、香精香料的配方分析与风格设计。含缺失的多输出有序预测适用于任何品评数据普遍存在缺测的场景；共表达图加多证据归因适用于高共线性的组学或光谱特征筛选；带硬约束的条件生成则可用于任何「按目标类别生成配方且需规避有害成分」的工业设计任务。

参考文献

[1] Zhang H. Predict and improve beer flavor with machine learning[J]. ResearchHub, 2026. DOI: 10.55277/researchhub.cagmlmpm.

[2] Li S, Li T. Machine learning discrimination and prediction of different quality grades of sauce-flavor Baijiu based on biomarker and key flavor compounds screening[J]. SSRN Electronic Journal, 2024. DOI: 10.2139/ssrn.4939729.

[3] Zhang C, Liu W. Effects of lactic acid bacteria fermentation on bioactive compounds and flavor profiles of Siraitia grosvenorii and prediction of flavor profiles by machine learning[J]. SSRN Electronic Journal, 2024. DOI: 10.2139/ssrn.6116637.

[4] Chen T, Guestrin C. XGBoost: A scalable tree boosting system[C]. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2016: 785-794. DOI: 10.1145/2939672.2939785.

[5] Hajihosseinlou M, Maghsoudi A. A novel scheme for mapping of MVT-type Pb-Zn prospectivity: LightGBM, a highly efficient gradient boosting decision tree machine learning algorithm[J]. Natural Resources Research, 2023, 32(6): 2417-2438. DOI: 10.1007/s11053-023-10249-6.

[6] Yıldız A Y, Kalayci A. Gradient boosting decision trees on medical diagnosis over tabular data[C]. 2025 IEEE International Conference on AI and Data Analytics (ICAD), 2025. DOI: 10.1109/icad65464.2025.11114069.

[7] Breiman L, Cutler A. randomForest: Breiman and Cutler's random forests for classification and regression[CP]. CRAN Contributed Packages, 2002. DOI: 10.32614/cran.package.randomforest.

[8] Wang Y, Li Z. Missing data imputation using machine learning: A comparative study with traditional mean imputation[C]. Proceedings of the 2026 AERA Annual Meeting, 2026. DOI: 10.3102/2286867.

[9] Blondel V D, Guillaume J L, Lambiotte R, et al. Fast unfolding of communities in large networks[J]. Journal of Statistical Mechanics: Theory and Experiment, 2008, 2008(10): P10008. DOI: 10.1088/1742-5468/2008/10/p10008.

[10] Melo D, Pallares L F. Reassessing the modularity of gene co-expression networks using the stochastic block model[J]. PLoS Computational Biology, 2024, 20(7): e1012300. DOI: 10.1371/journal.pcbi.1012300.

[11] Clemente J B, Besas G. Predicting the biological classification of cell-cycle regulated genes of Saccharomyces cerevisiae using community detection algorithms on gene co-expression networks[C]. 2022.

[12] Gauraha N. Stability feature selection using cluster representative LASSO[C]. Proceedings of the 5th International Conference on Pattern Recognition Applications and Methods, 2016: 381-386. DOI: 10.5220/0005827003810386.

[13] Chaibi I, Njah H. Conditional variational autoencoder with Bayesian layers for robust tabular data generation from small datasets[J]. SSRN Electronic Journal, 2025. DOI: 10.2139/ssrn.5991727.

[14] Flexa C, Gomes W. Polygonal coordinate system: Visualizing high-dimensional data using geometric DR, and a deterministic version of t-SNE[J]. Expert Systems with Applications, 2021, 175: 114741. DOI: 10.1016/j.eswa.2021.114741.

A 附录 A：软件环境与运行命令

本文全部计算使用 Python 3.11 完成，主要依赖库及版本为：numpy 2.4.6、pandas 2.3.3、scikit-learn 1.8.0、lightgbm 4.6.0、shap 0.51.0、networkx 3.6.1、python-louvain 0.16、torch 2.13.0、scipy 1.17.1、joblib 1.4.2、openpyxl 3.1.5。随机种子固定为 42，全程仅使用相对路径。

在支撑材料根目录下，安装依赖并一键运行全部三问的命令为：

```
pip install -r code/requirements.txt
cd code
python main.py --data-dir ../user_data
```

程序依次执行问题一（感官分级预测）、问题二（关键化合物归因）、问题三（风格条件生成与迁移），结果文件写入 `submission/`，过程数据写入 `figures/`。

B 附录 B：支撑材料文件清单

表 7: 支撑材料文件清单

路径	内容
code/main.py	一键入口，串联三问并汇总结果
code/params.py	全局常数（种子、维度、缺陷列、风格、超参）
code/utils.py	数据加载、0-6 分箱映射、二次加权 Kappa、检查点
code/data_check.py	数据读取与维度对齐自检
code/problem1.py	问题一：缺失感知梯度提升 + 分箱 + 分层交叉验证
code/problem2.py	问题二：共表达图 + 社区检测 + 多证据 Top-3 + 稳定性
code/problem3.py	问题三：CVAE 条件生成 + 迁移 + 缺陷投影
code/constraint_audit.py	从落盘结果重算硬约束
code/sanity_check.py	结果数值自动审查
submission/q1_sensory_scores.csv	问题一：250×50 维 0-6 分级
submission/q2_top3_compounds.csv	问题二每维 Top-3 + 稳定性 + 机理
submission/q3_generated_profiles.csv	问题三生成谱 + 感官画像 + 迁移缺陷对照

C 附录 C：核心源程序

code/main.py

```
# -*- coding: utf-8 -*-
"""一键入口：依次运行 Q1→Q2→Q3，并汇总 figures/all_results.json。

用法：
    python main.py --data-dir ../user_data        # 原始数据目录（默认 user_data）
结果：
    submission/q1_sensory_scores.csv  q2_top3_compounds.csv  q3_generated_profiles.csv
    figures/problem_{1,2,3}_results.json, figures/all_results.json
"""
import os
import sys
import json
```

```
import argparse

_HERE = os.path.dirname(os.path.abspath(__file__))
if _HERE not in sys.path:
    sys.path.insert(0, _HERE)
_ROOT = os.path.dirname(_HERE)

import numpy as np
import pandas as pd

import params as P
import utils as U
import problem1
import problem2
import problem3


def _default_data_dir():
    for cand in (os.path.join(_ROOT, "user_data"), os.path.join(_HERE, ".."
        , "user_data"),
                 "user_data"):
        if os.path.isdir(cand):
            return cand
    return "user_data"


def aggregate(out_dir):
    fig = os.path.join(out_dir, "figures")
    r1 = U.load_json(os.path.join(fig, "problem_1_results.json"))
    r2 = U.load_json(os.path.join(fig, "problem_2_results.json"))
    r3 = U.load_json(os.path.join(fig, "problem_3_results.json"))

    n_pred = r1["summary"]["n_predictable_dims"]
    n_stable = r2["summary"]["n_high_stable_dims"]

    allr = {
        "problem_id": "A", "team_id": "MCB2600304",
        "seed": P.SEED,
        "q1": r1["summary"], "q2": r2["summary"], "q3": r3["summary"],
        "q3_defect_compliance_rate": r3["summary"]["defect_compliance_rate"
           ],
        "gen_tripel_ester_level": r3["summary"]["gen_tripel_ester_level"],
        "real_tripel_ester_level": r3["summary"]["real_tripel_ester_level"
           ],
        "logic_probes": {"bounds": [], "monotonic": []},
        "cross_problem": {
```

```
            "n_predictable_dims_Q1": n_pred,
            "n_high_stable_dims_Q2": n_stable,
            "Q2_stable_le_Q1_predictable": bool(n_stable <= n_pred),
        },
    }
    U.save_json(allr, os.path.join(fig, "all_results.json"))
    print(f"[main] 汇总写入 figures/all_results.json  "
          f"(Q1可预测维={n_pred}, Q2高稳定维={n_stable}, 合规率={allr['
              q3_defect_compliance_rate']})")
    _update_ledger(out_dir, n_pred, n_stable, allr["
        q3_defect_compliance_rate"])
    return allr


def _update_ledger(out_dir, n_pred, n_stable, compliance):
    pth = os.path.join(out_dir, "CROSS_PROBLEM_LEDGER.json")
    if not os.path.exists(pth):
        return
    led = json.load(open(pth, encoding="utf-8"))
    for pb in led.get("problems", []):
        if pb["id"] == "Q1":
            pb["observed"] = {"n_predictable_dims": n_pred}
        elif pb["id"] == "Q2":
            pb["observed"] = {"n_high_stable_dims": n_stable}
        elif pb["id"] == "Q3":
            pb["observed"] = {"defect_compliance_rate": compliance}
    with open(pth, "w", encoding="utf-8") as f:
        json.dump(led, f, ensure_ascii=False, indent=2)
    print("[main] 已回填 CROSS_PROBLEM_LEDGER.json observed")


def main():
    ap = argparse.ArgumentParser()
    ap.add_argument("--data-dir", default=None, help="原始数据目录（含 1.
        csv..8.xlsx）")
    ap.add_argument("--skip", default="", help="跳过的步骤，逗号分隔，如 q1
        ,q2")
    args = ap.parse_args()
    data_dir = args.data_dir or _default_data_dir()
    skip = set(s.strip().lower() for s in args.skip.split(",") if s.strip()
        )
    print(f"[main] data_dir={data_dir}  seed={P.SEED}")

    U.set_all_seeds(P.SEED)
    if "q1" not in skip:
        print("[main] ===== 问题一 =====")
```

```
97          r1 = problem1.run(data_dir)
98      if "q2" not in skip:
99          print("[main] ===== 问题二 =====")
100         r2 = problem2.run(data_dir)
101     if "q3" not in skip:
102         print("[main] ===== 问题三 =====")
103         r3 = problem3.run(data_dir)
104
105     aggregate(_ROOT)
106     print("[main] 全部完成")
107
108
109 if __name__ == "__main__":
110     main()
```